
Gareth James ■ Daniela Witten ■ Trevor Hastie
Robert Tibshirani ■ Jonathan Taylor

Nhập môn Statistical Learning

với ứng dụng trong Python

Lần in đầu: ngày 5 tháng 7 năm 2023

Kính tặng cha mẹ chúng tôi:

Alison và Michael James

Chiara Nappi và Edward Witten

Valerie và Patrick Hastie

Vera và Sami Tibshirani

John và Brenda Taylor

và gửi tặng gia đình chúng tôi:

Michael, Daniel và Catherine

Tessa, Theo, Otto và Ari

Samantha, Timothy và Lynda

Charlie, Ryan, Julie và Cheryl

Lee-Ann và Isobel

Lời tựa

Statistical learning là một tập hợp các công cụ giúp hiểu những *dataset phức tạp*. Trong những năm gần đây, quy mô và phạm vi thu thập dữ liệu đã tăng lên đáng kinh ngạc trong hầu hết mọi lĩnh vực khoa học và công nghiệp. Vì vậy, statistical learning đã trở thành một bộ công cụ thiết yếu đối với bất kỳ ai muốn hiểu dữ liệu. Khi ngày càng nhiều công việc hiện nay liên quan đến dữ liệu, điều đó cũng có nghĩa là statistical learning đang nhanh chóng trở thành một bộ công cụ thiết yếu cho *tất cả mọi người*.

Một trong những cuốn sách đầu tiên về statistical learning, *The Elements of Statistical Learning* (ESL, của Hastie, Tibshirani và Friedman), được xuất bản năm 2001; ấn bản thứ hai ra mắt năm 2009. ESL đã trở thành một giáo trình phổ biến không chỉ trong thống kê mà còn trong các lĩnh vực liên quan. Một lý do khiến ESL được đón nhận rộng rãi là cách trình bày tương đối dễ tiếp cận. Tuy nhiên, ESL phù hợp nhất với những người đã được đào tạo chuyên sâu về các ngành khoa học toán học.

An Introduction to Statistical Learning, With Applications in R (ISLR), xuất bản lần đầu năm 2013 và có ấn bản thứ hai năm 2021, ra đời từ nhu cầu rõ rệt về một cách trình bày bao quát hơn và ít đi sâu vào kỹ thuật hơn đối với các chủ đề cốt lõi của statistical learning. Bên cạnh việc ôn lại linear regression, ISLR đề cập đến nhiều phương pháp thống kê và machine learning quan trọng nhất hiện nay, bao gồm resampling, sparse methods cho classification và regression, generalized additive models, tree-based methods, support vector machines, deep learning, survival analysis, clustering và multiple testing.

Kể từ khi xuất bản năm 2013, ISLR đã trở thành giáo trình chủ đạo trong nhiều lớp học bậc đại học và sau đại học trên toàn thế giới, đồng thời là một tài liệu tham khảo quan trọng cho các data scientist. Một trong những yếu tố làm nên thành công của sách là, bắt đầu từ Chương 2, mỗi chương đều có một bài thực hành bằng R minh họa cách triển khai các phương pháp statistical learning được trình bày trong chương, mang lại cho người đọc kinh nghiệm thực hành quý giá.

Tuy nhiên, trong những năm gần đây, **Python** ngày càng trở nên phổ biến trong data science, và nhu cầu về một phiên bản thay thế ISLR sử dụng **Python** cũng ngày càng tăng. Vì vậy, cuốn sách này, *An Introduction to Statistical Learning, With Applications in Python* (ISLP), trình bày cùng nội dung với ISLR nhưng triển khai các bài thực hành bằng **Python**. Thành quả này có được nhờ sự tham gia của đồng tác giả mới, Jonathan Taylor. Một số bài thực hành sử dụng **ISLP**, một Python package do chúng tôi xây dựng để hỗ trợ việc triển khai bằng **Python** các phương pháp statistical learning trong từng chương. Những bài thực hành này hữu ích cho cả người mới bắt đầu lẫn người đã có kinh nghiệm với **Python**.

ISLP (cũng như ISLR) hướng đến việc tập trung nhiều hơn vào ứng dụng của các phương pháp và ít hơn vào các chi tiết toán học. Vì thế, sách phù hợp với sinh viên đại học năm cuối hoặc học viên cao học ngành thống kê hay các lĩnh vực định lượng liên quan, cũng như những người ở các chuyên ngành khác muốn sử dụng công cụ statistical learning để phân tích dữ liệu của mình. Sách có thể được dùng làm giáo trình cho một học phần kéo dài hai học kỳ.

Chúng tôi biết ơn những độc giả sau đây vì các ý kiến đóng góp quý báu cho ấn bản đầu tiên của ISLR: Pallavi Basu, Alexandra Chouldechova, Patrick Danaher, Will Fithian, Luella Fu, Sam Gross, Max Grazier G'Sell, Courtney Paulson, Xinghao Qiao, Elisa Sheng, Noah Simon, Kean Ming Tan, Xin Lu Tan. Chúng tôi cảm ơn những độc giả sau vì các góp ý hữu ích cho ấn bản thứ hai của ISLR: Alan Agresti, Iain Carmichael, Yiqun Chen, Erin Craig, Daisy Ding, Lucy Gao, Ismael Lemhadri, Bryan Martin, Anna Neufeld, Geoff Tims, Carsten Voelkmann, Steve Yadlowsky và James Zou. Chúng tôi đặc biệt biết ơn Balasubramanian “Naras” Narasimhan vì sự hỗ trợ của ông đối với cả ISLR và ISLP.

Với chúng tôi, được chứng kiến ảnh hưởng đáng kể của ISLR đối với việc ứng dụng statistical learning, cả trong và ngoài môi trường học thuật, là một vinh dự và đặc ân. Chúng tôi hy vọng ấn bản **Python** mới này sẽ tiếp tục cung cấp cho các nhà thống kê ứng dụng và data scientist hôm nay cũng như mai sau những công cụ cần thiết để thành công trong một thế giới vận hành dựa trên dữ liệu.

Đưa ra dự đoán thật khó, nhất là dự đoán về tương lai.

-Yogi Berra

Mục lục

Lời tựa	vii
1 Giới thiệu	1
2 Statistical Learning	15
2.1 Statistical Learning là gì?	15
2.1.1 Tại sao cần ước lượng f ?	17
2.1.2 Ước lượng f như thế nào?	20
2.1.3 Trade-Off giữa Prediction Accuracy và Model Interpretability	23
2.1.4 So sánh Supervised và Unsupervised Learning	25
2.1.5 So sánh bài toán Regression và Classification	27
2.2 Đánh giá độ chính xác của mô hình	27
2.2.1 Đo lường chất lượng fit	28
2.2.2 Bias-Variance Trade-Off	31
2.2.3 Bối cảnh Classification	34
2.3 Thực hành: Nhập môn Python	40
2.3.1 Bắt đầu	40
2.3.2 Các lệnh cơ bản	40
2.3.3 Giới thiệu Numerical Python	42
2.3.4 Đồ họa	48
2.3.5 Sequence và ký hiệu Slice	51
2.3.6 Đánh chỉ số dữ liệu	51
2.3.7 Nạp dữ liệu	55
2.3.8 Vòng lặp For	59
2.3.9 Các cách tóm tắt bổ sung bằng đồ thị và số	61
2.4 Bài tập	63
3 Linear Regression	69
3.1 Simple Linear Regression	70
3.1.1 Ước lượng các hệ số	71
3.1.2 Đánh giá độ chính xác của các ước lượng hệ số	72

3.1.3	Đánh giá độ chính xác của mô hình	77
3.2	Multiple Linear Regression	80
3.2.1	Ước lượng các hệ số Regression	81
3.2.2	Một số câu hỏi quan trọng	83
3.3	Những vấn đề khác trong mô hình Regression	91
3.3.1	Qualitative Predictors	91
3.3.2	Các mở rộng của Linear Model	94
3.3.3	Những vấn đề có thể gặp	100
3.4	Kế hoạch marketing	109
3.5	So sánh Linear Regression với K-Nearest Neighbors	111
3.6	Thực hành: Linear Regression	116
3.6.1	Import các package	116
3.6.2	Simple Linear Regression	117
3.6.3	Multiple Linear Regression	122
3.6.4	Multivariate Goodness of Fit	123
3.6.5	Interaction Terms	124
3.6.6	Các phép biến đổi phi tuyến của Predictor	125
3.6.7	Qualitative Predictors	126
3.7	Bài tập	127
4	Classification	135
4.1	Tổng quan về Classification	135
4.2	Tại sao không dùng Linear Regression?	136
4.3	Logistic Regression	138
4.3.1	Logistic Model	139
4.3.2	Ước lượng các hệ số Regression	140
4.3.3	Đưa ra dự đoán	141
4.3.4	Multiple Logistic Regression	142
4.3.5	Multinomial Logistic Regression	144
4.4	Generative Models cho Classification	146
4.4.1	Linear Discriminant Analysis với $p = 1$	147
4.4.2	Linear Discriminant Analysis với $p > 1$	150
4.4.3	Quadratic Discriminant Analysis	156
4.4.4	Naive Bayes	158
4.5	So sánh các phương pháp Classification	161
4.5.1	So sánh bằng phân tích lý thuyết	161
4.5.2	So sánh bằng thực nghiệm	164
4.6	Generalized Linear Models	167
4.6.1	Linear Regression trên dữ liệu Bikeshare	167
4.6.2	Poisson Regression trên dữ liệu Bikeshare	169
4.6.3	Generalized Linear Models trong bối cảnh tổng quát hơn	172
4.7	Thực hành: Logistic Regression, LDA, QDA, và KNN	173
4.7.1	Dữ liệu thị trường chứng khoán	173
4.7.2	Logistic Regression	174
4.7.3	Linear Discriminant Analysis	179
4.7.4	Quadratic Discriminant Analysis	181
4.7.5	Naive Bayes	182
4.7.6	K-Nearest Neighbors	183

4.7.7	Linear và Poisson Regression trên dữ liệu Bikeshare .	188
4.8	Bài tập	193
5	Các phương pháp Resampling	201
5.1	Cross-Validation	202
5.1.1	Phương pháp Validation Set	202
5.1.2	Leave-One-Out Cross-Validation	204
5.1.3	k-Fold Cross-Validation	206
5.1.4	Bias-Variance Trade-Off for k-Fold Cross-Validation .	208
5.1.5	Cross-Validation cho bài toán Classification	209
5.2	Bootstrap	212
5.3	Thực hành: Cross-Validation và Bootstrap	215
5.3.1	Phương pháp Validation Set	216
5.3.2	Cross-Validation	217
5.3.3	Bootstrap	220
5.4	Bài tập	224
6	Lựa chọn Linear Model và Regularization	229
6.1	Subset Selection	231
6.1.1	Best Subset Selection	231
6.1.2	Stepwise Selection	233
6.1.3	Lựa chọn mô hình tối ưu	235
6.2	Các phương pháp Shrinkage	240
6.2.1	Ridge Regression	240
6.2.2	Lasso	244
6.2.3	Lựa chọn Tuning Parameter	252
6.3	Các phương pháp Dimension Reduction	253
6.3.1	Principal Components Regression	254
6.3.2	Partial Least Squares	260
6.4	Những vấn đề khi số chiều lớn	262
6.4.1	High-Dimensional Data	262
6.4.2	Điều gì có thể xảy ra khi số chiều lớn?	263
6.4.3	Regression khi số chiều lớn	265
6.4.4	Diễn giải kết quả khi số chiều lớn	266
6.5	Thực hành: Linear Models và các phương pháp Regularization	267
6.5.1	Các phương pháp Subset Selection	268
6.5.2	Ridge Regression và Lasso	273
6.5.3	PCR và PLS Regression	280
6.6	Bài tập	283
7	Vượt ra ngoài tính tuyến tính	289
7.1	Polynomial Regression	290
7.2	Step Functions	292
7.3	Basis Functions	293
7.4	Regression Splines	294
7.4.1	Piecewise Polynomials	294
7.4.2	Các ràng buộc và Spline	296
7.4.3	Biểu diễn bằng Spline Basis	296
7.4.4	Chọn số lượng và vị trí của Knot	297

7.4.5	So sánh với Polynomial Regression	299
7.5	Smoothing Splines	300
7.5.1	Tổng quan về Smoothing Splines	300
7.5.2	Lựa chọn Smoothing Parameter λ	301
7.6	Local Regression	303
7.7	Generalized Additive Models	305
7.7.1	GAM cho bài toán Regression	306
7.7.2	GAM cho bài toán Classification	308
7.8	Thực hành: Mô hình hóa phi tuyến	309
7.8.1	Polynomial Regression và Step Functions	310
7.8.2	Splines	315
7.8.3	Smoothing Splines và GAMs	317
7.8.4	Local Regression	324
7.9	Bài tập	325
8	Các phương pháp Tree-Based	331
8.1	Cơ sở của Decision Trees	331
8.1.1	Regression Trees	331
8.1.2	Classification Trees	337
8.1.3	So sánh Tree với Linear Model	341
8.1.4	Ưu và nhược điểm của Tree	341
8.2	Bagging, Random Forests, Boosting và Bayesian Additive Regression Trees	343
8.2.1	Bagging	343
8.2.2	Random Forests	346
8.2.3	Boosting	347
8.2.4	Bayesian Additive Regression Trees	350
8.2.5	Tổng kết các phương pháp Tree Ensemble	353
8.3	Thực hành: Các phương pháp Tree-Based	354
8.3.1	Fit Classification Trees	355
8.3.2	Fit Regression Trees	358
8.3.3	Bagging và Random Forests	360
8.3.4	Boosting	361
8.3.5	Bayesian Additive Regression Trees	362
8.4	Bài tập	363
9	Support Vector Machines	367
9.1	Maximal Margin Classifier	367
9.1.1	Hyperplane là gì?	368
9.1.2	Classification bằng Separating Hyperplane	368
9.1.3	Maximal Margin Classifier	370
9.1.4	Xây dựng Maximal Margin Classifier	372
9.1.5	Trường hợp Non-separable	372
9.2	Support Vector Classifiers	373
9.2.1	Tổng quan về Support Vector Classifier	373
9.2.2	Chi tiết về Support Vector Classifier	374
9.3	Support Vector Machines	377
9.3.1	Classification với Decision Boundary phi tuyến	378
9.3.2	Support Vector Machine	379

9.3.3	Ứng dụng vào dữ liệu bệnh tim	382
9.4	SVM với nhiều hơn hai Class	383
9.4.1	One-Versus-One Classification	384
9.4.2	One-Versus-All Classification	384
9.5	Mối liên hệ với Logistic Regression	384
9.6	Thực hành: Support Vector Machines	387
9.6.1	Support Vector Classifier	387
9.6.2	Support Vector Machine	390
9.6.3	ROC Curves	392
9.6.4	SVM với nhiều Class	393
9.6.5	Ứng dụng vào dữ liệu biểu hiện gene	394
9.7	Bài tập	395
10	Deep Learning	399
10.1	Neural Network một Layer	400
10.2	Neural Network nhiều Layer	402
10.3	Convolutional Neural Networks	406
10.3.1	Convolution Layers	407
10.3.2	Pooling Layers	410
10.3.3	Kiến trúc của một Convolutional Neural Network	410
10.3.4	Data Augmentation	411
10.3.5	Kết quả khi dùng Pretrained Classifier	412
10.4	Document Classification	413
10.5	Recurrent Neural Networks	416
10.5.1	Sequential Models cho Document Classification	418
10.5.2	Time Series Forecasting	420
10.5.3	Tổng kết về RNN	424
10.6	Khi nào nên dùng Deep Learning	425
10.7	Fit một Neural Network	427
10.7.1	Backpropagation	428
10.7.2	Regularization và Stochastic Gradient Descent	429
10.7.3	Dropout Learning	431
10.7.4	Network Tuning	431
10.8	Interpolation và Double Descent	432
10.9	Thực hành: Deep Learning	435
10.9.1	Network một Layer trên dữ liệu Hitters	437
10.9.2	Network nhiều Layer trên dữ liệu chữ số MNIST	444
10.9.3	Convolutional Neural Networks	448
10.9.4	Sử dụng các mô hình Pretrained CNN	452
10.9.5	Document Classification trên IMDB	454
10.9.6	Recurrent Neural Networks	458
10.10	Bài tập	465
11	Survival Analysis và Censored Data	469
11.1	Survival Time và Censoring Time	470
11.2	Tìm hiểu kỹ hơn về Censoring	470
11.3	Kaplan–Meier Survival Curve	472
11.4	Log-Rank Test	474
11.5	Mô hình Regression với Survival Response	476

11.5.1	Hazard Function	476
11.5.2	Proportional Hazards	478
11.5.3	Ví dụ: Dữ liệu ung thư não	482
11.5.4	Ví dụ: Dữ liệu Publication	482
11.6	Shrinkage cho Cox Model	484
11.7	Các chủ đề bổ sung	486
11.7.1	Area Under the Curve cho Survival Analysis	486
11.7.2	Lựa chọn thang thời gian	487
11.7.3	Time-Dependent Covariates	488
11.7.4	Kiểm tra giả định Proportional Hazards	488
11.7.5	Survival Trees	488
11.8	Thực hành: Survival Analysis	489
11.8.1	Dữ liệu ung thư não	489
11.8.2	Dữ liệu Publication	493
11.8.3	Dữ liệu tổng đài	494
11.9	Bài tập	498
12	Unsupervised Learning	503
12.1	Thách thức của Unsupervised Learning	503
12.2	Principal Components Analysis	504
12.2.1	Principal Components là gì?	505
12.2.2	Một cách diễn giải khác về Principal Components	508
12.2.3	Proportion of Variance Explained	510
12.2.4	Tìm hiểu thêm về PCA	512
12.2.5	Các ứng dụng khác của Principal Components	515
12.3	Missing Values và Matrix Completion	515
12.4	Các phương pháp Clustering	520
12.4.1	K-Means Clustering	521
12.4.2	Hierarchical Clustering	525
12.4.3	Những vấn đề thực tiễn trong Clustering	532
12.5	Thực hành: Unsupervised Learning	535
12.5.1	Principal Components Analysis	535
12.5.2	Matrix Completion	539
12.5.3	Clustering	542
12.5.4	Ví dụ với dữ liệu NCI60	546
12.6	Bài tập	552
13	Multiple Testing	557
13.1	Ôn nhanh về Hypothesis Testing	558
13.1.1	Kiểm định một giả thuyết	558
13.1.2	Type I Error và Type II Error	562
13.2	Thách thức của Multiple Testing	563
13.3	Family-Wise Error Rate	565
13.3.1	Family-Wise Error Rate là gì?	565
13.3.2	Các cách kiểm soát Family-Wise Error Rate	567
13.3.3	Trade-Off giữa FWER và Power	572
13.4	False Discovery Rate	573
13.4.1	Trực giác về False Discovery Rate	573
13.4.2	Quy trình Benjamini-Hochberg	575

13.5	Phương pháp Re-Sampling cho p-Value và False Discovery Rate	577
13.5.1	Phương pháp Re-Sampling cho p-Value	578
13.5.2	Phương pháp Re-Sampling cho False Discovery Rate	579
13.5.3	Khi nào các phương pháp Re-Sampling hữu ích?	581
13.6	Thực hành: Multiple Testing	583
13.6.1	Ôn lại các Hypothesis Test	583
13.6.2	Family-Wise Error Rate	585
13.6.3	False Discovery Rate	588
13.6.4	Phương pháp Re-Sampling	590
13.7	Bài tập	593
Chỉ mục		597




Giới thiệu

Tổng quan về Statistical Learning

Statistical learning là một tập hợp rộng lớn các công cụ giúp *hiểu dữ liệu*. Các công cụ này có thể được phân loại thành *supervised* hoặc *unsupervised*. Nói khái quát, supervised statistical learning xây dựng một mô hình thống kê để dự đoán hoặc ước lượng một *output* dựa trên một hay nhiều *input*. Những bài toán như vậy xuất hiện trong nhiều lĩnh vực khác nhau, từ kinh doanh, y học, vật lý thiên văn đến chính sách công. Với unsupervised statistical learning, ta có các input nhưng không có output đóng vai trò giám sát; dù vậy, ta vẫn có thể học được các mối quan hệ và cấu trúc từ dữ liệu đó. Để minh họa một số ứng dụng của statistical learning, chúng tôi trình bày ngắn gọn ba dataset thực tế được xem xét trong cuốn sách này.

Dữ liệu Wage

Trong ứng dụng này, được gọi là dataset **Wage** xuyên suốt cuốn sách, chúng tôi xem xét một số yếu tố liên quan đến tiền lương của một nhóm nam giới sống ở vùng ven Đại Tây Dương của Hoa Kỳ. Cụ thể, chúng tôi muốn tìm hiểu mối liên hệ của tuổi, trình độ học vấn của một người lao động, cùng với năm dương lịch, với tiền lương của người đó. Chẳng hạn, hãy xem ô bên trái của Hình 1.1, biểu diễn **wage** theo **age** của từng người trong dataset. Có dấu hiệu cho thấy **wage** tăng theo **age**, nhưng lại giảm sau khoảng 60 tuổi. Đường màu xanh lam, ước lượng **wage** trung bình tại mỗi **age**, làm xu hướng này rõ hơn. Khi biết **age** của một người lao động, ta có thể dùng đường cong này để dự đoán **wage** của họ. Tuy nhiên, Hình 1.1 cũng cho thấy rõ ràng các giá trị dao động đáng kể quanh mức trung bình này, nên chỉ riêng **age** khó có thể đưa ra dự đoán chính xác về **wage** của một người cụ thể.




HÌNH 1.1. Dữ liệu *Wage*, chứa thông tin khảo sát thu nhập của nam giới ở vùng Trung Đại Tây Dương của Hoa Kỳ. Trái: *wage* là một hàm của *age*. Trung bình, *wage* tăng theo *age* đến khoảng 60 tuổi, rồi bắt đầu giảm. Giữa: *wage* là một hàm của *year*. Từ năm 2003 đến 2009, *wage* trung bình tăng chậm nhưng đều, tổng cộng khoảng \$10,000. Phải: Các boxplot biểu diễn *wage* theo *education*, trong đó 1 là trình độ thấp nhất (chưa tốt nghiệp trung học phổ thông) và 5 là cao nhất (có bằng sau đại học ở bậc cao). Trung bình, *wage* tăng theo trình độ *education*.

Chúng tôi cũng có thông tin về trình độ học vấn của từng người lao động và *year* mà họ nhận mức *wage* đó. Ở giữa và ô bên phải của Hình 1.1, biểu diễn *wage* theo *year* và *education*, cho thấy cả hai yếu tố này đều có liên hệ với *wage*. Tiền lương tăng khoảng \$10,000 theo dạng gần tuyến tính, tức gần một đường thẳng, từ năm 2003 đến 2009; tuy nhiên, mức tăng này rất nhỏ so với độ biến thiên của dữ liệu. Tiền lương cũng thường cao hơn ở những người có trình độ học vấn cao hơn: nam giới thuộc mức học vấn thấp nhất (1) thường có lương thấp hơn đáng kể so với những người thuộc mức cao nhất (5). Rõ ràng, dự đoán chính xác nhất về *wage* của một người sẽ có được bằng cách kết hợp *age*, *education* và *year*. Trong Chương 3, chúng tôi trình bày linear regression, phương pháp có thể dùng để dự đoán *wage* từ dataset này. Lý tưởng nhất, ta nên dự đoán *wage* theo cách có tính đến mối quan hệ phi tuyến giữa *wage* và *age*. Trong Chương 7, chúng tôi thảo luận một nhóm phương pháp để giải quyết vấn đề này.

Dữ liệu thị trường chứng khoán

Dữ liệu *Wage* đặt ra yêu cầu dự đoán một giá trị output *continuous* hoặc *quantitative*. Đây thường được gọi là bài toán *regression*. Tuy nhiên, trong một số trường hợp, ta muốn dự đoán một giá trị không phải số, tức một output *categorical* hoặc *qualitative*. Chẳng hạn, trong Chương 4, chúng tôi xem xét một dataset thị trường chứng khoán chứa biến động hằng ngày của chỉ số Standard & Poor's 500 (S&P) trong giai đoạn 5 năm từ 2001 đến 2005. Chúng tôi gọi đây là dữ liệu *Smarket*. Mục tiêu là dự đoán chỉ số sẽ *tăng* hay *giảm* vào một ngày nhất định, dựa trên tỷ lệ phần trăm thay đổi của chỉ số trong 5 ngày trước đó. Ở đây, bài toán statistical learning không yêu cầu dự đoán một giá trị số. Thay vào đó, ta dự đoán diễn biến của thị trường chứng khoán trong một ngày sẽ thuộc nhóm *Up* hay nhóm




HÌNH 1.2. Trái: Các boxplot của tỷ lệ phần trăm thay đổi chỉ số S&P trong ngày trước đó, chia theo những ngày thị trường tăng hoặc giảm, được lấy từ dữ liệu *Smarket*. Giữa và phải: Tương tự ở bên trái, nhưng biểu diễn tỷ lệ phần trăm thay đổi của 2 và 3 ngày trước đó.

Down. Đây được gọi là bài toán *classification*. Một mô hình có thể dự đoán chính xác hướng biến động của thị trường hần sẽ rất hữu ích!

Ở bên trái của Hình 1.2 có hai boxplot biểu diễn tỷ lệ phần trăm thay đổi của chỉ số chứng khoán trong ngày trước đó: một boxplot cho 648 ngày mà thị trường tăng trong ngày tiếp theo, và một boxplot cho 602 ngày mà thị trường giảm. Hai đồ thị trông gần như giống hệt nhau, cho thấy không có một chiến lược đơn giản nào để dùng biến động S&P của hôm qua dự đoán mức sinh lời hôm nay. Những ô còn lại, biểu diễn các boxplot của tỷ lệ phần trăm thay đổi cách hôm nay 2 và 3 ngày, cũng cho thấy ít liên hệ giữa mức sinh lời trong quá khứ và hiện tại. Tất nhiên, việc không thấy một quy luật rõ ràng như vậy là điều có thể dự kiến: nếu tồn tại tương quan mạnh giữa mức sinh lời của các ngày liên tiếp, ta có thể áp dụng một chiến lược giao dịch đơn giản để kiếm lợi nhuận từ thị trường. Dù vậy, trong Chương 4, chúng tôi vẫn khảo sát dữ liệu này bằng một số phương pháp statistical learning khác nhau. Điều thú vị là dữ liệu hé lộ một vài xu hướng yếu, cho thấy ít nhất trong giai đoạn 5 năm này, ta có thể dự đoán đúng hướng biến động thị trường trong khoảng 60% số trường hợp (Hình 1.3).

Dữ liệu biểu hiện gene

Hai ứng dụng trước minh họa những dataset có cả biến input và biến output. Tuy nhiên, một nhóm bài toán quan trọng khác liên quan đến tình huống ta chỉ quan sát được các biến input mà không có output tương ứng. Chẳng hạn, trong marketing, ta có thể có thông tin nhân khẩu học của một số khách hàng hiện tại hoặc tiềm năng. Ta muốn biết những kiểu khách hàng nào giống nhau bằng cách nhóm các cá nhân theo đặc điểm quan sát được của họ. Đây được gọi là bài toán *clustering*. Khác với các ví dụ trước, ở đây ta không tìm cách dự đoán một biến output.




HÌNH 1.3. Chúng tôi fit một mô hình *quadratic discriminant analysis* trên tập con của dữ liệu *Smarket* tương ứng với giai đoạn 2001–2004, rồi dự đoán xác suất thị trường chứng khoán giảm bằng dữ liệu năm 2005. Trung bình, xác suất giảm được dự đoán cao hơn vào những ngày thị trường thực sự giảm. Dựa trên các kết quả này, chúng tôi dự đoán đúng hướng biến động thị trường trong 60% số trường hợp.

Chúng tôi dành Chương 12 để thảo luận các phương pháp statistical learning cho những bài toán không có sẵn một biến output tự nhiên. Chúng tôi xem xét dataset *NCI60*, gồm 6,830 phép đo biểu hiện gene cho mỗi dòng trong số 64 dòng tế bào ung thư. Thay vì dự đoán một biến output cụ thể, chúng tôi muốn xác định xem có những nhóm, hay *cluster*, giữa các dòng tế bào dựa trên các phép đo biểu hiện gene của chúng hay không. Đây là một câu hỏi khó giải quyết, một phần vì mỗi dòng tế bào có hàng nghìn phép đo biểu hiện gene, khiến việc trực quan hóa dữ liệu trở nên khó khăn.

Ở bên trái của Hình 1.4 giải quyết vấn đề này bằng cách biểu diễn mỗi dòng trong số 64 dòng tế bào chỉ bằng hai số, Z_1 và Z_2 . Đây là hai *principal components* đầu tiên của dữ liệu, tóm lược 6,830 phép đo biểu hiện gene của mỗi dòng tế bào thành hai số, hay hai chiều. Dù việc *dimension reduction* này có thể đã làm mất một phần thông tin, giờ đây ta có thể quan sát dữ liệu để tìm dấu hiệu của clustering. Quyết định số lượng cluster thường là một bài toán khó. Tuy nhiên, ở bên trái của Hình 1.4 gợi ý có ít nhất bốn nhóm dòng tế bào, được chúng tôi biểu diễn bằng các màu riêng biệt.

Trong dataset cụ thể này, các dòng tế bào thực ra tương ứng với 14 loại ung thư khác nhau. (Tuy nhiên, thông tin này không được dùng để tạo ô bên trái của Hình 1.4.) Ở bên phải của Hình 1.4 giống ô bên trái, ngoại trừ việc 14 loại ung thư được thể hiện bằng những ký hiệu có màu khác nhau. Có bằng chứng rõ ràng rằng các dòng tế bào thuộc cùng một loại ung thư thường nằm gần nhau trong biểu diễn hai chiều này. Hơn nữa, dù thông tin về loại ung thư không được dùng để tạo ô bên trái, kết quả clustering thu được vẫn phần nào tương đồng với một số loại ung thư thực tế quan sát được ở ô bên phải. Điều này cung cấp một sự kiểm chứng độc lập nhất định về độ chính xác của phân tích clustering.



HÌNH 1.4. Trái: Biểu diễn dataset biểu hiện gene *NCI60* trong không gian hai chiều Z_1 và Z_2 . Mỗi điểm tương ứng với một trong 64 dòng tế bào. Dường như có bốn nhóm dòng tế bào, được chúng tôi thể hiện bằng các màu khác nhau. Phải: Tương tự ô bên trái, nhưng mỗi loại trong số 14 loại ung thư được biểu diễn bằng một ký hiệu có màu riêng. Những dòng tế bào thuộc cùng một loại ung thư thường nằm gần nhau trong không gian hai chiều.

Lược sử Statistical Learning

Dù thuật ngữ *statistical learning* còn khá mới, nhiều khái niệm nền tảng của lĩnh vực này đã được phát triển từ lâu. Đầu thế kỷ XIX, phương pháp *least squares* được xây dựng, triển khai dạng thức sớm nhất của phương pháp ngày nay được gọi là *linear regression*. Phương pháp này lần đầu được áp dụng thành công cho các bài toán thiên văn học. Linear regression được dùng để dự đoán những giá trị quantitative, chẳng hạn tiền lương của một người. Để dự đoán những giá trị qualitative, như một bệnh nhân sống hay tử vong, hoặc thị trường chứng khoán tăng hay giảm, *linear discriminant analysis* đã được đề xuất vào năm 1936. Trong thập niên 1940, nhiều tác giả đưa ra một phương pháp thay thế là *logistic regression*. Đầu thập niên 1970, thuật ngữ *generalized linear model* được xây dựng để mô tả cả một lớp phương pháp statistical learning, trong đó linear regression và logistic regression là những trường hợp riêng.

Đến cuối thập niên 1970, đã có thêm nhiều kỹ thuật học từ dữ liệu. Tuy nhiên, chúng gần như chỉ là các phương pháp tuyến tính, bởi việc fit những mối quan hệ phi tuyến khi đó còn khó khăn về mặt tính toán. Đến thập niên 1980, công nghệ máy tính cuối cùng đã tiến bộ đủ để chi phí tính toán của các phương pháp phi tuyến không còn là trở ngại quá lớn. Vào giữa thập niên 1980, *classification and regression trees* được phát triển; ngay sau đó là *generalized additive models*. *Neural networks* trở nên phổ biến trong thập niên 1980, còn *support vector machines* xuất hiện trong thập niên 1990.

Từ đó, statistical learning nổi lên như một nhánh mới của thống kê, tập trung vào mô hình hóa và dự đoán theo hướng supervised và unsupervised. Trong những năm gần đây, tiến bộ của statistical learning gắn liền với việc ngày càng có nhiều phần mềm mạnh và tương đối dễ sử dụng, chẳng hạn hệ thống *Python* phổ biến và được cung cấp miễn phí. Điều này có thể

tiếp tục thúc đẩy sự chuyển đổi của lĩnh vực, từ một tập hợp các kỹ thuật do các nhà thống kê và nhà khoa học máy tính sử dụng, phát triển, thành một bộ công cụ thiết yếu cho một cộng đồng rộng lớn hơn nhiều.

Về cuốn sách này

The Elements of Statistical Learning (ESL) của Hastie, Tibshirani và Friedman được xuất bản lần đầu vào năm 2001. Kể từ đó, cuốn sách đã trở thành một tài liệu tham khảo quan trọng về nền tảng của statistical machine learning. Thành công của sách bắt nguồn từ cách trình bày toàn diện và chi tiết nhiều chủ đề quan trọng của statistical learning, cũng như việc sách có thể tiếp cận một lượng độc giả rộng rãi nếu so với nhiều giáo trình thống kê nâng cao. Tuy nhiên, yếu tố lớn nhất làm nên thành công của ESL là tính thời sự. Vào thời điểm sách ra đời, sự quan tâm đến statistical learning bắt đầu bùng nổ. ESL cung cấp một trong những phần nhập môn đầu tiên vừa dễ tiếp cận vừa toàn diện về chủ đề này.

Kể từ lần xuất bản đầu tiên của ESL, statistical learning tiếp tục phát triển mạnh. Sự mở rộng diễn ra theo hai hướng. Rõ rệt nhất là việc phát triển các phương pháp statistical learning mới và cải tiến nhằm trả lời nhiều câu hỏi khoa học trong nhiều lĩnh vực. Tuy nhiên, statistical learning cũng mở rộng cộng đồng người sử dụng. Trong thập niên 1990, năng lực tính toán tăng lên đã tạo ra một làn sóng quan tâm từ những người không chuyên về thống kê, những người mong muốn dùng các công cụ thống kê tiên tiến để phân tích dữ liệu của mình. Đáng tiếc, tính kỹ thuật cao của các phương pháp này khiến cộng đồng người dùng chủ yếu vẫn giới hạn ở các chuyên gia thống kê, khoa học máy tính và những lĩnh vực liên quan, vốn có đủ nền tảng đào tạo và thời gian để hiểu cũng như triển khai chúng.

Trong những năm gần đây, các software package mới và được cải tiến đã giảm đáng kể gánh nặng triển khai của nhiều phương pháp statistical learning. Đồng thời, ngày càng nhiều lĩnh vực, từ kinh doanh, chăm sóc sức khỏe, di truyền học đến khoa học xã hội và xa hơn nữa, nhận ra rằng statistical learning là một công cụ mạnh với những ứng dụng thực tiễn quan trọng. Vì vậy, lĩnh vực này đã chuyển từ chỗ chủ yếu được quan tâm trong giới học thuật thành một ngành được sử dụng rộng rãi, với lượng độc giả tiềm năng rất lớn. Xu hướng này chắc chắn sẽ tiếp diễn khi những khối lượng dữ liệu khổng lồ và phần mềm phân tích chúng ngày càng sẵn có.

Mục đích của *An Introduction to Statistical Learning* (ISL) là hỗ trợ statistical learning chuyển từ một lĩnh vực học thuật sang một lĩnh vực được sử dụng rộng rãi. ISL không nhằm thay thế ESL, vốn toàn diện hơn nhiều cả về số lượng phương pháp được xem xét lẫn mức độ chuyên sâu. Chúng tôi xem ESL là một tài liệu đồng hành quan trọng cho những người làm chuyên môn có bằng sau đại học về thống kê, machine learning hoặc các lĩnh vực liên quan, những người cần hiểu chi tiết kỹ thuật đứng sau các phương pháp statistical learning. Tuy nhiên, cộng đồng sử dụng các kỹ thuật statistical learning đã mở rộng, bao gồm những người có mối quan tâm và nền tảng đa dạng hơn. Vì thế, vẫn có chỗ cho một phiên bản ít chuyên sâu về kỹ thuật hơn và dễ tiếp cận hơn của ESL.

Qua nhiều năm giảng dạy các chủ đề này, chúng tôi nhận thấy chúng thu hút học viên cao học và nghiên cứu sinh thuộc những lĩnh vực khác nhau như quản trị kinh doanh, sinh học và khoa học máy tính, cũng như sinh viên đại học các năm cuối có định hướng định lượng. Điều quan trọng với nhóm độc giả đa dạng này là hiểu được mô hình, trực giác, điểm mạnh và điểm yếu của từng phương pháp. Tuy nhiên, nhiều chi tiết kỹ thuật phía sau các phương pháp statistical learning, như các thuật toán tối ưu hóa và những tính chất lý thuyết, không phải mối quan tâm chính của họ. Chúng tôi tin rằng những người học này không cần hiểu thật sâu các khía cạnh đó để sử dụng các phương pháp một cách có hiểu biết, cũng như đóng góp cho lĩnh vực đã chọn bằng các công cụ statistical learning.

ISL được xây dựng trên bốn tiền đề sau.

1. *Nhiều phương pháp statistical learning có liên quan và hữu ích trong rất nhiều lĩnh vực học thuật lẫn ngoài học thuật, vượt ra ngoài phạm vi các ngành thống kê.* Chúng tôi tin rằng nhiều phương pháp statistical learning đương đại nên được, và sẽ được, phổ biến cũng như sử dụng rộng rãi như các phương pháp cổ điển, chẳng hạn linear regression, hiện nay. Vì thế, thay vì cố gắng xem xét mọi phương pháp có thể có, một việc bất khả thi, chúng tôi tập trung trình bày những phương pháp mà mình tin là có khả năng ứng dụng rộng nhất.
2. *Không nên nhìn nhận statistical learning như một chuỗi các black box.* Không có phương pháp đơn lẻ nào hoạt động tốt trong mọi ứng dụng có thể có. Nếu không hiểu các bánh răng bên trong chiếc hộp hoặc cách chúng tương tác với nhau, ta không thể chọn được chiếc hộp tốt nhất. Vì vậy, chúng tôi cố gắng mô tả cẩn thận mô hình, trực giác, giả định và những trade-off đứng sau mỗi phương pháp được xem xét.
3. *Dù cần biết mỗi bánh răng làm nhiệm vụ gì, ta không nhất thiết phải có kỹ năng chế tạo cả cỗ máy bên trong chiếc hộp!* Do đó, chúng tôi hạn chế tối đa việc thảo luận các chi tiết kỹ thuật liên quan đến quy trình fit và các tính chất lý thuyết. Chúng tôi giả định người đọc nắm được những khái niệm toán học cơ bản, nhưng không giả định họ có bằng sau đại học trong các ngành khoa học toán học. Chẳng hạn, chúng tôi gần như hoàn toàn tránh sử dụng đại số ma trận, và người đọc có thể hiểu toàn bộ cuốn sách mà không cần kiến thức chi tiết về ma trận và vector.
4. *Chúng tôi giả định người đọc quan tâm đến việc áp dụng các phương pháp statistical learning vào những bài toán thực tế.* Để hỗ trợ điều đó và tạo động lực cho các kỹ thuật được thảo luận, chúng tôi dành một phần trong mỗi chương cho các bài thực hành trên máy tính. Trong mỗi bài, chúng tôi hướng dẫn người đọc thực hiện một ứng dụng thực tế của các phương pháp được xem xét trong chương. Khi giảng dạy nội dung này, chúng tôi dành khoảng một phần ba thời gian trên lớp để làm các bài thực hành và nhận thấy chúng cực kỳ hữu ích. Nhiều sinh viên ít thiên về tính toán, ban đầu còn e ngại các bài thực hành, đã dần thành thạo trong suốt học kỳ hoặc học kỳ quý. Cuốn sách này ban đầu được xuất bản năm 2013, với ấn bản thứ hai năm 2021,

kèm các bài thực hành viết bằng ngôn ngữ **R**. Kể từ đó, nhu cầu về các bản triển khai bằng **Python** của những kỹ thuật quan trọng trong statistical learning ngày càng tăng. Do vậy, phiên bản này có các bài thực hành bằng **Python**. Số lượng Python package hiện có tăng rất nhanh; khi xem các lệnh import ở đầu mỗi bài thực hành, người đọc sẽ thấy chúng tôi đã lựa chọn cẩn thận và sử dụng những package phù hợp nhất. Chúng tôi cũng cung cấp thêm một số mã lệnh và chức năng trong package **ISLP**. Tuy nhiên, các bài thực hành trong ISL là những phần độc lập; người đọc có thể bỏ qua nếu muốn dùng một software package khác hoặc không muốn áp dụng các phương pháp được thảo luận vào những bài toán thực tế.

Ai nên đọc cuốn sách này?

Cuốn sách dành cho bất kỳ ai quan tâm đến việc dùng các phương pháp thống kê hiện đại để mô hình hóa và dự đoán từ dữ liệu. Nhóm này bao gồm nhà khoa học, kỹ sư, data analyst, data scientist và chuyên gia phân tích định lượng, nhưng cũng bao gồm những người ít thiên về kỹ thuật, có bằng cấp thuộc các lĩnh vực không định lượng như khoa học xã hội hoặc kinh doanh. Chúng tôi kỳ vọng người đọc đã học ít nhất một học phần thống kê nhập môn. Nền tảng về linear regression cũng hữu ích, dù không bắt buộc, vì chúng tôi ôn lại các khái niệm cốt lõi của linear regression trong Chương 3. Mức độ toán học của sách vừa phải và không đòi hỏi kiến thức chi tiết về các phép toán ma trận. Sách có phần nhập môn **Python**. Việc từng tiếp xúc với một ngôn ngữ lập trình, chẳng hạn **MATLAB** hoặc **R**, là hữu ích nhưng không bắt buộc.

Ấn bản đầu tiên của giáo trình này đã được dùng để giảng dạy cho học viên cao học và nghiên cứu sinh trong kinh doanh, kinh tế, khoa học máy tính, sinh học, khoa học Trái Đất, tâm lý học và nhiều ngành khác thuộc khoa học tự nhiên cũng như khoa học xã hội. Sách cũng được dùng để dạy sinh viên đại học các năm cuối đã học một học phần về linear regression. Trong một học phần chặt chẽ hơn về toán học, sử dụng ESL làm giáo trình chính, ISL có thể đóng vai trò tài liệu bổ trợ để giảng dạy những khía cạnh tính toán của các phương pháp khác nhau.

Ký hiệu và đại số ma trận cơ bản

Lựa chọn ký hiệu cho một giáo trình luôn là việc khó. Phần lớn, chúng tôi áp dụng cùng những quy ước ký hiệu như ESL.

Chúng tôi dùng n để biểu thị số điểm dữ liệu phân biệt, hay *observations*, trong mẫu. Chúng tôi dùng p để chỉ số biến có thể sử dụng cho việc dự đoán. Ví dụ, dataset **Wage** gồm 11 biến của 3,000 người, nên ta có $n = 3,000$ observations và $p = 11$ biến, chẳng hạn **year**, **age**, **race** và những biến khác. Lưu ý rằng trong toàn bộ cuốn sách, tên biến được biểu thị bằng chữ có màu: **Variable Name**.

Trong một số ví dụ, p có thể khá lớn, ở mức hàng nghìn hoặc thậm chí hàng triệu. Tình huống này xuất hiện tương đối thường xuyên, chẳng hạn khi phân tích dữ liệu sinh học hiện đại hoặc dữ liệu quảng cáo trên web.

Nói chung, chúng tôi dùng x_{ij} để biểu thị giá trị của biến thứ j ở observation thứ i , trong đó $i = 1, 2, \dots, n$ và $j = 1, 2, \dots, p$. Trong toàn bộ cuốn sách, i được dùng để đánh chỉ số các mẫu hoặc observations (từ 1 đến n), còn j được dùng để đánh chỉ số các biến (từ 1 đến p). Chúng tôi ký hiệu $\mathbf{X}$ là một ma trận $n \times p$ có phần tử (i, j) bằng x_{ij} . Nghĩa là,

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}.$$

Với những độc giả chưa quen với ma trận, có thể hình dung $\mathbf{X}$ như một bảng tính chứa các số, có n hàng và p cột.

Đôi khi ta quan tâm đến các hàng của $\mathbf{X}$, được viết là $x_1, x_2, \dots, x_n$. Ở đây, x_i là một vector có độ dài p , chứa các giá trị đo của p biến ở observation thứ i . Nghĩa là,

$$x_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix}. \quad (1.1)$$

(Theo mặc định, các vector được biểu diễn dưới dạng cột.) Chẳng hạn, với dữ liệu **Wage**, x_i là một vector có độ dài 11, gồm **year**, **age**, **race** và những giá trị khác của người thứ i . Những lúc khác, ta lại quan tâm đến các cột của $\mathbf{X}$, được viết là $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$. Mỗi cột là một vector có độ dài n . Nghĩa là,

$$\mathbf{x}_j = \begin{pmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{pmatrix}.$$

Ví dụ, với dữ liệu **Wage**, $\mathbf{x}_1$ chứa $n = 3,000$ giá trị của **year**.

Với ký hiệu này, ma trận $\mathbf{X}$ có thể được viết là

$$\mathbf{X} = (\mathbf{x}_1 \quad \mathbf{x}_2 \quad \dots \quad \mathbf{x}_p),$$

hoặc

$$\mathbf{X} = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{pmatrix}.$$

Ký hiệu T biểu thị *transpose* của một ma trận hoặc vector. Do đó, chẳng hạn,

$$\mathbf{X}^T = \begin{pmatrix} x_{11} & x_{21} & \dots & x_{n1} \\ x_{12} & x_{22} & \dots & x_{n2} \\ \vdots & \vdots & & \vdots \\ x_{1p} & x_{2p} & \dots & x_{np} \end{pmatrix},$$

còn

$$x_i^T = (x_{i1} \quad x_{i2} \quad \dots \quad x_{ip}).$$

Chúng tôi dùng y_i để biểu thị observation thứ i của biến mà ta muốn dự đoán, chẳng hạn **wage**. Vì thế, tập hợp tất cả n observations được viết dưới dạng vector như sau:

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Khi đó, dữ liệu quan sát của ta gồm $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, trong đó mỗi x_i là một vector có độ dài p . (Nếu $p = 1$, x_i chỉ là một scalar.)

Trong cuốn sách này, một vector có độ dài n luôn được ký hiệu bằng *chữ thường in đậm*; ví dụ,

$$\mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}.$$

Tuy nhiên, các vector có độ dài khác n , chẳng hạn feature vector có độ dài p như trong (1.1), được ký hiệu bằng *chữ thường không in đậm*, ví dụ a . Scalar cũng được ký hiệu bằng chữ thường không in đậm, ví dụ a . Trong những trường hợp hiếm hoi mà hai cách sử dụng này gây mơ hồ, chúng tôi sẽ làm rõ ý nghĩa được dùng. Ma trận được ký hiệu bằng *chữ hoa in đậm*, chẳng hạn **A**. Random variable được ký hiệu bằng chữ hoa không in đậm, ví dụ A , bất kể số chiều của chúng.

Đôi khi ta muốn chỉ rõ số chiều của một đối tượng. Để cho biết một đối tượng là scalar, chúng tôi dùng ký hiệu $a \in \mathbb{R}$. Để cho biết đó là một vector có độ dài k , chúng tôi dùng $a \in \mathbb{R}^k$ (hoặc $\mathbf{a} \in \mathbb{R}^n$ nếu vector có độ dài n). Một đối tượng là ma trận $r \times s$ được biểu thị bằng $\mathbf{A} \in \mathbb{R}^{r \times s}$.

Chúng tôi tránh dùng đại số ma trận bất cứ khi nào có thể. Tuy nhiên, trong một vài trường hợp, việc tránh hoàn toàn khiến cách trình bày trở nên quá rườm rà. Khi đó, điều quan trọng là hiểu khái niệm nhân hai ma trận. Giả sử $\mathbf{A} \in \mathbb{R}^{r \times d}$ và $\mathbf{B} \in \mathbb{R}^{d \times s}$. Tích của $\mathbf{A}$ và $\mathbf{B}$ được ký hiệu là **AB**. Phần tử (i, j) của **AB** được tính bằng cách nhân từng phần tử của hàng thứ i trong $\mathbf{A}$ với phần tử tương ứng của cột thứ j trong $\mathbf{B}$ rồi cộng lại. Nghĩa là, $(\mathbf{AB})_{ij} = \sum_{k=1}^d a_{ik}b_{kj}$. Chẳng hạn, xét

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \quad \text{và} \quad \mathbf{B} = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}.$$

Khi đó,

$$\mathbf{AB} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix} = \begin{pmatrix} 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 \\ 3 \times 5 + 4 \times 7 & 3 \times 6 + 4 \times 8 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}.$$

Lưu ý rằng phép toán này tạo ra một ma trận $r \times s$. Chỉ có thể tính $\mathbf{AB}$ khi số cột của $\mathbf{A}$ bằng số hàng của $\mathbf{B}$.

Cấu trúc cuốn sách

Chương 2 giới thiệu các thuật ngữ và khái niệm cơ bản của statistical learning. Chương này cũng trình bày K-nearest neighbor classifier, một phương pháp rất đơn giản nhưng hoạt động tốt một cách đáng ngạc nhiên trên nhiều bài toán. Chương 3 và 4 đề cập đến những phương pháp tuyến tính cổ điển cho regression và classification. Cụ thể, Chương 3 ôn lại linear regression, điểm khởi đầu nền tảng của mọi phương pháp regression. Trong Chương 4, chúng tôi thảo luận hai trong số những phương pháp classification cổ điển quan trọng nhất: logistic regression và linear discriminant analysis.

Một vấn đề trung tâm trong mọi tình huống statistical learning là lựa chọn phương pháp tốt nhất cho một ứng dụng cụ thể. Vì vậy, trong Chương 5, chúng tôi giới thiệu cross-validation và bootstrap, những công cụ có thể dùng để ước lượng độ chính xác của nhiều phương pháp khác nhau nhằm chọn ra phương pháp tốt nhất.

Phần lớn nghiên cứu gần đây về statistical learning tập trung vào các phương pháp phi tuyến. Tuy nhiên, các phương pháp tuyến tính thường có lợi thế so với những phương pháp phi tuyến cạnh tranh về khả năng diễn giải, và đôi khi cả độ chính xác. Vì vậy, trong Chương 6, chúng tôi xem xét nhiều phương pháp tuyến tính, cả cổ điển lẫn hiện đại hơn, có khả năng cải thiện so với linear regression tiêu chuẩn. Những phương pháp này bao gồm stepwise selection, ridge regression, principal components regression và lasso.

Các chương còn lại đi vào thế giới statistical learning phi tuyến. Trước tiên, trong Chương 7, chúng tôi giới thiệu một số phương pháp phi tuyến hoạt động tốt với những bài toán chỉ có một biến input. Sau đó, chúng tôi chỉ ra cách dùng chúng để fit các mô hình cộng phi tuyến có nhiều hơn một input. Trong Chương 8, chúng tôi khảo sát các tree-based methods, bao gồm bagging, boosting và random forests. Support vector machines, một tập hợp các phương pháp thực hiện classification tuyến tính lẫn phi tuyến, được thảo luận trong Chương 9. Trong Chương 10, chúng tôi trình bày deep learning, một hướng tiếp cận regression và classification phi tuyến thu hút nhiều sự chú ý trong những năm gần đây. Chương 11 khảo sát survival analysis, một hướng tiếp cận regression chuyên dùng cho trường hợp biến output bị censored, tức không được quan sát đầy đủ.

Trong Chương 12, chúng tôi xem xét bối cảnh unsupervised, nơi ta có các biến input nhưng không có biến output. Cụ thể, chúng tôi trình bày principal components analysis, K-means clustering và hierarchical clustering. Cuối cùng, trong Chương 13, chúng tôi đề cập đến chủ đề rất quan trọng là multiple hypothesis testing.

Tên	Mô tả
Auto	Quãng đường trên một đơn vị nhiên liệu, công suất và thông tin khác về ô tô.
Bikeshare	Mức sử dụng theo giờ của một chương trình xe đạp dùng chung tại Washington, DC.
Boston	Giá trị nhà ở và thông tin khác về các khu vực điều tra dân số tại Boston.
BrainCancer	Thời gian sống của bệnh nhân được chẩn đoán ung thư não.
Caravan	Thông tin về những người được chào bán bảo hiểm caravan.
Carseats	Thông tin về doanh số ghế ô tô tại 400 cửa hàng.
College	Đặc điểm nhân khẩu học, học phí và thông tin khác về các trường đại học ở Hoa Kỳ.
Credit	Thông tin về dư nợ thẻ tín dụng của 400 khách hàng.
Default	Hồ sơ vỡ nợ của khách hàng tại một công ty thẻ tín dụng.
Fund	Mức sinh lời của 2,000 nhà quản lý hedge fund trong 50 tháng.
Hitters	Thành tích và tiền lương của các cầu thủ bóng chày.
Khan	Các phép đo biểu hiện gene của bốn loại ung thư.
NCI60	Các phép đo biểu hiện gene của 64 dòng tế bào ung thư.
NYSE	Mức sinh lời, volatility và khối lượng giao dịch của Sở Giao dịch Chứng khoán New York.
OJ	Thông tin bán hàng của nước cam Citrus Hill và Minute Maid.
Portfolio	Giá trị quá khứ của tài sản tài chính, dùng cho phân bổ danh mục đầu tư.
Publication	Thời gian đến khi công bố của 244 thử nghiệm lâm sàng.
Smarket	Mức sinh lời phần trăm hằng ngày của S&P 500 trong một giai đoạn 5 năm.
USArrests	Thống kê tội phạm trên 100,000 dân tại 50 tiểu bang của Hoa Kỳ.
Wage	Dữ liệu khảo sát thu nhập của nam giới ở vùng Trung Đại Tây Dương của Hoa Kỳ.
Weekly	1,089 mức sinh lời hằng tuần của thị trường chứng khoán trong 21 năm.

BẢNG 1.1. Danh sách các dataset cần để thực hiện những bài thực hành và bài tập trong giáo trình này. Tất cả đều có trong package **ISLP**, ngoại trừ **USArrests**, thuộc bản phân phối **R** cơ bản nhưng có thể truy cập từ **Python**.

Ở cuối mỗi chương, chúng tôi trình bày một hoặc nhiều phần thực hành **Python**, hướng dẫn có hệ thống các ứng dụng của những phương pháp được thảo luận trong chương. Những bài thực hành này minh họa điểm mạnh và điểm yếu của các phương pháp, đồng thời là tài liệu tham khảo hữu ích về cú pháp cần dùng để triển khai chúng. Người đọc có thể thực hiện theo tốc độ của riêng mình, hoặc dùng các bài thực hành làm nội dung chính cho những buổi học nhóm trên lớp. Trong mỗi bài thực hành **Python**, chúng tôi trình bày những kết quả thu được khi thực hiện bài đó vào thời điểm viết sách. Tuy nhiên, các phiên bản **Python** mới liên tục được phát hành, và theo thời gian, các package được gọi trong bài thực hành cũng sẽ được cập nhật. Vì thế, trong tương lai, những kết quả ở các phần thực hành có thể không còn khớp hoàn toàn với kết quả mà người đọc thu được khi tự thực hiện. Khi cần thiết, chúng tôi sẽ đăng các bản cập nhật bài thực hành trên website của sách.

Chúng tôi dùng ký hiệu  để đánh dấu những mục hoặc bài tập chứa các khái niệm khó hơn. Người đọc có thể dễ dàng bỏ qua chúng nếu không muốn tìm hiểu sâu đến mức đó hoặc chưa có nền tảng toán học cần thiết.

Dataset dùng trong bài thực hành và bài tập

Trong giáo trình này, chúng tôi minh họa các phương pháp statistical learning bằng những ứng dụng trong marketing, tài chính, sinh học và các lĩnh vực khác. Package **ISLP** chứa một số dataset cần thiết để thực hiện các bài thực hành và bài tập đi kèm sách. Một dataset khác, **USArrests**, thuộc bản phân phối **R** cơ bản; chúng tôi hướng dẫn cách truy cập dữ liệu này từ **Python** trong Mục 12.5.1. Bảng 1.1 tóm tắt các dataset cần dùng cho bài thực hành và bài tập. Một vài dataset trong số này cũng được cung cấp dưới dạng tệp văn bản trên website của sách để sử dụng trong Chương 2.

Website của sách

Website của cuốn sách này có địa chỉ

www.statlearning.com

Trang web cung cấp nhiều tài nguyên, bao gồm Python package đi kèm sách và một số dataset bổ sung.

Lời cảm ơn

Một vài đồ thị trong cuốn sách này được lấy từ ESL: Hình 6.7, 8.3 và 12.14. Tất cả các đồ thị khác được tạo cho phiên bản **R** của ISL, ngoại trừ Hình 13.10, vốn khác đi do phần mềm **Python** dùng để hỗ trợ vẽ đồ thị đó.