



Linear Regression

Chương này trình bày linear regression, một cách tiếp cận rất đơn giản cho supervised learning. Cụ thể, linear regression là công cụ hữu ích để dự đoán một quantitative response. Phương pháp này đã tồn tại từ lâu và là chủ đề của vô số sách giáo khoa. Dù có vẻ hơi nhàm chán khi so với một số cách tiếp cận statistical learning hiện đại hơn được mô tả ở những chương sau, linear regression vẫn là một phương pháp statistical learning hữu ích và được dùng rộng rãi. Hơn nữa, nó là điểm khởi đầu tốt để tìm hiểu các cách tiếp cận mới hơn: như ta sẽ thấy trong các chương sau, nhiều phương pháp statistical learning phức tạp có thể được xem là dạng tổng quát hóa hoặc mở rộng của linear regression. Vì vậy, không thể xem nhẹ tầm quan trọng của việc hiểu vững linear regression trước khi nghiên cứu những phương pháp learning phức tạp hơn. Trong chương này, chúng tôi ôn lại một số ý tưởng chính làm nền tảng cho linear regression model, cùng cách tiếp cận least squares thường được dùng nhất để fit mô hình này.

Nhớ lại dữ liệu **Advertising** ở Chương 2. Hình 2.1 biểu diễn **sales**, tính bằng nghìn đơn vị, của một sản phẩm cụ thể theo ngân sách quảng cáo, tính bằng nghìn đô la, trên các phương tiện **TV**, **radio** và **newspaper**. Giả sử với vai trò chuyên gia tư vấn thống kê, ta được yêu cầu dựa trên dữ liệu này để đề xuất một kế hoạch marketing cho năm tới nhằm tạo ra doanh số cao. Những thông tin nào sẽ hữu ích để đưa ra đề xuất như vậy? Sau đây là một số câu hỏi quan trọng cần giải quyết:

1. *Có mối quan hệ giữa ngân sách quảng cáo và doanh số không?* Mục tiêu đầu tiên là xác định dữ liệu có cung cấp bằng chứng về association giữa chi tiêu quảng cáo và doanh số hay không. Nếu bằng chứng yếu, người ta có thể lập luận rằng không nên chi tiền cho quảng cáo!
2. *Mối quan hệ giữa ngân sách quảng cáo và doanh số mạnh đến đâu?* Giả sử quảng cáo và doanh số có quan hệ với nhau, ta muốn biết

độ mạnh của mối quan hệ ấy. Biết ngân sách quảng cáo có cung cấp nhiều thông tin về doanh số sản phẩm không?

3. *Những phương tiện nào liên hệ với doanh số?* Cả ba phương tiện – **TV**, **radio** và **newspaper** – đều liên hệ với doanh số, hay chỉ một hoặc hai phương tiện có liên hệ? Để trả lời, ta phải tách riêng contribution của từng phương tiện đối với doanh số khi đã chi tiền cho cả ba.
4. *Mức độ association giữa từng phương tiện và doanh số lớn đến đâu?* Với mỗi đô la chi cho quảng cáo trên một phương tiện cụ thể, doanh số sẽ tăng bao nhiêu? Ta có thể dự đoán mức tăng này chính xác đến đâu?
5. *Ta có thể dự đoán doanh số tương lai chính xác đến đâu?* Với một mức chi quảng cáo **TV**, **radio** hoặc **newspaper** đã cho, dự đoán doanh số là bao nhiêu và dự đoán ấy chính xác đến đâu?
6. *Mối quan hệ có tuyến tính không?* Nếu chi tiêu quảng cáo trên các phương tiện khác nhau và doanh số có quan hệ gần như đường thẳng, linear regression là công cụ phù hợp. Nếu không, vẫn có thể transform predictor hoặc response để dùng linear regression.
7. *Có synergy giữa các phương tiện quảng cáo không?* Có thể việc chi 50.000 đô la cho quảng cáo truyền hình và 50.000 đô la cho radio đi kèm doanh số cao hơn so với dồn cả 100.000 đô la cho riêng truyền hình hoặc radio. Trong marketing, hiện tượng này được gọi là *synergy effect*; trong thống kê, nó được gọi là *interaction effect*.

synergy effect
interaction effect

Hóa ra linear regression có thể trả lời từng câu hỏi trên. Trước hết, chúng tôi sẽ thảo luận các câu hỏi trong bối cảnh tổng quát, rồi quay lại tình huống cụ thể này ở Mục 3.4.

3.1 Simple Linear Regression

Đúng như tên gọi, *simple linear regression* là một cách tiếp cận rất trực tiếp để dự đoán quantitative response Y dựa trên một predictor variable X . Phương pháp giả định X và Y có mối quan hệ gần tuyến tính. Về toán học, ta viết

simple linear regression

$$Y \approx \beta_0 + \beta_1 X. \quad (3.1)$$

Có thể đọc dấu “ $\approx$ ” là “được mô hình hóa gần đúng bởi”. Đôi khi, ta mô tả (3.1) bằng cách nói rằng ta regress Y trên X .

Chẳng hạn, X có thể biểu diễn quảng cáo **TV**, còn Y biểu diễn **sales**. Khi đó, ta có thể regress **sales** trên **TV** bằng cách fit mô hình

$$\text{sales} \approx \beta_0 + \beta_1 \times \text{TV}.$$

Trong Phương trình 3.1, β_0 và β_1 là hai hằng số chưa biết, lần lượt biểu diễn *intercept* và *slope* trong linear model. Gộp lại, β_0 và β_1 được gọi là các *model coefficient* hoặc *parameter*. Sau khi dùng training data để thu được

intercept
slope
model coefficient
parameter

các ước lượng $\hat{\beta}_0$ và $\hat{\beta}_1$ của model coefficient, ta có thể dự đoán doanh số tương lai với một giá trị quảng cáo **TV** cụ thể bằng cách tính

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x, \quad (3.2)$$

trong đó $\hat{y}$ là dự đoán của Y dựa trên $X = x$. Ở đây, dấu mũ “ $\hat{\cdot}$ ” ký hiệu giá trị ước lượng của một parameter hay coefficient chưa biết, hoặc giá trị dự đoán của response.

3.1.1 Ước lượng các coefficient

Trong thực tế, β_0 và β_1 chưa biết. Vì vậy, trước khi dùng (3.1) để dự đoán, ta phải dùng dữ liệu để ước lượng các coefficient. Gọi

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

là n cặp observation, mỗi cặp gồm một phép đo X và một phép đo Y . Trong ví dụ **Advertising**, dataset này gồm ngân sách quảng cáo **TV** và doanh số sản phẩm tại $n = 200$ thị trường khác nhau. (Nhớ rằng dữ liệu được biểu diễn trong Hình 2.1.) Mục tiêu là tìm các ước lượng coefficient $\hat{\beta}_0$ và $\hat{\beta}_1$ sao cho linear model (3.1) fit tốt dữ liệu sẵn có, tức $y_i \approx \hat{\beta}_0 + \hat{\beta}_1 x_i$ với $i = 1, \dots, n$. Nói cách khác, ta muốn tìm intercept $\hat{\beta}_0$ và slope $\hat{\beta}_1$ sao cho đường thẳng thu được gần nhất có thể với $n = 200$ điểm dữ liệu. Có nhiều cách đo độ gần. Tuy nhiên, cách phổ biến nhất là giảm thiểu tiêu chuẩn *least squares*; đó là cách tiếp cận được dùng trong chương này. Các cách khác sẽ được xem xét ở Chương 6.

Gọi $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ là dự đoán cho Y dựa trên giá trị thứ i của X . Khi đó, $e_i = y_i - \hat{y}_i$ là *residual* thứ i – chênh lệch giữa response quan sát thứ i và response thứ i được linear model dự đoán. Ta định nghĩa *residual sum of squares* (RSS) là

$$\text{RSS} = e_1^2 + e_2^2 + \dots + e_n^2,$$

hoặc tương đương,


$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2. \quad (3.3)$$

Cách tiếp cận least squares chọn $\hat{\beta}_0$ và $\hat{\beta}_1$ để giảm thiểu RSS. Dùng một số phép tính giải tích, có thể chứng minh rằng các giá trị giảm thiểu là

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \quad (3.4)$$

trong đó $\bar{y} \equiv n^{-1} \sum_{i=1}^n y_i$ và $\bar{x} \equiv n^{-1} \sum_{i=1}^n x_i$ là các sample mean. Nói cách khác, (3.4) xác định các least squares coefficient estimate cho simple linear regression.

Hình 3.1 biểu diễn simple linear regression fit cho dữ liệu **Advertising**, với $\hat{\beta}_0 = 7.03$ và $\hat{\beta}_1 = 0.0475$. Nói cách khác, theo phép xấp xỉ này, mỗi 1.000 đô la chi thêm cho quảng cáo **TV** đi kèm khoảng 47,5 đơn vị sản phẩm bán thêm. Trong Hình 3.2, chúng tôi tính RSS tại một số giá trị β_0 và β_1 , dùng dữ liệu advertising với **sales** là response và **TV** là predictor. Trong mỗi đồ thị, chấm đỏ biểu diễn cặp least squares estimate ($\hat{\beta}_0, \hat{\beta}_1$) từ (3.4). Rõ ràng, các giá trị này giảm thiểu RSS.



HÌNH 3.1. Với dữ liệu *Advertising*, hình biểu diễn *least squares fit* của phép regression *sales* trên *TV*. Kết quả fit được tìm bằng cách giảm thiểu *residual sum of squares*. Mỗi đoạn thẳng xám biểu diễn một *residual*. Trong trường hợp này, *linear fit* nắm bắt được bản chất của mối quan hệ, dù ước lượng quá cao trend ở phía trái đồ thị.

3.1.2 Đánh giá độ chính xác của các coefficient estimate

Nhớ lại từ (2.1), ta giả định mối quan hệ thực giữa X và Y có dạng $Y = f(X) + \epsilon$ với một hàm f chưa biết, trong đó ϵ là error term ngẫu nhiên có mean bằng không. Nếu xấp xỉ f bằng một hàm tuyến tính, ta viết

$$Y = \beta_0 + \beta_1 X + \epsilon. \quad (3.5)$$

Ở đây, β_0 là intercept, tức expected value của Y khi $X = 0$; còn β_1 là slope, tức mức tăng trung bình của Y đi kèm mức tăng một đơn vị của X . Error term gom tất cả những gì mô hình đơn giản này bỏ sót: mối quan hệ thực có lẽ không tuyến tính, có thể tồn tại những biến khác làm Y biến thiên, và có thể có measurement error. Ta thường giả định error term độc lập với X .


Mô hình (3.5) xác định *population regression line*, là phép xấp xỉ tuyến tính tốt nhất cho mối quan hệ thực giữa X và Y .¹ Các least squares regression coefficient estimate trong (3.4) xác định *least squares line*. Ở bên trái của Hình 3.3 biểu diễn hai đường này trong một ví dụ mô phỏng đơn giản. Chúng tôi tạo 100 giá trị X ngẫu nhiên và sinh 100 giá trị Y tương ứng từ mô hình

$$Y = 2 + 3X + \epsilon, \quad (3.6)$$

trong đó ϵ được sinh từ phân phối normal có mean bằng không. Đường đỏ ở ô trái Hình 3.3 biểu diễn mối quan hệ thực $f(X) = 2 + 3X$, còn đường xanh

population
regression line
least squares
line

¹Giả định tuyến tính thường là một working model hữu ích. Tuy nhiên, trái với điều nhiều sách giáo khoa có thể nói, hiếm khi ta tin mỗi quan hệ thực sự là tuyến tính.



HÌNH 3.2. Contour plot và đồ thị ba chiều của RSS trên dữ liệu *Advertising*, dùng *sales* làm response và *TV* làm predictor. Các chấm đỏ tương ứng với least squares estimate $\hat{\beta}_0$ và $\hat{\beta}_1$ trong (3.4).


làm là least squares estimate dựa trên dữ liệu quan sát. Với dữ liệu thực, mỗi quan hệ thực thường không được biết, nhưng ta luôn tính được least squares line bằng các coefficient estimate trong (3.4). Nói cách khác, trong ứng dụng thực tế, ta có một tập observations để tính least squares line; còn population regression line không quan sát được. Ở ô phải Hình 3.3, chúng tôi sinh mười dataset khác nhau từ mô hình (3.6) và vẽ mười least squares line tương ứng. Lưu ý rằng các dataset khác nhau được sinh từ cùng mô hình thực tạo ra các least squares line hơi khác nhau, nhưng population regression line không đổi.

Thoạt nhìn, khác biệt giữa population regression line và least squares line có thể có vẻ tinh tế và khó hiểu. Ta chỉ có một dataset, vậy việc hai đường khác nhau cùng mô tả quan hệ giữa predictor và response có nghĩa gì? Về căn bản, khái niệm hai đường này là phần mở rộng tự nhiên của cách tiếp cận thống kê tiêu chuẩn: dùng thông tin từ một sample để ước lượng đặc trưng của population lớn.

Chẳng hạn, giả sử ta muốn biết population mean μ của một biến ngẫu nhiên Y . Tiếc rằng μ chưa biết, nhưng ta có n observations $y_1, \dots, y_n$ từ Y để ước lượng μ . Một ước lượng hợp lý là $\hat{\mu} = \bar{y}$, trong đó $\bar{y} = n^{-1} \sum_{i=1}^n y_i$ là sample mean. Sample mean và population mean khác nhau, nhưng nhìn chung sample mean cung cấp một ước lượng tốt của population mean. Tương tự, các coefficient chưa biết β_0 và β_1 trong linear regression xác định population regression line. Ta tìm cách ước lượng chúng bằng $\hat{\beta}_0$ và $\hat{\beta}_1$ trong (3.4); các coefficient estimate này xác định least squares line.

Phép so sánh giữa linear regression và việc ước lượng mean của một biến ngẫu nhiên phù hợp dựa trên khái niệm *bias*. Nếu dùng sample mean $\hat{\mu}$ để ước lượng μ , ước lượng này là *unbiased*, theo nghĩa xét trung bình ta kỳ vọng $\hat{\mu}$ bằng μ . Chính xác thì điều này có nghĩa gì? Trên một tập observations $y_1, \dots, y_n$ cụ thể, $\hat{\mu}$ có thể ước lượng quá cao μ ; trên một tập khác, $\hat{\mu}$ có thể ước lượng quá thấp μ . Nhưng nếu có thể lấy trung bình của rất nhiều ước lượng μ thu được từ rất nhiều tập observations, trung bình đó

bias
unbiased



HÌNH 3.3. Một dataset mô phỏng. Trái: Đường đỏ biểu diễn mối quan hệ thực $f(X) = 2 + 3X$, gọi là *population regression line*. Đường xanh lam là *least squares line*, tức *least squares estimate* của $f(X)$ dựa trên dữ liệu quan sát màu đen. Phải: *Population regression line* vẫn được vẽ màu đỏ và *least squares line* màu xanh lam đậm. Mười *least squares line* màu xanh nhạt được tính từ mười tập observations ngẫu nhiên riêng biệt. Các *least squares line* khác nhau, nhưng xét trung bình, chúng khá gần *population regression line*.

sẽ đúng bằng μ . Vì thế, một unbiased estimator không ước lượng quá cao hay quá thấp parameter thực một cách có hệ thống. Tính unbiased cũng đúng với các least squares coefficient estimate trong (3.4): khi ước lượng β_0 và β_1 từ một dataset cụ thể, các ước lượng không hoàn toàn bằng β_0 và β_1 . Nhưng nếu có thể lấy trung bình các ước lượng từ rất nhiều dataset, giá trị trung bình sẽ chính xác. Thật vậy, ở phải của Hình 3.3 cho thấy trung bình của nhiều least squares line, mỗi đường được ước lượng từ một dataset riêng, khá gần population regression line thực.

Tiếp tục phép so sánh với việc ước lượng population mean μ của biến ngẫu nhiên Y . Một câu hỏi tự nhiên là: sample mean $\hat{\mu}$ ước lượng μ chính xác đến đâu? Ta đã xác định rằng trung bình của $\hat{\mu}$ trên nhiều dataset sẽ rất gần μ , nhưng một ước lượng $\hat{\mu}$ đơn lẻ có thể thấp hơn hoặc cao hơn μ đáng kể. Ước lượng đơn lẻ đó sẽ lệch bao xa? Nói chung, ta trả lời bằng cách tính *standard error* của $\hat{\mu}$, viết là $SE(\hat{\mu})$. Công thức quen thuộc là

standard error

$$\text{Var}(\hat{\mu}) = SE(\hat{\mu})^2 = \frac{\sigma^2}{n}, \quad (3.7)$$

trong đó σ là standard deviation của mỗi realization y_i của Y .² Nói gần đúng, standard error cho biết mức chênh lệch trung bình giữa ước lượng $\hat{\mu}$ và giá trị thực μ . Phương trình 3.7 cũng cho thấy độ lệch này giảm theo n : càng có nhiều observations, standard error của $\hat{\mu}$ càng nhỏ.

²Công thức này đúng với điều kiện n observations không correlated.

Tương tự, ta có thể hỏi $\hat{\beta}_0$ và $\hat{\beta}_1$ gần các giá trị thực β_0 và β_1 đến đâu. Để tính standard error của $\hat{\beta}_0$ và $\hat{\beta}_1$, ta dùng

$$\text{SE}(\hat{\beta}_0)^2 = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right], \quad \text{SE}(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad (3.8)$$

trong đó $\sigma^2 = \text{Var}(\epsilon)$. Để các công thức này hoàn toàn chính xác, ta cần giả định error ϵ_i của mỗi observation có cùng variance σ^2 và không correlated. Điều này rõ ràng không đúng trong Hình 3.1, nhưng công thức vẫn là một phép xấp xỉ tốt. Lưu ý rằng $\text{SE}(\hat{\beta}_1)$ nhỏ hơn khi các x_i phân tán rộng hơn; trực giác là khi đó ta có nhiều leverage hơn để ước lượng slope. Ta cũng thấy $\text{SE}(\hat{\beta}_0)$ sẽ bằng $\text{SE}(\hat{\mu})$ nếu $\bar{x} = 0$, khi đó $\hat{\beta}_0 = \bar{y}$. Nhìn chung, σ^2 chưa biết nhưng có thể được ước lượng từ dữ liệu. Ước lượng của σ được gọi là *residual standard error*, cho bởi $\text{RSE} = \sqrt{\text{RSS}/(n-2)}$. Nói chặt chẽ, khi σ^2 được ước lượng từ dữ liệu, ta nên viết $\widehat{\text{SE}}(\hat{\beta}_1)$ để thể hiện đã dùng một ước lượng; để ký hiệu đơn giản, chúng tôi bỏ dấu mũ bỏ sung này.

residual
standard error

Standard error có thể dùng để tính *confidence interval*. Confidence interval 95% được định nghĩa là một khoảng sao cho với xác suất 95%, khoảng đó chứa giá trị thực chưa biết của parameter. Cận dưới và cận trên của khoảng được tính từ sample dữ liệu. Confidence interval 95% có tính chất sau: nếu lấy sample lặp lại và dựng confidence interval cho từng sample, 95% số khoảng sẽ chứa giá trị thực chưa biết của parameter. Với linear regression, confidence interval 95% của β_1 có dạng xấp xỉ

confidence
interval

$$\hat{\beta}_1 \pm 2 \cdot \text{SE}(\hat{\beta}_1). \quad (3.9)$$

Nghĩa là có xấp xỉ 95% khả năng khoảng

$$[\hat{\beta}_1 - 2 \cdot \text{SE}(\hat{\beta}_1), \hat{\beta}_1 + 2 \cdot \text{SE}(\hat{\beta}_1)] \quad (3.10)$$

chứa giá trị thực của β_1 .³ Tương tự, confidence interval của β_0 có dạng xấp xỉ

$$\hat{\beta}_0 \pm 2 \cdot \text{SE}(\hat{\beta}_0). \quad (3.11)$$

Với dữ liệu advertising, confidence interval 95% của β_0 là [6.130, 7.935], còn của β_1 là [0.042, 0.053]. Vì vậy, ta kết luận rằng khi không quảng cáo, doanh số trung bình nằm đâu đó từ 6.130 đến 7.935 đơn vị. Hơn nữa, với mỗi 1.000 đô la tăng thêm cho quảng cáo truyền hình, doanh số trung bình tăng từ 42 đến 53 đơn vị.

Standard error cũng được dùng để thực hiện *hypothesis test* trên các coefficient. Hypothesis test phổ biến nhất kiểm tra *null hypothesis*

hypothesis
test
null
hypothesis

$$H_0 : \text{Không có mối quan hệ giữa } X \text{ và } Y \quad (3.12)$$

so với *alternative hypothesis*

alternative
hypothesis

$$H_a : \text{Có một mối quan hệ giữa } X \text{ và } Y. \quad (3.13)$$

³Đây là xấp xỉ vì nhiều lý do. Phương trình 3.10 dựa trên giả định error có phân phối Gaussian. Ngoài ra, hệ số 2 trước $\text{SE}(\hat{\beta}_1)$ thay đổi đôi chút theo số observations n . Chính xác hơn, thay vì 2, (3.10) phải dùng quantile 97,5% của phân phối t với $n-2$ degrees of freedom. Cách tính chính xác confidence interval 95% bằng R sẽ được trình bày sau trong chương.

BẢNG 3.1. Với dữ liệu *Advertising*, các coefficient của least squares model cho phép regression số đơn vị bán được trên ngân sách quảng cáo *TV*. Ngân sách *TV* tăng 1.000 đô la đi kèm doanh số tăng khoảng 50 đơn vị. Nhờ rằng biến *sales* tính bằng nghìn đơn vị, còn biến *TV* tính bằng nghìn đô la.

	Coefficient	Std. error	<i>t</i> -statistic	<i>p</i> -value
Intercept	7.0325	0.4578	15.36	< 0.0001
TV	0.0475	0.0027	17.67	< 0.0001

Về toán học, điều này tương ứng với kiểm tra $H_0 : \beta_1 = 0$ so với $H_a : \beta_1 \neq 0$, vì nếu $\beta_1 = 0$ thì mô hình (3.5) rút gọn thành $Y = \beta_0 + \epsilon$, và X không associated với Y . Để kiểm tra null hypothesis, ta cần xác định liệu ước lượng $\hat{\beta}_1$ có cách 0 đủ xa để có thể tin rằng β_1 khác 0 hay không. Xa đến đâu mới là đủ? Điều này phụ thuộc vào độ chính xác của $\hat{\beta}_1$, tức phụ thuộc vào $SE(\hat{\beta}_1)$. Nếu standard error nhỏ, ngay cả giá trị $\hat{\beta}_1$ tương đối nhỏ cũng có thể cung cấp bằng chứng mạnh rằng $\beta_1 \neq 0$, nên X và Y có quan hệ. Ngược lại, nếu standard error lớn, $|\hat{\beta}_1|$ phải lớn mới có thể bác bỏ null hypothesis. Trong thực tế, ta tính *t*-statistic

t-statistic

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)}, \quad (3.14)$$

đo số standard deviation từ $\hat{\beta}_1$ đến 0. Nếu thực sự không có quan hệ giữa X và Y , ta kỳ vọng (3.14) có phân phối t với $n - 2$ degrees of freedom. Phân phối t có dạng chuông và khi n lớn hơn khoảng 30, nó khá giống phân phối standard normal. Vì vậy, với giả định $\beta_1 = 0$, ta dễ dàng tính xác suất quan sát được một giá trị có độ lớn tuyệt đối bằng hoặc vượt $|t|$. Xác suất này được gọi là *p-value*. Nói gần đúng, *p*-value nhỏ cho biết nếu không có association thực giữa predictor và response, khả năng tình cờ quan sát được một association mạnh như vậy là thấp. Vì thế, nếu thấy *p*-value nhỏ, ta có thể suy ra predictor và response có association. Ta bác bỏ null hypothesis, tức tuyên bố X và Y có quan hệ, nếu *p*-value đủ nhỏ. Các ngưỡng *p*-value thường dùng là 5% hoặc 1%, dù chủ đề này sẽ được khảo sát kỹ hơn trong Chương 13. Khi $n = 30$, chúng tương ứng với *t*-statistic (3.14) xấp xỉ 2 và 2,75.

p-value

Bảng 3.1 trình bày chi tiết least squares model cho phép regression số đơn vị bán được trên ngân sách quảng cáo *TV* của dữ liệu *Advertising*. Lưu ý rằng các coefficient $\hat{\beta}_0$ và $\hat{\beta}_1$ rất lớn so với standard error tương ứng, nên *t*-statistic cũng lớn; nếu H_0 đúng, xác suất thấy các giá trị như vậy gần như bằng không. Vì thế, ta có thể kết luận $\beta_0 \neq 0$ và $\beta_1 \neq 0$.⁴

3.1.3 Đánh giá độ chính xác của mô hình

Sau khi bác bỏ null hypothesis (3.12) để ủng hộ alternative hypothesis (3.13), ta tự nhiên muốn định lượng mức độ mô hình fit dữ liệu. Chất

⁴Trong Bảng 3.1, *p*-value nhỏ của intercept cho phép bác bỏ null hypothesis $\beta_0 = 0$, còn *p*-value nhỏ của *TV* cho phép bác bỏ null hypothesis $\beta_1 = 0$. Bác bỏ giả thuyết sau cho phép kết luận *TV* và *sales* có quan hệ. Bác bỏ giả thuyết trước cho phép kết luận rằng khi không chỉ cho *TV*, doanh số khác không.

BẢNG 3.2. Với dữ liệu *Advertising*, thông tin bổ sung về least squares model cho phép regression số đơn vị bán được trên ngân sách quảng cáo *TV*.

Quantity	Value
Residual standard error	3.26
R^2	0.612
F -statistic	312.1

lượng của linear regression fit thường được đánh giá bằng hai đại lượng liên quan: residual standard error (RSE) và thống kê R^2 .

Bảng 3.2 trình bày RSE, thống kê R^2 , và F -statistic (sẽ được mô tả ở Mục 3.2.2) cho linear regression của số đơn vị bán được trên ngân sách quảng cáo *TV*.

Residual Standard Error

Nhớ lại mô hình (3.5): mỗi observation có một error term ϵ . Do các error term này tồn tại, ngay cả khi biết regression line thực, tức biết β_0 và β_1 , ta vẫn không thể dự đoán hoàn hảo Y từ X . RSE là một ước lượng của standard deviation của ϵ . Nói gần đúng, nó là mức trung bình mà response lệch khỏi regression line thực. RSE được tính bằng

$$\text{RSE} = \sqrt{\frac{1}{n-2} \text{RSS}} = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3.15)$$

Lưu ý rằng RSS đã được định nghĩa ở Mục 3.1.1, với công thức

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (3.16)$$

Với dữ liệu advertising, kết quả linear regression trong Bảng 3.2 cho RSE bằng 3,26. Nói cách khác, doanh số thực tại mỗi thị trường lệch khỏi regression line thực trung bình khoảng 3.260 đơn vị. Một cách diễn giải khác: ngay cả khi mô hình đúng và biết chính xác các giá trị chưa biết β_0, β_1 , mọi dự đoán doanh số dựa trên quảng cáo *TV* vẫn lệch trung bình khoảng 3.260 đơn vị. Tất nhiên, sai số dự đoán 3.260 đơn vị có chấp nhận được hay không phụ thuộc vào bối cảnh. Trong dữ liệu advertising, mean doanh số trên mọi thị trường xấp xỉ 14.000 đơn vị, nên phần trăm sai số là $3.260/14.000 = 23\%$.

RSE được xem là thước đo mức độ mô hình (3.5) không fit dữ liệu. Nếu các dự đoán từ mô hình rất gần outcome thực, tức $\hat{y}_i \approx y_i$ với $i = 1, \dots, n$, thì (3.15) nhỏ và ta có thể kết luận mô hình fit dữ liệu rất tốt. Ngược lại, nếu một hay nhiều $\hat{y}_i$ rất xa y_i , RSE có thể khá lớn, cho thấy mô hình không fit tốt dữ liệu.

Thống kê R^2

RSE cung cấp thước đo tuyệt đối về mức độ mô hình (3.5) không fit dữ liệu. Nhưng vì được đo theo đơn vị của Y , không phải lúc nào cũng rõ RSE

như thế nào là tốt. Thống kê R^2 cung cấp một thước đo khác. Nó có dạng một tỷ lệ – proportion of variance explained – nên luôn nhận giá trị từ 0 đến 1 và không phụ thuộc vào scale của Y . Để tính R^2 , ta dùng

$$R^2 = \frac{\text{TSS} - \text{RSS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}, \quad (3.17)$$

trong đó $\text{TSS} = \sum_i (y_i - \bar{y})^2$ là *total sum of squares*, còn RSS được định nghĩa trong (3.16). TSS đo total variance trong response Y , có thể xem là lượng variability vốn có của response trước khi thực hiện regression. Ngược lại, RSS đo variability còn chưa được giải thích sau regression. Vì thế, $\text{TSS} - \text{RSS}$ đo variability trong response được giải thích, hay loại bỏ, nhờ regression; còn R^2 đo tỷ lệ variability trong Y có thể được giải thích bằng X . R^2 gần 1 cho thấy regression giải thích phần lớn variability của response. Giá trị gần 0 cho thấy regression không giải thích nhiều variability; điều này có thể xảy ra vì linear model sai, error variance σ^2 cao, hoặc cả hai. Trong Bảng 3.2, $R^2 = 0.61$, nên chưa đến hai phần ba variability trong **sales** được giải thích bằng linear regression trên **TV**.

So với RSE (3.15), thống kê R^2 (3.17) có lợi thế về diễn giải vì luôn nằm từ 0 đến 1. Tuy nhiên, xác định thế nào là một giá trị R^2 tốt vẫn có thể khó và nói chung phụ thuộc vào ứng dụng. Chẳng hạn, trong một số bài toán vật lý, ta có thể biết dữ liệu thực sự đến từ linear model với residual error nhỏ. Khi đó, ta kỳ vọng R^2 cực gần 1; một giá trị nhỏ hơn đáng kể có thể báo hiệu vấn đề nghiêm trọng trong thí nghiệm tạo dữ liệu. Trái lại, trong các ứng dụng điển hình của sinh học, tâm lý học, marketing và nhiều lĩnh vực khác, linear model (3.5) tốt nhất cũng chỉ là phép xấp xỉ rất thô cho dữ liệu, còn residual error do những yếu tố không đo được khác thường rất lớn. Trong bối cảnh này, ta kỳ vọng predictor chỉ giải thích một tỷ lệ nhỏ variance của response; R^2 thấp hơn nhiều so với 0,1 có thể thực tế hơn.

Thống kê R^2 đo mối quan hệ tuyến tính giữa X và Y . Nhớ rằng *correlation*, được định nghĩa là

$$\text{Cor}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}, \quad (3.18)$$

cũng là thước đo mối quan hệ tuyến tính giữa X và Y .⁵ Điều này gợi ý có thể dùng $r = \text{Cor}(X, Y)$ thay cho R^2 để đánh giá linear model fit. Thật vậy, có thể chỉ ra rằng trong bối cảnh simple linear regression, $R^2 = r^2$. Nói cách khác, bình phương correlation và thống kê R^2 là một. Tuy nhiên, ở mục tiếp theo, ta thảo luận multiple linear regression, dùng đồng thời nhiều predictor để dự đoán response. Khái niệm correlation giữa các predictor và response không tự động mở rộng sang bối cảnh này, vì correlation định lượng association giữa một cặp biến duy nhất chứ không phải một số lượng biến lớn hơn. Ta sẽ thấy R^2 đảm nhiệm vai trò đó.

⁵Về phải của (3.18) thực ra là sample correlation; vì thế, viết $\widehat{\text{Cor}}(X, Y)$ sẽ chính xác hơn. Tuy nhiên, để ký hiệu đơn giản, chúng tôi bỏ dấu mũ.

BẢNG 3.3. Các simple linear regression model khác cho dữ liệu *Advertising*. Coefficient của mô hình dự đoán số đơn vị bán được theo ngân sách quảng cáo *radio* (trên) và *newspaper* (dưới). Chi thêm 1.000 đô la cho *radio* đi kèm doanh số trung bình tăng khoảng 203 đơn vị; cùng mức tăng cho *newspaper* đi kèm doanh số tăng khoảng 55 đơn vị.

Simple regression of <i>sales</i> on <i>radio</i>				
	Coefficient	Std. error	<i>t</i> -statistic	<i>p</i> -value
Intercept	9.312	0.563	16.54	< 0.0001
radio	0.203	0.020	9.92	< 0.0001
Simple regression of <i>sales</i> on <i>newspaper</i>				
Intercept	12.351	0.621	19.88	< 0.0001
newspaper	0.055	0.017	3.30	0.00115

3.2 Multiple Linear Regression

Simple linear regression hữu ích khi dự đoán response dựa trên một predictor variable. Nhưng trong thực tế, ta thường có nhiều hơn một predictor. Chẳng hạn, với dữ liệu *Advertising*, ta đã khảo sát mối quan hệ giữa *sales* và quảng cáo *TV*. Ta còn có dữ liệu về số tiền chi cho quảng cáo *radio* và *newspaper*, và có thể muốn biết hai phương tiện này có associated với doanh số hay không. Làm thế nào mở rộng phân tích dữ liệu advertising để chứa thêm hai predictor này?

Một lựa chọn là chạy ba simple linear regression riêng biệt, mỗi mô hình dùng một phương tiện quảng cáo khác nhau làm predictor. Chẳng hạn, ta có thể fit simple linear regression để dự đoán *sales* dựa trên số tiền chi cho quảng cáo *radio*. Kết quả nằm ở phần trên Bảng 3.3. Ta thấy chi thêm 1.000 đô la cho quảng cáo radio đi kèm doanh số tăng khoảng 203 đơn vị. Phần dưới Bảng 3.3 chứa các least squares coefficient của simple linear regression giữa *sales* và ngân sách *newspaper*. Ngân sách quảng cáo newspaper tăng 1.000 đô la đi kèm doanh số tăng khoảng 55 đơn vị.

Tuy nhiên, cách fit một simple linear regression model riêng cho từng predictor chưa hoàn toàn thỏa đáng. Thứ nhất, không rõ phải đưa ra một dự đoán *sales* duy nhất như thế nào khi biết ngân sách của cả ba phương tiện, vì mỗi ngân sách gắn với một regression equation riêng. Thứ hai, mỗi regression equation bỏ qua hai phương tiện còn lại khi ước lượng regression coefficient. Ta sẽ sớm thấy rằng nếu ngân sách các phương tiện correlated với nhau trên 200 thị trường trong dataset, điều này có thể dẫn đến những ước lượng rất sai lệch về association giữa ngân sách từng phương tiện và doanh số.

Thay vì fit một simple linear regression model riêng cho từng predictor, cách tốt hơn là mở rộng simple linear regression model (3.5) để trực tiếp chứa nhiều predictor. Ta làm điều này bằng cách gán một slope coefficient riêng cho từng predictor trong cùng một mô hình. Tổng quát, giả sử ta có p predictor khác nhau. Khi đó, multiple linear regression model có dạng

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon, \quad (3.19)$$

BẢNG 3.4. Với dữ liệu *Advertising*, các least squares coefficient estimate của multiple linear regression giữa số đơn vị bán được với ngân sách quảng cáo *TV*, *radio* và *newspaper*.

	Coefficient	Std. error	t-statistic	p-value
Intercept	2.939	0.3119	9.42	< 0.0001
TV	0.046	0.0014	32.81	< 0.0001
radio	0.189	0.0086	21.89	< 0.0001
newspaper	-0.001	0.0059	-0.18	0.8599

trong đó X_j là predictor thứ j , còn β_j định lượng association giữa biến đó và response. Ta diễn giải β_j là ảnh hưởng trung bình lên Y khi X_j tăng một đơn vị, trong khi giữ cố định tất cả predictor khác. Trong ví dụ advertising, (3.19) trở thành

$$\text{sales} = \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times \text{newspaper} + \epsilon. \quad (3.20)$$

3.2.1 Ước lượng regression coefficient

Giống bối cảnh simple linear regression, các regression coefficient $\beta_0, \beta_1, \dots, \beta_p$ trong (3.19) chưa biết và phải được ước lượng. Khi có các ước lượng $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$, ta dự đoán bằng


$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p. \quad (3.21)$$

Các parameter được ước lượng bằng cùng cách tiếp cận least squares đã gặp trong simple linear regression. Ta chọn $\beta_0, \beta_1, \dots, \beta_p$ để giảm thiểu tổng bình phương residual

$$\begin{aligned} \text{RSS} &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip})^2. \end{aligned} \quad (3.22)$$

Các giá trị $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ giảm thiểu (3.22) là multiple least squares regression coefficient estimate. Khác với simple linear regression estimate trong (3.4), multiple regression coefficient estimate có dạng khá phức tạp và dễ biểu diễn nhất bằng matrix algebra. Vì vậy, chúng tôi không trình bày công thức ở đây. Mọi package thống kê đều có thể tính các coefficient estimate này; phần sau của chương sẽ chỉ ra cách thực hiện trong R. Hình 3.4 minh họa least squares fit cho một toy dataset có $p = 2$ predictor.

Bảng 3.4 trình bày multiple regression coefficient estimate khi dùng ngân sách quảng cáo *TV*, *radio* và *newspaper* để dự đoán doanh số sản phẩm trong dữ liệu *Advertising*. Ta diễn giải kết quả như sau: với ngân sách *TV* và *newspaper* không đổi, chỉ thêm 1.000 đô la cho quảng cáo *radio* đi kèm khoảng 189 đơn vị doanh số tăng thêm. So sánh những coefficient estimate này với Bảng 3.1 và Bảng 3.3, ta thấy multiple regression



HÌNH 3.4. Trong không gian ba chiều với hai predictor và một response, least squares regression line trở thành một mặt phẳng. Mặt phẳng được chọn để giảm thiểu tổng bình phương khoảng cách theo phương thẳng đứng giữa mỗi observation, biểu diễn bằng màu đỏ, và mặt phẳng.

BẢNG 3.5. Correlation matrix của *TV*, *radio*, *newspaper* và *sales* trong dữ liệu *Advertising*.

	TV	radio	newspaper	sales
TV	1.0000	0.0548	0.0567	0.7822
radio		1.0000	0.3541	0.5762
newspaper			1.0000	0.2283
sales				1.0000

coefficient estimate của **TV** và **radio** khá giống simple linear regression coefficient estimate. Tuy nhiên, dù coefficient estimate của **newspaper** trong Bảng 3.3 khác không có ý nghĩa thống kê, coefficient estimate của **newspaper** trong multiple regression model lại gần 0, và p -value tương ứng không còn significant, vào khoảng 0,86. Điều này minh họa rằng simple regression coefficient và multiple regression coefficient có thể khá khác nhau. Khác biệt bắt nguồn từ việc trong simple regression, slope biểu diễn mức tăng trung bình của doanh số sản phẩm đi kèm mức tăng 1.000 đô la cho quảng cáo newspaper, bỏ qua các predictor khác như TV và radio. Trái lại, trong multiple regression, coefficient của newspaper biểu diễn mức tăng trung bình của doanh số đi kèm mức tăng 1.000 đô la chỉ cho newspaper trong khi giữ TV và radio cố định.

Việc multiple regression cho rằng **sales** không có quan hệ với **newspaper**, trong khi simple linear regression lại gợi ý điều ngược lại, có hợp lý không? Thực ra là có. Xét correlation matrix của ba predictor variable và response variable trong Bảng 3.5. Lưu ý correlation giữa **radio** và **newspaper** là 0,35.

Điều này cho thấy các thị trường chi nhiều cho quảng cáo newspaper thường cũng chi nhiều cho radio. Bây giờ, giả sử multiple regression là đúng: quảng cáo newspaper không associated với doanh số, còn quảng cáo radio thì có. Khi đó, ở những thị trường chi nhiều hơn cho radio, doanh số có xu hướng cao hơn; như correlation matrix cho thấy, tại chính những thị trường này ta cũng thường chi nhiều hơn cho newspaper. Vì vậy, trong simple linear regression chỉ xét **sales** theo **newspaper**, ta quan sát thấy giá trị newspaper cao thường đi kèm sales cao, dù quảng cáo newspaper không trực tiếp associated với sales. Như vậy, newspaper là một surrogate cho radio; newspaper được “ghi công” cho association giữa radio và sales.

Kết quả hơi trái trực giác này rất phổ biến trong đời thực. Xét một ví dụ phi lý để minh họa. Regress số vụ cá mập tấn công trên doanh số kem bằng dữ liệu thu thập tại một cộng đồng ven biển theo thời gian sẽ cho thấy mối quan hệ dương, tương tự mối quan hệ giữa sales và newspaper. Dĩ nhiên, chưa ai đề xuất cấm kem ở bãi biển để giảm cá mập tấn công. Thực tế là nhiệt độ cao khiến nhiều người đến bãi biển hơn, từ đó làm tăng cả doanh số kem lẫn số vụ cá mập tấn công. Multiple regression số vụ cá mập tấn công trên doanh số kem và nhiệt độ cho thấy, đúng như trực giác, doanh số kem không còn là predictor significant sau khi điều chỉnh theo nhiệt độ.

3.2.2 Một số câu hỏi quan trọng

Khi thực hiện multiple linear regression, ta thường quan tâm đến một số câu hỏi quan trọng:

1. Có ít nhất một predictor $X_1, X_2, \dots, X_p$ hữu ích để dự đoán response không?
2. Tất cả predictor đều giúp giải thích Y , hay chỉ một tập con là hữu ích?
3. Mô hình fit dữ liệu tốt đến đâu?
4. Với một tập giá trị predictor, nên dự đoán response bằng giá trị nào, và dự đoán chính xác đến đâu?

Sau đây, ta lần lượt giải quyết từng câu hỏi.

Một: Response và các predictor có quan hệ không?

Nhớ lại trong simple linear regression, để xác định response và predictor có quan hệ hay không, ta chỉ cần kiểm tra $\beta_1 = 0$. Trong multiple regression với p predictor, ta cần hỏi mọi regression coefficient có đồng thời bằng 0 hay không, tức $\beta_1 = \beta_2 = \dots = \beta_p = 0$. Giống simple linear regression, ta dùng hypothesis test để trả lời. Null hypothesis là

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0,$$

so với alternative

$$H_a : \text{có ít nhất một } \beta_j \text{ khác } 0.$$

Hypothesis test này được thực hiện bằng cách tính *F-statistic*

F-statistic

BẢNG 3.6. Thông tin bổ sung về least squares model giữa số đơn vị bán được với ngân sách quảng cáo TV, newspaper và radio trong dữ liệu Advertising. Thông tin khác về mô hình nằm trong Bảng 3.4.

Quantity	Value
Residual standard error	1.69
R^2	0.897
F -statistic	570

$$F = \frac{(\text{TSS} - \text{RSS})/p}{\text{RSS}/(n - p - 1)}, \quad (3.23)$$

trong đó, giống simple linear regression, $\text{TSS} = \sum_i (y_i - \bar{y})^2$ và $\text{RSS} = \sum_i (y_i - \hat{y}_i)^2$. Nếu các giả định của linear model đúng, có thể chỉ ra rằng

$$E\{\text{RSS}/(n - p - 1)\} = \sigma^2,$$

và với điều kiện H_0 đúng,

$$E\{(\text{TSS} - \text{RSS})/p\} = \sigma^2.$$

Vì thế, khi response và các predictor không có quan hệ, ta kỳ vọng F -statistic gần 1. Trái lại, nếu H_a đúng thì $E\{(\text{TSS} - \text{RSS})/p\} > \sigma^2$, nên ta kỳ vọng $F > 1$.

F -statistic của multiple linear regression model giữa sales với radio, TV và newspaper được trình bày trong Bảng 3.6. Trong ví dụ này, F -statistic bằng 570. Vì giá trị này lớn hơn 1 rất nhiều, nó cung cấp bằng chứng thuyết phục chống lại null hypothesis H_0 . Nói cách khác, F -statistic lớn gợi ý rằng ít nhất một phương tiện quảng cáo phải liên hệ với doanh số. Nhưng nếu F -statistic gần 1 hơn thì sao? F -statistic phải lớn đến đâu mới có thể bác bỏ H_0 và kết luận tồn tại mối quan hệ? Hóa ra câu trả lời phụ thuộc vào n và p . Khi n lớn, F -statistic chỉ lớn hơn 1 một chút vẫn có thể cung cấp bằng chứng chống lại H_0 . Ngược lại, nếu n nhỏ, cần F -statistic lớn hơn để bác bỏ H_0 . Khi H_0 đúng và error ϵ_i có phân phối normal, F -statistic tuân theo phân phối F .⁶ Với giá trị n, p bất kỳ, software thống kê có thể dùng phân phối này để tính p -value của F -statistic. Dựa vào p -value, ta xác định có bác bỏ H_0 hay không. Với dữ liệu advertising, p -value gần với F -statistic trong Bảng 3.6 gần như bằng 0, nên có bằng chứng cực mạnh rằng ít nhất một phương tiện associated với doanh số tăng.

Trong (3.23), ta kiểm tra H_0 rằng tất cả coefficient đều bằng 0. Đôi khi, ta muốn kiểm tra một tập con gồm q coefficient bằng 0. Điều này tương ứng với null hypothesis

$$H_0 : \beta_{p-q+1} = \beta_{p-q+2} = \cdots = \beta_p = 0,$$

trong đó để tiện trình bày, ta đặt các biến được chọn để loại bỏ ở cuối danh sách. Khi đó, ta fit một mô hình thứ hai dùng tất cả các biến trừ q biến

⁶Ngay cả khi error không có phân phối normal, F -statistic vẫn xấp xỉ phân phối F với điều kiện cỡ mẫu n lớn.

cuối. Giả sử residual sum of squares của mô hình đó là RSS_0 . F -statistic phù hợp là

$$F = \frac{(RSS_0 - RSS)/q}{RSS/(n - p - 1)}. \quad (3.24)$$

Lưu ý rằng trong Bảng 3.4, mỗi predictor riêng lẻ có một t -statistic và một p -value. Chúng cho biết từng predictor có liên hệ với response hay không, sau khi điều chỉnh theo các predictor khác. Hóa ra mỗi kiểm tra đó hoàn toàn tương đương⁷ với F -test loại một biến đó khỏi mô hình trong khi giữ nguyên tất cả biến khác, tức $q = 1$ trong (3.24). Vì vậy, nó báo cáo partial effect của việc thêm biến đó vào mô hình. Chẳng hạn, như đã thảo luận, các p -value cho thấy **TV** và **radio** liên hệ với **sales**, nhưng không có bằng chứng **newspaper** associated với **sales** khi giữ **TV**, **radio** cố định.

Khi đã có p -value riêng của từng biến, tại sao còn phải xem F -statistic tổng thể? Có vẻ nếu bất kỳ p -value riêng lẻ nào rất nhỏ thì ít nhất một predictor phải liên hệ với response. Tuy nhiên, lập luận này có sai sót, đặc biệt khi số predictor p lớn.

Chẳng hạn, xét ví dụ có $p = 100$ và $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ đúng, tức không biến nào thực sự associated với response. Trong tình huống này, do ngẫu nhiên, khoảng 5% số p -value gần với từng biến sẽ nhỏ hơn 0,05. Nói cách khác, ta kỳ vọng thấy xấp xỉ năm p -value nhỏ ngay cả khi predictor và response không có association thực.⁸ Thật vậy, khả năng ta tình cờ quan sát được ít nhất một p -value dưới 0,05 là cao. Vì thế, nếu dùng các t -statistic riêng lẻ và p -value tương ứng để quyết định có association giữa các biến và response hay không, khả năng kết luận sai là rất cao. F -statistic không gặp vấn đề này vì nó điều chỉnh theo số predictor. Do đó, nếu H_0 đúng, xác suất F -statistic tạo ra p -value dưới 0,05 chỉ là 5%, bất kể số predictor hay số observations.

Cách dùng F -statistic để kiểm tra association bất kỳ giữa các predictor và response hoạt động khi p tương đối nhỏ, và chắc chắn nhỏ so với n . Nhưng đôi khi ta có số biến rất lớn. Nếu $p > n$, số coefficient β_j cần ước lượng nhiều hơn số observations dùng để ước lượng chúng. Khi đó, ta thậm chí không thể fit multiple linear regression model bằng least squares, nên không thể dùng F -statistic hay phần lớn khái niệm đã gặp đến đây trong chương. Khi p lớn, có thể dùng một số cách tiếp cận được trình bày ở mục tiếp theo, chẳng hạn forward selection. Bối cảnh *high-dimensional* này được thảo luận chi tiết hơn trong Chương 6.

high-
dimensional

Hai: Quyết định các biến quan trọng

Như đã thảo luận, bước đầu tiên trong phân tích multiple regression là tính F -statistic và xem p -value tương ứng. Nếu dựa vào p -value ta kết luận ít nhất một predictor liên hệ với response, câu hỏi tự nhiên tiếp theo là predictor nào! Ta có thể xem p -value riêng lẻ như trong Bảng 3.4, nhưng như đã thảo luận, và sẽ được khảo sát thêm ở Chương 13, nếu p lớn thì khả năng có một số false discovery là cao.

Có thể tất cả predictor đều associated với response, nhưng thường response chỉ associated với một tập con predictor. Nhiệm vụ xác định

⁷Bình phương của mỗi t -statistic chính là F -statistic tương ứng.

⁸Điều này liên hệ với khái niệm quan trọng multiple testing, trọng tâm của Chương 13.

những predictor nào associated với response để fit một mô hình duy nhất chỉ chứa các predictor đó được gọi là *variable selection*. Bài toán variable selection được nghiên cứu kỹ ở Chương 6; ở đây, chúng tôi chỉ phác thảo một số cách tiếp cận cổ điển.

variable
selection

Lý tưởng nhất, ta muốn thực hiện variable selection bằng cách thử nhiều mô hình khác nhau, mỗi mô hình chứa một tập con predictor khác nhau. Chẳng hạn, nếu $p = 2$, ta có thể xét bốn mô hình: (1) không chứa biến nào; (2) chỉ chứa X_1 ; (3) chỉ chứa X_2 ; và (4) chứa cả X_1, X_2 . Sau đó, ta chọn mô hình tốt nhất trong số đã xét. Làm sao xác định mô hình nào tốt nhất? Có thể dùng nhiều thống kê để đánh giá chất lượng mô hình, gồm *Mallow's C_p* , *Akaike information criterion (AIC)*, *Bayesian information criterion (BIC)*, và *adjusted R^2* . Các đại lượng này được thảo luận chi tiết hơn ở Chương 6. Ta cũng có thể xác định mô hình tốt nhất bằng cách vẽ các output của mô hình, như residual, để tìm pattern.

Mallow's C_p
Akaike
information
criterion
Bayesian
information
criterion
adjusted R^2

Tiếc rằng có tổng cộng 2^p mô hình chứa các tập con của p biến. Nghĩa là ngay cả với p vừa phải, việc thử mọi tập con predictor cũng bất khả thi. Chẳng hạn, nếu $p = 2$, có $2^2 = 4$ mô hình cần xét. Nhưng nếu $p = 30$, ta phải xét $2^{30} = 1.073.741.824$ mô hình! Điều này không thực tế. Vì vậy, trừ khi p rất nhỏ, ta không thể xét tất cả 2^p mô hình mà cần một cách tiếp cận tự động, hiệu quả để chọn một tập mô hình nhỏ hơn. Có ba cách tiếp cận cổ điển:

- *Forward selection.* Ta bắt đầu với *null model*, tức mô hình có intercept nhưng không có predictor. Sau đó, ta fit p simple linear regression và thêm vào null model biến tạo ra RSS thấp nhất. Tiếp theo, thêm biến tạo ra RSS thấp nhất cho mô hình mới có hai biến. Tiếp tục cho đến khi thỏa một stopping rule nào đó.
- *Backward selection.* Ta bắt đầu với tất cả biến trong mô hình và loại biến có p -value lớn nhất, tức biến ít statistically significant nhất. Fit mô hình mới có $p - 1$ biến rồi loại biến có p -value lớn nhất. Tiếp tục đến khi đạt stopping rule; chẳng hạn, dừng khi mọi biến còn lại có p -value thấp hơn một threshold.
- *Mixed selection.* Đây là sự kết hợp giữa forward và backward selection. Ta bắt đầu không có biến nào trong mô hình; giống forward selection, thêm biến tạo fit tốt nhất và tiếp tục thêm từng biến. Như đã thấy với ví dụ **Advertising**, p -value của biến có thể tăng khi thêm predictor mới. Vì thế, nếu tại bất kỳ thời điểm nào p -value của một biến trong mô hình vượt threshold, ta loại biến đó. Tiếp tục các bước tiến và lùi cho đến khi mọi biến trong mô hình đều có p -value đủ thấp, còn mọi biến ngoài mô hình sẽ có p -value lớn nếu được thêm vào.

Forward
selection
null model

Backward
selection

Mixed
selection

Backward selection không thể dùng nếu $p > n$, còn forward selection luôn dùng được. Forward selection là một greedy approach và có thể sớm đưa vào những biến về sau trở nên redundant. Mixed selection có thể khắc phục điều này.

Ba: Model fit

Hai thước đo bằng số phổ biến nhất của model fit là RSE và R^2 , tức tỷ lệ variance được giải thích. Chúng được tính và diễn giải giống như với simple linear regression.

Nhớ rằng trong simple regression, R^2 là bình phương correlation giữa response và biến. Trong multiple linear regression, nó bằng $\text{Cor}(Y, \hat{Y})^2$, tức bình phương correlation giữa response và linear model đã fit. Thực ra, một tính chất của linear model đã fit là nó tối đa hóa correlation này trong mọi linear model có thể có.

R^2 gần 1 cho thấy mô hình giải thích phần lớn variance của response variable. Chẳng hạn, trong Bảng 3.6, mô hình dùng cả ba phương tiện quảng cáo để dự đoán sales có $R^2 = 0.8972$. Mặt khác, mô hình chỉ dùng TV và radio có $R^2 = 0.89719$. Nói cách khác, thêm quảng cáo newspaper vào mô hình đã có TV, radio chỉ làm R^2 tăng rất ít, dù trước đó ta thấy p -value của newspaper trong Bảng 3.4 không significant. Hóa ra R^2 luôn tăng khi thêm biến vào mô hình, ngay cả khi những biến ấy chỉ associated yếu với response. Nguyên nhân là thêm biến luôn làm residual sum of squares trên training data giảm, dù chưa chắc giảm trên test data. Vì R^2 cũng được tính trên training data, nó bắt buộc phải tăng. Việc thêm newspaper vào mô hình chỉ có TV và radio làm R^2 tăng rất nhỏ cung cấp thêm bằng chứng rằng có thể loại newspaper. Về cơ bản, newspaper không thực sự cải thiện model fit trên training sample; đưa nó vào có thể gây kết quả kém trên independent test sample do overfitting.


Trái lại, mô hình chỉ chứa TV có $R^2 = 0.61$ (Bảng 3.2). Thêm radio làm R^2 cải thiện đáng kể. Điều này cho thấy mô hình dùng chỉ tiêu TV, radio để dự đoán sales tốt hơn đáng kể mô hình chỉ dùng quảng cáo TV. Ta có thể định lượng thêm mức cải thiện bằng cách xem p -value của coefficient radio trong mô hình chỉ chứa TV và radio.

Mô hình chỉ có TV, radio làm predictor có RSE bằng 1,681, còn mô hình có thêm newspaper có RSE bằng 1,686 (Bảng 3.6). Ngược lại, mô hình chỉ chứa TV có RSE bằng 3,26 (Bảng 3.2). Điều này xác nhận kết luận trước đó: mô hình dùng chỉ tiêu TV và radio để dự đoán sales chính xác hơn nhiều trên training data so với mô hình chỉ dùng TV. Hơn nữa, khi TV và radio đã là predictor, không có lý do gì thêm chỉ tiêu newspaper vào mô hình. Bạn đọc tinh ý có thể thắc mắc tại sao RSE lại tăng khi thêm newspaper, dù RSS bắt buộc giảm. Nói chung,

$$\text{RSE} = \sqrt{\frac{1}{n - p - 1} \text{RSS}}, \quad (3.25)$$

và công thức này rút gọn thành (3.15) cho simple linear regression. Do đó, mô hình có nhiều biến hơn có thể có RSE cao hơn nếu mức giảm RSS nhỏ so với mức tăng p .

Ngoài RSE và R^2 , việc vẽ dữ liệu cũng hữu ích. Tóm tắt bằng đồ thị có thể bộc lộ những vấn đề của mô hình mà thống kê bằng số không cho thấy. Chẳng hạn, Hình 3.5 biểu diễn đồ thị ba chiều của TV, radio và sales. Một số observations nằm trên, số khác nằm dưới least squares regression plane. Cụ thể, linear model dường như ước lượng sales quá cao khi phần lớn tiền quảng cáo chỉ được chi riêng cho TV hoặc radio. Nó ước lượng sales quá



HÌNH 3.5. Với dữ liệu *Advertising*, linear regression fit cho *sales* dùng *TV* và *radio* làm predictor. Pattern của residual cho thấy dữ liệu có mối quan hệ phi tuyến rõ rệt. Residual dương, nhìn thấy phía trên mặt phẳng, thường nằm dọc đường 45 độ nơi ngân sách TV và radio được chia đều. Residual âm, phần lớn không nhìn thấy, thường nằm xa đường này, nơi ngân sách nghiêng hẳn về một phương tiện.

thấp khi ngân sách được chia cho hai phương tiện. Pattern phi tuyến rõ rệt này gợi ý *synergy* hay *interaction effect* giữa các phương tiện: kết hợp các phương tiện tạo ra mức tăng doanh số lớn hơn dùng riêng một phương tiện. Trong Mục 3.3.2, ta sẽ mở rộng linear model để chứa synergy effect bằng interaction term.

synergy
interaction
effect

Bốn: Prediction

Sau khi fit multiple regression model, ta dễ dàng áp dụng (3.21) để dự đoán response Y dựa trên một tập giá trị predictor $X_1, X_2, \dots, X_p$. Tuy nhiên, dự đoán này có ba loại uncertainty:

1. Các coefficient estimate $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ là ước lượng của $\beta_0, \beta_1, \dots, \beta_p$. Nghĩa là least squares plane

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_p X_p$$

chỉ là một ước lượng của population regression plane thực

$$f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p.$$

Độ thiếu chính xác trong coefficient estimate liên hệ với reducible error ở Chương 2. Ta có thể tính confidence interval để xác định $\hat{Y}$ gần $f(X)$ đến đâu.

2. Trong thực tế, giả định linear model cho $f(X)$ hầu như luôn là một phép xấp xỉ thực tế, nên có thêm một nguồn reducible error tiềm tàng gọi là *model bias*. Vì vậy, khi dùng linear model, thực chất ta đang ước lượng phép xấp xỉ tuyến tính tốt nhất của bề mặt thực. Tuy nhiên, ở đây ta bỏ qua khác biệt này và xử lý như thể linear model là đúng.

model bias

3. Ngay cả khi biết $f(X)$, tức biết giá trị thực của $\beta_0, \beta_1, \dots, \beta_p$, ta vẫn không thể dự đoán hoàn hảo response do random error ϵ trong mô hình (3.20). Trong Chương 2, đây được gọi là irreducible error. Y sẽ biến thiên bao nhiêu quanh $\hat{Y}$? Ta dùng prediction interval để trả lời. Prediction interval luôn rộng hơn confidence interval vì nó bao gồm cả sai số trong ước lượng $f(X)$ (reducible error) lẫn uncertainty về mức độ một điểm riêng lẻ khác population regression plane (irreducible error).

Ta dùng *confidence interval* để định lượng uncertainty quanh doanh số trung bình trên một số lượng lớn thành phố. Chẳng hạn, giả sử tại mỗi thành phố chi 100.000 đô la cho quảng cáo TV và 20.000 đô la cho radio, confidence interval 95% là [10.985, 11.528]. Ta diễn giải rằng 95% số khoảng có dạng này sẽ chứa giá trị thực của $f(X)$.⁹ Mặt khác, có thể dùng *prediction interval* để định lượng uncertainty quanh doanh số của một thành phố cụ thể. Nếu tại thành phố đó chi 100.000 đô la cho quảng cáo TV và 20.000 đô la cho radio, prediction interval 95% là [7.930, 14.580]. Ta diễn giải rằng 95% số khoảng có dạng này sẽ chứa giá trị thực của Y cho thành phố đó. Lưu ý cả hai khoảng đều có tâm tại 11.256, nhưng prediction interval rộng hơn đáng kể confidence interval, phản ánh uncertainty lớn hơn về doanh số tại một thành phố cụ thể so với doanh số trung bình trên nhiều địa điểm.

confidence
interval

prediction
interval

⁹Nói cách khác, nếu thu thập nhiều dataset giống *Advertising*, rồi từ mỗi dataset dựng một confidence interval của doanh số trung bình với 100.000 đô la cho TV và 20.000 đô la cho radio, thì 95% số confidence interval đó sẽ chứa giá trị thực của doanh số trung bình.