

3.3 Các cân nhắc khác trong Regression Model



3.3.1 Qualitative Predictors

Trong phần thảo luận đến đây, ta giả định rằng mọi biến trong linear regression model đều là quantitative. Nhưng trong thực tế điều này không nhất thiết đúng; một số predictor thường là qualitative.

Chẳng hạn, dataset **Credit** trong Hình 3.6 ghi lại các biến của một số chủ thẻ tín dụng. Response là **balance** (dư nợ thẻ tín dụng trung bình của mỗi người), cùng một số quantitative predictor: **age**, **cards** (số thẻ tín dụng), **education** (số năm học), **income** (nghìn đô la), **limit** (hạn mức tín dụng) và **rating** (điểm tín dụng). Mỗi panel trong Hình 3.6 là scatterplot của một cặp biến, được xác định bằng nhãn hàng và cột tương ứng. Ví dụ, scatterplot ngay bên phải từ “Balance” biểu diễn **balance** theo **age**, còn đồ thị ngay bên phải “Age” biểu diễn **age** theo **cards**. Ngoài các quantitative variable này, ta còn có bốn qualitative variable: **own** (sở hữu nhà), **student** (tình trạng sinh viên), **status** (tình trạng hôn nhân) và **region** (East, West hoặc South).

Predictor chỉ có hai level

Giả sử ta muốn khảo sát khác biệt về dư nợ thẻ tín dụng giữa người sở hữu nhà và người không sở hữu nhà, tạm thời bỏ qua các biến khác. Nếu một qualitative predictor (còn gọi là *factor*) chỉ có hai *level*, hay hai giá trị khả dĩ, việc đưa nó vào regression model rất đơn giản. Ta chỉ cần tạo một *indicator variable* hay *dummy variable* nhận hai giá trị số khả dĩ.¹ Chẳng hạn, từ biến **own**, ta tạo biến mới

factor
level
indicator
variable
dummy
variable

$$x_i = \begin{cases} 1 & \text{nếu người thứ } i \text{ sở hữu nhà,} \\ 0 & \text{nếu người thứ } i \text{ không sở hữu nhà,} \end{cases} \quad (3.26)$$

rồi dùng biến này làm predictor trong regression equation. Khi đó ta có mô hình


$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i & \text{nếu người thứ } i \text{ sở hữu nhà,} \\ \beta_0 + \epsilon_i & \text{nếu người thứ } i \text{ không sở hữu nhà.} \end{cases} \quad (3.27)$$

Giờ đây, β_0 được diễn giải là dư nợ thẻ tín dụng trung bình của nhóm không sở hữu nhà; $\beta_0 + \beta_1$ là dư nợ trung bình của nhóm sở hữu nhà; và β_1 là chênh lệch trung bình về dư nợ giữa hai nhóm.

Bảng 3.7 trình bày coefficient estimate và các thông tin khác của mô hình (3.27). Dư nợ thẻ tín dụng trung bình của người không sở hữu nhà được ước lượng là 509,80 đô la; nhóm sở hữu nhà được ước lượng có thêm 19,73 đô la dư nợ, tổng cộng $509.80 + 19.73 = 529.53$ đô la. Tuy nhiên, *p*-value của dummy variable rất cao. Vì vậy không có bằng chứng thống kê về khác biệt trong dư nợ trung bình dựa trên quyền sở hữu nhà.

Việc mã hóa nhóm sở hữu nhà là 1 và nhóm không sở hữu là 0 trong (3.27) hoàn toàn tùy ý. Nó không ảnh hưởng regression fit nhưng làm thay

¹Trong cộng đồng machine learning, việc tạo dummy variable để xử lý qualitative predictor được gọi là “one-hot encoding”.



HÌNH 3.6. Dataset *Credit* chứa thông tin về *balance*, *age*, *cards*, *education*, *income*, *limit* và *rating* của một số khách hàng tiềm năng.

BẢNG 3.7. Least squares coefficient estimate của regression *balance* trên *own* trong dataset *Credit*. Linear model được cho bởi (3.27); quyền sở hữu được mã hóa thành dummy variable như trong (3.26).

	Coefficient	Std. error	t-statistic	p-value
Intercept	509.80	33.13	15.389	< 0.0001
own[Yes]	19.73	46.05	0.429	0.6690

đổi cách diễn giải coefficient. Nếu mã hóa người không sở hữu là 1 và người sở hữu là 0, các ước lượng của β_0 và β_1 lần lượt sẽ là 529,53 và $-19,73$, vẫn cho dự đoán $529.53 - 19.73 = 509.80$ đô la với người không sở hữu và 529,53 đô la với người sở hữu. Một lựa chọn khác là dùng dummy variable

$$x_i = \begin{cases} 1 & \text{nếu người thứ } i \text{ sở hữu nhà,} \\ -1 & \text{nếu người thứ } i \text{ không sở hữu nhà,} \end{cases}$$

trong regression equation, tạo thành mô hình

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i & \text{nếu người thứ } i \text{ sở hữu nhà,} \\ \beta_0 - \beta_1 + \epsilon_i & \text{nếu người thứ } i \text{ không sở hữu nhà.} \end{cases}$$

Lúc này β_0 có thể được diễn giải là dư nợ thẻ tín dụng trung bình tổng thể (bỏ qua ảnh hưởng của quyền sở hữu nhà), còn β_1 là mức mà dư nợ

BẢNG 3.8. *Least squares coefficient estimate của regression **balance** trên **region** trong dataset **Credit**. Linear model được cho bởi (3.30); **region** được mã hóa bằng hai dummy variable (3.28) và (3.29).*

	Coefficient	Std. error	<i>t</i> -statistic	<i>p</i> -value
Intercept	531.00	46.32	11.464	< 0.0001
region[South]	−12.50	56.68	−0.221	0.8260
region[West]	−18.69	65.02	−0.287	0.7740

của nhóm sở hữu và không sở hữu lần lượt nằm trên và dưới trung bình.² Trong ví dụ này, $\hat{\beta}_0 = 519.665$ đô la, nằm giữa hai trung bình 509,80 và 529,53 đô la; $\hat{\beta}_1 = 9.865$ đô la, bằng một nửa chênh lệch trung bình 19,73 đô la. Dù dùng cách mã hóa nào, dự đoán cuối cùng cho hai nhóm vẫn giống hệt nhau; chỉ cách diễn giải coefficient thay đổi.

Qualitative predictor có nhiều hơn hai level

Khi qualitative predictor có nhiều hơn hai level, một dummy variable không thể biểu diễn mọi giá trị khả dĩ. Ta có thể tạo thêm dummy variable. Ví dụ, với biến **region**, ta tạo hai biến. Biến thứ nhất là

$$x_{i1} = \begin{cases} 1 & \text{nếu người thứ } i \text{ đến từ South,} \\ 0 & \text{nếu người thứ } i \text{ không đến từ South,} \end{cases} \quad (3.28)$$

và biến thứ hai là

$$x_{i2} = \begin{cases} 1 & \text{nếu người thứ } i \text{ đến từ West,} \\ 0 & \text{nếu người thứ } i \text{ không đến từ West.} \end{cases} \quad (3.29)$$

Đưa cả hai biến vào regression equation cho mô hình

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i & \text{nếu người thứ } i \text{ đến từ South,} \\ \beta_0 + \beta_2 + \epsilon_i & \text{nếu người thứ } i \text{ đến từ West,} \\ \beta_0 + \epsilon_i & \text{nếu người thứ } i \text{ đến từ East.} \end{cases} \quad (3.30)$$

Ta diễn giải β_0 là dư nợ thể tín dụng trung bình của người ở East; β_1 là chênh lệch dư nợ trung bình giữa South và East; còn β_2 là chênh lệch giữa West và East. Số dummy variable luôn ít hơn số level một đơn vị. Level không có dummy variable—trong ví dụ này là East—được gọi là *baseline*. baseline

Từ Bảng 3.8, estimated balance của baseline East là 531,00 đô la. Nhóm South được ước lượng có dư nợ thấp hơn East 12,50 đô la, còn nhóm West thấp hơn East 18,69 đô la. Tuy nhiên, *p*-value của hai dummy variable đều rất lớn, cho thấy không có bằng chứng thống kê về khác biệt thực sự trong dư nợ trung bình giữa South với East hay West với East.³ Baseline được chọn tùy ý và dự đoán cuối cùng của mỗi nhóm không phụ thuộc lựa chọn

²Chính xác hơn, β_0 bằng một nửa tổng dư nợ trung bình của hai nhóm. Do đó, β_0 chỉ đúng bằng trung bình tổng thể khi hai nhóm có cùng số thành viên.

³Về lý thuyết vẫn có thể có khác biệt giữa South và West, dù dữ liệu ở đây không gợi ý khác biệt nào.

đó, nhưng coefficient và p -value của chúng thì có. Thay vì dựa vào từng coefficient, ta có thể dùng F -test cho $H_0 : \beta_1 = \beta_2 = 0$; kiểm định này không phụ thuộc cách mã hóa. F -test cho p -value 0,96, nên ta không thể bác bỏ null hypothesis rằng **balance** không liên hệ với **region**.

Dummy-variable approach không gây khó khăn khi đưa đồng thời quantitative và qualitative predictor vào mô hình. Chẳng hạn, để regress **balance** trên quantitative variable **income** và qualitative variable **student**, ta chỉ cần tạo dummy variable cho **student**, rồi fit multiple regression model dùng **income** và dummy variable đó để dự đoán **balance**.

Có nhiều cách mã hóa qualitative variable ngoài dummy-variable approach. Tất cả cho model fit tương đương, nhưng coefficient khác nhau, có cách diễn giải khác nhau và được thiết kế để đo những *contrast* cụ thể. Chủ đề này nằm ngoài phạm vi cuốn sách.

3.3.2 Mở rộng Linear Model

Linear regression model chuẩn (3.19) cho kết quả dễ diễn giải và hoạt động khá tốt trên nhiều bài toán thực tế. Tuy nhiên, nó đặt ra một số giả định rất hạn chế và thường bị vi phạm. Hai giả định quan trọng nhất nói rằng quan hệ giữa predictor và response có tính *additive* và *linear*. Giả định additivity nghĩa là association giữa predictor X_j và response Y không phụ thuộc giá trị của predictor khác. Giả định linearity nói rằng mức thay đổi của Y gắn với một đơn vị thay đổi của X_j là hằng số, bất kể giá trị của X_j . Ở các chương sau, ta sẽ gặp những phương pháp tinh vi hơn nhằm nói lỏng hai giả định này. Trước hết, ta xem nhanh một số cách mở rộng cổ điển thường dùng.

Loại bỏ giả định Additive

Trong phân tích dữ liệu **Advertising** trước đó, ta kết luận cả **TV** và **radio** dường như associated với **sales**. Các linear model làm nền tảng cho kết luận này giả định ảnh hưởng của việc tăng chi tiêu ở một phương tiện không phụ thuộc số tiền dành cho phương tiện kia. Ví dụ, mô hình (3.20) nói rằng mức tăng sales trung bình khi TV tăng một đơn vị luôn là β_1 , bất kể chi cho radio bao nhiêu.

Nhưng mô hình đơn giản ấy có thể sai. Giả sử chi tiền quảng cáo radio thực sự làm quảng cáo TV hiệu quả hơn, khiến slope của TV tăng khi radio tăng. Khi có ngân sách cố định 100.000 đô la, chia một nửa cho radio và một nửa cho TV có thể làm sales tăng nhiều hơn dồn toàn bộ cho một trong hai. Trong marketing, đây là *synergy effect*; trong statistics, nó được gọi là *interaction effect*. Hình 3.5 gợi ý hiệu ứng này có thể tồn tại: khi TV hoặc radio thấp, sales thực thấp hơn dự đoán của linear model; khi ngân sách được chia giữa hai phương tiện, mô hình lại có xu hướng dự đoán thấp hơn sales thực.

Xét linear regression model chuẩn với hai biến,

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon.$$

Theo mô hình này, X_1 tăng một đơn vị đi kèm mức tăng trung bình β_1 đơn vị của Y . Sự có mặt của X_2 không làm thay đổi phát biểu đó. Một

BẢNG 3.9. Với dữ liệu *Advertising*, least squares coefficient estimate của regression *sales* trên *TV* và *radio*, có interaction term như trong (3.33).

	Coefficient	Std. error	t-statistic	p-value
Intercept	6.7502	0.248	27.23	< 0.0001
TV	0.0191	0.002	12.70	< 0.0001
radio	0.0289	0.009	3.24	0.0014
TV×radio	0.0011	0.000	20.73	< 0.0001

cách mở rộng là thêm predictor thứ ba, gọi là *interaction term*, được tạo bằng tích X_1X_2 : interaction term

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \epsilon. \quad (3.31)$$

Vì sao interaction term giúp nới lỏng giả định additive? Ta có thể viết lại (3.31) thành

$$\begin{aligned} Y &= \beta_0 + (\beta_1 + \beta_3 X_2) X_1 + \beta_2 X_2 + \epsilon \\ &= \beta_0 + \tilde{\beta}_1 X_1 + \beta_2 X_2 + \epsilon, \end{aligned} \quad (3.32)$$

trong đó $\tilde{\beta}_1 = \beta_1 + \beta_3 X_2$. Vì $\tilde{\beta}_1$ nay là hàm của X_2 , association giữa X_1 và Y không còn cố định: thay đổi X_2 sẽ làm thay đổi association giữa X_1 và Y . Lập luận tương tự cho thấy thay đổi X_1 cũng làm thay đổi association giữa X_2 và Y .

Ví dụ, giả sử ta nghiên cứu năng suất nhà máy và muốn dự đoán số đơn vị sản phẩm từ số dây chuyền cùng tổng số công nhân. Ảnh hưởng của việc tăng số dây chuyền có vẻ sẽ phụ thuộc số công nhân, bởi nếu không có người vận hành thì thêm dây chuyền không thể làm sản lượng tăng. Vì vậy, linear model dự đoán **units** nên có interaction term giữa **lines** và **workers**. Giả sử fit cho kết quả

$$\begin{aligned} \text{units} &\approx 1.2 + 3.4 \times \text{lines} + 0.22 \times \text{workers} + 1.4 \times (\text{lines} \times \text{workers}) \\ &= 1.2 + (3.4 + 1.4 \times \text{workers}) \times \text{lines} + 0.22 \times \text{workers}. \end{aligned}$$

Nói cách khác, thêm một dây chuyền làm số đơn vị sản xuất tăng $3.4 + 1.4 \times \text{workers}$. Do đó càng nhiều công nhân, ảnh hưởng của dây chuyền càng mạnh.

Trở lại ví dụ *Advertising*, linear model dùng *radio*, *TV* và interaction giữa hai biến để dự đoán *sales* có dạng

$$\begin{aligned} \text{sales} &= \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times (\text{radio} \times \text{TV}) + \epsilon \\ &= \beta_0 + (\beta_1 + \beta_3 \times \text{radio}) \times \text{TV} + \beta_2 \times \text{radio} + \epsilon. \end{aligned} \quad (3.33)$$

Ta có thể diễn giải β_3 là mức tăng hiệu quả của quảng cáo TV gắn với việc quảng cáo radio tăng một đơn vị (hoặc ngược lại). Các coefficient thu được khi fit (3.33) nằm trong Bảng 3.9.

Kết quả trong Bảng 3.9 cho thấy rõ mô hình chứa interaction term tốt hơn mô hình chỉ có *main effect*. p -value của **TV×radio** cực thấp, cung cấp bằng chứng mạnh cho $H_a : \beta_3 \neq 0$; quan hệ thực không phải additive. R^2 của mô hình (3.33) là 96,8%, so với 89,7% khi dự đoán sales bằng TV và main effect

radio mà không có interaction. Như vậy, $(96.8 - 89.7)/(100 - 89.7) = 69\%$ phần variability của sales còn lại sau additive model đã được interaction term giải thích. Các coefficient gợi ý rằng quảng cáo TV tăng 1.000 đô la gắn với sales tăng $(\hat{\beta}_1 + \hat{\beta}_3 \times \text{radio}) \times 1,000 = 19 + 1.1 \times \text{radio}$ đơn vị; quảng cáo radio tăng 1.000 đô la gắn với sales tăng $29 + 1.1 \times \text{TV}$ đơn vị.

Trong ví dụ này, TV, radio và interaction term đều statistically significant. Nhưng đôi khi interaction term có p -value rất nhỏ trong khi main effect tương ứng lại không. *Hierarchical principle* nói rằng nếu đưa interaction vào mô hình, ta cũng nên đưa các main effect vào, ngay cả khi p -value của coefficient không significant. Nếu X_1X_2 liên hệ với response thì việc coefficient riêng của X_1 hay X_2 có đúng bằng 0 hay không không mấy quan trọng. Hơn nữa, X_1X_2 thường correlated với X_1 và X_2 , nên bỏ chúng làm thay đổi ý nghĩa của interaction.

Hierarchical
principle

Khái niệm interaction cũng áp dụng cho qualitative variable hoặc kết hợp qualitative và quantitative variable. Thực ra, interaction giữa một qualitative variable và một quantitative variable có cách diễn giải rất tự nhiên. Xét dataset **Credit**; giả sử ta dự đoán **balance** bằng quantitative variable **income** và qualitative variable **student**. Không có interaction term, mô hình là

$$\text{balance}_i \approx \beta_0 + \beta_1 \text{income}_i + \begin{cases} \beta_2 & \text{nếu người thứ } i \text{ là student,} \\ 0 & \text{nếu không phải student,} \end{cases} \quad (3.34)$$

tức là fit hai đường song song: một cho student, một cho non-student. Hai đường có intercept khác nhau, $\beta_0 + \beta_2$ và β_0 , nhưng cùng slope β_1 , như panel trái Hình 3.7. Điều đó có nghĩa ảnh hưởng trung bình của một đơn vị tăng trong income lên balance không phụ thuộc tình trạng student. Đây có thể là hạn chế nghiêm trọng vì thay đổi income có thể ảnh hưởng rất khác đến balance của student và non-student.

Ta khắc phục bằng cách thêm interaction variable, tạo bởi tích của **income** với dummy variable của **student**:

$$\text{balance}_i \approx \begin{cases} (\beta_0 + \beta_2) + (\beta_1 + \beta_3) \text{income}_i & \text{nếu là student,} \\ \beta_0 + \beta_1 \text{income}_i & \text{nếu không phải student.} \end{cases} \quad (3.35)$$

Ta vẫn có hai regression line, nhưng giờ chúng khác cả intercept lẫn slope. Mô hình cho phép thay đổi income ảnh hưởng khác nhau tới hai nhóm.

Panel phải Hình 3.7 cho thấy quan hệ ước lượng giữa income và balance trong mô hình (3.35). Slope của student thấp hơn slope của non-student, gợi ý rằng income tăng associated với mức tăng balance nhỏ hơn ở student so với non-student.

Quan hệ phi tuyến

Linear regression model (3.19) giả định quan hệ tuyến tính giữa response và predictor, nhưng quan hệ thực đôi khi phi tuyến. Một cách mở rộng trực tiếp, rất đơn giản là *polynomial regression*. Các chương sau sẽ trình bày những cách tổng quát và phức tạp hơn.

polynomial
regression

Hình 3.8 biểu diễn **mpg** (miles per gallon) theo **horsepower** của các xe trong dataset **Auto**. Đường cam là linear regression fit. Dữ liệu cho thấy




FIGURE 3.7. For the **Credit** data, the least squares lines are shown for pre-

HÌNH 3.7. Với dữ liệu **Credit**, các least squares line dự đoán **balance** từ **income** được biểu diễn cho **student** và **non-student**. Trái: Fit mô hình (3.34), không có interaction giữa **income** và **student**. Phải: Fit mô hình (3.35), có interaction term giữa **income** và **student**.

BẢNG 3.10. Với dataset **Auto**, least squares coefficient estimate của regression **mpg** trên **horsepower** và **horsepower²**.

	Coefficient	Std. error	<i>t</i> -statistic	<i>p</i> -value
Intercept	56.9001	1.8004	31.6	< 0.0001
horsepower	-0.4662	0.0311	-15.0	< 0.0001
horsepower ²	0.0012	0.0001	10.1	< 0.0001

quan hệ rõ rệt nhưng bị uốn cong, không phải tuyến tính. Ta có thể đưa các phiên bản biến đổi của predictor vào linear model. Hình dạng gần quadratic gợi ý mô hình


$$\text{mpg} = \beta_0 + \beta_1 \times \text{horsepower} + \beta_2 \times \text{horsepower}^2 + \epsilon. \quad (3.36)$$

Mặc dù (3.36) dự đoán mpg bằng một hàm phi tuyến của horsepower, đây vẫn là linear model: chỉ là multiple linear regression với $X_1 = \text{horsepower}$ và $X_2 = \text{horsepower}^2$. Do đó ta vẫn dùng software linear regression chuẩn để ước lượng $\beta_0, \beta_1, \beta_2$.

Đường cong xanh lam trong Hình 3.8 là quadratic fit. Nó tốt hơn đáng kể so với fit chỉ có linear term: $R^2 = 0.688$, so với 0,606 của linear fit, và *p*-value của quadratic term trong Bảng 3.10 rất significant.

Nếu thêm **horsepower²** cải thiện mô hình nhiều như vậy, tại sao không thêm bậc ba, bậc bốn hay bậc năm? Đường xanh lục trong Hình 3.8 là fit chứa mọi polynomial đến bậc năm. Fit thu được có vẻ gọn quá mức; chưa rõ các term bổ sung có thực sự cải thiện fit cho dữ liệu hay không.

Cách mở rộng linear model bằng polynomial function của predictor được gọi là polynomial regression. Ta sẽ khảo sát sâu hơn phương pháp này và các mở rộng phi tuyến khác của linear model trong Chương 7.



HÌNH 3.8. Dataset *Auto. mpg* và *horsepower* được biểu diễn cho một số xe. Linear regression fit màu cam. Fit của mô hình có horsepower^2 là đường cong xanh lam. Fit của mô hình chứa mọi polynomial của *horsepower* đến bậc năm có màu xanh lục.

3.3.3 Các vấn đề tiềm ẩn

Khi fit linear regression model cho một dataset cụ thể, nhiều vấn đề có thể xảy ra. Phổ biến nhất gồm:

1. Quan hệ response–predictor phi tuyến.
2. Các error term correlated.
3. Variance của error term không hằng.
4. Outlier.
5. High-leverage point.
6. Collinearity.

Trong thực tế, nhận diện và khắc phục những vấn đề này vừa là nghệ thuật vừa là khoa học. Vô số sách đã dành nhiều trang cho chủ đề đó. Vì linear regression model không phải trọng tâm chính ở đây, chúng tôi chỉ tóm lược một số điểm then chốt.

1. Tính phi tuyến của dữ liệu

Linear regression model giả định có quan hệ đường thẳng giữa predictor và response. Nếu quan hệ thực khác xa tuyến tính, gần như mọi kết luận từ model fit đều đáng ngờ và prediction accuracy có thể suy giảm đáng kể.

Residual plot là công cụ đồ họa hữu ích để nhận diện tính phi tuyến. Với simple linear regression, ta vẽ residual $e_i = y_i - \hat{y}_i$ theo predictor x_i . Với multiple regression có nhiều predictor, ta vẽ residual theo predicted hay

Residual plot




FIGURE 3.9. Plots of residuals versus predicted (or fitted) values for the **Auto** data set. In each plot, the red line is a smooth fit to the residuals, intended to make it easier to identify a trend. Left: A linear regression of **mpg** on **horsepower**. A strong pattern in the residuals indicates non-linearity in the data. Right: A linear regression of **mpg** on **horsepower** and **horsepower**². There is little pattern in the

HÌNH 3.9. Đồ thị residual theo predicted (hay fitted) value cho dataset **Auto**. Trong mỗi đồ thị, đường đỏ là smooth fit của residual nhằm làm trend dễ nhận thấy hơn. Trái: Linear regression của **mpg** trên **horsepower**; pattern mạnh trong residual cho thấy dữ liệu phi tuyến. Phải: Linear regression của **mpg** trên **horsepower** và **horsepower**²; residual hầu như không còn pattern.


fitted value $\hat{y}_i$. Lý tưởng nhất, residual plot không có pattern dễ nhận biết; nếu có, một khía cạnh nào đó của linear model có thể đang gặp vấn đề.

Panel trái Hình 3.9 là residual plot của linear regression **mpg** trên **horsepower** trong dataset **Auto**. Đường đỏ là smooth fit giúp dễ thấy trend. Residual có hình chữ U rõ rệt, là dấu hiệu mạnh của tính phi tuyến. Panel phải là residual plot của mô hình (3.36) có quadratic term. Hầu như không còn pattern, cho thấy quadratic term cải thiện model fit.

Nếu residual plot cho thấy association phi tuyến, cách đơn giản là đưa các phép biến đổi phi tuyến của predictor như $\log X$, $\sqrt{X}$ và X^2 vào regression model. Các chương sau sẽ bàn về những phương pháp phi tuyến tiên tiến hơn.

2. Correlation của Error Term

Một giả định quan trọng của linear regression model là các error term $\epsilon_1, \epsilon_2, \dots, \epsilon_n$ không correlated. Nếu error không correlated, việc ϵ_i dương hầu như không cung cấp thông tin về dấu của ϵ_{i+1} . Standard error của regression coefficient estimate và fitted value được tính dựa trên giả định này. Nếu error term thực sự correlated, standard error ước lượng thường thấp hơn standard error thực, làm confidence interval và prediction interval hẹp hơn mức cần thiết. Chẳng hạn, confidence interval 95% trên thực tế có thể có xác suất chứa parameter thực thấp hơn 0,95 nhiều. p -value cũng thấp



HÌNH 3.10. Đồ thị residual của các time-series dataset mô phỏng, được tạo với các mức correlation ρ khác nhau giữa error term tại hai thời điểm liên kế.

hơn mức đúng, khiến ta có thể kết luận nhầm một parameter statistically significant. Tóm lại, error correlated có thể tạo ra sự tự tin không có cơ sở vào mô hình.

Một ví dụ cực đoan: giả sử ta vô tình nhân đôi dữ liệu, tạo ra từng cặp observation và error term giống hệt nhau. Nếu bỏ qua điều này, phép tính standard error sẽ hành xử như ta có sample size $2n$, trong khi thực tế chỉ có n sample. Parameter estimate vẫn giống nhau, nhưng confidence interval sẽ hẹp đi theo hệ số $\sqrt{2}$.

Correlation giữa error term thường xuất hiện trong *time series data*, nơi observation được đo tại các thời điểm rời rạc. Observation ở hai thời điểm liên kế thường có error correlated dương. Để kiểm tra, ta vẽ residual của mô hình theo thời gian. Nếu error không correlated, đồ thị không nên có pattern rõ rệt. Nếu correlated dương, residual có thể xuất hiện *tracking*: các residual liên kế nhận giá trị tương tự nhau.

Panel trên Hình 3.10 dùng error không correlated và không cho thấy trend theo thời gian. Panel dưới dùng correlation 0,9 giữa các error liên kế, nên residual có pattern rõ: các giá trị gần nhau có xu hướng giống nhau. Panel giữa là trường hợp vừa phải với correlation 0,5; tracking vẫn tồn tại nhưng kém rõ hơn.




FIGURE 3.11. Residual plots. In each plot, the red line is a smooth fit to the residuals, intended to make it easier to identify a trend. The blue lines track the outer quantiles of the residuals, and emphasize patterns. Left: The funnel shape

HÌNH 3.11. Residual plot. Trong mỗi đồ thị, đường đỏ là smooth fit của residual; các đường xanh theo outer quantile và nhấn mạnh pattern. Trái: Hình phễu cho thấy heteroscedasticity. Phải: Response đã được log-transform và không còn bằng chứng về heteroscedasticity.

Nhiều phương pháp đã được phát triển để xử lý đúng correlation của error term trong time-series data. Hiện tượng này cũng có thể xuất hiện ngoài time series. Ví dụ, trong nghiên cứu dự đoán chiều cao từ cân nặng, giả định error không correlated có thể bị vi phạm nếu một số người cùng gia đình, cùng chế độ ăn hoặc cùng tiếp xúc với yếu tố môi trường. Giả định error không correlated cực kỳ quan trọng đối với linear regression và nhiều phương pháp thống kê khác; experimental design tốt là yếu tố then chốt để giảm nguy cơ correlation như vậy.

3. Variance của Error Term không hằng

Một giả định quan trọng khác là error term có variance hằng, $\text{Var}(\epsilon_i) = \sigma^2$. Standard error, confidence interval và hypothesis test của linear model đều dựa vào giả định này.

Thực tế, variance của error term thường không hằng; nó có thể tăng theo response. Ta nhận diện non-constant variance, hay *heteroscedasticity*, qua hình phễu trong residual plot. Panel trái Hình 3.11 cho thấy độ lớn residual tăng cùng fitted value. Một giải pháp là biến đổi response Y bằng hàm lõm như $\log Y$ hoặc $\sqrt{Y}$. Phép biến đổi co các response lớn nhiều hơn và làm giảm heteroscedasticity. Panel phải biểu diễn residual sau khi dùng $\log Y$; variance trông đã hằng, dù vẫn có chút bằng chứng về quan hệ phi tuyến.

Đôi khi ta biết khá rõ variance của từng response. Ví dụ, response thứ i có thể là trung bình của n_i raw observation. Nếu mỗi raw observation không correlated và có variance σ^2 , trung bình của chúng có variance $\sigma_i^2 = \sigma^2/n_i$. Khi đó, ta có thể fit mô hình bằng *weighted least squares*, với weight tỷ

weighted least
squares




FIGURE 3.12. Left: The least squares regression line is shown in red, and the regression line after removing the outlier is shown in blue. Center: The residual plot clearly identifies the outlier. Right: The outlier has a studentized residual of 6; typically we expect values between -3 and 3 .

HÌNH 3.12. Trái: Least squares regression line màu đỏ; đường sau khi bỏ outlier màu xanh. Giữa: Residual plot nhận diện rõ outlier. Phải: Outlier có studentized residual bằng 6; thông thường ta kỳ vọng giá trị nằm giữa -3 và 3 .

lệ nghịch variance—trong ví dụ này $w_i = n_i$. Phần lớn software linear regression đều hỗ trợ observation weight.

4. Outlier

Outlier là một điểm có y_i cách xa giá trị mô hình dự đoán. Outlier có thể xuất hiện vì nhiều nguyên nhân, chẳng hạn ghi sai observation khi thu thập dữ liệu.

Điểm đỏ (observation 20) ở panel trái Hình 3.12 là một outlier điển hình. Đường đỏ liền là least squares fit; đường xanh đứt là fit sau khi bỏ outlier. Việc bỏ điểm này gần như không đổi slope và chỉ giảm intercept rất ít. Một outlier không có predictor value bất thường thường ít ảnh hưởng least squares fit. Nhưng nó vẫn có thể gây vấn đề khác: RSE bằng 1,09 khi giữ outlier và chỉ 0,77 khi bỏ nó. Vì RSE được dùng để tính mọi confidence interval và p -value, một điểm duy nhất làm tăng RSE mạnh có thể thay đổi cách diễn giải fit. Tương tự, outlier làm R^2 giảm từ 0,892 xuống 0,805.

Residual plot giúp nhận diện outlier, nhưng khó quyết định residual phải lớn đến đâu mới được coi là outlier. Thay vì residual thô, ta có thể vẽ *studentized residual*, tính bằng cách chia mỗi residual e_i cho estimated standard error của nó. Observation có trị tuyệt đối studentized residual lớn hơn 3 là outlier khả dĩ. Trong panel phải Hình 3.12, studentized residual của outlier vượt 6, còn mọi observation khác nằm giữa -2 và 2 .

Nếu tin rằng outlier xuất phát từ lỗi thu thập hay ghi dữ liệu, một giải pháp là bỏ observation. Tuy nhiên phải thận trọng: outlier có thể phản ánh khiếm khuyết của mô hình, chẳng hạn thiếu một predictor.

5. High-Leverage Point

Outlier là observation có response y_i bất thường khi đã biết predictor x_i . Ngược lại, observation có *high leverage* mang giá trị x_i bất thường. Observation 41 trong panel trái Hình 3.13 có predictor value lớn so với

Outlier

studentized
residual

high leverage




FIGURE 3.13. Left: Observation 41 is a high leverage point, while 20 is not. The red line is the fit to all the data, and the blue line is the fit with observation 41 removed. Center: The red observation is not unusual in terms of its X_1 value or its X_2 value, but still falls outside the bulk of the data, and hence has high leverage. Right: Observation 41 has a high leverage and a high residual.

HÌNH 3.13. Trái: Observation 41 là high-leverage point, còn observation 20 thì không. Đường đỏ fit toàn bộ dữ liệu; đường xanh fit sau khi bỏ observation 41. Giữa: Observation đỏ không bất thường nếu xét riêng X_1 hay X_2 , nhưng nằm ngoài phần lớn dữ liệu nên có high leverage. Phải: Observation 41 vừa có leverage cao vừa có residual cao.

các observation khác. Dữ liệu giống Hình 3.12, chỉ thêm một high-leverage observation. Đường đỏ liền là fit cho toàn bộ dữ liệu, đường xanh đứt là fit khi bỏ observation 41.

So sánh panel trái của Hình 3.12 và Hình 3.13, ta thấy bỏ high-leverage observation ảnh hưởng đến least squares line nhiều hơn hẳn bỏ outlier. High-leverage observation thường ảnh hưởng đáng kể đến estimated regression line. Nếu chỉ vài observation chi phối mạnh đường fit, mọi vấn đề ở các điểm đó có thể làm toàn bộ fit mất hiệu lực; vì vậy cần nhận diện chúng.

Trong simple linear regression, high-leverage observation khá dễ thấy vì predictor value nằm ngoài range bình thường. Trong multiple regression, một observation có thể nằm trong range của từng predictor riêng lẻ nhưng vẫn bất thường khi xét toàn bộ predictor. Panel giữa Hình 3.13 minh họa dataset có X_1, X_2 : phần lớn observation nằm trong ellipse xanh đứt, còn điểm đỏ ở ngoài dù cả X_1 lẫn X_2 của nó đều không bất thường khi xét riêng. Với hơn hai predictor, vấn đề còn rõ hơn vì không có cách đơn giản để vẽ đồng thời mọi dimension.

Để định lượng leverage của một observation, ta tính *leverage statistic*. Giá trị lớn cho biết high leverage. Với simple linear regression,

leverage
statistic

$$h_i = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i'=1}^n (x_{i'} - \bar{x})^2}. \quad (3.37)$$

Rõ ràng h_i tăng theo khoảng cách giữa x_i và $\bar{x}$. Công thức có thể mở rộng cho multiple predictor. Leverage statistic luôn nằm giữa $1/n$ và 1, còn leverage trung bình của mọi observation luôn là $(p+1)/n$. Nếu một observation có leverage vượt xa $(p+1)/n$, ta có thể nghi ngờ đó là high-leverage point.




FIGURE 3.14. Scatterplots of the observations from the **Credit** data set. Left: A plot of **age** versus **limit**. These two variables are not collinear. Right: A plot of **rating** versus **limit**. There is high collinearity.

HÌNH 3.14. Scatterplot của observation trong dataset **Credit**. Trái: **age** theo **limit**; hai biến không collinear. Phải: **rating** theo **limit**; collinearity rất cao.

Panel phải Hình 3.13 vẽ studentized residual theo h_i . Observation 41 nổi bật vì vừa có leverage statistic rất cao vừa có studentized residual lớn—nó đồng thời là outlier và high-leverage observation, một tổ hợp đặc biệt nguy hiểm. Đồ thị cũng giải thích vì sao observation 20 ít ảnh hưởng fit trong Hình 3.12: leverage của nó thấp.

6. Collinearity

Collinearity là tình huống hai hay nhiều predictor variable liên hệ chặt với nhau. Hình 3.14 minh họa bằng dataset **Credit**. Ở panel trái, **limit** và **age** không có quan hệ rõ. Ở panel phải, **limit** và **rating** correlated rất mạnh nên được gọi là collinear. Collinearity gây khó khăn vì khó tách ảnh hưởng riêng của từng biến lên response. Do **limit** và **rating** có xu hướng cùng tăng hoặc cùng giảm, ta khó xác định riêng từng biến associated với **balance** như thế nào.

Collinearity

Hình 3.15 cho thấy khó khăn do collinearity. Panel trái là contour plot của RSS (3.22) theo các coefficient estimate khả dĩ của regression **balance** trên **limit** và **age**. Mỗi ellipse là tập coefficient có cùng RSS; ellipse càng gần tâm thì RSS càng thấp. Chấm đen và đường đứt tương ứng với coefficient estimate cho RSS nhỏ nhất, tức least squares estimate. Trục **limit** và **age** được scale để chứa giá trị đến bốn standard error ở hai phía của estimate, nên gồm mọi giá trị coefficient hợp lý. Chẳng hạn, coefficient thật của **limit** gần như chắc chắn nằm giữa 0,15 và 0,20.

Panel phải Hình 3.15 là contour plot RSS của regression **balance** trên hai biến highly collinear là **limit** và **rating**. Contour chạy dọc một thung lũng hẹp; một range rộng của coefficient estimate cho cùng RSS. Một thay đổi nhỏ trong dữ liệu có thể làm cặp least squares estimate di chuyển tới




FIGURE 3.15. Contour plots for the RSS values as a function of the parameters β for various regressions involving the **Credit** data set. In each plot, the black dots represent the coefficient values corresponding to the minimum RSS. Left: A contour plot of RSS for the regression of **balance** onto **age** and **limit**. The

HÌNH 3.15. Contour plot của RSS theo parameter β cho các regression dùng dataset **Credit**. Chấm đen là coefficient value cho RSS nhỏ nhất. Trái: Regression **balance** trên **age** và **limit**; minimum được xác định rõ. Phải: Regression **balance** trên **rating** và **limit**; do collinearity, nhiều cặp $(\beta_{\text{Limit}}, \beta_{\text{Rating}})$ có RSS tương tự nhau.

BẢNG 3.11. Kết quả của hai multiple regression model dùng dataset **Credit**. Model 1 regress **balance** trên **age** và **limit**; Model 2 regress **balance** trên **rating** và **limit**. Standard error của $\hat{\beta}_{\text{limit}}$ tăng 12 lần trong regression thứ hai do collinearity.

		Coefficient	Std. error	t-statistic	p-value
Model 1	Intercept	-173.411	43.828	-3.957	< 0.0001
	age	-2.292	0.672	-3.407	0.0007
	limit	0.173	0.005	34.496	< 0.0001
Model 2	Intercept	-377.537	45.254	-8.343	< 0.0001
	rating	2.202	0.952	2.312	0.0213
	limit	0.025	0.064	0.384	0.7012

bất kỳ đầu dọc thung lũng, tạo uncertainty lớn. Scale của coefficient limit nay từ khoảng -0.2 đến 0.2 , rộng gấp tám lần range hợp lý khi regression cùng age. Dù từng coefficient có uncertainty lớn hơn nhiều, cặp coefficient gần như chắc chắn vẫn nằm đâu đó trong thung lũng contour này. Ví dụ, ta không kỳ vọng coefficient limit và rating thực lẫn lượt là -0.1 và 1 , dù từng giá trị riêng lẻ đều có vẻ hợp lý.

Vì collinearity làm coefficient estimate kém chính xác, standard error của $\hat{\beta}_j$ tăng. t -statistic được tính bằng $\hat{\beta}_j$ chia standard error, nên collinearity làm t -statistic giảm. Khi đó ta có thể không bác bỏ được $H_0 : \beta_j = 0$. Nói cách khác, collinearity làm giảm *power* của hypothesis test—xác suất phát hiện đúng một coefficient khác 0.

Bảng 3.11 so sánh hai multiple regression model. Trong mô hình thứ nhất, age và limit đều highly significant với p -value rất nhỏ. Trong mô hình thứ

hai, collinearity giữa limit và rating làm standard error của coefficient limit tăng 12 lần và p -value tăng lên 0,701. Tầm quan trọng của limit đã bị che khuất bởi collinearity. Vì vậy, cần nhận diện và xử lý vấn đề collinearity khi fit mô hình.

Cách đơn giản để phát hiện collinearity là xem correlation matrix của predictor. Phần tử có trị tuyệt đối lớn cho biết một cặp biến highly correlated. Nhưng correlation matrix không phát hiện được mọi trường hợp: ba hay nhiều biến có thể collinear dù không cặp nào có correlation đặc biệt cao. Tình huống này gọi là *multicollinearity*.

Cách tốt hơn để đánh giá multicollinearity là tính *variance inflation factor* (VIF): tỷ số giữa variance của $\hat{\beta}_j$ khi fit full model và variance của $\hat{\beta}_j$ khi fit riêng. VIF nhỏ nhất bằng 1, tương ứng hoàn toàn không có collinearity. Trong thực tế thường có một lượng nhỏ collinearity; theo rule of thumb, VIF vượt 5 hoặc 10 cho thấy mức collinearity có vấn đề. Với mỗi biến,

variance
inflation
factor

$$\text{VIF}(\hat{\beta}_j) = \frac{1}{1 - R_{X_j|X_{-j}}^2},$$

trong đó $R_{X_j|X_{-j}}^2$ là R^2 của regression X_j trên mọi predictor khác. Nếu giá trị này gần 1 thì có collinearity và VIF lớn.

Trong dữ liệu **Credit**, regression **balance** trên **age**, **rating** và **limit** cho VIF lần lượt là 1,01; 160,67; và 160,59. Đúng như nghi ngờ, dữ liệu có collinearity đáng kể.

Khi gặp collinearity, có hai giải pháp đơn giản. Thứ nhất, bỏ một biến có vấn đề khỏi regression. Thường việc này không làm model fit giảm nhiều vì collinearity ngụ ý thông tin biến đó cung cấp về response là redundant khi đã có các biến còn lại. Ví dụ, nếu regress balance trên age và limit mà bỏ rating, VIF giảm gần mức tối thiểu 1, còn R^2 chỉ giảm từ 0,754 xuống 0,75. Như vậy, bỏ rating giải quyết collinearity mà hầu như không ảnh hưởng fit. Giải pháp thứ hai là gộp các biến collinear thành một predictor duy nhất. Chẳng hạn, ta có thể lấy trung bình các phiên bản standardized của limit và rating để tạo biến mới đo credit worthiness.