

3.4 Kế hoạch Marketing



Giờ ta quay lại ngắn gọn với bảy câu hỏi về dữ liệu **Advertising** đã đặt ra ở đầu chương.

1. *Sales và advertising budget có quan hệ không?*

Ta trả lời bằng cách fit multiple regression model của **sales** trên **TV**, **radio**, **newspaper**, như trong (3.20), rồi kiểm định $H_0 : \beta_{TV} = \beta_{radio} = \beta_{newspaper} = 0$. Trong Mục 3.2.2, F -statistic được dùng để quyết định có bác bỏ null hypothesis hay không. Ở đây, p -value của F -statistic trong Bảng 3.6 rất thấp, cho bằng chứng rõ ràng về quan hệ giữa advertising và sales.

2. *Mối quan hệ mạnh đến đâu?*

Ta đã bàn hai thước đo model accuracy ở Mục 3.1.3. RSE ước lượng standard deviation của response quanh population regression line. Với dữ liệu **Advertising**, RSE là 1,69 đơn vị, còn response trung bình là 14,022, tương ứng percentage error khoảng 12%. Thứ hai, R^2 ghi nhận tỷ lệ variability của response được predictor giải thích. Các predictor giải thích gần 90% variance của sales. RSE và R^2 được trình bày trong Bảng 3.6.

3. *Phương tiện nào associated với sales?*

Ta xem p -value gắn với t -statistic của từng predictor (Mục 3.1.2). Trong multiple linear regression ở Bảng 3.4, p -value của TV và radio thấp, còn newspaper thì không. Điều này gợi ý chỉ TV và radio liên hệ với sales. Chương 6 sẽ khảo sát sâu hơn.

4. *Association giữa từng phương tiện và sales lớn đến đâu?*

Trong Mục 3.1.2, standard error của $\hat{\beta}_j$ được dùng để dựng confidence interval cho β_j . Từ Bảng 3.4, confidence interval 95% của coefficient trong multiple regression model dùng cả ba ngân sách là (0.043, 0.049) cho TV, (0.172, 0.206) cho radio và (-0.013, 0.011) cho newspaper. Khoảng của TV và radio hẹp, cách xa 0, cho bằng chứng rằng hai phương tiện liên hệ với sales. Khoảng của newspaper chứa 0, nên biến này không statistically significant khi đã biết TV và radio.

Collinearity có thể làm standard error rất rộng. Liệu đó có phải lý do confidence interval của newspaper rộng? VIF của TV, radio và newspaper lần lượt là 1,005; 1,145; và 1,145, nên không có bằng chứng collinearity.

Để đánh giá riêng association của từng phương tiện với sales, ta có thể thực hiện ba simple linear regression. Kết quả trong Bảng 3.1 và Bảng 3.3 cho bằng chứng về association cực mạnh giữa TV với sales và giữa radio với sales. Nếu bỏ qua giá trị TV và radio, newspaper có association nhẹ với sales.

5. *Có thể dự đoán future sales chính xác đến đâu?*

Response được dự đoán bằng (3.21). Accuracy phụ thuộc vào việc ta muốn dự đoán individual response $Y = f(X) + \epsilon$ hay average response $f(X)$ (Mục 3.2.2). Trường hợp đầu dùng prediction interval; trường

hợp sau dùng confidence interval. Prediction interval luôn rộng hơn vì tính cả uncertainty gắn với ϵ , tức irreducible error.

6. *Quan hệ có tuyến tính không?*

Residual plot có thể nhận diện tính phi tuyến. Nếu quan hệ tuyến tính, residual plot không nên có pattern. Với dữ liệu **Advertising**, ta thấy nonlinear effect trong Hình 3.5; hiệu ứng này cũng có thể quan sát trên residual plot. Trong Mục 3.3.2, ta đã đưa transformation của predictor vào linear regression model để xử lý quan hệ phi tuyến.

7. *Có synergy giữa các advertising media không?*

Linear regression model chuẩn giả định quan hệ additive giữa predictor và response. Additive model dễ diễn giải vì association giữa từng predictor với response không phụ thuộc giá trị predictor khác. Tuy nhiên, giả định này có thể không thực tế. Trong Mục 3.3.2, interaction term được thêm vào regression model để biểu diễn quan hệ non-additive; p -value nhỏ của interaction term chỉ ra sự hiện diện của quan hệ đó. Hình 3.5 gợi ý dữ liệu **Advertising** có thể không additive. Thêm interaction term làm R^2 tăng đáng kể, từ khoảng 90% lên gần 97%.

3.5 So sánh Linear Regression với K-Nearest Neighbors

Như đã thảo luận trong Chương 2, linear regression là một parametric approach vì nó giả định functional form tuyến tính cho $f(X)$. Parametric method có một số ưu điểm: thường dễ fit vì chỉ cần ước lượng ít coefficient; trong linear regression, coefficient có cách diễn giải đơn giản và dễ thực hiện statistical significance test. Nhưng chúng cũng có nhược điểm: ngay từ cách xây dựng, chúng đặt giả định mạnh lên dạng của $f(X)$. Nếu functional form được chỉ định khác xa sự thật và mục tiêu là prediction accuracy, parametric method sẽ hoạt động kém. Chẳng hạn, nếu giả định quan hệ tuyến tính giữa X và Y trong khi quan hệ thực khác xa tuyến tính, model fit sẽ kém và mọi kết luận đều đáng ngờ.

Trái lại, non-parametric method không giả định tường minh một parametric form cho $f(X)$, do đó cung cấp cách tiếp cận regression linh hoạt hơn. Cuốn sách sẽ bàn nhiều phương pháp non-parametric. Ở đây, ta xét một phương pháp đơn giản và nổi tiếng: *K-nearest neighbors regression* (KNN regression), họ hàng gần của KNN classifier trong Chương 2. Với K và prediction point x_0 , KNN regression trước hết xác định K training observation gần x_0 nhất, ký hiệu $\mathcal{N}_0$, rồi ước lượng $f(x_0)$ bằng trung bình mọi training response trong $\mathcal{N}_0$:

$$\hat{f}(x_0) = \frac{1}{K} \sum_{x_i \in \mathcal{N}_0} y_i.$$

Hình 3.16 minh họa hai KNN fit trên dataset có $p = 2$ predictor. Panel trái dùng $K = 1$, panel phải dùng $K = 9$. Khi $K = 1$, KNN fit nội suy hoàn hảo training observation và có dạng step function gồ ghề. Với $K = 9$,

*K-nearest
neighbors
regression*




FIGURE 3.16. Plots of $\hat{f}(X)$ using KNN regression on a two-dimensional data set with 64 observations (orange dots). Left: $K = 1$ results in a rough step function fit. Right: $K = 9$ produces a much smoother fit.

HÌNH 3.16. Đồ thị $\hat{f}(X)$ bằng KNN regression trên dataset hai chiều có 64 observation (chấm cam). Trái: $K = 1$ tạo một step-function fit gồ ghề. Phải: $K = 9$ tạo fit mượt hơn nhiều.


nó vẫn là step function, nhưng việc lấy trung bình chín observation tạo các vùng dự đoán hằng nhỏ hơn và fit mượt hơn.

Nói chung, K tối ưu phụ thuộc bias–variance tradeoff đã giới thiệu ở Chương 2. K nhỏ cho fit linh hoạt nhất, bias thấp nhưng variance cao, vì prediction trong một vùng hoàn toàn phụ thuộc chỉ một observation. K lớn cho fit mượt và ít biến thiên hơn; prediction là trung bình của nhiều điểm nên thay đổi một observation ít ảnh hưởng hơn. Tuy nhiên, smoothing có thể tạo bias do che khuất cấu trúc trong $f(X)$. Chương 5 giới thiệu một số cách ước lượng test error rate, có thể dùng để tìm K tối ưu.


Khi nào parametric approach như least squares linear regression vượt non-parametric approach như KNN? Câu trả lời đơn giản: khi parametric form được chọn gần dạng thực của f . Hình 3.17 minh họa dữ liệu sinh từ one-dimensional linear regression model. Đường đen liền là $f(X)$, đường xanh là KNN fit với $K = 1$ và $K = 9$. Prediction khi $K = 1$ biến thiên quá mạnh, còn fit $K = 9$ mượt hơn và gần $f(X)$ hơn. Nhưng vì quan hệ thực tuyến tính, non-parametric approach khó cạnh tranh với linear regression: nó phải trả giá bằng variance mà không được bù lại bởi bias thấp hơn.

Đường xanh đứt ở panel trái Hình 3.18 là linear regression fit trên cùng dữ liệu và gần như hoàn hảo. Panel phải cho thấy linear regression vượt KNN: đường xanh lục biểu diễn test-set mean squared error (MSE) của KNN theo $1/K$, còn đường đen đứt là test MSE của linear regression. KNN error cao hơn; với K lớn nó chỉ kém least squares một chút, nhưng kém xa khi K nhỏ.

Trong thực tế, quan hệ giữa X và Y hiếm khi tuyến tính hoàn toàn. Hình 3.19 so sánh least squares regression với KNN khi mức phi tuyến



HÌNH 3.17. Đồ thị $\hat{f}(X)$ bằng KNN regression trên dataset một chiều có 50 observation. Quan hệ thực là đường đen liền. Trái: Đường xanh với $K = 1$ nội suy training data. Phải: Đường xanh với $K = 9$ cho fit mượt hơn.



HÌNH 3.18. Khảo sát tiếp dataset trong Hình 3.17. Trái: Đường xanh đứt là least squares fit; vì $f(X)$ thực sự tuyến tính (đường đen), regression line ước lượng $f(X)$ rất tốt. Phải: Đường ngang đứt là least-squares test MSE; đường xanh lục là KNN MSE theo $1/K$ trên log scale. Linear regression có test MSE thấp hơn. KNN tốt nhất khi K rất lớn, tương ứng $1/K$ nhỏ.

tăng. Hàng trên có quan hệ gần tuyến tính: test MSE của linear regression tốt hơn KNN khi K nhỏ, nhưng KNN vượt linear regression khi $K \geq 4$. Hàng dưới lệch tuyến tính mạnh hơn; KNN vượt đáng kể linear regression với mọi K . Khi mức phi tuyến tăng, test MSE của KNN gần như không đổi, còn test MSE của linear regression tăng mạnh.

Hình 3.18 và Hình 3.19 cho thấy KNN kém linear regression một chút khi quan hệ tuyến tính nhưng tốt hơn nhiều khi phi tuyến. Khi không biết quan hệ thực, có vẻ nên ưu tiên KNN: tệ nhất chỉ kém nhẹ nếu quan hệ tuyến tính, nhưng có thể tốt hơn đáng kể nếu phi tuyến. Tuy nhiên, ngay cả




FIGURE 3.19. Top Left: In a setting with a slightly non-linear relationship between X and Y (solid black line), the KNN fits with $K = 1$ (blue) and $K = 9$ (red) are displayed. Top Right: For the slightly non-linear data, the test set MSE for least squares regression (horizontal black) and KNN with various values of $1/K$ (green) are displayed. Bottom Left and Bottom Right: As in the top panel, but with a strongly non-linear relationship between X and Y .

HÌNH 3.19. Trên trái: Với quan hệ hơi phi tuyến giữa X, Y (đường đen liền), biểu diễn KNN fit $K = 1$ (xanh) và $K = 9$ (đỏ). Trên phải: Test MSE của least squares regression (ngang đen) và KNN theo các giá trị $1/K$ (xanh lục). Hai panel dưới: Tương tự hàng trên nhưng quan hệ giữa X, Y phi tuyến mạnh.

khi quan hệ thực highly non-linear, KNN vẫn có thể kém linear regression. Các hình trên đều chỉ có $p = 1$ predictor; trong higher dimension, KNN thường hoạt động kém hơn.

Hình 3.20 xét cùng tình huống phi tuyến mạnh như hàng dưới Hình 3.19, nhưng thêm các noise predictor không associated với response. Khi $p = 1$ hoặc $p = 2$, KNN vượt linear regression. Với $p = 3$, kết quả lẫn lộn; khi $p \geq 4$, linear regression tốt hơn. Tăng dimension chỉ làm linear-regression test MSE giảm nhẹ, nhưng khiến KNN MSE tăng hơn mười lần.

Performance của KNN giảm khi dimension tăng vì sample size hữu hiệu bị thu nhỏ. Dataset có 50 training observation; với $p = 1$, lượng thông




FIGURE 3.20. Test MSE for linear regression (black dashed lines) and KNN (green curves) as the number of variables p increases. The true function is non-linear in the first variable, as in the lower panel in Figure 3.19, and does not depend on the additional variables. The performance of linear regression deteriorates slowly in the presence of these additional noise variables, whereas KNN's performance degrades much more quickly as p increases.

and 3.19 illustrate settings with $p = 1$ predictor. But in higher dimensions,

HÌNH 3.20. Test MSE của linear regression (đường đen đứt) và KNN (đường xanh lục) khi số biến p tăng. Hàm thực phi tuyến theo biến thứ nhất, như panel dưới Hình 3.19, và không phụ thuộc các biến bổ sung. Noise variable làm linear-regression performance giảm chậm, còn KNN giảm nhanh hơn nhiều khi p tăng.

tin này đủ để ước lượng chính xác $f(X)$. Nhưng trải 50 observation trên $p = 20$ dimension dẫn đến hiện tượng một observation không có neighbor nào thực sự gần—gọi là *curse of dimensionality*. Khi p lớn, K observation gần một test observation x_0 nhất vẫn có thể ở rất xa x_0 trong không gian p chiều, dẫn đến prediction $f(x_0)$ rất kém và KNN fit kém. Theo nguyên tắc chung, parametric method có xu hướng vượt non-parametric approach khi số observation trên mỗi predictor nhỏ.

curse of dimensionality

Ngay cả khi dimension nhỏ, ta vẫn có thể chọn linear regression thay vì KNN vì interpretability. Nếu test MSE của KNN chỉ thấp hơn một chút, ta có thể chấp nhận mất ít prediction accuracy để đổi lấy mô hình đơn giản, mô tả bằng vài coefficient và có sẵn p -value.