

3.7 Exercises



Conceptual

1. Hãy mô tả các null hypothesis tương ứng với những p -value trong Bảng 3.4. Giải thích các kết luận có thể rút ra từ những p -value này. Phần giải thích phải được diễn đạt theo **sales**, **TV**, **radio** và **newspaper**, thay vì theo coefficient của linear model.
2. Giải thích cẩn thận sự khác nhau giữa KNN classifier và KNN regression.
3. Giả sử ta có dataset với năm predictor: $X_1 = \text{GPA}$, $X_2 = \text{IQ}$, $X_3 = \text{Level}$ (1 cho College, 0 cho High School), X_4 là interaction giữa GPA và IQ, còn X_5 là interaction giữa GPA và Level. Response là mức lương khởi điểm sau khi tốt nghiệp, tính bằng nghìn đô la. Dùng least squares fit mô hình và thu được

$$\hat{\beta}_0 = 50, \quad \hat{\beta}_1 = 20, \quad \hat{\beta}_2 = 0.07, \quad \hat{\beta}_3 = 35, \quad \hat{\beta}_4 = 0.01, \quad \hat{\beta}_5 = -10.$$

- (a) Đáp án nào đúng, và tại sao?
 - i. Với IQ và GPA cố định, trung bình học sinh tốt nghiệp High School kiếm được nhiều hơn người tốt nghiệp College.
 - ii. Với IQ và GPA cố định, trung bình người tốt nghiệp College kiếm được nhiều hơn học sinh tốt nghiệp High School.
 - iii. Với IQ và GPA cố định, học sinh tốt nghiệp High School kiếm được nhiều hơn người tốt nghiệp College nếu GPA đủ cao.
 - iv. Với IQ và GPA cố định, người tốt nghiệp College kiếm được nhiều hơn học sinh tốt nghiệp High School nếu GPA đủ cao.
 - (b) Dự đoán lương của một người tốt nghiệp College có IQ bằng 110 và GPA bằng 4.0.
 - (c) Đúng hay sai: Vì coefficient của interaction term GPA/IQ rất nhỏ nên có rất ít bằng chứng về interaction effect. Hãy giải thích.
4. Tôi thu thập dataset có $n = 100$ observation, gồm một predictor và một quantitative response. Sau đó, tôi fit linear regression model và một cubic regression riêng biệt,

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon.$$

- (a) Giả sử quan hệ thực giữa X, Y là tuyến tính, $Y = \beta_0 + \beta_1 X + \epsilon$. Xét training RSS của linear regression và cubic regression. Ta kỳ vọng một giá trị thấp hơn, kỳ vọng chúng bằng nhau, hay chưa đủ thông tin để kết luận? Hãy giải thích.
- (b) Trả lời (a) khi dùng test RSS thay cho training RSS.
- (c) Giả sử quan hệ thực giữa X, Y không tuyến tính nhưng ta không biết nó lệch tuyến tính bao xa. Xét training RSS của linear

regression và cubic regression. Ta kỳ vọng một giá trị thấp hơn, chúng bằng nhau, hay chưa đủ thông tin? Hãy giải thích.

(d) Trả lời (c) khi dùng test RSS thay cho training RSS.

5. Xét fitted value thu được từ linear regression không có intercept. Khi đó, fitted value thứ i là

$$\hat{y}_i = x_i \hat{\beta}, \quad \hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}. \quad (3.1)$$

Chứng minh rằng có thể viết

$$\hat{y}_i = \sum_{i'=1}^n a_{i'} y_{i'}.$$

$a_{i'}$ là gì?

Lưu ý: Kết quả này được diễn giải rằng fitted value của linear regression là linear combination của response value.

6. Dùng (3.4) để lập luận rằng trong simple linear regression, least squares line luôn đi qua điểm $(\bar{x}, \bar{y})$.
7. Trong simple linear regression của Y trên X , sách khẳng định R^2 statistic (3.17) bằng bình phương correlation giữa X, Y trong (3.18). Hãy chứng minh. Để đơn giản, có thể giả sử $\bar{x} = \bar{y} = 0$.

Applied

8. Bài này dùng simple linear regression trên dataset `Auto`.
- Dùng function `sm.OLS()` thực hiện simple linear regression với `mpg` là response và `horsepower` là predictor. Dùng `summarize()` in kết quả và nhận xét output, chẳng hạn:
 - Predictor và response có quan hệ không?
 - Mối quan hệ mạnh đến đâu?
 - Quan hệ dương hay âm?
 - Predicted `mpg` ứng với `horsepower=98` là bao nhiêu? Confidence interval và prediction interval 95% tương ứng là gì?
 - Vẽ response và predictor trên một tập axis mới `ax`. Dùng method `ax.axline()` hoặc function `abline()` đã định nghĩa trong lab để biểu diễn least squares regression line.
 - Tạo một số diagnostic plot của least squares regression fit như mô tả trong lab. Nhận xét mọi vấn đề nhìn thấy ở fit.
9. Bài này dùng multiple linear regression trên dataset `Auto`.
- Tạo scatterplot matrix gồm mọi biến trong dataset.
 - Tính correlation matrix giữa các biến bằng method `DataFrame.corr()`.

- (c) Dùng `sm.OLS()` thực hiện multiple linear regression với `mpg` là response và mọi biến khác trừ `name` là predictor. Dùng `summarize()` in kết quả và nhận xét output, chẳng hạn:
- Các predictor và response có quan hệ không? Dùng `anova_lm()` từ `statsmodels` để trả lời.
 - Predictor nào có quan hệ statistically significant với response?
 - Coefficient của biến `year` gợi ý điều gì?
- (d) Tạo một số diagnostic plot của linear regression fit như trong lab. Nhận xét vấn đề nhìn thấy. Residual plot có gợi ý outlier đặc biệt lớn không? Leverage plot có chỉ ra observation có leverage cao bất thường không?
- (e) Fit một số model có interaction như trong lab. Interaction nào statistically significant không?
- (f) Thử vài transformation khác nhau của biến, như $\log(X)$, $\sqrt{X}$, X^2 . Nhận xét kết quả.
10. Trả lời bài này bằng dataset `Carseats`.
- Fit multiple regression model dự đoán `Sales` bằng `Price`, `Urban` và `US`.
 - Diễn giải từng coefficient trong mô hình. Hãy cẩn thận: một số biến là qualitative.
 - Viết mô hình dưới dạng equation, xử lý đúng qualitative variable.
 - Với predictor nào có thể bác bỏ null hypothesis $H_0 : \beta_j = 0$?
 - Dựa trên câu trước, fit mô hình nhỏ hơn chỉ dùng predictor có bằng chứng associated với outcome.
 - Mô hình ở (a) và (e) fit dữ liệu tốt đến đâu?
 - Dùng mô hình ở (e), tìm confidence interval 95% cho các coefficient.
 - Có bằng chứng về outlier hay high-leverage observation trong mô hình ở (e) không?
11. Ta khảo sát t -statistic cho null hypothesis $H_0 : \beta = 0$ trong simple linear regression không có intercept. Trước hết, tạo predictor `x` và response `y` như sau:
- ```
rng = np.random.default_rng(1)
x = rng.normal(size=100)
y = 2 * x + rng.normal(size=100)
```
- Thực hiện simple linear regression của `y` trên `x`, không có intercept. Báo cáo coefficient estimate  $\hat{\beta}$ , standard error,  $t$ -statistic và  $p$ -value của  $H_0 : \beta = 0$ ; nhận xét kết quả. Có thể regression không intercept bằng keyword argument `intercept=False` cho `ModelSpec()`.
  - Regression `x` trên `y` không intercept, rồi báo cáo coefficient estimate, standard error,  $t$ -statistic và  $p$ -value tương ứng với  $H_0 : \beta = 0$ . Nhận xét.

- (c) Kết quả ở (a) và (b) liên hệ thế nào?
- (d) Với regression  $Y$  trên  $X$  không intercept,  $t$ -statistic cho  $H_0 : \beta = 0$  là  $\hat{\beta}/\text{SE}(\hat{\beta})$ , trong đó  $\hat{\beta}$  được cho bởi (3.38) và

$$\text{SE}(\hat{\beta}) = \sqrt{\frac{\sum_{i=1}^n (y_i - x_i \hat{\beta})^2}{(n-1) \sum_{i'=1}^n x_{i'}^2}}.$$

Chứng minh bằng đại số và xác nhận bằng số trong Python rằng  $t$ -statistic có thể viết thành

$$\frac{\sqrt{n-1} \sum_{i=1}^n x_i y_i}{\sqrt{(\sum_{i=1}^n x_i^2) (\sum_{i'=1}^n y_{i'}^2) - (\sum_{i'=1}^n x_{i'} y_{i'})^2}}.$$

- (e) Từ (d), lập luận rằng  $t$ -statistic của regression  $\mathbf{y}$  trên  $\mathbf{x}$  giống  $t$ -statistic của regression  $\mathbf{x}$  trên  $\mathbf{y}$ .
- (f) Trong Python, chỉ ra rằng khi regression có intercept,  $t$ -statistic cho  $H_0 : \beta_1 = 0$  giống nhau giữa regression  $\mathbf{y}$  trên  $\mathbf{x}$  và regression  $\mathbf{x}$  trên  $\mathbf{y}$ .
12. Bài này xét simple linear regression không có intercept.
- (a) Nhớ rằng coefficient estimate  $\hat{\beta}$  của regression  $Y$  trên  $X$  không intercept được cho bởi (3.38). Trong điều kiện nào coefficient estimate của regression  $X$  trên  $Y$  bằng coefficient estimate của regression  $Y$  trên  $X$ ?
- (b) Tạo một ví dụ bằng Python với  $n = 100$  observation trong đó hai coefficient estimate khác nhau.
- (c) Tạo một ví dụ bằng Python với  $n = 100$  observation trong đó hai coefficient estimate bằng nhau.
13. Trong bài này, bạn sẽ tạo dữ liệu mô phỏng và fit simple linear regression model. Trước phần (a), hãy dùng default random number generator với seed bằng 1 để bảo đảm kết quả nhất quán.
- (a) Dùng method `normal()` của random number generator tạo vector  $\mathbf{x}$  gồm 100 observation từ phân phối  $N(0, 1)$ . Đây là feature  $X$ .
- (b) Dùng `normal()` tạo vector  $\mathbf{eps}$  gồm 100 observation từ phân phối  $N(0, 0.25)$ —normal distribution có mean 0 và variance 0,25.
- (c) Dùng  $\mathbf{x}$ ,  $\mathbf{eps}$  tạo vector  $\mathbf{y}$  theo mô hình

$$Y = -1 + 0.5X + \epsilon. \quad (3.2)$$

Vector  $\mathbf{y}$  dài bao nhiêu?  $\beta_0, \beta_1$  của linear model bằng bao nhiêu?

- (d) Tạo scatterplot biểu diễn quan hệ giữa  $\mathbf{x}$ ,  $\mathbf{y}$ . Nhận xét điều quan sát được.
- (e) Fit least squares linear model dự đoán  $\mathbf{y}$  bằng  $\mathbf{x}$ . Nhận xét mô hình.  $\hat{\beta}_0, \hat{\beta}_1$  so với  $\beta_0, \beta_1$  thế nào?

- (f) Vẽ least squares line trên scatterplot ở (d). Vẽ population regression line bằng màu khác. Dùng method `legend()` của axis tạo legend phù hợp.
- (g) Fit polynomial regression model dự đoán  $y$  bằng  $x$ ,  $x^2$ . Có bằng chứng quadratic term cải thiện model fit không? Giải thích.
- (h) Lặp (a)–(f) sau khi sửa data-generation process để dữ liệu ít noise hơn, vẫn giữ mô hình (3.39). Có thể giảm variance của normal distribution dùng tạo error term  $\epsilon$  ở (b). Mô tả kết quả.
- (i) Lặp (a)–(f) với nhiều noise hơn bằng cách tăng variance của error term, vẫn giữ (3.39). Mô tả kết quả.
- (j) Confidence interval của  $\beta_0, \beta_1$  trên dataset gốc, dataset nhiều noise và dataset ít noise là gì? Nhận xét.

14. Bài này tập trung vào collinearity.

- (a) Thực hiện các lệnh Python sau:

```
rng = np.random.default_rng(10)
x1 = rng.uniform(0, 1, size=100)
x2 = 0.5 * x1 + rng.normal(size=100) / 10
y = 2 + 2 * x1 + 0.3 * x2 + rng.normal(size=100)
```

Dòng cuối tạo linear model trong đó  $y$  là hàm của  $x1$ ,  $x2$ . Viết dạng linear model và xác định regression coefficient.

- (b) Correlation giữa  $x1$ ,  $x2$  bằng bao nhiêu? Tạo scatterplot biểu diễn quan hệ giữa chúng.
- (c) Dùng dữ liệu này fit least squares regression dự đoán  $y$  bằng  $x1$ ,  $x2$ . Mô tả kết quả.  $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$  bằng bao nhiêu và liên hệ thế nào với giá trị thực? Có bác bỏ  $H_0 : \beta_1 = 0$  không? Còn  $H_0 : \beta_2 = 0$ ?
- (d) Fit least squares regression dự đoán  $y$  chỉ bằng  $x1$ . Nhận xét. Có bác bỏ  $H_0 : \beta_1 = 0$  không?
- (e) Fit least squares regression dự đoán  $y$  chỉ bằng  $x2$ . Nhận xét. Có bác bỏ  $H_0 : \beta_1 = 0$  không?
- (f) Kết quả ở (c)–(e) có mâu thuẫn nhau không? Giải thích.
- (g) Giả sử có thêm một observation bị đo sai. Dùng `np.concatenate()` thêm nó vào  $x1$ ,  $x2$ ,  $y$ :

```
x1 = np.concatenate([x1, [0.1]])
x2 = np.concatenate([x2, [0.8]])
y = np.concatenate([y, [6]])
```

Fit lại các linear model từ (c)–(e). Observation mới ảnh hưởng thế nào đến từng mô hình? Trong mỗi mô hình, nó là outlier, high-leverage point, cả hai, hay không phải? Giải thích.

15. Bài này dùng dataset `Boston` đã gặp trong lab. Ta dự đoán per-capita crime rate bằng các biến khác: crime rate là response và các biến còn lại là predictor.

- (a) Với từng predictor, fit simple linear regression model để dự đoán response. Mô tả kết quả. Mô hình nào có association statistically significant giữa predictor và response? Tạo plot hỗ trợ kết luận.
- (b) Fit multiple regression model dự đoán response bằng mọi predictor. Mô tả kết quả. Với predictor nào có thể bác bỏ  $H_0 : \beta_j = 0$ ?
- (c) So sánh kết quả (a) với (b). Tạo plot có univariate regression coefficient ở trục  $x$  và multiple regression coefficient ở trục  $y$ . Mỗi predictor là một điểm: coefficient simple linear regression trên trục  $x$ , coefficient estimate multiple linear regression trên trục  $y$ .
- (d) Có bằng chứng về association phi tuyến giữa predictor nào và response không? Với từng predictor  $X$ , fit mô hình

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon.$$