



Classification

Linear regression model được thảo luận trong Chương 3 giả định response variable Y là quantitative. Nhưng trong nhiều tình huống, response variable lại là qualitative. Chẳng hạn, màu mắt là qualitative. Các qualitative variable thường được gọi là categorical; chúng tôi sẽ dùng hai thuật ngữ này thay thế cho nhau. Trong chương này, ta nghiên cứu các cách tiếp cận để dự đoán qualitative response, một quá trình được gọi là *classification*. Việc dự đoán qualitative response cho một observation có thể được gọi là phân loại observation đó, vì nó bao gồm việc gán observation vào một category, hay class. Mặt khác, các phương pháp dùng cho classification thường trước hết dự đoán xác suất observation thuộc về từng category của qualitative variable, rồi dựa vào đó để thực hiện classification. Theo nghĩa này, chúng cũng hoạt động giống các regression method.

Có nhiều kỹ thuật classification, hay *classifier*, có thể được dùng để dự đoán qualitative response. Ta đã đề cập sơ lược một số kỹ thuật trong các Mục 2.1.5 và 2.2.3. Trong chương này, chúng tôi thảo luận một số classifier được dùng rộng rãi: *logistic regression*, *linear discriminant analysis*, *quadratic discriminant analysis*, *naive Bayes* và *K-nearest neighbors*. Phần trình bày logistic regression được dùng làm điểm xuất phát để thảo luận *generalized linear model*, đặc biệt là *Poisson regression*. Những classification method đòi hỏi tính toán chuyên sâu hơn sẽ được thảo luận ở các chương sau: gồm generalized additive model (Chương 7); tree, random forest và boosting (Chương 8); cùng support vector machine (Chương 9).

4.1 An Overview of Classification

Các bài toán classification xuất hiện rất thường xuyên, thậm chí có lẽ còn thường xuyên hơn bài toán regression. Một số ví dụ gồm:

classification

classifier

logistic
regressionlinear
discriminant
analysisquadratic
discriminant
analysis

naive Bayes

K-nearest
neighborsgeneralized
linear modelPoisson
regression

1. Một người đến phòng cấp cứu với một tập triệu chứng có thể được quy cho một trong ba tình trạng bệnh lý. Người đó mắc tình trạng nào trong ba tình trạng này?
2. Một dịch vụ ngân hàng trực tuyến phải xác định một giao dịch đang được thực hiện trên trang có gian lận hay không, dựa trên địa chỉ IP của người dùng, lịch sử giao dịch trước đây, v.v.
3. Dựa trên dữ liệu DNA sequence của một số bệnh nhân có và không mắc một căn bệnh nhất định, một nhà sinh học muốn xác định những DNA mutation nào là deleterious (gây bệnh) và những mutation nào không.

Cũng như trong bối cảnh regression, trong bối cảnh classification ta có một tập training observation $(x_1, y_1), \dots, (x_n, y_n)$ để xây dựng classifier. Ta muốn classifier hoạt động tốt không chỉ trên training data mà cả trên những test observation không được dùng để train classifier.


Trong chương này, chúng tôi minh họa khái niệm classification bằng dataset mô phỏng **Default**. Ta quan tâm đến việc dự đoán liệu một cá nhân có default khoản thanh toán thẻ tín dụng hay không, dựa trên annual income và monthly credit card balance. Dataset được biểu diễn trong Hình 4.1. Ở ô bên trái của Hình 4.1, chúng tôi vẽ annual income và monthly credit card balance cho một tập con gồm 10.000 cá nhân. Những người default trong một tháng nhất định được biểu diễn bằng màu cam, còn những người không default bằng màu xanh lam. (Default rate tổng thể khoảng 3%, vì vậy chúng tôi chỉ vẽ một phần những người không default.) Có vẻ những người default có xu hướng mang credit card balance cao hơn những người không default. Hai ô giữa và phải của Hình 4.1 biểu diễn hai cặp boxplot. Cặp thứ nhất cho thấy distribution của **balance** được chia theo binary variable **default**; cặp thứ hai là đồ thị tương tự cho **income**. Trong chương này, ta sẽ học cách xây dựng một model để dự đoán **default** (Y) với bất kỳ giá trị nào của **balance** (X_1) và **income** (X_2). Vì Y không phải quantitative, simple linear regression model của Chương 3 không phải lựa chọn tốt; ta sẽ giải thích kỹ hơn điều này trong Mục 4.2.

Đáng lưu ý là Hình 4.1 thể hiện mối quan hệ rất rõ rệt giữa predictor **balance** và response **default**. Trong phần lớn ứng dụng thực tế, mối quan hệ giữa predictor và response sẽ không mạnh đến vậy. Tuy nhiên, để minh họa các classification procedure được thảo luận trong chương này, chúng tôi dùng một ví dụ trong đó mối quan hệ giữa predictor và response được nhấn mạnh hơn đôi chút.

4.2 Why Not Linear Regression?

Chúng tôi đã khẳng định rằng linear regression không phù hợp khi response là qualitative. Tại sao?

Giả sử ta đang cố dự đoán tình trạng bệnh lý của một bệnh nhân tại phòng cấp cứu dựa trên các triệu chứng của người đó. Trong ví dụ đơn giản này, có ba chẩn đoán khả dĩ: stroke, drug overdose và epileptic seizure. Ta



HÌNH 4.1. Dataset *Default*. Trái: Annual income và monthly credit card balance của một số cá nhân. Những người default khoản thanh toán thẻ tín dụng được biểu diễn bằng màu cam, còn những người không default bằng màu xanh lam. Giữa: Boxplot của *balance* theo trạng thái *default*. Phải: Boxplot của *income* theo trạng thái *default*.

có thể cần nhắc mã hóa các giá trị này thành một quantitative response variable Y như sau:

$$Y = \begin{cases} 1 & \text{nếu stroke;} \\ 2 & \text{nếu drug overdose;} \\ 3 & \text{nếu epileptic seizure.} \end{cases}$$

Với cách mã hóa này, có thể dùng least squares để fit một linear regression model nhằm dự đoán Y dựa trên một tập predictor $X_1, \dots, X_p$. Tiếc rằng cách mã hóa này áp đặt một thứ tự lên các outcome: đặt drug overdose ở giữa stroke và epileptic seizure, đồng thời buộc chênh lệch giữa stroke và drug overdose phải bằng chênh lệch giữa drug overdose và epileptic seizure. Trong thực tế, không có lý do cụ thể nào khiến điều này phải đúng. Chẳng hạn, ta có thể chọn một cách mã hóa hợp lý không kém:

$$Y = \begin{cases} 1 & \text{nếu epileptic seizure;} \\ 2 & \text{nếu stroke;} \\ 3 & \text{nếu drug overdose,} \end{cases}$$

nhưng cách này lại hàm ý một mối quan hệ hoàn toàn khác giữa ba tình trạng. Mỗi cách mã hóa sẽ tạo ra những linear model khác nhau về căn bản, cuối cùng dẫn đến những tập prediction khác nhau trên test observation.

Nếu các giá trị của response variable thực sự có một thứ tự tự nhiên, chẳng hạn mild, moderate và severe, đồng thời ta cho rằng khoảng cách giữa mild và moderate tương tự khoảng cách giữa moderate và severe, thì cách mã hóa 1, 2, 3 là hợp lý. Tiếc rằng nhìn chung không có cách tự nhiên nào để chuyển một qualitative response variable có hơn hai level thành một quantitative response sẵn sàng cho linear regression.

Với binary qualitative response (có hai level), tình hình tốt hơn. Chẳng hạn, có thể chỉ có hai khả năng đối với tình trạng bệnh lý của bệnh nhân:

stroke và drug overdose. Khi đó, ta có thể dùng cách tiếp cận dummy variable từ Mục 3.3.1 để mã hóa response như sau:

$$Y = \begin{cases} 0 & \text{nếu stroke;} \\ 1 & \text{nếu drug overdose.} \end{cases}$$

Sau đó, ta có thể fit linear regression cho binary response này và dự đoán drug overdose nếu $\hat{Y} > 0.5$, còn không thì dự đoán stroke. Trong trường hợp binary, không khó để chứng minh rằng ngay cả khi đảo cách mã hóa trên, linear regression vẫn tạo ra cùng những prediction cuối cùng.

Đối với binary response được mã hóa 0/1 như trên, regression bằng least squares không hoàn toàn vô lý: có thể chứng minh rằng $X\hat{\beta}$ thu được bằng linear regression thực ra là một ước lượng của $\Pr(\text{drug overdose} \mid X)$ trong trường hợp đặc biệt này. Tuy nhiên, nếu dùng linear regression, một số ước lượng có thể nằm ngoài khoảng $[0, 1]$ (xem Hình 4.2), khiến chúng khó được diễn giải như xác suất! Dẫu vậy, các prediction vẫn cung cấp một thứ tự và có thể được diễn giải như những ước lượng xác suất thô. Điều khá thú vị là classification thu được khi dùng linear regression để dự đoán binary response sẽ giống với classification của thủ tục linear discriminant analysis (LDA) được thảo luận trong Mục 4.4.

Tóm lại, có ít nhất hai lý do không nên thực hiện classification bằng regression method: (a) regression method không thể xử lý qualitative response có hơn hai class; (b) regression method sẽ không cung cấp các ước lượng có ý nghĩa cho $\Pr(Y \mid X)$, ngay cả khi chỉ có hai class. Vì vậy, nên dùng một classification method thực sự phù hợp với qualitative response value. Ở mục tiếp theo, chúng tôi trình bày logistic regression, phương pháp rất phù hợp cho binary qualitative response; trong các mục sau nữa, chúng tôi sẽ đề cập những classification method thích hợp khi qualitative response có từ hai class trở lên.