




HÌNH 4.2. Classification bằng dữ liệu *Default*. Trái: Xác suất default ước lượng bằng linear regression. Một số xác suất ước lượng mang giá trị âm! Các vạch màu cam biểu diễn giá trị 0/1 được mã hóa cho *default* (No hoặc Yes). Phải: Xác suất default dự đoán bằng logistic regression. Mọi xác suất đều nằm giữa 0 và 1.

4.3 Logistic Regression

Xét lại dataset *Default*, trong đó response *default* thuộc một trong hai category, *Yes* hoặc *No*. Thay vì trực tiếp modeling response Y này, logistic regression modeling xác suất Y thuộc một category cụ thể.

Với dữ liệu *Default*, logistic regression modeling xác suất default. Chẳng hạn, xác suất default khi biết *balance* có thể được viết là

$$\Pr(\text{default} = \text{Yes} \mid \text{balance}).$$

Các giá trị của $\Pr(\text{default} = \text{Yes} \mid \text{balance})$, được viết tắt là $p(\text{balance})$, sẽ nằm trong khoảng từ 0 đến 1. Khi đó, với bất kỳ giá trị *balance* nào, ta đều có thể đưa ra prediction cho *default*. Chẳng hạn, có thể dự đoán $\text{default} = \text{Yes}$ cho mọi cá nhân có $p(\text{balance}) > 0.5$. Hoặc nếu một công ty muốn thận trọng khi dự đoán những cá nhân có nguy cơ default, họ có thể chọn threshold thấp hơn, chẳng hạn $p(\text{balance}) > 0.1$.

4.3.1 The Logistic Model

Ta nên modeling mối quan hệ giữa $p(X) = \Pr(Y = 1 \mid X)$ và X như thế nào? (Để tiện trình bày, ta dùng cách mã hóa response tổng quát 0/1.) Trong Mục 4.2, ta đã cân nhắc dùng linear regression model để biểu diễn các xác suất này:

$$p(X) = \beta_0 + \beta_1 X. \quad (4.1)$$

Nếu dùng cách tiếp cận này để dự đoán $\text{default} = \text{Yes}$ bằng *balance*, ta thu được model trong ô bên trái của Hình 4.2. Ở đây, vấn đề của cách tiếp cận này bộc lộ rõ: với *balance* gần bằng 0, ta dự đoán xác suất default âm; nếu dự đoán cho *balance* rất lớn, ta sẽ nhận giá trị lớn hơn 1. Những prediction này không hợp lý, vì xác suất default thực, bất kể credit card *balance* là bao nhiêu, hiển nhiên phải nằm giữa 0 và 1. Vấn đề này không chỉ xảy ra với dữ liệu credit default. Bất cứ khi nào fit một đường thẳng cho binary response được mã hóa là 0 hoặc 1, về nguyên tắc ta luôn có thể

dự đoán $p(X) < 0$ với một số giá trị X và $p(X) > 1$ với những giá trị khác (trừ khi range của X bị giới hạn).

Để tránh vấn đề này, ta phải modeling $p(X)$ bằng một hàm cho output nằm giữa 0 và 1 với mọi giá trị X . Có nhiều hàm thỏa mãn mô tả đó. Trong logistic regression, ta dùng *logistic function*,

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}. \quad (4.2)$$

Để fit model (4.2), ta dùng một phương pháp gọi là *maximum likelihood*, sẽ được thảo luận ở mục tiếp theo. Ở bên phải của Hình 4.2 minh họa logistic regression model được fit vào dữ liệu **Default**. Lưu ý rằng với balance thấp, giờ đây xác suất default được dự đoán gần bằng nhưng không bao giờ nhỏ hơn 0. Tương tự, với balance cao, ta dự đoán xác suất default gần bằng nhưng không bao giờ lớn hơn 1. Logistic function luôn tạo ra đường cong hình chữ S như vậy, nên với mọi giá trị X , ta đều nhận được prediction hợp lý. Ta cũng thấy logistic model nắm bắt range của xác suất tốt hơn linear regression model ở đồ thị bên trái. Average fitted probability trong cả hai trường hợp là 0.0333 (lấy trung bình trên training data), bằng đúng tỷ lệ người default tổng thể trong dataset.

Sau một vài biến đổi của (4.2), ta thu được

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X}. \quad (4.3)$$

Đại lượng $p(X)/[1 - p(X)]$ được gọi là *odds* và có thể nhận mọi giá trị từ 0 đến ∞ . Odds gần 0 và ∞ lần lượt biểu thị xác suất default rất thấp và rất cao. Chẳng hạn, trung bình cứ 5 người có odds bằng 1/4 thì 1 người sẽ default, vì $p(X) = 0.2$ hàm ý odds bằng $0.2/(1 - 0.2) = 1/4$. Tương tự, trung bình cứ 10 người có odds bằng 9 thì 9 người sẽ default, vì $p(X) = 0.9$ hàm ý odds bằng $0.9/(1 - 0.9) = 9$. Trong horse-racing, theo truyền thống người ta dùng odds thay cho xác suất vì odds liên hệ tự nhiên hơn với betting strategy đúng.

Lấy logarithm hai vế của (4.3), ta có

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X. \quad (4.4)$$

Vế trái được gọi là *log odds* hoặc *logit*. Ta thấy logistic regression model (4.2) có logit tuyến tính theo X .

Nhớ lại từ Chương 3, trong linear regression model, β_1 cho biết mức thay đổi trung bình của Y đi kèm mức tăng một đơn vị của X . Trái lại, trong logistic regression model, tăng X một đơn vị làm log odds thay đổi β_1 (4.4). Tương đương, nó nhân odds với e^{β_1} (4.3). Tuy nhiên, vì mối quan hệ giữa $p(X)$ và X trong (4.2) không phải đường thẳng, β_1 không tương ứng với mức thay đổi của $p(X)$ đi kèm mức tăng một đơn vị của X . Mức thay đổi của $p(X)$ do X thay đổi một đơn vị phụ thuộc vào giá trị hiện tại của X . Nhưng bất kể X nhận giá trị nào, nếu β_1 dương thì tăng X sẽ đi kèm tăng $p(X)$; nếu β_1 âm thì tăng X sẽ đi kèm giảm $p(X)$. Việc $p(X)$ và X không có quan hệ đường thẳng, cũng như rate of change của $p(X)$ trên mỗi đơn vị thay đổi của X phụ thuộc vào giá trị hiện tại của X , cũng có thể thấy trực tiếp ở ô bên phải của Hình 4.2.

BẢNG 4.1. Với dữ liệu *Default*, các *coefficient estimate* của *logistic regression model* dự đoán xác suất default bằng *balance*. *balance* tăng một đơn vị đi kèm log odds của default tăng 0.0055 đơn vị.

	Coefficient	Std. error	z-statistic	p-value
Intercept	-10.6513	0.3612	-29.5	< 0.0001
balance	0.0055	0.0002	24.9	< 0.0001

4.3.2 Estimating the Regression Coefficients

Các coefficient β_0 và β_1 trong (4.2) chưa biết và phải được ước lượng dựa trên training data sẵn có. Trong Chương 3, ta dùng cách tiếp cận least squares để ước lượng các linear regression coefficient chưa biết. Dù có thể dùng (non-linear) least squares để fit model (4.4), phương pháp tổng quát hơn là maximum likelihood được ưu tiên vì có statistical property tốt hơn. Trực giác cơ bản của việc dùng maximum likelihood để fit logistic regression model như sau: ta tìm các ước lượng β_0 và β_1 sao cho xác suất default dự đoán $\hat{p}(x_i)$ của từng cá nhân theo (4.2) khớp sát nhất có thể với trạng thái default quan sát được của cá nhân đó. Nói cách khác, ta cố tìm $\hat{\beta}_0$ và $\hat{\beta}_1$ sao cho thay các ước lượng này vào model của $p(X)$ trong (4.2) sẽ cho một số gần 1 với mọi cá nhân đã default và một số gần 0 với mọi cá nhân không default. Trực giác này có thể được hình thức hóa bằng một phương trình toán học gọi là *likelihood function*:

likelihood
function

$$\ell(\beta_0, \beta_1) = \prod_{i: y_i=1} p(x_i) \prod_{i': y_{i'}=0} (1 - p(x_{i'})). \quad (4.5)$$

Các ước lượng $\hat{\beta}_0$ và $\hat{\beta}_1$ được chọn để maximize likelihood function này.

Maximum likelihood là một cách tiếp cận rất tổng quát, được dùng để fit nhiều non-linear model mà ta khảo sát xuyên suốt cuốn sách. Trong bối cảnh linear regression, cách tiếp cận least squares thực ra là một trường hợp đặc biệt của maximum likelihood. Các chi tiết toán học của maximum likelihood nằm ngoài phạm vi cuốn sách này. Tuy nhiên, nhìn chung logistic regression và các model khác có thể dễ dàng được fit bằng statistical software như R, nên ta không cần bận tâm đến chi tiết của thủ tục maximum likelihood fitting.

Bảng 4.1 trình bày coefficient estimate và thông tin liên quan thu được khi fit logistic regression model trên dữ liệu *Default* để dự đoán xác suất *default = Yes* bằng *balance*. Ta thấy $\hat{\beta}_1 = 0.0055$; điều này cho biết *balance* tăng đi kèm xác suất default tăng. Chính xác hơn, *balance* tăng một đơn vị đi kèm log odds của default tăng 0.0055 đơn vị.

Nhiều khía cạnh trong logistic regression output ở Bảng 4.1 tương tự linear regression output của Chương 3. Chẳng hạn, ta có thể đo độ chính xác của coefficient estimate bằng standard error. *z*-statistic trong Bảng 4.1 có vai trò giống *t*-statistic trong linear regression output, ví dụ Bảng 3.1. *z*-statistic ứng với β_1 bằng $\hat{\beta}_1 / \text{SE}(\hat{\beta}_1)$, nên giá trị tuyệt đối lớn của *z*-statistic cung cấp bằng chứng chống lại null hypothesis $H_0 : \beta_1 = 0$. Null hypothesis này hàm ý $p(X) = e^{\beta_0} / (1 + e^{\beta_0})$; nói cách khác, xác suất default không phụ thuộc vào *balance*. Vì *p*-value gắn với *balance* trong Bảng 4.1 cực nhỏ,

BẢNG 4.2. Với dữ liệu *Default*, các *coefficient estimate* của *logistic regression model* dự đoán xác suất default bằng *student status*. *Student status* được mã hóa thành *dummy variable*, nhận giá trị 1 với *student* và 0 với *non-student*, đồng thời được biểu diễn bằng biến *student[Yes]* trong bảng.

	Coefficient	Std. error	z-statistic	p-value
Intercept	-3.5041	0.0707	-49.55	< 0.0001
student[Yes]	0.4049	0.1150	3.52	0.0004

ta có thể bác bỏ H_0 . Nói cách khác, ta kết luận thực sự có association giữa balance và xác suất default. Estimated intercept trong Bảng 4.1 thường không phải điều được quan tâm; mục đích chính của nó là điều chỉnh average fitted probability cho khớp với tỷ lệ các giá trị 1 trong dữ liệu (ở đây là default rate tổng thể).

4.3.3 Making Predictions

Sau khi các coefficient đã được ước lượng, ta có thể tính xác suất default với bất kỳ credit card balance nào. Chẳng hạn, dùng coefficient estimate trong Bảng 4.1, ta dự đoán xác suất default của một cá nhân có balance 1.000 đô la là

$$\hat{p}(X) = \frac{e^{\hat{\beta}_0 + \hat{\beta}_1 X}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_1 X}} = \frac{e^{-10.6513 + 0.0055 \times 1,000}}{1 + e^{-10.6513 + 0.0055 \times 1,000}} = 0.00576,$$

thấp hơn 1%. Trái lại, xác suất default dự đoán cho một cá nhân có balance 2.000 đô la cao hơn nhiều, bằng 0.586 hay 58.6%.

Ta có thể dùng qualitative predictor với logistic regression model bằng cách tiếp cận dummy variable trong Mục 3.3.1. Chẳng hạn, dataset *Default* chứa qualitative variable *student*. Để fit một model dùng student status làm predictor variable, ta chỉ cần tạo dummy variable nhận giá trị 1 với student và 0 với non-student. Logistic regression model thu được khi dự đoán xác suất default từ student status được trình bày trong Bảng 4.2. Coefficient gắn với dummy variable là dương và *p*-value tương ứng có statistical significance. Điều này cho thấy student có xu hướng mang xác suất default cao hơn non-student:

$$\begin{aligned} \Pr(\text{default} = \text{Yes} \mid \text{student} = \text{Yes}) &= \frac{e^{-3.5041 + 0.4049 \times 1}}{1 + e^{-3.5041 + 0.4049 \times 1}} = 0.0431, \\ \Pr(\text{default} = \text{Yes} \mid \text{student} = \text{No}) &= \frac{e^{-3.5041 + 0.4049 \times 0}}{1 + e^{-3.5041 + 0.4049 \times 0}} = 0.0292. \end{aligned}$$

4.3.4 Multiple Logistic Regression

Bây giờ ta xét bài toán dự đoán binary response bằng nhiều predictor. Tương tự phép mở rộng từ simple sang multiple linear regression trong Chương 3, ta có thể tổng quát hóa (4.4) như sau:

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p, \quad (4.6)$$

BẢNG 4.3. Với dữ liệu *Default*, các coefficient estimate của logistic regression model dự đoán xác suất default bằng *balance*, *income* và *student status*. *Student status* được mã hóa thành dummy variable *student[Yes]*, nhận giá trị 1 với *student* và 0 với *non-student*. Khi fit model này, *income* được đo theo nghìn đô la.

	Coefficient	Std. error	z-statistic	p-value
Intercept	-10.8690	0.4923	-22.08	< 0.0001
balance	0.0057	0.0002	24.74	< 0.0001
income	0.0030	0.0082	0.37	0.7115
student[Yes]	-0.6468	0.2362	-2.74	0.0062


trong đó $X = (X_1, \dots, X_p)$ gồm p predictor. Phương trình 4.6 có thể được viết lại thành

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}. \quad (4.7)$$

Cũng như trong Mục 4.3.2, ta dùng maximum likelihood để ước lượng $\beta_0, \beta_1, \dots, \beta_p$.

Bảng 4.3 trình bày coefficient estimate của logistic regression model dùng *balance*, *income* (theo nghìn đô la) và *student status* để dự đoán xác suất default. Ở đây có một kết quả đáng ngạc nhiên. Các p -value gắn với *balance* và dummy variable của *student status* đều rất nhỏ, cho thấy mỗi biến đều associated với xác suất default. Tuy nhiên, coefficient của dummy variable lại âm, cho biết *student* ít có khả năng default hơn *non-student*. Trái lại, coefficient của dummy variable trong Bảng 4.2 là dương. Làm sao *student status* có thể associated với sự gia tăng xác suất default trong Bảng 4.2, nhưng lại associated với sự suy giảm xác suất default trong Bảng 4.3? Ở bên trái của Hình 4.3 minh họa bằng đồ thị nghịch lý có vẻ tồn tại này. Các đường liền màu cam và xanh lam lần lượt biểu diễn average default rate của *student* và *non-student* theo credit card balance. Coefficient âm của *student* trong multiple logistic regression cho biết với một giá trị *balance* và *income* cố định, *student* ít có khả năng default hơn *non-student*. Thật vậy, từ ô bên trái của Hình 4.3, ta thấy default rate của *student* không vượt quá default rate của *non-student* ở mọi giá trị *balance*. Nhưng các đường đứt đoạn nằm ngang gần đáy đồ thị, biểu diễn default rate của *student* và *non-student* được lấy trung bình trên mọi giá trị *balance* và *income*, lại gợi ý tác động ngược lại: overall *student* default rate cao hơn *non-student* default rate. Do đó, coefficient của *student* trong single-variable logistic regression output ở Bảng 4.2 là dương.

Ở bên phải của Hình 4.3 giải thích sự khác biệt này. Hai biến *student* và *balance* correlated với nhau. *Student* có xu hướng mang mức nợ cao hơn, và điều này lại associated với xác suất default cao hơn. Nói cách khác, *student* có nhiều khả năng mang credit card balance lớn; như ta biết từ ô bên trái của Hình 4.3, *balance* lớn thường associated với default rate cao. Vì vậy, dù một *student* cụ thể có credit card balance nhất định thường mang xác suất default thấp hơn một *non-student* có cùng credit card balance, việc *student* nhìn chung có credit card balance cao hơn đồng nghĩa với việc xét tổng thể, *student* có xu hướng default với rate cao hơn *non-student*. Đây là khác biệt quan trọng đối với một công ty thẻ tín dụng đang xác định nên



HÌNH 4.3. *Confounding trong dữ liệu **Default**. Trái: Default rate của student (màu cam) và non-student (màu xanh lam). Các đường liền biểu diễn default rate theo **balance**, còn các đường đứt đoạn nằm ngang biểu diễn overall default rate. Phải: Boxplot của **balance** cho student (màu cam) và non-student (màu xanh lam).*

cung cấp tín dụng cho ai. Nếu không có thông tin về credit card balance, một student rủi ro hơn một non-student. Tuy nhiên, student đó lại ít rủi ro hơn một non-student có cùng credit card balance!

Ví dụ đơn giản này minh họa những nguy cơ và điểm tinh tế khi thực hiện regression chỉ với một predictor trong khi các predictor khác cũng có thể liên quan. Cũng như trong bối cảnh linear regression, kết quả thu được khi dùng một predictor có thể rất khác kết quả khi dùng nhiều predictor, đặc biệt khi các predictor correlated với nhau. Nhìn chung, hiện tượng trong Hình 4.3 được gọi là *confounding*.

confounding

Thay các regression coefficient estimate từ Bảng 4.3 vào (4.7), ta có thể đưa ra prediction. Chẳng hạn, một student có credit card balance 1.500 đô la và income 40.000 đô la có xác suất default ước lượng là

$$\hat{p}(X) = \frac{e^{-10.869+0.00574 \times 1,500+0.003 \times 40-0.6468 \times 1}}{1 + e^{-10.869+0.00574 \times 1,500+0.003 \times 40-0.6468 \times 1}} = 0.058. \quad (4.8)$$

Một non-student có cùng balance và income có xác suất default ước lượng là

$$\hat{p}(X) = \frac{e^{-10.869+0.00574 \times 1,500+0.003 \times 40-0.6468 \times 0}}{1 + e^{-10.869+0.00574 \times 1,500+0.003 \times 40-0.6468 \times 0}} = 0.105. \quad (4.9)$$

(Ở đây, ta nhân income coefficient estimate trong Bảng 4.3 với 40 thay vì 40.000, vì trong bảng đó model được fit với income đo theo đơn vị 1.000 đô la.)

4.3.5 Multinomial Logistic Regression

Đôi khi ta muốn phân loại một response variable có hơn hai class. Chẳng hạn, trong Mục 4.2, ta có ba category tình trạng bệnh lý tại phòng cấp cứu: stroke, drug overdose và epileptic seizure. Tuy nhiên, cách tiếp cận logistic regression đã trình bày trong mục này chỉ cho phép response variable có $K = 2$ class.

Hóa ra có thể mở rộng cách tiếp cận two-class logistic regression sang bối cảnh $K > 2$ class. Phần mở rộng này đôi khi được gọi là *multinomial*

logistic regression. Để thực hiện, trước hết ta chọn một class làm baseline; không mất tính tổng quát, ta chọn class thứ K cho vai trò này. Sau đó, ta thay model (4.7) bằng model

multinomial
logistic
regression

$$\Pr(Y = k \mid X = x) = \frac{e^{\beta_{k0} + \beta_{k1}x_1 + \dots + \beta_{kp}x_p}}{1 + \sum_{l=1}^{K-1} e^{\beta_{l0} + \beta_{l1}x_1 + \dots + \beta_{lp}x_p}} \quad (4.10)$$

với $k = 1, \dots, K-1$, và

$$\Pr(Y = K \mid X = x) = \frac{1}{1 + \sum_{l=1}^{K-1} e^{\beta_{l0} + \beta_{l1}x_1 + \dots + \beta_{lp}x_p}}. \quad (4.11)$$

Không khó để chứng minh rằng với $k = 1, \dots, K-1$,

$$\log\left(\frac{\Pr(Y = k \mid X = x)}{\Pr(Y = K \mid X = x)}\right) = \beta_{k0} + \beta_{k1}x_1 + \dots + \beta_{kp}x_p. \quad (4.12)$$

Lưu ý rằng (4.12) khá giống (4.6). Phương trình 4.12 cho thấy một lần nữa, log odds giữa bất kỳ cặp class nào cũng tuyến tính theo các feature.

Hóa ra trong các Phương trình 4.10–4.12, quyết định dùng class thứ K làm baseline không quan trọng. Chẳng hạn, khi phân loại các lượt đến phòng cấp cứu thành stroke, drug overdose và epileptic seizure, giả sử ta fit hai multinomial logistic regression model: một model dùng stroke làm baseline, model kia dùng drug overdose làm baseline. Coefficient estimate sẽ khác nhau giữa hai fitted model do lựa chọn baseline khác nhau, nhưng fitted value (prediction), log odds giữa bất kỳ cặp class nào và các model output quan trọng khác vẫn giống nhau.

Dẫu vậy, phải cẩn thận khi diễn giải coefficient trong multinomial logistic regression model vì diễn giải đó gắn với lựa chọn baseline. Chẳng hạn, nếu đặt epileptic seizure làm baseline, ta có thể diễn giải $\beta_{\text{stroke},0}$ là log odds của stroke so với epileptic seizure khi $x_1 = \dots = x_p = 0$. Hơn nữa, X_j tăng một đơn vị đi kèm log odds của stroke so với epileptic seizure tăng $\beta_{\text{stroke},j}$. Nói cách khác, nếu X_j tăng một đơn vị thì

$$\frac{\Pr(Y = \text{stroke} \mid X = x)}{\Pr(Y = \text{epileptic seizure} \mid X = x)}$$

tăng theo hệ số $e^{\beta_{\text{stroke},j}}$.

Bây giờ chúng tôi trình bày ngắn gọn một cách mã hóa khác cho multinomial logistic regression, gọi là *softmax coding*. Softmax coding tương đương cách mã hóa vừa mô tả theo nghĩa fitted value, log odds giữa bất kỳ cặp class nào và các model output quan trọng khác vẫn giống nhau, bất kể cách mã hóa. Tuy nhiên, softmax coding được dùng rộng rãi trong một số lĩnh vực của machine learning literature (và sẽ xuất hiện lại trong Chương 10), nên ta cần biết đến nó. Trong softmax coding, thay vì chọn một baseline class, ta xử lý đối xứng cả K class và giả định rằng với $k = 1, \dots, K$,

softmax
coding

$$\Pr(Y = k \mid X = x) = \frac{e^{\beta_{k0} + \beta_{k1}x_1 + \dots + \beta_{kp}x_p}}{\sum_{l=1}^K e^{\beta_{l0} + \beta_{l1}x_1 + \dots + \beta_{lp}x_p}}. \quad (4.13)$$

Vì vậy, thay vì ước lượng coefficient cho $K - 1$ class, ta thực sự ước lượng coefficient cho cả K class. Từ (4.13), không khó để thấy log odds ratio giữa class thứ k và class thứ k' bằng

$$\begin{aligned} \log \left(\frac{\Pr(Y = k \mid X = x)}{\Pr(Y = k' \mid X = x)} \right) &= (\beta_{k0} - \beta_{k'0}) + (\beta_{k1} - \beta_{k'1})x_1 + \cdots \\ &\quad + (\beta_{kp} - \beta_{k'p})x_p. \end{aligned} \quad (4.14)$$