

4.4 Generative Models for Classification

Logistic regression trực tiếp modeling $\Pr(Y = k \mid X = x)$ bằng logistic function, được cho bởi (4.7) trong trường hợp có hai response class. Theo thuật ngữ thống kê, ta modeling conditional distribution của response Y khi biết predictor X . Bây giờ ta xét một cách tiếp cận khác, gián tiếp hơn, để ước lượng các xác suất này. Trong cách tiếp cận mới, ta modeling distribution của predictor X riêng biệt trong từng response class (tức với từng giá trị của Y). Sau đó, ta dùng Bayes' theorem để đảo chiều chúng thành các ước lượng của $\Pr(Y = k \mid X = x)$. Khi distribution của X trong mỗi class được giả định là normal, model thu được có dạng rất giống logistic regression.

Tại sao cần một phương pháp khác khi đã có logistic regression? Có một số lý do:

- Khi hai class có sự phân tách đáng kể, parameter estimate của logistic regression model bắt đầu trở nên không ổn định. Các phương pháp được xét trong mục này không gặp vấn đề đó.
- Nếu distribution của predictor X trong mỗi class xấp xỉ normal và sample size nhỏ, các cách tiếp cận trong mục này có thể chính xác hơn logistic regression.
- Các phương pháp trong mục này có thể mở rộng tự nhiên sang trường hợp có hơn hai response class. (Khi có hơn hai response class, ta cũng có thể dùng multinomial logistic regression trong Mục 4.3.5.)

Giả sử ta muốn phân loại một observation vào một trong K class, với $K \geq 2$. Nói cách khác, qualitative response variable Y có thể nhận K giá trị riêng biệt và không có thứ tự. Gọi π_k là xác suất tổng thể, hay *prior probability*, để một observation được chọn ngẫu nhiên đến từ class thứ k . Gọi $f_k(X) \equiv \Pr(X \mid Y = k)$ ¹ là *density function* của X đối với một observation đến từ class thứ k . Nói cách khác, $f_k(x)$ tương đối lớn nếu một observation trong class thứ k có khả năng cao mang $X \approx x$, và $f_k(x)$ nhỏ nếu điều đó rất khó xảy ra. Khi đó, Bayes' theorem cho biết

$$\Pr(Y = k \mid X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^K \pi_l f_l(x)}. \quad (4.15)$$

Theo ký hiệu trước đây, ta viết tắt $p_k(x) = \Pr(Y = k \mid X = x)$; đây là *posterior probability* để observation $X = x$ thuộc class thứ k . Tức là xác suất observation thuộc class thứ k khi biết predictor value của observation đó.

Phương trình 4.15 gợi ý rằng thay vì trực tiếp tính posterior probability $p_k(x)$ như trong Mục 4.3.1, ta chỉ cần thay các ước lượng của π_k và $f_k(x)$ vào (4.15). Nhìn chung, nếu có random sample từ population thì việc ước lượng π_k rất dễ: ta chỉ cần tính tỷ lệ training observation thuộc class thứ k . Tuy nhiên, ước lượng density function $f_k(x)$ khó hơn nhiều. Như sẽ thấy, để ước lượng $f_k(x)$, ta thường phải đưa ra một số simplifying assumption.

¹Về mặt kỹ thuật, định nghĩa này chỉ đúng nếu X là qualitative random variable. Nếu X là quantitative, $f_k(x) dx$ tương ứng với xác suất X rơi vào một vùng nhỏ dx quanh x .

prior
probability
density
function

posterior
probability

Ta biết từ Chương 2 rằng Bayes classifier, tức classifier gán observation x vào class có $p_k(x)$ lớn nhất, có error rate thấp nhất có thể trong tất cả classifier. (Tất nhiên, điều này chỉ đúng nếu mọi term trong (4.15) đều được chỉ định đúng.) Vì vậy, nếu tìm được cách ước lượng $f_k(x)$, ta có thể thay nó vào (4.15) để xấp xỉ Bayes classifier.

Trong các mục tiếp theo, chúng tôi thảo luận ba classifier dùng những ước lượng khác nhau của $f_k(x)$ trong (4.15) để xấp xỉ Bayes classifier: linear discriminant analysis, quadratic discriminant analysis và naive Bayes.

4.4.1 Linear Discriminant Analysis for $p = 1$

Trước mắt, giả sử $p = 1$, tức ta chỉ có một predictor. Ta muốn thu được một ước lượng của $f_k(x)$ để thay vào (4.15) nhằm ước lượng $p_k(x)$. Sau đó, ta sẽ phân loại observation vào class có $p_k(x)$ lớn nhất. Để ước lượng $f_k(x)$, trước hết ta đưa ra một số giả định về dạng của nó.

Cụ thể, ta giả định $f_k(x)$ là *normal* hay *Gaussian*. Trong bối cảnh một chiều, normal density có dạng normal
Gaussian

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{1}{2\sigma_k^2}(x - \mu_k)^2\right), \quad (4.16)$$

trong đó μ_k và σ_k^2 là mean parameter và variance parameter của class thứ k . Trước mắt, ta giả định thêm $\sigma_1^2 = \dots = \sigma_K^2$, tức cả K class dùng chung một variance term, được ký hiệu đơn giản là σ^2 . Thay (4.16) vào (4.15), ta có

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}(x - \mu_k)^2\right]}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}(x - \mu_l)^2\right]}. \quad (4.17)$$

(Lưu ý trong (4.17), π_k biểu diễn prior probability để một observation thuộc class thứ k , không nên nhầm với hằng số toán học $\pi \approx 3.14159$.) Bayes classifier² gán observation $X = x$ vào class có (4.17) lớn nhất.

Lấy log của (4.17) rồi sắp xếp lại các term, không khó để chứng minh³ rằng điều này tương đương với việc gán observation vào class có

$$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k) \quad (4.18)$$


lớn nhất. Chẳng hạn, nếu $K = 2$ và $\pi_1 = \pi_2$, Bayes classifier gán observation vào class 1 nếu $2x(\mu_1 - \mu_2) > \mu_1^2 - \mu_2^2$, và vào class 2 trong trường hợp còn lại. Bayes decision boundary là điểm tại đó $\delta_1(x) = \delta_2(x)$; có thể chứng minh điểm này là

$$x = \frac{\mu_1^2 - \mu_2^2}{2(\mu_1 - \mu_2)} = \frac{\mu_1 + \mu_2}{2}. \quad (4.19)$$

Một ví dụ được biểu diễn trong ô trái của Hình 4.4. Hai normal density function $f_1(x)$ và $f_2(x)$ đại diện cho hai class riêng biệt. Mean và variance

²Nhớ rằng Bayes classifier gán observation vào class có $p_k(x)$ lớn nhất. Điều này khác Bayes' theorem trong (4.15), vốn cho phép biến đổi conditional distribution.

³Xem Bài tập 2 ở cuối chương.



HÌNH 4.4. Trái: Hai one-dimensional normal density function. Đường đứt đoạn thẳng đứng biểu diễn Bayes decision boundary. Phải: 20 observation được rút từ mỗi class và biểu diễn bằng histogram. Bayes decision boundary vẫn là đường đứt đoạn thẳng đứng. Đường liền thẳng đứng biểu diễn LDA decision boundary được ước lượng từ training data.

parameter của hai density function là $\mu_1 = -1.25$, $\mu_2 = 1.25$ và $\sigma_1^2 = \sigma_2^2 = 1$. Hai density chồng lấn, nên khi biết $X = x$, vẫn có sự không chắc chắn về class của observation. Nếu giả định observation có khả năng như nhau đến từ mỗi class, tức $\pi_1 = \pi_2 = 0.5$, thì từ (4.19), ta thấy Bayes classifier gán observation vào class 1 nếu $x < 0$, và class 2 trong trường hợp còn lại. Lưu ý ở đây ta tính được Bayes classifier vì biết X được rút từ Gaussian distribution trong mỗi class và biết mọi parameter liên quan. Trong tình huống thực tế, ta không thể tính Bayes classifier.

Trong thực tế, ngay cả khi khá chắc chắn về giả định X được rút từ Gaussian distribution trong mỗi class, để áp dụng Bayes classifier ta vẫn phải ước lượng các parameter $\mu_1, \dots, \mu_K$, $\pi_1, \dots, \pi_K$ và σ^2 . Phương pháp *linear discriminant analysis* (LDA) xấp xỉ Bayes classifier bằng cách thay các ước lượng của π_k , μ_k và σ^2 vào (4.18). Cụ thể, các ước lượng sau được dùng:

linear
discriminant
analysis


$$\begin{aligned}\hat{\mu}_k &= \frac{1}{n_k} \sum_{i:y_i=k} x_i, \\ \hat{\sigma}^2 &= \frac{1}{n-K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)^2.\end{aligned}\quad (4.20)$$

Ở đây, n là tổng số training observation và n_k là số training observation trong class thứ k . Ước lượng μ_k đơn giản là trung bình của mọi training observation từ class thứ k , còn $\hat{\sigma}^2$ có thể được xem là weighted average của sample variance trong từng class. Đôi khi ta biết các class membership probability $\pi_1, \dots, \pi_K$ và có thể dùng trực tiếp. Khi không có thông tin bổ sung, LDA ước lượng π_k bằng tỷ lệ training observation thuộc class thứ k :

$$\hat{\pi}_k = n_k/n. \quad (4.21)$$

LDA classifier thay các ước lượng trong (4.20) và (4.21) vào (4.18), rồi gán observation $X = x$ vào class có

$$\hat{\delta}_k(x) = x \cdot \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k) \quad (4.22)$$



HÌNH 4.5. Hai multivariate Gaussian density function với $p = 2$. Trái: Hai predictor không correlated. Phải: Hai variable có correlation bằng 0.7.

lớn nhất. Từ *linear* trong tên classifier bắt nguồn từ việc các *discriminant function* $\hat{\delta}_k(x)$ trong (4.22) là linear function của x chứ không phải một hàm phức tạp hơn.

discriminant
function

Ô bên phải của Hình 4.4 biểu diễn histogram của random sample gồm 20 observation từ mỗi class. Để triển khai LDA, trước hết ta ước lượng π_k , μ_k và σ^2 bằng (4.20) và (4.21). Sau đó, ta tính decision boundary, biểu diễn bằng đường liền màu đen, thu được từ việc gán observation vào class có (4.22) lớn nhất. Mọi điểm bên trái đường này được gán vào class xanh lục, còn điểm bên phải được gán vào class tím. Vì $n_1 = n_2 = 20$, ta có $\hat{\pi}_1 = \hat{\pi}_2$. Do đó, decision boundary tương ứng với midpoint giữa sample mean của hai class, $(\hat{\mu}_1 + \hat{\mu}_2)/2$. Hình cho thấy LDA decision boundary nằm hơi lệch trái so với Bayes decision boundary tối ưu, vốn bằng $(\mu_1 + \mu_2)/2 = 0$. LDA classifier hoạt động tốt đến đâu trên dữ liệu này? Vì đây là simulated data, ta có thể sinh nhiều test observation để tính Bayes error rate và LDA test error rate. Hai giá trị lần lượt là 10.6% và 11.1%. Nói cách khác, error rate của LDA classifier chỉ cao hơn error rate nhỏ nhất có thể 0.5%! Điều này cho thấy LDA hoạt động khá tốt trên dataset này.


Nhắc lại, LDA classifier xuất phát từ giả định observation trong mỗi class đến từ normal distribution với class-specific mean và common variance σ^2 , rồi thay các estimate của parameter này vào Bayes classifier. Trong Mục 4.4.3, ta sẽ xét một tập giả định ít nghiêm ngặt hơn bằng cách cho phép observation trong class thứ k có class-specific variance σ_k^2 .

4.4.2 Linear Discriminant Analysis for $p > 1$

Bây giờ ta mở rộng LDA classifier sang trường hợp có nhiều predictor. Ta giả định $X = (X_1, X_2, \dots, X_p)$ được rút từ *multivariate Gaussian* (hay multivariate normal) distribution, với class-specific mean vector và common covariance matrix. Trước hết, ta ôn lại ngắn gọn distribution này.

multivariate
Gaussian

Multivariate Gaussian distribution giả định mỗi predictor riêng lẻ tuân theo one-dimensional normal distribution như trong (4.16), cùng một mức



HÌNH 4.6. Ví dụ với ba class. Observation trong mỗi class được rút từ multivariate Gaussian distribution với $p = 2$, class-specific mean vector và common covariance matrix. Trái: Các ellipse chứa 95% probability của từng class. Đường đứt đoạn là Bayes decision boundary. Phải: 20 observation được sinh từ mỗi class; LDA decision boundary tương ứng là các đường liền màu đen. Bayes decision boundary vẫn được biểu diễn bằng đường đứt đoạn.

correlation giữa từng cặp predictor. Hai ví dụ về multivariate Gaussian distribution với $p = 2$ được biểu diễn trong Hình 4.5. Độ cao của surface tại một điểm biểu diễn xác suất cả X_1 và X_2 cùng rơi vào một vùng nhỏ quanh điểm đó. Trong mỗi ô, nếu cắt surface dọc trục X_1 hoặc X_2 , cross-section thu được có dạng one-dimensional normal distribution. Ô trái của Hình 4.5 minh họa trường hợp $\text{Var}(X_1) = \text{Var}(X_2)$ và $\text{Cor}(X_1, X_2) = 0$; surface này có dạng chuông đặc trưng. Tuy nhiên, dạng chuông bị biến dạng nếu các predictor correlated hoặc có variance không bằng nhau, như ô phải của Hình 4.5. Khi đó, đáy chuông có dạng ellipse thay vì hình tròn. Để ký hiệu random variable p chiều X có multivariate Gaussian distribution, ta viết $X \sim N(\mu, \Sigma)$. Ở đây $E(X) = \mu$ là mean của X (một vector có p component), còn $\text{Cov}(X) = \Sigma$ là covariance matrix $p \times p$ của X . Về hình thức, multivariate Gaussian density được định nghĩa là

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]. \quad (4.23)$$

Trong trường hợp $p > 1$ predictor, LDA classifier giả định observation trong class thứ k được rút từ multivariate Gaussian distribution $N(\mu_k, \Sigma)$, trong đó μ_k là class-specific mean vector và Σ là covariance matrix chung cho cả K class. Thay density function $f_k(X = x)$ của class thứ k vào (4.15) và thực hiện một ít đại số cho thấy Bayes classifier gán observation $X = x$ vào class có

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k \quad (4.24)$$

lớn nhất. Đây là phiên bản vector/matrix của (4.18).

Một ví dụ được biểu diễn trong ô trái của Hình 4.6. Ba Gaussian class có kích thước bằng nhau được biểu diễn với class-specific mean vector và common covariance matrix. Ba ellipse đại diện cho các vùng chứa 95%

BẢNG 4.4. *Confusion matrix so sánh LDA prediction với trạng thái `default` thực của 10.000 training observation trong dataset `Default`. Các element trên diagonal là những cá nhân được dự đoán đúng trạng thái default; các element ngoài diagonal là những cá nhân bị misclassified. LDA dự đoán sai 23 người không default và 252 người default.*

		True default status		
		No	Yes	Total
Predicted default status	No	9644	252	9896
	Yes	23	81	104
	Total	9667	333	10000

probability của từng class. Các đường đứt đoạn là Bayes decision boundary, tức tập giá trị x sao cho $\delta_k(x) = \delta_l(x)$:

$$x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k = x^T \Sigma^{-1} \mu_l - \frac{1}{2} \mu_l^T \Sigma^{-1} \mu_l, \quad (4.25)$$

với $k \neq l$. (Term $\log \pi_k$ trong (4.24) biến mất vì ba class có cùng số training observation, tức π_k như nhau với mỗi class.) Có ba đường Bayes decision boundary vì có ba cặp class trong ba class. Một boundary tách class 1 khỏi class 2, một boundary tách class 1 khỏi class 3 và một boundary tách class 2 khỏi class 3. Ba boundary này chia predictor space thành ba vùng. Bayes classifier phân loại observation theo vùng chứa nó.

Một lần nữa, ta cần ước lượng các parameter chưa biết $\mu_1, \dots, \mu_K$, $\pi_1, \dots, \pi_K$ và Σ ; các công thức tương tự trường hợp một chiều trong (4.20). Để gán observation mới $X = x$, LDA thay các ước lượng này vào (4.24) để thu được $\hat{\delta}_k(x)$ và phân loại vào class có $\hat{\delta}_k(x)$ lớn nhất. Lưu ý $\delta_k(x)$ trong (4.24) là linear function của x ; tức LDA decision rule chỉ phụ thuộc vào x thông qua linear combination của các element. Như đã thảo luận, đây là lý do có từ *linear* trong LDA.

Ở bên phải của Hình 4.6 biểu diễn 20 observation được rút từ mỗi class, cùng các LDA decision boundary thu được bằng đường liền màu đen. Nhìn chung, LDA decision boundary khá gần Bayes decision boundary, vẫn được biểu diễn bằng đường đứt đoạn. Test error rate của Bayes classifier và LDA classifier lần lượt là 0.0746 và 0.0770. Điều này cho thấy LDA hoạt động tốt trên dữ liệu này.

Ta có thể thực hiện LDA trên dữ liệu `Default` để dự đoán một cá nhân có default hay không dựa trên credit card balance và student status.⁴ LDA model được fit trên 10.000 training sample cho training error rate bằng 2.75%. Con số này có vẻ thấp, nhưng cần lưu ý hai điểm:

- Training error rate thường thấp hơn test error rate, là đại lượng thực sự được quan tâm. Nói cách khác, classifier này có thể hoạt động kém hơn khi dùng để dự đoán một tập cá nhân mới có default hay không, vì ta đã điều chỉnh parameter của model để hoạt động tốt trên training data.

⁴Người đọc cẩn thận sẽ nhận thấy student status là qualitative, nên giả định normality của LDA rõ ràng bị vi phạm trong ví dụ này! Tuy nhiên, LDA thường bền vững đáng kể trước model violation, như ví dụ cho thấy. Naive Bayes trong Mục 4.4.4 là một lựa chọn thay thế không giả định predictor có normal distribution.

Tỷ lệ parameter p trên sample n càng cao, ta càng kỳ vọng *overfitting* đóng vai trò lớn. Với dữ liệu này, đây không phải vấn đề đáng ngại vì $p = 2$ và $n = 10,000$.

- Vì chỉ 3.33% cá nhân trong training sample default, một classifier đơn giản nhưng vô dụng luôn dự đoán một cá nhân không default, bất kể credit card balance và student status, sẽ có error rate 3.33%. Nói cách khác, *null classifier* tầm thường đạt error rate chỉ cao hơn LDA training set error rate đôi chút.

Trong thực tế, binary classifier như thế này có thể mắc hai loại error: gán nhầm một cá nhân default vào category no default, hoặc gán nhầm một cá nhân không default vào category default. Ta thường muốn xác định classifier đang mắc loại error nào. *Confusion matrix* trong Bảng 4.4 là cách thuận tiện để biểu diễn thông tin này. Matrix cho thấy LDA dự đoán tổng cộng 104 người sẽ default; trong số đó, 81 người thực sự default và 23 người không. Vì vậy, chỉ 23 trong số 9.667 cá nhân không default bị gán nhầm sai. Error rate này có vẻ rất thấp! Tuy nhiên, trong 333 cá nhân default, LDA bỏ sót 252 người, tức 75.7%. Vì thế, dù overall error rate thấp, error rate trong nhóm default rất cao. Từ góc nhìn của công ty thẻ tín dụng muốn nhận diện cá nhân rủi ro cao, error rate $252/333 = 75.7\%$ trong nhóm default có thể hoàn toàn không chấp nhận được.

Class-specific performance cũng quan trọng trong y học và sinh học, nơi các thuật ngữ *sensitivity* và *specificity* đặc trưng hóa performance của classifier hay screening test. Ở đây, sensitivity là tỷ lệ true defaulter được nhận diện, bằng 24.3%. Specificity là tỷ lệ non-defaulter được nhận diện đúng, bằng $1 - 23/9667 = 99.8\%$.

Tại sao LDA phân loại những khách hàng default kém đến vậy, tức tại sao sensitivity thấp? Như đã thấy, LDA cổ xấp xỉ Bayes classifier, classifier có total error rate thấp nhất trong mọi classifier. Bayes classifier tạo ra tổng số observation bị misclassified nhỏ nhất có thể, bất kể error đến từ class nào. Một số misclassification phát sinh do gán nhầm khách hàng không default vào class default, số khác do gán nhầm khách hàng default vào class non-default. Trái lại, công ty thẻ tín dụng có thể đặc biệt muốn tránh phân loại sai một người sẽ default; còn phân loại sai một người không default, dù vẫn nên tránh, ít nghiêm trọng hơn. Bây giờ ta sẽ thấy có thể sửa đổi LDA để tạo classifier phù hợp hơn với nhu cầu của công ty.

Bayes classifier gán observation vào class có posterior probability $p_k(X)$ lớn nhất. Trong trường hợp two-class, điều này tương đương gán observation vào class default nếu


$$\Pr(\text{default} = \text{Yes} \mid X = x) > 0.5. \quad (4.26)$$

Vì vậy, Bayes classifier, và theo đó là LDA, dùng threshold 50% cho posterior probability của default để gán observation vào class default. Tuy nhiên, nếu quan tâm đến việc dự đoán sai trạng thái của những cá nhân sẽ default, ta có thể hạ threshold. Chẳng hạn, có thể gán mọi khách hàng có posterior probability của default lớn hơn 20% vào class default. Tức thay vì yêu cầu (4.26), ta dùng

$$\Pr(\text{default} = \text{Yes} \mid X = x) > 0.2. \quad (4.27)$$

BẢNG 4.5. Confusion matrix so sánh LDA prediction với trạng thái *default* thực của 10.000 training observation trong dataset *Default*, dùng threshold đã sửa đổi: dự đoán default cho mọi cá nhân có posterior default probability vượt 20%.

		True default status		
		No	Yes	Total
Predicted default status	No	9432	138	9570
	Yes	235	195	430
	Total	9667	333	10000



HÌNH 4.7. Với dataset *Default*, các error rate được biểu diễn theo threshold của posterior probability dùng để thực hiện phép gán. Đường liền màu đen biểu diễn overall error rate. Đường đứt đoạn màu xanh lam là tỷ lệ khách hàng default bị phân loại sai; đường chấm màu cam là tỷ lệ error trong nhóm khách hàng không default.


Các error rate thu được từ cách tiếp cận này được biểu diễn trong Bảng 4.5.

Bây giờ LDA dự đoán 430 cá nhân sẽ default. Trong 333 cá nhân default, LDA dự đoán đúng tất cả trừ 138 người, tức sai 41.4%. Đây là cải thiện rất lớn so với error rate 75.7% khi dùng threshold 50%. Tuy nhiên, sự cải thiện này có cái giá của nó: giờ đây 235 cá nhân không default bị phân loại sai. Vì vậy, overall error rate tăng nhẹ lên 3.73%. Nhưng một công ty thẻ tín dụng có thể xem mức tăng nhỏ của total error rate này là cái giá nhỏ để nhận diện chính xác hơn những người thực sự default.

Hình 4.7 minh họa trade-off khi thay đổi threshold của posterior probability của default. Nhiều error rate được biểu diễn theo threshold. Dùng threshold 0.5 như trong (4.26) sẽ giảm thiểu overall error rate, là đường liền màu đen. Điều này phù hợp kỳ vọng vì Bayes classifier dùng threshold 0.5 và có overall error rate thấp nhất. Nhưng khi dùng threshold 0.5, error rate trong nhóm default khá cao (đường đứt đoạn màu xanh lam). Khi giảm threshold, error rate trong nhóm default giảm đều, nhưng error rate trong nhóm không default tăng. Làm sao quyết định threshold nào tốt nhất? Quyết định này phải dựa trên domain knowledge, chẳng hạn thông tin chi tiết về chi phí gắn với default.

ROC curve là đồ thị phổ biến để đồng thời biểu diễn hai loại error trên mọi threshold có thể. Tên “ROC” có nguồn gốc lịch sử từ communications theory và là viết tắt của *receiver operating characteristics*. Hình 4.8 biểu diễn ROC curve của LDA classifier trên training data.

ROC curve



HÌNH 4.8. ROC curve của LDA classifier trên dữ liệu *Default*. Nó biểu diễn hai loại error khi thay đổi threshold của posterior probability của default; threshold thực tế không được thể hiện. True positive rate là sensitivity: tỷ lệ defaulter được nhận diện đúng với một threshold. False positive rate là $1 - \text{specificity}$: tỷ lệ non-defaulter bị phân loại sai thành defaulter với cùng threshold. ROC curve lý tưởng áp sát góc trên bên trái, biểu thị true positive rate cao và false positive rate thấp. Đường chấm biểu diễn classifier “không có thông tin”, là điều ta kỳ vọng nếu student status và credit card balance không associated với xác suất default.

Overall performance của classifier, được tóm tắt trên mọi threshold có thể, được cho bởi *area under the (ROC) curve* (AUC). ROC curve lý tưởng áp sát góc trên bên trái, nên AUC càng lớn thì classifier càng tốt. Với dữ liệu này, AUC bằng 0.95, gần mức tối đa 1.0 và được xem là rất tốt. Ta kỳ vọng một classifier không tốt hơn chance sẽ có AUC 0.5 (khi được đánh giá trên independent test set không dùng để train model). ROC curve hữu ích để so sánh các classifier khác nhau vì tính đến mọi threshold có thể. Hóa ra ROC curve của logistic regression model trong Mục 4.3.4 được fit trên dữ liệu này gần như không thể phân biệt với ROC curve của LDA model, nên không được biểu diễn ở đây.

area under
the (ROC)
curve

Như đã thấy, thay đổi classifier threshold làm thay đổi true positive rate và false positive rate. Chúng cũng được gọi là sensitivity và một trừ specificity của classifier. Vì có một hệ thuật ngữ gần như gây rối trong bối cảnh này, ta tóm tắt chúng. Bảng 4.6 biểu diễn các kết quả có thể khi áp dụng classifier (hay diagnostic test) cho population. Để kết nối với epidemiology literature, ta xem “+” là “disease” cần phát hiện và “−” là trạng thái “non-disease”. Để kết nối với classical hypothesis testing literature, ta xem “−” là null hypothesis và “+” là alternative (non-null) hypothesis. Trong dữ liệu *Default*, “+” chỉ cá nhân default và “−” chỉ người không default.

BẢNG 4.6. Các kết quả có thể khi áp dụng classifier hoặc diagnostic test cho population.

		True class		Total
		– or Null	+ or Non-null	
Predicted class	– or Null	True Neg. (TN)	False Neg. (FN)	N^*
	+ or Non-null	False Pos. (FP)	True Pos. (TP)	P^*
	Total	N	P	

BẢNG 4.7. Các performance measure quan trọng cho classification và diagnostic testing, được suy ra từ các đại lượng trong Bảng 4.6.

Name	Definition	Synonyms
False Pos. rate	FP/N	Type I error, $1 - \text{Specificity}$
True Pos. rate	TP/P	$1 - \text{Type II error}$, power, sensitivity, recall
Pos. Pred. value	TP/P^*	Precision, $1 - \text{false discovery proportion}$
Neg. Pred. value	TN/N^*	

Bảng 4.7 liệt kê nhiều performance measure phổ biến trong bối cảnh này. Denominator của false positive rate và true positive rate là population count thực trong từng class. Trái lại, denominator của positive predictive value và negative predictive value là tổng predicted count trong từng class.