




HÌNH 4.9. Trái: Bayes decision boundary (đường đứt đoạn màu tím), LDA decision boundary (đường chấm màu đen) và QDA decision boundary (đường liền màu xanh lục) cho bài toán two-class với $\Sigma_1 = \Sigma_2$. Phần tô màu biểu diễn QDA decision rule. Vì Bayes decision boundary tuyến tính, LDA xấp xỉ nó chính xác hơn QDA. Phải: Các chỉ tiết giống ô trái, ngoại trừ $\Sigma_1 \neq \Sigma_2$. Vì Bayes decision boundary phi tuyến, QDA xấp xỉ nó chính xác hơn LDA.

4.4.3 Quadratic Discriminant Analysis

Như đã thảo luận, LDA giả định observation trong mỗi class được rút từ multivariate Gaussian distribution với class-specific mean vector và một covariance matrix chung cho cả K class. Quadratic discriminant analysis (QDA) cung cấp một cách tiếp cận thay thế. Giống LDA, QDA classifier xuất phát từ giả định observation của mỗi class được rút từ Gaussian distribution, rồi thay các parameter estimate vào Bayes' theorem để thực hiện prediction. Tuy nhiên, khác với LDA, QDA giả định mỗi class có covariance matrix riêng. Tức nó giả định observation từ class thứ k có dạng $X \sim N(\mu_k, \Sigma_k)$, trong đó Σ_k là covariance matrix của class thứ k . Với giả định này, Bayes classifier gán observation $X = x$ vào class có

Quadratic
discriminant
analysis

$$\begin{aligned} \delta_k(x) &= -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k \\ &= -\frac{1}{2} x^T \Sigma_k^{-1} x + x^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \log |\Sigma_k| + \log \pi_k \end{aligned} \quad (4.28)$$

lớn nhất. Vì vậy, QDA classifier thay các ước lượng của Σ_k , μ_k và π_k vào (4.28), rồi gán observation $X = x$ vào class có đại lượng này lớn nhất. Khác với (4.24), x xuất hiện như một quadratic function trong (4.28). Đây là nguồn gốc tên gọi QDA.

Việc giả định K class có chung covariance matrix hay không quan trọng thế nào? Nói cách khác, khi nào nên chọn LDA thay cho QDA, hoặc ngược lại? Câu trả lời nằm ở bias-variance trade-off.

Khi có p predictor, việc ước lượng một covariance matrix đòi hỏi ước lượng $p(p+1)/2$ parameter. QDA ước lượng một covariance matrix riêng cho mỗi class, tổng cộng $Kp(p+1)/2$ parameter. Với 50 predictor, con số này là một bội số của 1.275, tức rất nhiều parameter. Trái lại, khi giả định K class dùng chung covariance matrix, LDA model trở thành tuyến tính theo x , nghĩa là có Kp linear coefficient cần ước lượng. Do đó, LDA là

classifier kém flexible hơn QDA rất nhiều và vì vậy có variance thấp hơn đáng kể. Điều này có thể giúp cải thiện prediction performance. Nhưng có một trade-off: nếu giả định các class dùng chung covariance matrix của LDA sai nghiêm trọng, LDA có thể chịu bias cao. Nói gần đúng, LDA thường là lựa chọn tốt hơn QDA khi có tương đối ít training observation và việc giảm variance là thiết yếu. Ngược lại, QDA được khuyến nghị nếu training set rất lớn, nên variance của classifier không phải mối lo chính, hoặc nếu giả định common covariance matrix cho K class rõ ràng không thể chấp nhận.

Hình 4.9 minh họa performance của LDA và QDA trong hai kịch bản. Ở ô trái, hai Gaussian class có cùng correlation 0.7 giữa X_1 và X_2 . Do đó, Bayes decision boundary tuyến tính và được LDA decision boundary xấp xỉ chính xác. QDA decision boundary kém hơn vì chịu variance cao hơn mà bias không giảm tương ứng. Trái lại, ô phải biểu diễn tình huống class màu cam có correlation 0.7 giữa hai variable, còn class màu xanh lam có correlation -0.7 . Lúc này Bayes decision boundary là quadratic, nên QDA xấp xỉ boundary này chính xác hơn LDA.

4.4.4 Naive Bayes

Trong các mục trước, ta dùng Bayes' theorem (4.15) để phát triển LDA và QDA classifier. Ở đây, ta dùng Bayes' theorem để tạo động lực cho *naive Bayes* classifier phổ biến.

naive Bayes

Nhớ rằng Bayes' theorem (4.15) cung cấp biểu thức cho posterior probability $p_k(x) = \Pr(Y = k \mid X = x)$ theo $\pi_1, \dots, \pi_K$ và $f_1(x), \dots, f_K(x)$. Để dùng (4.15) trong thực tế, ta cần các ước lượng của $\pi_1, \dots, \pi_K$ và $f_1(x), \dots, f_K(x)$. Như đã thấy, việc ước lượng prior probability $\pi_1, \dots, \pi_K$ thường khá trực tiếp: chẳng hạn, ta có thể ước lượng $\hat{\pi}_k$ bằng tỷ lệ training observation thuộc class thứ k , với $k = 1, \dots, K$.

Tuy nhiên, việc ước lượng $f_1(x), \dots, f_K(x)$ tinh tế hơn. Nhớ rằng $f_k(x)$ là p -dimensional density function của observation trong class thứ k , với $k = 1, \dots, K$. Nhìn chung, ước lượng một p -dimensional density function là bài toán khó. Trong LDA, ta đưa ra một giả định rất mạnh giúp đơn giản hóa đáng kể nhiệm vụ: f_k là density function của multivariate normal random variable với class-specific mean μ_k và shared covariance matrix Σ . Trái lại, trong QDA, ta giả định f_k là density function của multivariate normal random variable với class-specific mean μ_k và class-specific covariance matrix Σ_k . Nhờ các giả định rất mạnh này, ta thay bài toán cực khó là ước lượng K density function p chiều bằng bài toán đơn giản hơn nhiều: ước lượng K mean vector p chiều và một covariance matrix $p \times p$ (với LDA) hoặc K covariance matrix $p \times p$ (với QDA).

Naive Bayes classifier dùng một hướng khác để ước lượng $f_1(x), \dots, f_K(x)$. Thay vì giả định các hàm này thuộc một family of distribution cụ thể, chẳng hạn multivariate normal, ta chỉ đưa ra một giả định:

Trong class thứ k , p predictor độc lập với nhau.

Viết bằng toán học, giả định này có nghĩa rằng với $k = 1, \dots, K$,

$$f_k(x) = f_{k1}(x_1) \times f_{k2}(x_2) \times \dots \times f_{kp}(x_p), \quad (4.29)$$

trong đó f_{kj} là density function của predictor thứ j trong các observation thuộc class thứ k .

Tại sao giả định này mạnh đến vậy? Về bản chất, việc ước lượng p -dimensional density function khó vì ta không chỉ phải xét *marginal distribution* của từng predictor, tức distribution riêng của từng predictor, mà còn phải xét *joint distribution* của các predictor, tức association giữa những predictor khác nhau. Trong multivariate normal distribution, association giữa các predictor được tóm tắt bởi các element ngoài diagonal của covariance matrix. Tuy nhiên, nhìn chung association này có thể rất khó đặc trưng hóa và cực kỳ khó ước lượng. Nhưng bằng cách giả định p covariate độc lập trong mỗi class, ta hoàn toàn loại bỏ nhu cầu xem xét association giữa p predictor, vì đơn giản ta đã giả định không có association giữa chúng!

marginal
distribution
joint
distribution

Ta có thực sự tin giả định naive Bayes rằng p covariate độc lập trong mỗi class không? Trong phần lớn bối cảnh, câu trả lời là không. Nhưng dù modeling assumption này được đưa ra vì sự tiện lợi, nó thường cho kết quả khá tốt, đặc biệt trong những bối cảnh n không đủ lớn so với p để ta ước lượng hiệu quả joint distribution của predictor trong mỗi class. Thật vậy, vì ước lượng joint distribution đòi hỏi lượng dữ liệu khổng lồ, naive Bayes là lựa chọn tốt trong nhiều bối cảnh. Về bản chất, giả định naive Bayes đưa thêm một ít bias nhưng giảm variance, tạo ra một classifier hoạt động khá tốt trong thực tế nhờ bias-variance trade-off.

Sau khi đưa ra giả định naive Bayes, ta có thể thay (4.29) vào (4.15) để thu được biểu thức cho posterior probability,

$$\Pr(Y = k \mid X = x) = \frac{\pi_k \prod_{j=1}^p f_{kj}(x_j)}{\sum_{l=1}^K \pi_l \prod_{j=1}^p f_{lj}(x_j)}, \quad (4.30)$$


với $k = 1, \dots, K$.

Để ước lượng one-dimensional density function f_{kj} bằng training data $x_{1j}, \dots, x_{nj}$, ta có một vài lựa chọn.


- Nếu X_j là quantitative, ta có thể giả định $X_j \mid Y = k \sim N(\mu_{jk}, \sigma_{jk}^2)$. Nói cách khác, trong mỗi class, predictor thứ j được rút từ univariate normal distribution. Điều này có vẻ hơi giống QDA, nhưng có một khác biệt then chốt: ở đây ta giả định các predictor độc lập; tương đương QDA với giả định bổ sung rằng class-specific covariance matrix là diagonal.
- Nếu X_j là quantitative, một lựa chọn khác là dùng non-parametric estimate cho f_{kj} . Một cách rất đơn giản là tạo histogram cho observation của predictor thứ j trong mỗi class. Sau đó, ta có thể ước lượng $f_{kj}(x_j)$ bằng tỷ lệ training observation trong class thứ k thuộc cùng histogram bin với x_j . Hoặc ta có thể dùng *kernel density estimator*, về bản chất là phiên bản được làm mượt của histogram.
- Nếu X_j là qualitative, ta chỉ cần đếm tỷ lệ training observation của predictor thứ j ứng với từng class. Chẳng hạn, giả sử $X_j \in \{1, 2, 3\}$ và

kernel density
estimator

Density estimates for class k=1



Density estimates for class k=2



HÌNH 4.10. Trong toy example ở Mục 4.4.4, ta sinh dữ liệu với $p = 3$ predictor và $K = 2$ class. Hai predictor đầu là quantitative, predictor thứ ba là qualitative với ba level. Với mỗi class, estimated density của từng predictor được biểu diễn. Nếu prior probability của hai class bằng nhau thì observation $x^* = (0.4, 1.5, 1)^T$ có posterior probability 94.4% thuộc class thứ nhất.

ta có 100 observation trong class thứ k . Giả sử predictor thứ j nhận các giá trị 1, 2 và 3 lần lượt trong 32, 55 và 13 observation. Khi đó, ta ước lượng f_{kj} bằng

$$\hat{f}_{kj}(x_j) = \begin{cases} 0.32 & \text{nếu } x_j = 1, \\ 0.55 & \text{nếu } x_j = 2, \\ 0.13 & \text{nếu } x_j = 3. \end{cases}$$

Bây giờ ta xét naive Bayes classifier trong một toy example với $p = 3$ predictor và $K = 2$ class. Hai predictor đầu là quantitative, predictor thứ ba là qualitative với ba level. Giả sử thêm rằng $\hat{\pi}_1 = \hat{\pi}_2 = 0.5$. Các estimated density function $\hat{f}_{kj}$ với $k = 1, 2$ và $j = 1, 2, 3$ được biểu diễn trong Hình 4.10. Bây giờ giả sử ta muốn phân loại observation mới $x^* = (0.4, 1.5, 1)^T$.

Trong ví dụ này, $\hat{f}_{11}(0.4) = 0.368$, $\hat{f}_{12}(1.5) = 0.484$, $\hat{f}_{13}(1) = 0.226$, $\hat{f}_{21}(0.4) = 0.030$, $\hat{f}_{22}(1.5) = 0.130$ và $\hat{f}_{23}(1) = 0.616$. Thay các estimate này vào (4.30) cho posterior probability estimate $\Pr(Y = 1 \mid X = x^*) = 0.944$ và $\Pr(Y = 2 \mid X = x^*) = 0.056$.

BẢNG 4.8. So sánh naive Bayes prediction với trạng thái *default* thực của 10.000 training observation trong dataset *Default*, khi dự đoán default cho mọi observation có $\Pr(Y = \text{default} \mid X = x) > 0.5$.

		True default status		
		No	Yes	Total
Predicted default status	No	9621	244	9865
	Yes	46	89	135
	Total	9667	333	10000

BẢNG 4.9. So sánh naive Bayes prediction với trạng thái *default* thực của 10.000 training observation trong dataset *Default*, khi dự đoán default cho mọi observation có $\Pr(Y = \text{default} \mid X = x) > 0.2$.

		True default status		
		No	Yes	Total
Predicted default status	No	9339	130	9469
	Yes	328	203	531
	Total	9667	333	10000

Bảng 4.8 cung cấp confusion matrix thu được khi áp dụng naive Bayes classifier cho dataset *Default*, trong đó ta dự đoán default nếu posterior probability của default, tức $\Pr(Y = \text{default} \mid X = x)$, vượt 0.5. So với kết quả LDA trong Bảng 4.4, các phát hiện có cả mặt tốt lẫn mặt xấu. Dù LDA có overall error rate thấp hơn đôi chút, naive Bayes dự đoán đúng tỷ lệ true defaulter cao hơn. Trong implementation naive Bayes này, ta giả định mỗi quantitative predictor được rút từ Gaussian distribution và, tất nhiên, mỗi predictor độc lập trong từng class.

Cũng như với LDA, ta có thể dễ dàng điều chỉnh probability threshold để dự đoán default. Chẳng hạn, Bảng 4.9 cung cấp confusion matrix khi dự đoán default nếu $\Pr(Y = \text{default} \mid X = x) > 0.2$. Một lần nữa, so với LDA có cùng threshold trong Bảng 4.5, kết quả có cả mặt tốt lẫn mặt xấu. Naive Bayes có error rate cao hơn nhưng dự đoán đúng gần hai phần ba true default.

Trong ví dụ này, việc naive Bayes không vượt trội rõ ràng so với LDA không quá bất ngờ: dataset có $n = 10,000$ và $p = 2$, nên mức giảm variance nhờ giả định naive Bayes chưa chắc đáng giá. Ta kỳ vọng naive Bayes mang lại lợi ích lớn hơn so với LDA hoặc QDA trong trường hợp p lớn hơn hoặc n nhỏ hơn, khi việc giảm variance đặc biệt quan trọng.