

## 4.5 A Comparison of Classification Methods

### 4.5.1 An Analytical Comparison

Bây giờ ta tiến hành một phép so sánh về mặt phân tích (hay toán học) giữa LDA, QDA, naive Bayes và logistic regression. Ta xét các phương pháp này trong bối cảnh có  $K$  class, sao cho một observation được gán vào class làm cực đại  $\Pr(Y = k \mid X = x)$ . Tương đương, ta có thể chọn class  $K$  làm *baseline class* và gán một observation vào class làm cực đại

$$\log \left( \frac{\Pr(Y = k \mid X = x)}{\Pr(Y = K \mid X = x)} \right) \quad (4.31)$$

cho  $k = 1, \dots, K$ . Việc xem xét dạng cụ thể của (4.31) đối với từng method giúp ta hiểu rõ các điểm giống và khác nhau giữa chúng.

Trước hết, với LDA, ta có thể sử dụng định lý Bayes (4.15) cùng với giả định rằng các predictor trong mỗi class được rút ra từ một multivariate normal density (4.23), với mean riêng cho từng class và covariance matrix dùng chung, để chỉ ra rằng

$$\begin{aligned} \log \left( \frac{\Pr(Y = k \mid X = x)}{\Pr(Y = K \mid X = x)} \right) &= \log \left( \frac{\pi_k f_k(x)}{\pi_K f_K(x)} \right) \\ &= \log \left( \frac{\pi_k \exp[-\frac{1}{2}(x - \mu_k)^T \Sigma^{-1}(x - \mu_k)]}{\pi_K \exp[-\frac{1}{2}(x - \mu_K)^T \Sigma^{-1}(x - \mu_K)]} \right) \\ &= \log \left( \frac{\pi_k}{\pi_K} \right) - \frac{1}{2}(x - \mu_k)^T \Sigma^{-1}(x - \mu_k) \\ &\quad + \frac{1}{2}(x - \mu_K)^T \Sigma^{-1}(x - \mu_K) \\ &= \log \left( \frac{\pi_k}{\pi_K} \right) - \frac{1}{2}(\mu_k + \mu_K)^T \Sigma^{-1}(\mu_k - \mu_K) \\ &\quad + x^T \Sigma^{-1}(\mu_k - \mu_K) \\ &= a_k + \sum_{j=1}^p b_{kj} x_j, \end{aligned} \quad (4.32)$$

trong đó

$$a_k = \log \left( \frac{\pi_k}{\pi_K} \right) - \frac{1}{2}(\mu_k + \mu_K)^T \Sigma^{-1}(\mu_k - \mu_K),$$

và  $b_{kj}$  là component thứ  $j$  của  $\Sigma^{-1}(\mu_k - \mu_K)$ . Do đó LDA, giống logistic regression, giả định rằng log odds của các posterior probability là linear theo  $x$ .

Bằng các phép tính tương tự, trong bối cảnh QDA, (4.31) trở thành

$$\log \left( \frac{\Pr(Y = k \mid X = x)}{\Pr(Y = K \mid X = x)} \right) = a_k + \sum_{j=1}^p b_{kj} x_j + \sum_{j=1}^p \sum_{l=1}^p c_{kjl} x_j x_l, \quad (4.33)$$

trong đó  $a_k$ ,  $b_{kj}$  và  $c_{kjl}$  là các hàm của  $\pi_k$ ,  $\pi_K$ ,  $\mu_k$ ,  $\mu_K$ ,  $\Sigma_k$  và  $\Sigma_K$ . Một lần

nữa, đúng như tên gọi gợi ý, QDA giả định rằng log odds của các posterior probability là quadratic theo  $x$ .

Cuối cùng, ta xem xét (4.31) trong bối cảnh naive Bayes. Nhớ rằng ở đây,  $f_k(x)$  được model hóa thành tích của  $p$  hàm một chiều  $f_{kj}(x_j)$ , với  $j = 1, \dots, p$ . Do đó,

$$\begin{aligned}
 \log\left(\frac{\Pr(Y = k \mid X = x)}{\Pr(Y = K \mid X = x)}\right) &= \log\left(\frac{\pi_k f_k(x)}{\pi_K f_K(x)}\right) \\
 &= \log\left(\frac{\pi_k \prod_{j=1}^p f_{kj}(x_j)}{\pi_K \prod_{j=1}^p f_{Kj}(x_j)}\right) \\
 &= \log\left(\frac{\pi_k}{\pi_K}\right) + \sum_{j=1}^p \log\left(\frac{f_{kj}(x_j)}{f_{Kj}(x_j)}\right) \quad (4.34) \\
 &= a_k + \sum_{j=1}^p g_{kj}(x_j),
 \end{aligned}$$

trong đó  $a_k = \log(\pi_k/\pi_K)$  và  $g_{kj}(x_j) = \log(f_{kj}(x_j)/f_{Kj}(x_j))$ . Vì vậy, vế phải của (4.34) có dạng một generalized additive model, chủ đề sẽ được bàn sâu hơn trong Chương 7.

Quan sát (4.32), (4.33) và (4.34) cho ta các nhận xét sau về LDA, QDA và naive Bayes:

- LDA là một trường hợp đặc biệt của QDA với  $c_{kjl} = 0$  cho mọi  $j = 1, \dots, p$ ,  $l = 1, \dots, p$  và  $k = 1, \dots, K$ . (Dĩ nhiên điều này không đáng ngạc nhiên, vì LDA đơn giản là một phiên bản bị ràng buộc của QDA với  $\Sigma_1 = \dots = \Sigma_K = \Sigma$ .)
- Bất kỳ classifier nào có linear decision boundary đều là một trường hợp đặc biệt của naive Bayes với  $g_{kj}(x_j) = b_{kj}x_j$ . Đặc biệt, điều này có nghĩa là LDA là một trường hợp đặc biệt của naive Bayes! Điều này hoàn toàn không hiển nhiên từ các mô tả về LDA và naive Bayes trước đó trong chương, bởi hai method đưa ra những giả định rất khác nhau: LDA giả định các feature có normal distribution với một within-class covariance matrix dùng chung, còn naive Bayes lại giả định các feature độc lập.
- Nếu ta model  $f_{kj}(x_j)$  trong naive Bayes classifier bằng một Gaussian distribution một chiều  $N(\mu_{kj}, \sigma_j^2)$ , thì ta thu được  $g_{kj}(x_j) = b_{kj}x_j$ , trong đó  $b_{kj} = (\mu_{kj} - \mu_{Kj})/\sigma_j^2$ . Trong trường hợp này, naive Bayes thực ra là một trường hợp đặc biệt của LDA với  $\Sigma$  bị ràng buộc là một diagonal matrix có phần tử đường chéo thứ  $j$  bằng  $\sigma_j^2$ .
- QDA và naive Bayes không method nào là trường hợp đặc biệt của method kia. Naive Bayes có thể tạo ra một fit linh hoạt hơn, vì ta có thể chọn tùy ý  $g_{kj}(x_j)$ . Tuy nhiên, nó bị giới hạn ở một *additive fit* thuần túy, theo nghĩa là trong (4.34), một hàm của  $x_j$  được cộng với một hàm của  $x_l$ , với  $j \neq l$ ; các hạng tử này không bao giờ được nhân với nhau. Trái lại, QDA bao gồm các hạng tử nhân dạng  $c_{kjl}x_jx_l$ . Do đó, QDA có tiềm năng chính xác hơn trong những bối cảnh mà interaction giữa các predictor đóng vai trò quan trọng khi phân biệt

các class.

Không method nào trong số này luôn vượt trội so với các method còn lại: trong bất kỳ bối cảnh nào, việc lựa chọn method sẽ phụ thuộc vào distribution thực của các predictor trong mỗi class trong số  $K$  class, cùng với các yếu tố khác như giá trị của  $n$  và  $p$ . Yếu tố sau liên hệ trực tiếp với bias-variance trade-off.

Logistic regression liên hệ với câu chuyện này như thế nào? Nhớ từ (4.12) rằng multinomial logistic regression có dạng

$$\log\left(\frac{\Pr(Y = k \mid X = x)}{\Pr(Y = K \mid X = x)}\right) = \beta_{k0} + \sum_{j=1}^p \beta_{kj}x_j.$$

Dạng này giống hệt dạng linear của LDA trong (4.32): ở cả hai trường hợp,  $\log(\Pr(Y = k \mid X = x) / \Pr(Y = K \mid X = x))$  là một hàm linear của các predictor. Trong LDA, các coefficient của hàm linear này là các hàm của những estimate cho  $\pi_k$ ,  $\pi_K$ ,  $\mu_k$ ,  $\mu_K$  và  $\Sigma$ , thu được bằng cách giả định rằng  $X_1, \dots, X_p$  tuân theo normal distribution trong mỗi class. Trái lại, trong logistic regression, các coefficient được chọn để cực đại likelihood function (4.5). Vì vậy, ta kỳ vọng LDA sẽ vượt logistic regression khi giả định normality (xấp xỉ) đúng, và kỳ vọng logistic regression hoạt động tốt hơn khi giả định đó không đúng.


Ta kết thúc bằng một thảo luận ngắn về K-nearest neighbors (KNN), được giới thiệu ở Chương 2. Nhớ rằng KNN sử dụng một cách tiếp cận hoàn toàn khác với các classifier đã thấy trong chương này. Để đưa ra prediction cho một observation  $X = x$ , ta xác định các training observation gần  $x$  nhất. Sau đó,  $X$  được gán vào class có số lượng nhiều nhất trong số các observation này. Vì vậy KNN là một cách tiếp cận hoàn toàn non-parametric: không có giả định nào về hình dạng của decision boundary. Ta có các nhận xét sau về KNN:

- Vì KNN hoàn toàn non-parametric, ta có thể kỳ vọng phương pháp này vượt LDA và logistic regression khi decision boundary rất non-linear, với điều kiện  $n$  rất lớn và  $p$  nhỏ.
- Để classification chính xác, KNN đòi hỏi *rất nhiều* observation so với số predictor—tức là  $n$  lớn hơn  $p$  rất nhiều. Điều này liên quan đến việc KNN là non-parametric, do đó thường làm giảm bias nhưng phải trả giá bằng variance lớn.
- Trong những bối cảnh decision boundary là non-linear nhưng  $n$  chỉ ở mức vừa phải, hoặc  $p$  không thật sự nhỏ, QDA có thể được ưu tiên hơn KNN. Lý do là QDA có thể cung cấp một non-linear decision boundary trong khi vẫn tận dụng dạng parametric; vì vậy, so với KNN, nó cần sample size nhỏ hơn để classification chính xác.
- Không giống logistic regression, KNN không cho ta biết predictor nào quan trọng: ta không thu được một bảng coefficient như ở Bảng 4.3.

### 4.5.2 An Empirical Comparison

Bây giờ ta so sánh hiệu năng thực nghiệm (thực tiễn) của logistic regression, LDA, QDA, naive Bayes và KNN. Ta sinh dữ liệu từ sáu kịch bản khác nhau, mỗi kịch bản là một bài toán binary classification (hai class). Trong ba kịch bản, Bayes decision boundary là linear; trong các kịch bản còn lại, nó là non-linear. Với mỗi kịch bản, ta tạo 100 training dataset ngẫu nhiên. Trên từng training set, ta fit mỗi method vào dữ liệu và tính test error rate thu được trên một test set lớn. Kết quả cho các kịch bản linear được trình bày trong Hình 4.11, còn kết quả cho các kịch bản non-linear nằm trong Hình 4.12. Method KNN yêu cầu chọn  $K$ , tức số neighbor (không nên nhầm với số class ở các phần trước của chương này). Ta thực hiện KNN với hai giá trị của  $K$ :  $K = 1$ , và một giá trị  $K$  được chọn tự động bằng một phương pháp gọi là cross-validation, sẽ được thảo luận thêm trong Chương 5. Với naive Bayes, ta giả định các univariate Gaussian density cho feature trong mỗi class (và dĩ nhiên—vì đây là đặc trưng cốt lõi của naive Bayes—giả định các feature độc lập).

Trong cả sáu kịch bản, có  $p = 2$  quantitative predictor. Các kịch bản như sau:



**HÌNH 4.11.** Các boxplot của test error rate cho từng kịch bản linear được mô tả trong phần văn bản chính.


*Scenario 1:* Có 20 training observation trong mỗi class của hai class. Các observation trong mỗi class là những biến ngẫu nhiên normal không tương quan, với mean khác nhau giữa hai class. Panel bên trái của Hình 4.11 cho thấy LDA hoạt động tốt trong bối cảnh này, đúng như ta kỳ vọng vì đây chính là model mà LDA giả định. Logistic regression cũng hoạt động khá tốt, vì nó giả định linear decision boundary. KNN hoạt động kém vì phải trả giá về variance mà không được bù lại bằng mức giảm bias. QDA cũng kém hơn LDA, do nó fit một classifier linh hoạt hơn mức cần thiết. Naive Bayes hoạt động tốt hơn QDA một chút, vì giả định các predictor độc lập của naive Bayes là đúng.

*Scenario 2:* Các chỉ tiết giống Scenario 1, ngoại trừ việc trong mỗi class, hai predictor có correlation bằng  $-0.5$ . Panel giữa của Hình 4.11 cho thấy hiệu năng của hầu hết các method tương tự kịch bản trước. Ngoại lệ đáng chú ý là naive Bayes, hoạt động rất kém ở đây vì giả định các predictor độc lập của naive Bayes bị vi phạm.

*Scenario 3:* Giống như ở kịch bản trước, giữa các predictor trong mỗi

class tồn tại correlation âm đáng kể. Tuy nhiên, lần này ta sinh  $X_1$  và  $X_2$  từ t-distribution, với 50 observation cho mỗi class. T-distribution có hình dạng tương tự normal distribution, nhưng có xu hướng tạo ra nhiều điểm cực đoan hơn—tức nhiều điểm nằm xa mean hơn. Trong bối cảnh này, decision boundary vẫn linear, vì vậy phù hợp với framework của logistic regression. Thiết lập này vi phạm các giả định của LDA, vì các observation không được rút ra từ normal distribution. Panel bên phải của Hình 4.11 cho thấy logistic regression vượt LDA, dù cả hai method đều tốt hơn các cách tiếp cận còn lại. Đặc biệt, kết quả của QDA suy giảm đáng kể do non-normality. Naive Bayes hoạt động rất kém vì giả định independence bị vi phạm.

*Scenario 4:* Dữ liệu được sinh từ normal distribution, với correlation bằng 0.5 giữa các predictor trong class thứ nhất và correlation bằng  $-0.5$  giữa các predictor trong class thứ hai. Thiết lập này phù hợp với giả định của QDA và tạo ra các quadratic decision boundary.



**HÌNH 4.12.** Các boxplot của test error rate cho từng kịch bản non-linear được mô tả trong phần văn bản chính.

Panel bên trái của Hình 4.12 cho thấy QDA vượt tất cả các cách tiếp cận còn lại. Giả định các predictor độc lập của naive Bayes bị vi phạm, vì vậy naive Bayes hoạt động kém.

*Scenario 5:* Dữ liệu được sinh từ normal distribution với các predictor không tương quan. Sau đó, các response được lấy mẫu từ logistic function áp dụng lên một hàm non-linear phức tạp của các predictor. Panel giữa của Hình 4.12 cho thấy cả QDA lẫn naive Bayes đều cho kết quả tốt hơn đôi chút so với các linear method, trong khi method KNN-CV linh hoạt hơn nhiều cho kết quả tốt nhất. Nhưng KNN với  $K = 1$  lại cho kết quả kém nhất trong tất cả các method. Điều này nhấn mạnh rằng ngay cả khi dữ liệu biểu hiện một quan hệ non-linear phức tạp, một non-parametric method như KNN vẫn có thể cho kết quả kém nếu mức độ smoothness không được chọn đúng.

*Scenario 6:* Các observation được sinh từ normal distribution với một diagonal covariance matrix khác nhau cho mỗi class. Tuy nhiên, sample size rất nhỏ: chỉ  $n = 6$  trong mỗi class. Naive Bayes hoạt động rất tốt vì các giả định của nó được thỏa mãn. LDA và logistic regression hoạt động kém vì decision boundary thực là non-linear, do các covariance matrix không bằng nhau. QDA kém hơn naive Bayes một chút vì, với sample size rất nhỏ,

QDA phải chịu variance quá lớn khi estimate correlation giữa các predictor trong mỗi class. Hiệu năng của KNN cũng bị ảnh hưởng bởi sample size rất nhỏ.

Sáu ví dụ này minh họa rằng không một method nào sẽ vượt trội các method khác trong mọi tình huống. Khi các decision boundary thực là linear, LDA và logistic regression thường hoạt động tốt. Khi các boundary ở mức non-linear vừa phải, QDA hoặc naive Bayes có thể cho kết quả tốt hơn. Cuối cùng, với các decision boundary phức tạp hơn nhiều, một non-parametric approach như KNN có thể vượt trội. Nhưng mức độ smoothness của một non-parametric approach phải được chọn cẩn thận. Trong chương tiếp theo, ta sẽ xem xét một số cách để chọn đúng mức độ smoothness và, tổng quát hơn, chọn overall method tốt nhất.

Cuối cùng, nhớ từ Chương 3 rằng trong bối cảnh regression, ta có thể xử lý một quan hệ non-linear giữa các predictor và response bằng cách thực hiện regression sử dụng các phép biến đổi của predictor. Một cách tiếp cận tương tự cũng có thể được dùng trong bối cảnh classification. Chẳng hạn, ta có thể tạo một phiên bản logistic regression linh hoạt hơn bằng cách đưa  $X^2$ ,  $X^3$ , và thậm chí  $X^4$  vào làm predictor.

Việc này có thể cải thiện hoặc không cải thiện hiệu năng của logistic regression, tùy vào việc mức tăng variance do độ linh hoạt bổ sung có được bù lại bởi một mức giảm bias đủ lớn hay không. Ta cũng có thể làm tương tự với LDA. Nếu thêm vào LDA tất cả các hạng tử quadratic có thể có và các cross-product, dạng của model sẽ giống model QDA, mặc dù các parameter estimate sẽ khác nhau. Cách làm này cho phép ta di chuyển tới một vị trí nào đó giữa model LDA và model QDA.