

4.6 Generalized Linear Models

Trong Chương 3, ta giả định response Y là quantitative, và xem xét việc dùng least squares linear regression để dự đoán Y . Cho đến thời điểm này trong chương hiện tại, ta lại giả định Y là qualitative. Tuy nhiên, đôi khi ta có thể gặp những tình huống mà Y không hoàn toàn là qualitative cũng không hoàn toàn là quantitative, và vì thế cả linear regression của Chương 3 lẫn các classification approach đã trình bày trong chương này đều không áp dụng trực tiếp được.

Để có một ví dụ cụ thể, ta xét dataset **Bikeshare**. Response là **bikers**, tức số người sử dụng một chương trình chia sẻ xe đạp trong mỗi giờ tại Washington, DC. Giá trị response này không phải qualitative cũng không phải quantitative theo nghĩa thông thường: thay vào đó, nó nhận các giá trị nguyên không âm, hay *counts*. Ta sẽ dự đoán **bikers** bằng các covariate **mnth** (tháng trong năm), **hr** (giờ trong ngày, từ 0 đến 23), **workingday** (indicator variable bằng 1 nếu ngày đó không phải cuối tuần cũng không phải ngày lễ), **temp** (nhiệt độ đã chuẩn hóa, theo độ Celsius), và **weathersit** (một qualitative variable nhận một trong bốn giá trị: trời quang; sương mù hoặc nhiều mây; mưa nhẹ hoặc tuyết nhẹ; mưa lớn hoặc tuyết lớn).

counts

Trong các phân tích tiếp theo, ta sẽ coi **mnth**, **hr**, và **weathersit** là các qualitative variable.

4.6.1 Linear Regression on the Bikeshare Data

Trước hết, ta xét việc dự đoán **bikers** bằng linear regression. Kết quả được trình bày trong Bảng 4.10.


	Coefficient	Std. error	<i>t</i> -statistic	<i>p</i> -value
Intercept	73.60	5.13	14.34	0.00
workingday	1.27	1.78	0.71	0.48
temp	157.21	10.26	15.32	0.00
weathersit [cloudy/misty]	-12.89	1.96	-6.56	0.00
weathersit [light rain/snow]	-66.49	2.97	-22.43	0.00
weathersit [heavy rain/snow]	-109.75	76.67	-1.43	0.15

BẢNG 4.10. Kết quả của một least squares linear model được fit để dự đoán **bikers** trong dữ liệu **Bikeshare**. Các predictor **mnth** và **hr** được lược khỏi bảng này do giới hạn không gian, và có thể xem trong Hình 4.13. Với qualitative variable **weathersit**, baseline level tương ứng với trời quang.

Chẳng hạn, ta thấy việc thời tiết chuyển từ trời quang sang nhiều mây dẫn đến trung bình ít hơn 12.89 người đi xe đạp mỗi giờ; tuy nhiên, nếu thời tiết xấu thêm thành mưa hoặc tuyết, thì con số này tiếp tục giảm thêm 53.60 người mỗi giờ. Hình 4.13 hiển thị các coefficient gắn với **mnth** và các coefficient gắn với **hr**.

Ta thấy mức sử dụng xe đạp cao nhất vào mùa xuân và mùa thu, và thấp nhất trong các tháng mùa đông. Hơn nữa, việc sử dụng xe đạp đạt mức lớn nhất quanh giờ cao điểm (9 AM và 6 PM), và thấp nhất vào ban đêm. Vì vậy, thoạt nhìn, việc fit một linear regression model cho dataset **Bikeshare** dường như cho những kết quả hợp lý và trực quan.

Nhưng khi xem xét kỹ hơn, một số vấn đề trở nên rõ ràng. Chẳng hạn,



HÌNH 4.13. Một least squares linear regression model được fit để dự đoán **bikers** trong dataset **Bikeshare**. Trái: Các coefficient gắn với tháng trong năm. Mức sử dụng xe đạp cao nhất vào mùa xuân và mùa thu, và thấp nhất vào mùa đông. Phải: Các coefficient gắn với giờ trong ngày. Mức sử dụng xe đạp cao nhất trong các khung giờ đi làm cao điểm, và thấp nhất vào ban đêm.

9.6% fitted value trong dataset **Bikeshare** là âm: tức là linear regression model dự đoán một số lượng người dùng âm trong 9.6% số giờ của dataset. Điều này khiến khả năng tạo ra các prediction có ý nghĩa từ dữ liệu trở nên đáng ngờ, đồng thời cũng làm nảy sinh lo ngại về độ chính xác của coefficient estimate, confidence interval và các output khác của regression model.

Ngoài ra, hợp lý khi nghi ngờ rằng khi expected value của **bikers** nhỏ thì variance của **bikers** cũng nên nhỏ. Chẳng hạn, lúc 2 AM trong một trận bão tuyết lớn vào tháng Mười Hai, ta kỳ vọng cực kỳ ít người sử dụng xe đạp, và hơn nữa số người dùng trong các điều kiện đó cũng chỉ dao động rất ít. Điều này đúng với dữ liệu: từ 1 AM đến 4 AM, trong các tháng Mười Hai, Một và Hai, khi trời mưa, trung bình có 5.05 người dùng với standard deviation bằng 3.73. Trái lại, từ 7 AM đến 10 AM, trong các tháng Tư, Năm và Sáu, khi trời quang, trung bình có 243.59 người dùng với standard deviation bằng 131.7. Quan hệ mean–variance được hiển thị ở panel bên trái của Hình 4.14. Đây là một vi phạm lớn đối với các giả định của linear model, vốn phát biểu rằng

$$Y = \sum_{j=1}^p X_j \beta_j + \epsilon,$$


trong đó ϵ là một error term có mean bằng 0 và variance σ^2 không đổi, không phụ thuộc vào các covariate. Vì vậy, heteroscedasticity của dữ liệu khiến tính phù hợp của linear regression model bị đặt dấu hỏi.

Cuối cùng, response **bikers** nhận giá trị nguyên. Nhưng trong linear model,

$$Y = \beta_0 + \sum_{j=1}^p X_j \beta_j + \epsilon,$$

trong đó ϵ là một error term nhận giá trị liên tục. Điều này có nghĩa rằng trong linear model, response Y tất yếu nhận giá trị liên tục (quantitative). Do đó, bản chất integer-valued của response **bikers** cho thấy linear

regression model không hoàn toàn thỏa đáng với dataset này.



HÌNH 4.14. Trái: Trên dataset *Bikeshare*, số người đi xe đạp được hiển thị trên trục y , còn giờ trong ngày được hiển thị trên trục x . Jitter được áp dụng để dễ quan sát. Phần lớn thời gian, khi mean của số người đi xe đạp tăng thì variance của số người đi xe đạp cũng tăng. Một smoothing spline fit được vẽ bằng màu xanh lá. Phải: Log của số người đi xe đạp giờ được hiển thị trên trục y .

Một số vấn đề phát sinh khi fit linear regression model cho dữ liệu *Bikeshare* có thể được khắc phục bằng cách biến đổi response; chẳng hạn, ta có thể fit model

$$\log(Y) = \sum_{j=1}^p X_j \beta_j + \epsilon.$$

Việc biến đổi response tránh khả năng xuất hiện prediction âm, và khắc phục phần lớn heteroscedasticity trong dữ liệu chưa biến đổi, như được thể hiện ở panel bên phải của Hình 4.14. Tuy nhiên, đây vẫn chưa phải một giải pháp hoàn toàn thỏa đáng, vì prediction và inference được thực hiện theo log của response thay vì theo chính response. Điều này gây khó khăn khi diễn giải, chẳng hạn: “một mức tăng một đơn vị của X_j gắn với mức tăng β_j trong mean của log của Y ”. Hơn nữa, không thể áp dụng log transformation cho response trong những bối cảnh response có thể nhận giá trị 0. Vì vậy, dù việc fit linear model cho một phép biến đổi của response có thể là một cách tiếp cận phù hợp với một số count-valued dataset, nó thường vẫn để lại một số điểm chưa thỏa đáng. Trong mục tiếp theo, ta sẽ thấy Poisson regression model cung cấp một cách tiếp cận tự nhiên và thanh lịch hơn nhiều cho bài toán này.

4.6.2 Poisson Regression on the Bikeshare Data

Để khắc phục những điểm bất cập của linear regression khi phân tích dataset *Bikeshare*, ta sẽ sử dụng một cách tiếp cận khác gọi là *Poisson regression*. Trước khi bàn về Poisson regression, trước hết ta phải giới thiệu *Poisson distribution*.

Giả sử random variable Y nhận các giá trị nguyên không âm, tức $Y \in \{0, 1, 2, \dots\}$. Nếu Y tuân theo Poisson distribution, thì

$$\Pr(Y = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots \quad (4.35)$$

Poisson regression
Poisson
distribution

Ở đây, $\lambda > 0$ là expected value của Y , tức $E(Y)$. Hóa ra λ cũng bằng variance của Y , tức $\lambda = E(Y) = \text{Var}(Y)$. Điều này có nghĩa là nếu Y tuân theo Poisson distribution, thì mean của Y càng lớn, variance của nó cũng càng lớn. (Trong (4.35), ký hiệu $k!$, đọc là “ k factorial”, được định nghĩa là $k! = k \times (k-1) \times (k-2) \times \dots \times 3 \times 2 \times 1$.)

Poisson distribution thường được dùng để model các count; đây là một lựa chọn tự nhiên vì nhiều lý do, trong đó có việc count, giống Poisson distribution, nhận các giá trị nguyên không âm. Để thấy cách có thể dùng Poisson distribution trong thực tế, đặt Y là số người sử dụng chương trình chia sẻ xe đạp trong một giờ cụ thể của ngày, dưới một tập điều kiện thời tiết cụ thể và trong một tháng cụ thể của năm. Ta có thể model Y bằng một Poisson distribution với mean $E(Y) = \lambda = 5$. Khi đó probability không có người dùng nào trong giờ cụ thể này là $\Pr(Y = 0) = e^{-5}5^0/0! = e^{-5} = 0.0067$ (với $0! = 1$ theo quy ước). Probability có đúng một người dùng là $\Pr(Y = 1) = e^{-5}5^1/1! = 5e^{-5} = 0.034$, probability có hai người dùng là $\Pr(Y = 2) = e^{-5}5^2/2! = 0.084$, và cứ tiếp tục như vậy.

Dĩ nhiên, trong thực tế, ta kỳ vọng mean số người sử dụng chương trình chia sẻ xe đạp, $\lambda = E(Y)$, thay đổi theo giờ trong ngày, tháng trong năm, điều kiện thời tiết, v.v. Vì vậy, thay vì model số người đi xe đạp Y bằng một Poisson distribution với mean cố định như $\lambda = 5$, ta muốn cho phép mean thay đổi như một hàm của các covariate. Cụ thể, ta xét model sau cho mean $\lambda = E(Y)$, mà giờ ta viết là $\lambda(X_1, \dots, X_p)$ để nhấn mạnh rằng nó là một hàm của các covariate $X_1, \dots, X_p$:

$$\log(\lambda(X_1, \dots, X_p)) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p, \quad (4.36)$$

hoặc tương đương

$$\lambda(X_1, \dots, X_p) = e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}. \quad (4.37)$$

Ở đây, $\beta_0, \beta_1, \dots, \beta_p$ là các parameter cần estimate. Cùng nhau, (4.35) và (4.36) định nghĩa Poisson regression model. Lưu ý rằng trong (4.36), ta lấy log của $\lambda(X_1, \dots, X_p)$ là linear theo $X_1, \dots, X_p$, thay vì để chính $\lambda(X_1, \dots, X_p)$ linear theo $X_1, \dots, X_p$; điều này đảm bảo $\lambda(X_1, \dots, X_p)$ nhận giá trị không âm với mọi giá trị của các covariate.

Để estimate các coefficient $\beta_0, \beta_1, \dots, \beta_p$, ta dùng cùng maximum likelihood approach đã sử dụng cho logistic regression trong Mục 4.3.2. Cụ thể, với n observation độc lập từ Poisson regression model, likelihood có dạng


$$\ell(\beta_0, \beta_1, \dots, \beta_p) = \prod_{i=1}^n \frac{e^{-\lambda(x_i)} \lambda(x_i)^{y_i}}{y_i!}, \quad (4.38)$$

trong đó $\lambda(x_i) = e^{\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}}$ theo (4.37). Ta estimate các coefficient làm cực đại likelihood $\ell(\beta_0, \beta_1, \dots, \beta_p)$, tức các coefficient khiến observed data có likelihood lớn nhất có thể.

Bây giờ ta fit một Poisson regression model cho dataset **Bikeshare**. Kết quả được trình bày trong Bảng 4.11 và Hình 4.15. Xét về mặt định tính, kết quả tương tự kết quả từ linear regression ở Mục 4.6.1. Ta một lần nữa thấy mức sử dụng xe đạp cao nhất vào mùa xuân và mùa thu và trong giờ cao điểm,

	Coefficient	Std. error	z-statistic	p-value
Intercept	4.12	0.01	683.96	0.00
workingday	0.01	0.00	7.5	0.00
temp	0.79	0.01	68.43	0.00
weathersit[cloudy/misty]	-0.08	0.00	-34.53	0.00
weathersit[light rain/snow]	-0.58	0.00	-141.91	0.00
weathersit[heavy rain/snow]	-0.93	0.17	-5.55	0.00

BẢNG 4.11. Kết quả của một Poisson regression model được fit để dự đoán **bikers** trong dữ liệu **Bikeshare**. Các predictor *mnth* và *hr* được lược khỏi bảng này do giới hạn không gian, và có thể xem trong Hình 4.15. Với qualitative variable *weathersit*, baseline tương ứng với trời quang.



HÌNH 4.15. Một Poisson regression model được fit để dự đoán **bikers** trong dataset **Bikeshare**. Trái: Các coefficient gắn với tháng trong năm. Mức sử dụng xe đạp cao nhất vào mùa xuân và mùa thu, và thấp nhất vào mùa đông. Phải: Các coefficient gắn với giờ trong ngày. Mức sử dụng xe đạp cao nhất trong các khung giờ đi làm cao điểm, và thấp nhất vào ban đêm.

và thấp nhất vào mùa đông và trong các giờ sáng sớm. Hơn nữa, mức sử dụng xe đạp tăng khi nhiệt độ tăng, và giảm khi thời tiết xấu đi. Điều thú vị là coefficient gắn với **workingday** có statistical significance trong Poisson regression model, nhưng không có statistical significance trong linear regression model.

Một số điểm khác biệt quan trọng giữa Poisson regression model và linear regression model như sau:

- **Interpretation:** Để diễn giải các coefficient trong Poisson regression model, ta phải chú ý kỹ đến (4.37), vốn phát biểu rằng khi X_j tăng một đơn vị thì $E(Y) = \lambda$ thay đổi theo một hệ số $\exp(\beta_j)$. Chẳng hạn, việc thời tiết chuyển từ trời quang sang nhiều mây gắn với sự thay đổi mean mức sử dụng xe đạp theo hệ số $\exp(-0.08) = 0.923$, tức trung bình chỉ có 92.3% số người sử dụng xe đạp khi trời nhiều mây so với khi trời quang. Nếu thời tiết xấu thêm và bắt đầu mưa, thì mean mức sử dụng xe đạp tiếp tục thay đổi theo hệ số $\exp(-0.5) = 0.607$, tức trung bình chỉ có 60.7% số người sử dụng xe đạp khi trời mưa so với khi trời nhiều mây.

overdispersion

- *Mean–variance relationship*: Như đã đề cập trước đó, dưới Poisson model, $\lambda = E(Y) = \text{Var}(Y)$. Do đó, bằng cách model mức sử dụng xe đạp với Poisson regression, ta ngầm giả định rằng mean mức sử dụng xe đạp trong một giờ nhất định bằng variance của mức sử dụng xe đạp trong giờ đó. Trái lại, trong linear regression model, variance của mức sử dụng xe đạp luôn nhận một giá trị không đổi. Nhớ từ Hình 4.14 rằng trong dữ liệu **Bikeshare**, khi điều kiện đi xe đạp thuận lợi, cả mean lẫn variance của mức sử dụng xe đạp đều cao hơn nhiều so với khi điều kiện bất lợi. Vì vậy, Poisson regression model có thể xử lý quan hệ mean–variance quan sát được trong dữ liệu **Bikeshare** theo cách mà linear regression model không làm được.⁵
- *nonnegative fitted values*: Poisson regression model không tạo ra prediction âm. Lý do là bản thân Poisson model chỉ cho phép các giá trị không âm; xem (4.35). Trái lại, khi ta fit linear regression model cho dataset **Bikeshare**, gần 10% prediction là âm.

4.6.3 Generalized Linear Models in Greater Generality

Đến đây ta đã thảo luận ba loại regression model: linear, logistic và Poisson. Các cách tiếp cận này có một số đặc điểm chung:

1. Mỗi cách tiếp cận dùng các predictor $X_1, \dots, X_p$ để dự đoán response Y . Ta giả định rằng, conditional on $X_1, \dots, X_p$, Y thuộc một family of distributions nhất định. Với linear regression, ta thường giả định Y tuân theo Gaussian hay normal distribution. Với logistic regression, ta giả định Y tuân theo Bernoulli distribution. Cuối cùng, với Poisson regression, ta giả định Y tuân theo Poisson distribution.
2. Mỗi cách tiếp cận model mean của Y như một hàm của các predictor. Trong linear regression, mean của Y có dạng

$$E(Y \mid X_1, \dots, X_p) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p, \quad (4.39)$$

tức là một hàm linear của các predictor. Với logistic regression, mean thay vào đó có dạng

$$\begin{aligned} E(Y \mid X_1, \dots, X_p) &= \Pr(Y = 1 \mid X_1, \dots, X_p) \\ &= \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}, \end{aligned} \quad (4.40)$$

trong khi với Poisson regression, nó có dạng

$$E(Y \mid X_1, \dots, X_p) = \lambda(X_1, \dots, X_p) = e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}. \quad (4.41)$$

Các phương trình (4.39)–(4.41) có thể được biểu diễn bằng một *link function*, η , áp dụng một phép biến đổi lên $E(Y \mid X_1, \dots, X_p)$ sao cho mean

⁵Trên thực tế, variance trong dữ liệu **Bikeshare** dường như cao hơn mean rất nhiều, một tình huống được gọi là *overdispersion*. Điều này khiến các Z-value trong Bảng 4.11 bị phóng đại. Một phân tích cẩn thận hơn nên tính đến overdispersion để thu được các Z-value chính xác hơn, và có nhiều method khác nhau để làm điều này. Tuy nhiên, chúng nằm ngoài phạm vi của cuốn sách này.

sau biến đổi là một hàm linear của các predictor. Cụ thể,

$$\eta(E(Y \mid X_1, \dots, X_p)) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p. \quad (4.42)$$

link function

Các link function cho linear, logistic và Poisson regression lần lượt là $\eta(\mu) = \mu$, $\eta(\mu) = \log(\mu/(1 - \mu))$, và $\eta(\mu) = \log(\mu)$.

Gaussian, Bernoulli và Poisson distribution đều là thành viên của một class of distributions rộng hơn, được gọi là *exponential family*. Những thành viên nổi tiếng khác của family này gồm exponential distribution, Gamma distribution và negative binomial distribution. Tổng quát hơn, ta có thể thực hiện regression bằng cách model response Y như được sinh ra từ một thành viên cụ thể của exponential family, rồi biến đổi mean của response sao cho mean sau biến đổi là một hàm linear của các predictor thông qua (4.42). Bất kỳ regression approach nào tuân theo công thức rất tổng quát này đều được gọi là một *generalized linear model (GLM)*. Vì vậy, linear regression, logistic regression và Poisson regression là ba ví dụ về GLM. Các ví dụ khác không được trình bày ở đây gồm Gamma regression và negative binomial regression.

exponential family
exponential
Gamma
negative binomial
generalized linear
model