

4.8 Exercises

Conceptual

1. Dùng một chút đại số, hãy chứng minh rằng (4.2) tương đương với (4.3). Nói cách khác, biểu diễn logistic function và biểu diễn logit của logistic regression model là tương đương.
2. Trong phần nội dung trước, ta đã nói rằng việc classification một observation vào class mà (4.17) lớn nhất tương đương với việc classification observation đó vào class mà (4.18) lớn nhất. Hãy chứng minh điều này. Nói cách khác, dưới giả định rằng các observation trong class thứ k được rút ra từ distribution $N(\mu_k, \sigma^2)$, Bayes classifier gán một observation vào class mà discriminant function đạt cực đại.

3. Bài này liên quan đến QDA model, trong đó các observation thuộc mỗi class được rút ra từ một normal distribution với mean vector riêng cho class và covariance matrix riêng cho class. Ta xét trường hợp đơn giản khi $p = 1$; tức là chỉ có một feature.

Giả sử ta có K class, và nếu một observation thuộc class thứ k thì X đến từ một one-dimensional normal distribution, $X \sim N(\mu_k, \sigma_k^2)$. Nhắc lại rằng density function của one-dimensional normal distribution được cho trong (4.16). Hãy chứng minh rằng trong trường hợp này, Bayes classifier không phải là linear. Hãy lập luận rằng trên thực tế nó là quadratic.

Hint: Với bài này, hãy đi theo các lập luận được trình bày trong Mục 4.4.1, nhưng không đưa ra giả định $\sigma_1^2 = \dots = \sigma_K^2$.

4. Khi số feature p lớn, performance của KNN và các local approach khác có xu hướng suy giảm; các approach này thực hiện prediction chỉ bằng những observation ở gần test observation cần được dự đoán. Hiện tượng này được gọi là *curse of dimensionality*, và nó liên hệ với thực tế rằng các non-parametric approach thường hoạt động kém khi p lớn. Bây giờ ta sẽ khảo sát lời nguyên này.

- (a) Giả sử ta có một tập observation, mỗi observation có measurement trên $p = 1$ feature, X . Ta giả sử X được phân bố đều (uniformly) trên $[0, 1]$. Mỗi observation có một response value tương ứng. Giả sử ta muốn dự đoán response của một test observation chỉ bằng các observation nằm trong 10% range của X gần test observation đó nhất. Chẳng hạn, để dự đoán response cho một test observation với $X = 0.6$, ta sẽ dùng các observation trong range $[0.55, 0.65]$. Trung bình, ta sẽ dùng bao nhiêu phần của các observation sẵn có để thực hiện prediction?

- (b) Bây giờ giả sử ta có một tập observation, mỗi observation có measurement trên $p = 2$ feature, X_1 và X_2 . Ta giả sử (X_1, X_2) được phân bố đều trên $[0, 1] \times [0, 1]$. Ta muốn dự đoán response của một test observation chỉ bằng các observation nằm trong 10% range của X_1 và trong 10% range của X_2 gần test observation đó nhất. Chẳng hạn, để dự đoán response cho một test observation với $X_1 = 0.6$ và $X_2 = 0.35$, ta sẽ dùng các observation trong



range $[0.55, 0.65]$ đối với X_1 và trong range $[0.3, 0.4]$ đối với X_2 . Trung bình, ta sẽ dùng bao nhiêu phần của các observation sẵn có để thực hiện prediction?

- (c) Bây giờ giả sử ta có một tập observation trên $p = 100$ feature. Một lần nữa, các observation được phân bố đều trên từng feature, và mỗi feature lại nhận giá trị từ 0 đến 1. Ta muốn dự đoán response của một test observation bằng các observation nằm trong 10% range của từng feature gần test observation đó nhất. Ta sẽ dùng bao nhiêu phần của các observation sẵn có để thực hiện prediction?
- (d) Dựa trên các câu trả lời ở (a)–(c), hãy lập luận rằng một nhược điểm của KNN khi p lớn là có rất ít training observation “gần” một test observation bất kỳ.
- (e) Bây giờ giả sử ta muốn thực hiện prediction cho một test observation bằng cách tạo một p -dimensional hypercube có tâm tại test observation và trung bình chứa 10% training observation. Với $p = 1, 2$, và 100, độ dài mỗi cạnh của hypercube là bao nhiêu? Hãy nhận xét về câu trả lời của bạn.
Note: Hypercube là dạng tổng quát hóa của cube cho số chiều tùy ý. Khi $p = 1$, hypercube chỉ là một line segment; khi $p = 2$ nó là một square; và khi $p = 100$ nó là một 100-dimensional cube.

5. Bây giờ ta xem xét sự khác biệt giữa LDA và QDA.
 - (a) Nếu Bayes decision boundary là linear, ta kỳ vọng LDA hay QDA hoạt động tốt hơn trên training set? Trên test set?
 - (b) Nếu Bayes decision boundary là non-linear, ta kỳ vọng LDA hay QDA hoạt động tốt hơn trên training set? Trên test set?
 - (c) Nói chung, khi sample size n tăng, ta kỳ vọng test prediction accuracy của QDA so với LDA sẽ cải thiện, suy giảm, hay không đổi? Tại sao?
 - (d) Đúng hay Sai: Ngay cả khi Bayes decision boundary của một problem là linear, có lẽ ta vẫn đạt test error rate tốt hơn khi dùng QDA thay vì LDA vì QDA đủ flexible để model một linear decision boundary. Hãy giải thích câu trả lời.
6. Giả sử ta thu thập dữ liệu cho một nhóm sinh viên trong lớp thống kê với các variable $X_1 =$ số giờ học, $X_2 =$ undergrad GPA, và $Y =$ nhận điểm A. Ta fit một logistic regression và thu được các estimated coefficient, $\hat{\beta}_0 = -6$, $\hat{\beta}_1 = 0.05$, $\hat{\beta}_2 = 1$.
 - (a) Hãy estimate probability để một sinh viên học 40 giờ và có undergrad GPA là 3.5 nhận được điểm A trong lớp.
 - (b) Sinh viên ở phần (a) cần học bao nhiêu giờ để có 50% chance nhận được điểm A trong lớp?
7. Giả sử ta muốn dự đoán liệu một stock nhất định có phát hành dividend trong năm nay (“Yes” hoặc “No”) dựa trên X , phần trăm profit của năm trước. Ta xem xét một số lượng lớn company và phát hiện rằng mean value của X đối với các company đã phát hành dividend là

$\bar{X} = 10$, trong khi mean của các company không phát hành là $\bar{X} = 0$. Ngoài ra, variance của X đối với hai tập company này là $\hat{\sigma}^2 = 36$. Cuối cùng, 80% company đã phát hành dividend. Giả sử X tuân theo normal distribution, hãy dự đoán probability một company sẽ phát hành dividend trong năm nay khi phần trăm profit của năm trước là $X = 4$.

Hint: Nhắc lại rằng density function của một normal random variable là

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/(2\sigma^2)}.$$

Bạn sẽ cần dùng Bayes' theorem.

8. Giả sử ta lấy một dataset, chia thành training set và test set có kích thước bằng nhau, rồi thử hai classification procedure khác nhau. Đầu tiên ta dùng logistic regression và thu được error rate 20% trên training data và 30% trên test data. Tiếp theo ta dùng 1-nearest neighbors (tức $K = 1$) và thu được average error rate (lấy trung bình trên cả test và training dataset) là 18%. Dựa trên các kết quả này, ta nên ưu tiên method nào để classification các observation mới? Tại sao?
9. Bài này liên quan đến odds.
 - (a) Trung bình, tỷ lệ bao nhiêu trong số những người có odds 0.37 về việc default khoản thanh toán credit card sẽ thực sự default?
 - (b) Giả sử một người có 16% chance default khoản thanh toán credit card. Odds để người đó default là bao nhiêu?
10. Equation 4.32 đã suy ra một biểu thức cho

$$\log\left(\frac{\Pr(Y = k \mid X = x)}{\Pr(Y = K \mid X = x)}\right)$$

trong setting $p > 1$, vì thế mean của class thứ k , μ_k , là một p -dimensional vector, còn shared covariance Σ là một $p \times p$ matrix. Tuy nhiên, trong setting $p = 1$, (4.32) có dạng đơn giản hơn vì các mean $\mu_1, \dots, \mu_K$ và variance σ^2 là scalar. Trong setting đơn giản hơn này, hãy lặp lại phép tính trong (4.32), và đưa ra các biểu thức cho a_k và b_{kj} theo π_k , π_K , μ_k , μ_K , và σ^2 .

11. Hãy tính dạng chi tiết của a_k , b_{kj} , và b_{kjl} trong (4.33). Câu trả lời của bạn nên chứa π_k , π_K , μ_k , μ_K , Σ_k , và Σ_K .
12. Giả sử bạn muốn classification một observation $X \in \mathbb{R}$ thành *apples* và *oranges*. Bạn fit một logistic regression model và tìm được

$$\widehat{\Pr}(Y = \text{orange} \mid X = x) = \frac{\exp(\hat{\beta}_0 + \hat{\beta}_1 x)}{1 + \exp(\hat{\beta}_0 + \hat{\beta}_1 x)}.$$

Bạn của bạn fit một logistic regression model cho cùng dữ liệu bằng softmax formulation trong (4.13), và tìm được

$$\widehat{\Pr}(Y = \text{orange} \mid X = x) = \frac{\exp(\hat{\alpha}_{\text{orange}0} + \hat{\alpha}_{\text{orange}1}x)}{\exp(\hat{\alpha}_{\text{orange}0} + \hat{\alpha}_{\text{orange}1}x) + \exp(\hat{\alpha}_{\text{apple}0} + \hat{\alpha}_{\text{apple}1}x)}.$$

- (a) Log odds của orange so với apple trong model của bạn là gì?
- (b) Log odds của orange so với apple trong model của người bạn là gì?
- (c) Giả sử trong model của bạn, $\hat{\beta}_0 = 2$ và $\hat{\beta}_1 = -1$. Các coefficient estimate trong model của người bạn là gì? Hãy cụ thể nhất có thể.
- (d) Bây giờ giả sử bạn và người bạn fit cùng hai model trên một dataset khác. Lần này, người bạn thu được các coefficient estimate $\hat{\alpha}_{\text{orange}0} = 1.2$, $\hat{\alpha}_{\text{orange}1} = -2$, $\hat{\alpha}_{\text{orange}0} = 3$, $\hat{\alpha}_{\text{orange}1} = 0.6$. Các coefficient estimate trong model của bạn là gì?
- (e) Cuối cùng, giả sử bạn apply cả hai model ở (d) cho một dataset có 2,000 test observation. Bạn kỳ vọng predicted class label từ model của mình đồng ý với model của người bạn trong bao nhiêu phần thời gian? Hãy giải thích câu trả lời.

Applied

13. Câu hỏi này cần được trả lời bằng dataset **Weekly**, là một phần của package **ISLP**. Dữ liệu này tương tự về bản chất với dữ liệu **Smarket** trong lab của chapter này, ngoại trừ việc nó chứa 1,089 weekly return trong 21 năm, từ đầu năm 1990 đến cuối năm 2010.
 - (a) Hãy tạo một số numerical và graphical summary của dữ liệu **Weekly**. Có pattern nào xuất hiện không?
 - (b) Dùng full dataset để thực hiện logistic regression với **Direction** làm response và năm lag variable cộng với **Volume** làm predictor. Dùng summary function để in kết quả. Có predictor nào có vẻ statistically significant không? Nếu có, predictor nào?
 - (c) Tính confusion matrix và overall fraction của các prediction đúng. Hãy giải thích confusion matrix cho biết điều gì về các loại mistake do logistic regression tạo ra.
 - (d) Bây giờ fit logistic regression model bằng training data period từ 1990 đến 2008, với **Lag2** là predictor duy nhất. Tính confusion matrix và overall fraction của các prediction đúng cho held-out data (tức dữ liệu từ 2009 và 2010).
 - (e) Lặp lại (d) bằng LDA.
 - (f) Lặp lại (d) bằng QDA.
 - (g) Lặp lại (d) bằng KNN với $K = 1$.
 - (h) Lặp lại (d) bằng naive Bayes.
 - (i) Method nào trong số này có vẻ cho kết quả tốt nhất trên dữ liệu này?
 - (j) Hãy thử nghiệm các combination khác nhau của predictor, bao gồm các transformation và interaction có thể có, cho từng method. Báo cáo các variable, method, và confusion matrix tương ứng có vẻ cho kết quả tốt nhất trên held-out data. Lưu ý rằng bạn cũng nên thử nghiệm các giá trị của K trong KNN

classifier.

14. Trong bài này, bạn sẽ phát triển một model để dự đoán liệu một car cho trước có gas mileage cao hay thấp dựa trên dataset **Auto**.

- (a) Tạo binary variable **mpg01**, nhận giá trị 1 nếu **mpg** có giá trị lớn hơn median của nó, và 0 nếu **mpg** có giá trị nhỏ hơn median. Bạn có thể tính median bằng method **median()** của dataframe. Lưu ý rằng có thể sẽ hữu ích khi thêm column **mpg01** vào dataframe bằng assignment. Giả sử bạn đã lưu dataframe dưới tên **Auto**, điều này có thể được thực hiện như sau:

```
Auto['mpg01'] = mpg01
```

- (b) Khám phá dữ liệu bằng graphical analysis để khảo sát association giữa **mpg01** và các feature khác. Feature nào trong số các feature còn lại có vẻ hữu ích nhất để dự đoán **mpg01**? Scatterplot và boxplot có thể là các tool hữu ích để trả lời câu hỏi này. Hãy mô tả các phát hiện của bạn.
- (c) Chia dữ liệu thành training set và test set.
- (d) Thực hiện LDA trên training data để dự đoán **mpg01** bằng các variable có vẻ association mạnh nhất với **mpg01** trong (b). Test error của model thu được là bao nhiêu?
- (e) Thực hiện QDA trên training data để dự đoán **mpg01** bằng các variable có vẻ association mạnh nhất với **mpg01** trong (b). Test error của model thu được là bao nhiêu?
- (f) Thực hiện logistic regression trên training data để dự đoán **mpg01** bằng các variable có vẻ association mạnh nhất với **mpg01** trong (b). Test error của model thu được là bao nhiêu?
- (g) Thực hiện naive Bayes trên training data để dự đoán **mpg01** bằng các variable có vẻ association mạnh nhất với **mpg01** trong (b). Test error của model thu được là bao nhiêu?
- (h) Thực hiện KNN trên training data với một số giá trị của K để dự đoán **mpg01**. Chỉ dùng các variable có vẻ association mạnh nhất với **mpg01** trong (b). Bạn thu được những test error nào? Giá trị K nào có vẻ hoạt động tốt nhất trên dataset này?
15. Bài này liên quan đến việc viết function.
- (a) Viết một function, **Power()**, in ra kết quả của việc nâng 2 lên lũy thừa 3. Nói cách khác, function của bạn phải tính 2^3 và in kết quả.
Hint: Nhắc lại rằng $x**a$ nâng x lên lũy thừa a . Dùng function **print()** để hiển thị kết quả.
- (b) Tạo một function mới, **Power2()**, cho phép bạn truyền vào hai số bất kỳ, x và a , rồi in giá trị $x**a$. Bạn có thể làm điều này bằng cách bắt đầu function bằng dòng

```
def Power2(x, a):
```

Bạn có thể gọi function bằng cách nhập, chẳng hạn,

```
Power2(3, 8)
```

trên command line. Lệnh này phải output giá trị của 3^8 , tức 6,561.

- (c) Dùng function `Power2()` vừa viết để tính 10^3 , 8^{17} , và 13^{13} .
- (d) Bây giờ tạo một function mới, `Power3()`, thực sự *return* kết quả `x**a` dưới dạng một Python object, thay vì chỉ in nó ra screen. Tức là, nếu bạn lưu giá trị `x**a` trong một object tên `result` bên trong function, thì bạn chỉ cần return result bằng dòng sau:

```
return result
```

return

Lưu ý rằng dòng trên phải là dòng cuối cùng trong function, và nó phải được indent 4 space.

- (e) Bây giờ dùng function `Power3()` để tạo plot của $f(x) = x^2$. Trục x phải hiển thị range các integer từ 1 đến 10, và trục y phải hiển thị x^2 . Label các axis một cách phù hợp, và dùng title phù hợp cho figure. Hãy cân nhắc hiển thị trục x , trục y , hoặc cả hai trên log-scale. Bạn có thể làm điều này bằng cách dùng method `ax.set_xscale()` và `ax.set_yscale()` của axes mà bạn đang plot lên.

`.set_xscale()`
`.set_yscale()`

- (f) Tạo một function, `PlotPower()`, cho phép bạn tạo plot của x so với $x**a$ cho một a cố định và một sequence các giá trị của x . Chẳng hạn, nếu bạn gọi

```
PlotPower(np.arange(1, 11), 3)
```

thì một plot phải được tạo với trục x nhận các giá trị 1, 2, ..., 10, và trục y nhận các giá trị $1^3, 2^3, \dots, 10^3$.

16. Dùng dataset `Boston`, fit các classification model để dự đoán liệu một suburb cho trước có crime rate cao hơn hay thấp hơn median. Hãy khám phá logistic regression, LDA, naive Bayes, và KNN model bằng nhiều subset khác nhau của predictor. Mô tả các phát hiện của bạn.
Hint: Bạn sẽ phải tự tạo response variable bằng các variable có trong dataset `Boston`.