

6

Linear Model Selection and Regularization

Trong regression setting, standard linear model

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon \quad (6.1)$$

được dùng rất phổ biến để mô tả relationship giữa một response Y và một tập variable $X_1, X_2, \dots, X_p$. Ở Chapter 3, ta đã thấy model này thường được fit bằng least squares.

Trong các chapter tiếp theo, ta sẽ xét một số approach mở rộng linear model framework. Ở Chapter 7, ta tổng quát hóa (6.1) để accommodate các relationship non-linear nhưng vẫn additive; còn ở Chapters 8 và 10, ta xét những non-linear model tổng quát hơn nữa. Tuy nhiên, linear model có những ưu điểm rõ rệt về inference và, trên các real-world problem, thường cạnh tranh đáng ngạc nhiên so với non-linear methods. Vì vậy, trước khi chuyển sang thế giới non-linear, chapter này thảo luận một số cách cải thiện simple linear model bằng cách thay plain least squares fitting bằng các fitting procedure khác.

Tại sao ta lại muốn dùng một fitting procedure khác thay cho least squares? Như sẽ thấy, các alternative fitting procedure có thể mang lại prediction accuracy tốt hơn và model interpretability cao hơn.

- **Prediction Accuracy:** Nếu true relationship giữa response và predictors xấp xỉ linear, các least squares estimate sẽ có bias thấp. Nếu $n \gg p$ — tức n , số observation, lớn hơn nhiều so với p , số variable — thì các least squares estimate cũng thường có variance thấp và do đó hoạt động tốt trên test observation. Tuy nhiên, nếu n không lớn hơn p nhiều, least squares fit có thể biến động mạnh, dẫn đến overfitting và prediction kém trên future observation không được dùng để training model. Nếu $p > n$, thậm chí không còn một least squares coefficient estimate duy nhất: có vô số solution. Mỗi least squares solution đó cho error bằng zero trên training data, nhưng thường có test-set performance rất kém do variance cực cao.¹ Bằng cách con-

¹Khi $p \geq n$, least squares solution có tổng bình phương coefficient nhỏ nhất đôi khi có thể

strain hoặc shrink các estimated coefficient, ta thường có thể giảm variance đáng kể với cái giá là bias chỉ tăng rất ít. Điều này có thể cải thiện mạnh accuracy khi dự đoán response cho các observation không được dùng trong model training.

- **Model Interpretability:** Trong nhiều multiple regression model, một phần hoặc nhiều variable thực tế không liên quan đến response. Việc đưa các irrelevant variable này vào làm model phức tạp không cần thiết. Nếu loại bỏ chúng — tức đặt các coefficient estimate tương ứng bằng zero — ta có thể thu được model dễ interpret hơn. Least squares hầu như không bao giờ tạo ra coefficient estimate chính xác bằng zero. Trong chapter này, ta sẽ gặp một số approach tự động thực hiện *feature selection* hay *variable selection*, tức loại các irrelevant variable khỏi multiple regression model.

feature selection
variable selection

Có rất nhiều alternative, cả classical lẫn modern, cho việc dùng least squares để fit (6.1). Trong chapter này, ta thảo luận ba class method quan trọng.

- **Subset Selection.** Approach này xác định một subset trong số p predictors mà ta tin rằng có liên quan đến response. Sau đó ta fit model bằng least squares trên tập variable đã được rút gọn.
- **Shrinkage.** Approach này fit một model chứa toàn bộ p predictors, nhưng các estimated coefficient bị shrink về phía zero so với least squares estimate. Sự shrinkage này (cũng gọi là regularization) làm giảm variance. Tùy loại shrinkage, một số coefficient có thể được estimate chính xác bằng zero; vì vậy shrinkage method cũng có thể thực hiện variable selection.
- **Dimension Reduction.** Approach này project p predictors lên một M -dimensional subspace, với $M < p$. Việc này được thực hiện bằng cách tính M linear combination, hay projection, khác nhau của các variable. Sau đó M projection này được dùng làm predictors để fit linear regression model bằng least squares.

Trong các section sau, ta mô tả chi tiết từng approach cùng ưu và nhược điểm của chúng. Mặc dù chapter này trình bày các extension và modification của linear model cho regression ở Chapter 3, những concept tương tự cũng áp dụng cho các method khác, chẳng hạn classification model ở Chapter 4.

6.1 Subset Selection

Trong section này, ta xét một số method chọn subset của predictors, bao gồm best subset và stepwise model selection procedure.

6.1.1 Best Subset Selection

Để thực hiện *best subset selection*, ta fit một least squares regression riêng cho mọi combination có thể của p predictors. Cụ thể, ta fit toàn bộ p model chứa đúng một predictor, toàn bộ $\binom{p}{2} = p(p-1)/2$ model chứa đúng hai predictors, và tiếp tục như vậy. Sau đó ta xem xét toàn bộ model thu được, với mục tiêu xác định model tốt nhất.

Việc chọn best model trong số 2^p possibility được xét bởi best subset selection không hề đơn giản. Thường ta chia bài toán thành hai stage, như Algorithm 6.1.

Algorithm 6.1 Best subset selection


1. Gọi $\mathcal{M}_0$ là null model, không chứa predictor nào. Model này đơn giản dự đoán sample mean cho mọi observation.
2. Với $k = 1, 2, \dots, p$:
 - (a) Fit toàn bộ $\binom{p}{k}$ model chứa đúng k predictors.
 - (b) Chọn model tốt nhất trong $\binom{p}{k}$ model này và gọi là $\mathcal{M}_k$. Ở đây, “best” nghĩa là có RSS nhỏ nhất, hoặc tương đương R^2 lớn nhất.
3. Chọn một best model duy nhất trong $\mathcal{M}_0, \dots, \mathcal{M}_p$ bằng prediction error trên validation set, C_p (AIC), BIC, adjusted R^2 , hoặc cross-validation.

Trong Algorithm 6.1, Step 2 xác định best model (trên training data) cho mỗi subset size, nhờ đó rút bài toán từ 2^p possible model xuống còn $p+1$ possible model. Trong Figure 6.1, các model này tạo thành lower frontier màu đỏ.

Để chọn một best model duy nhất, ta chỉ còn phải chọn trong $p+1$ option đó. Tuy nhiên việc này cần cẩn trọng, vì RSS của $p+1$ model giảm đơn điệu còn R^2 tăng đơn điệu khi số feature trong model tăng. Nếu dùng trực tiếp hai statistic này để chọn best model, ta sẽ luôn kết thúc với model chứa tất cả variable. Vấn đề là RSS thấp hoặc R^2 cao chỉ ra training error thấp, trong khi điều ta muốn là test error thấp. Như Figures 2.9–2.11 ở Chapter 2 cho thấy, training error thường nhỏ hơn test error khá nhiều và training error thấp hoàn toàn không đảm bảo test error thấp. Vì vậy, ở Step 3 ta dùng error trên validation set, C_p , BIC, adjusted R^2 , hoặc cross-validation để chọn giữa $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$. Nếu dùng cross-validation, Step 2 được lặp riêng trên từng training fold rồi validation error được average để chọn giá trị k tốt nhất.

Sau khi chọn được k , model $\mathcal{M}_k$ được fit trên toàn bộ training set và được dùng làm model cuối. Các approach để chọn k được thảo luận ở Section 6.1.3.

Figure 6.1 minh họa best subset selection trên dataset **Credit**, đã được



HÌNH 6.1. Với mỗi possible model chứa một subset của mười predictors trong dataset *Credit*, RSS và R^2 được hiển thị. Red frontier nối best model cho từng số lượng predictors, theo RSS và R^2 . Mặc dù dataset chỉ có mười predictors, trục x chạy từ 1 đến 11 vì một variable là categorical với ba value, dẫn đến việc tạo hai dummy variable.

thảo luận ở Chapter 3. Mỗi point là một least squares regression model fit bằng một subset khác nhau của 10 predictors. Variable **region** là qualitative variable có ba level nên được biểu diễn bằng hai dummy variable, và trong trường hợp này hai dummy variable được chọn riêng rẽ. Vì thế có tổng cộng 11 possible variable có thể xuất hiện trong model. Ta plot RSS và R^2 của mỗi model theo số variable. Các red curve nối best model ở mỗi model size, dựa trên RSS hoặc R^2 . Đúng như kỳ vọng, hai quantity này cải thiện khi số variable tăng; tuy nhiên từ model ba-variable trở đi, việc thêm predictor chỉ cải thiện RSS và R^2 rất ít.

Dù ở đây ta trình bày best subset selection cho least squares regression, cùng ý tưởng cũng áp dụng cho các model khác, chẳng hạn logistic regression. Với logistic regression, thay vì sắp xếp model theo RSS ở Step 2 của Algorithm 6.1, ta dùng *deviance*, một measure đóng vai trò giống RSS cho một class model rộng hơn. Deviance bằng âm hai lần maximized log-likelihood; deviance càng nhỏ thì fit càng tốt.

deviance

Best subset selection đơn giản và hấp dẫn về mặt concept, nhưng có limitation về computation. Số possible model phải xét tăng rất nhanh theo p . Nói chung, có 2^p model hình thành từ các subset của p predictors. Nếu $p = 10$, có khoảng 1,000 possible model; nếu $p = 20$, có hơn một triệu possibility. Do đó best subset selection trở nên computationally infeasible khi p lớn hơn khoảng 40, ngay cả với computer hiện đại rất nhanh. Có các computational shortcut — gọi là branch-and-bound technique — để loại bớt một số choice, nhưng chúng cũng có limitation khi p lớn và chỉ áp dụng cho least squares linear regression. Tiếp theo ta xét các alternative hiệu quả hơn về computation.

6.1.2 Stepwise Selection

Vì lý do computation, best subset selection không thể áp dụng khi p rất lớn. Khi p lớn, best subset selection còn có thể gặp statistical problem: search space càng lớn thì càng dễ tìm được model trông rất tốt trên training data nhưng không có predictive power trên future data. Vì vậy một search space khổng lồ có thể dẫn đến overfitting và variance cao của coefficient estimate. Do cả hai lý do này, stepwise method — vốn chỉ khám phá một tập model hạn chế hơn nhiều — là alternative hấp dẫn cho best subset selection.

Forward Stepwise Selection

Forward stepwise selection là một alternative hiệu quả về computation cho best subset selection. Nếu best subset selection xét tất cả 2^p possible model chứa subset của p predictors, forward stepwise chỉ xét một tập model nhỏ hơn rất nhiều. Forward stepwise bắt đầu bằng model không có predictor, rồi thêm predictor vào model từng variable một cho đến khi toàn bộ predictors đều đã được đưa vào. Ở mỗi step, variable tạo ra improvement lớn nhất cho fit được thêm vào model. Procedure chính thức được cho trong Algorithm 6.2.

*forward stepwise
selection*

Algorithm 6.2 Forward stepwise selection

1. Gọi $\mathcal{M}_0$ là null model, không chứa predictor nào.
2. Với $k = 0, \dots, p - 1$:
 - (a) Xét toàn bộ $p - k$ model tạo ra bằng cách thêm một predictor vào tập predictor của $\mathcal{M}_k$.
 - (b) Chọn best model trong số $p - k$ model này và gọi là $\mathcal{M}_{k+1}$. “Best” nghĩa là có RSS nhỏ nhất hoặc R^2 lớn nhất.
3. Chọn một best model trong $\mathcal{M}_0, \dots, \mathcal{M}_p$ bằng prediction error trên validation set, C_p (AIC), BIC, adjusted R^2 , hoặc cross-validation.

Khác với best subset selection phải fit 2^p model, forward stepwise selection fit một null model và $p - k$ model ở iteration thứ k , với $k = 0, \dots, p - 1$. Tổng cộng là

$$1 + \sum_{k=0}^{p-1} (p - k) = 1 + \frac{p(p+1)}{2}$$

model. Khác biệt là rất lớn: khi $p = 20$, best subset selection cần fit 1,048,576 model, còn forward stepwise chỉ cần 211 model.²

Ở Step 2(b) của Algorithm 6.2, ta phải xác định best model trong số $p - k$ model được tạo bằng cách thêm một predictor vào $\mathcal{M}_k$. Ta có thể đơn giản chọn model có RSS thấp nhất hoặc R^2 cao nhất. Nhưng ở Step 3, ta phải xác định best model trong một tập model có số variable khác nhau; bài toán này khó hơn và được thảo luận ở Section 6.1.3.

Lợi thế computation của forward stepwise selection so với best subset selection là rõ ràng. Dù forward stepwise thường hoạt động tốt trong thực

²Mặc dù forward stepwise selection xét $p(p+1)/2 + 1$ model một cách trực tiếp, nó thực hiện guided search trong model space, nên effective model space được xét lớn hơn đáng kể con số này.

# Variables	Best subset	Forward stepwise
One	rating	rating
Two	rating, income	rating, income
Three	rating, income, student	rating, income, student
Four	cards, income	rating, income,
	student, limit	student, limit

BẢNG 6.1. Bốn model đầu tiên được chọn bởi best subset selection và forward stepwise selection trên dataset *Credit*. Ba model đầu giống nhau, nhưng model thứ tư khác nhau.

tế, nó không được đảm bảo tìm ra best possible model trong tất cả 2^p model. Ví dụ, giả sử dataset có $p = 3$ predictors, best possible one-variable model chứa X_1 , trong khi best possible two-variable model lại chứa X_2 và X_3 . Forward stepwise sẽ không thể chọn best two-variable model vì $\mathcal{M}_1$ đã chứa X_1 , nên $\mathcal{M}_2$ bắt buộc cũng chứa X_1 cùng một variable khác.

Table 6.1 minh họa phenomenon này trên dataset *Credit*. Cả best subset selection lẫn forward stepwise selection đều chọn **rating** cho best one-variable model, rồi thêm **income** và **student** vào two- và three-variable model. Tuy nhiên, ở four-variable model, best subset selection thay **rating** bằng **cards**, trong khi forward stepwise phải giữ **rating**. Figure 6.1 cho thấy trong ví dụ này three- và four-variable model không khác nhau nhiều về RSS, vì thế cả hai four-variable model đều có thể đủ tốt.

Forward stepwise selection có thể áp dụng ngay cả trong high-dimensional setting $n < p$; tuy nhiên khi đó chỉ có thể xây dựng các submodel $\mathcal{M}_0, \dots, \mathcal{M}_{n-1}$, vì mỗi submodel được fit bằng least squares, vốn không có unique solution nếu số predictor trong model lớn hơn hoặc bằng n .

Backward Stepwise Selection

Giống forward stepwise selection, *backward stepwise selection* là một alternative hiệu quả cho best subset selection. Tuy nhiên, thay vì bắt đầu từ null model, backward stepwise bắt đầu bằng full least squares model chứa toàn bộ p predictors, rồi lặp đi lặp lại việc loại predictor ít hữu ích nhất, từng variable một. Chi tiết ở Algorithm 6.3.

*backward stepwise
selection*

Algorithm 6.3 Backward stepwise selection

1. Gọi $\mathcal{M}_p$ là full model, chứa toàn bộ p predictors.
2. Với $k = p, p - 1, \dots, 1$:
 - (a) Xét toàn bộ k model chứa tất cả predictors trong $\mathcal{M}_k$ trừ một predictor, nên mỗi model có $k - 1$ predictors.
 - (b) Chọn best model trong số k model này và gọi là $\mathcal{M}_{k-1}$. “Best” nghĩa là RSS nhỏ nhất hoặc R^2 lớn nhất.
3. Chọn một best model trong $\mathcal{M}_0, \dots, \mathcal{M}_p$ bằng prediction error trên validation set, C_p (AIC), BIC, adjusted R^2 , hoặc cross-validation.

Giống forward stepwise selection, backward selection chỉ search qua $1 + p(p+1)/2$ model và vì thế có thể dùng khi p quá lớn để best subset selection

khả thi.³ Nó cũng không được đảm bảo tạo ra best model trong tất cả subset của p predictors.

Backward selection yêu cầu số sample n lớn hơn số variable p để full model có thể được fit. Ngược lại, forward stepwise dùng được ngay cả khi $n < p$, vì vậy đây là subset method khả thi duy nhất khi p rất lớn.

Hybrid Approaches

Best subset, forward stepwise và backward stepwise selection thường cho các model tương tự nhưng không hoàn toàn giống nhau. Một alternative khác là các hybrid version của forward và backward stepwise selection. Trong đó variable được thêm vào model sequentially như forward selection, nhưng sau mỗi lần thêm variable mới, method cũng có thể loại đi những variable không còn tạo improvement cho model fit. Approach này cố gắng mô phỏng best subset selection sát hơn trong khi vẫn giữ computational advantage của forward và backward stepwise selection.

6.1.3 Choosing the Optimal Model

Best subset selection, forward selection và backward selection tạo ra một tập model, mỗi model chứa một subset của p predictors. Để dùng các method này, ta cần một cách xác định model nào là best. Như đã thảo luận ở Section 6.1.1, model chứa toàn bộ predictors luôn có RSS nhỏ nhất và R^2 lớn nhất vì các quantity này gắn với training error. Nhưng điều ta muốn là model có test error thấp. Training error có thể là estimate rất kém của test error; vì thế RSS và R^2 không phù hợp để chọn best model trong một collection model có số predictor khác nhau.

Để chọn best model theo test error, ta cần estimate test error. Có hai approach phổ biến:

1. Indirectly estimate test error bằng cách điều chỉnh training error để account cho bias do overfitting.
2. Directly estimate test error bằng validation set approach hoặc cross-validation approach, như đã thảo luận ở Chapter 5.

Ta xét cả hai approach dưới đây.

C_p , AIC, BIC, and Adjusted R^2

Chapter 2 cho thấy training-set MSE nói chung underestimate test MSE (nhắc lại $MSE = RSS/n$). Khi fit model trên training data bằng least squares, ta cụ thể chọn regression coefficient sao cho training RSS — chứ không phải test RSS — nhỏ nhất có thể. Đặc biệt, training error sẽ giảm khi thêm variable vào model, trong khi test error thì không nhất thiết giảm. Do đó training-set RSS và training-set R^2 không thể dùng để chọn giữa các model có số variable khác nhau.

Tuy nhiên, có một số technique điều chỉnh training error theo model size. Các approach này cho phép chọn giữa các model có số variable khác nhau. Ta xét bốn approach: C_p , Akaike information criterion (AIC), Bayesian information criterion (BIC), và adjusted R^2 . Figure 6.2 hiển thị C_p , BIC

³Giống forward stepwise selection, backward stepwise selection thực hiện guided search trong model space nên effective number of model được xét lớn hơn đáng kể $1 + p(p+1)/2$.


và adjusted R^2 cho best model ở mỗi size do best subset selection tạo ra trên dataset **Credit**.

Với một fitted least squares model chứa d predictors, C_p estimate của test MSE được tính bởi

$$C_p = \frac{1}{n} (\text{RSS} + 2d\hat{\sigma}^2), \quad (6.2)$$

trong đó $\hat{\sigma}^2$ là estimate của variance của error ε gắn với mỗi response measurement trong (6.1).⁴ Thông thường $\hat{\sigma}^2$ được estimate bằng full model chứa tất cả predictors. Về bản chất, statistic C_p cộng penalty $2d\hat{\sigma}^2$ vào training RSS để điều chỉnh việc training error có xu hướng underestimate test error. Penalty tăng khi số predictor trong model tăng.

C_p
Akaike information
criterion
Bayesian
information
criterion
adjusted R^2



HÌNH 6.2. C_p , BIC và adjusted R^2 cho best model ở mỗi size trên dataset **Credit** (lower frontier trong Figure 6.1). C_p và BIC là estimate của test MSE. Ở middle plot, BIC estimate của test error tăng sau khi bốn variable được chọn. Hai plot còn lại khá flat sau khi bốn variable được đưa vào.

Mục đích của penalty là account cho decrease tương ứng trong training RSS khi thêm predictor. Dù nằm ngoài scope của sách, có thể chứng minh rằng nếu $\hat{\sigma}^2$ là unbiased estimate của σ^2 trong (6.2), thì C_p là unbiased estimate của test MSE. Vì vậy C_p có xu hướng nhỏ với model có test error thấp, và ta chọn model có C_p nhỏ nhất. Trong Figure 6.2, C_p chọn six-variable model chứa predictors **income**, **limit**, **rating**, **cards**, **age** và **student**.

AIC criterion được định nghĩa cho một class model rộng được fit bằng maximum likelihood. Với model (6.1) có Gaussian error, maximum likelihood và least squares là cùng một procedure. Trong trường hợp này,

$$\text{AIC} = \frac{1}{n} (\text{RSS} + 2d\hat{\sigma}^2),$$

trong đó để đơn giản ta đã bỏ các constant không liên quan.⁵ Vì vậy, với

⁴Mallow's C_p đôi khi được định nghĩa là $C'_p = \text{RSS}/\hat{\sigma}^2 + 2d - n$. Định nghĩa này tương đương với định nghĩa ở đây theo nghĩa $C_p = (\hat{\sigma}^2/n)(C'_p + n)$, nên model có C_p nhỏ nhất cũng có C'_p nhỏ nhất.

⁵Có hai formula cho AIC trong least squares regression. Formula ở đây cần một expression cho σ^2 , được estimate bằng full model chứa tất cả predictors. Formula thứ hai phù hợp khi σ^2 unknown và ta không muốn estimate trực tiếp; khi đó có term $\log(\text{RSS})$ thay cho RSS. Derivation chi tiết của hai formula nằm ngoài scope của sách.

least squares model, C_p và AIC tỷ lệ với nhau nên Figure 6.2 chỉ hiển thị C_p .

BIC được suy ra từ Bayesian point of view nhưng cuối cùng cũng có dạng tương tự C_p và AIC. Với least squares model chứa d predictors, bỏ qua các constant không liên quan,

$$\text{BIC} = \frac{1}{n} (\text{RSS} + \log(n)d\hat{\sigma}^2). \quad (6.3)$$

Giống C_p , BIC thường nhỏ với model có test error thấp, nên nhìn chung ta chọn model có BIC nhỏ nhất. BIC thay $2d\hat{\sigma}^2$ trong C_p bằng $\log(n)d\hat{\sigma}^2$. Vì $\log n > 2$ khi $n > 7$, BIC thường penalize model có nhiều variable mạnh hơn và do đó có xu hướng chọn model nhỏ hơn C_p .

Figure 6.2 cho thấy đúng phenomenon này trên dataset **Credit**: BIC chọn model chỉ gồm bốn predictors **income**, **limit**, **cards** và **student**. Trong ví dụ này các curve rất flat, nên accuracy của four-variable và six-variable model có vẻ không khác nhau nhiều.

Adjusted R^2 là một approach phổ biến khác để chọn giữa các model có số variable khác nhau. Nhắc lại $R^2 = 1 - \text{RSS}/\text{TSS}$, với $\text{TSS} = \sum_i (y_i - \bar{y})^2$. Vì RSS luôn giảm khi thêm variable, R^2 luôn tăng. Với least squares model có d variables, adjusted R^2 được tính bởi

$$\text{Adjusted } R^2 = 1 - \frac{\text{RSS}/(n - d - 1)}{\text{TSS}/(n - 1)}. \quad (6.4)$$

Khác C_p , AIC và BIC, nơi value nhỏ gợi ý test error thấp, adjusted R^2 càng lớn càng tốt. Maximizing adjusted R^2 tương đương minimizing $\text{RSS}/(n - d - 1)$. Dù RSS luôn giảm khi tăng số variable, quantity này có thể tăng hoặc giảm vì d cũng xuất hiện trong denominator.


Intuition của adjusted R^2 là: sau khi tất cả correct variable đã được đưa vào model, thêm noise variable chỉ làm RSS giảm rất ít. Nhưng vì noise variable làm d tăng, chúng có thể làm $\text{RSS}/(n - d - 1)$ tăng và adjusted R^2 giảm. Về lý thuyết, model có adjusted R^2 lớn nhất sẽ chỉ chứa correct variable và không chứa noise variable. Khác ordinary R^2 , adjusted R^2 phải trả một “price” cho việc đưa unnecessary variable vào. Với dataset **Credit**, statistic này chọn seven-variable model, tức thêm **own** vào model được C_p và AIC chọn.

C_p , AIC và BIC đều có theoretical justification chặt chẽ nhưng nằm ngoài scope của sách; chúng dựa trên asymptotic argument, tức scenario khi sample size n rất lớn. Dù phổ biến và khá intuitive, adjusted R^2 không được motivate trong statistical theory tốt bằng AIC, BIC và C_p . Tất cả measure này đều dễ dùng và dễ compute. Ở đây ta trình bày formula cho linear model fit bằng least squares, nhưng AIC và BIC cũng có thể được định nghĩa cho các model tổng quát hơn.

Validation and Cross-Validation

Một alternative là estimate test error trực tiếp bằng validation set và cross-validation method ở Chapter 5. Ta compute validation-set error hoặc cross-validation error cho từng model đang xét, rồi chọn model có estimated test error nhỏ nhất. Procedure này có advantage so với AIC, BIC, C_p và adjusted R^2 : nó cho direct estimate của test error và đặt ít assumption

hơn lên true underlying model. Nó cũng áp dụng được cho nhiều model-selection task hơn, kể cả khi khó xác định model degrees of freedom (ví dụ số predictors) hoặc khó estimate error variance σ^2 .



HÌNH 6.3. Với dataset *Credit*, ba quantity được hiển thị cho best model chứa d predictors, với d từ 1 đến 11. Overall best model theo từng quantity được đánh dấu bằng blue cross. Left: Square root của BIC. Center: Validation-set error. Right: Cross-validation error.

Khi dùng cross-validation, sequence $\mathcal{M}_k$ trong Algorithms 6.1–6.3 được xác định riêng cho từng training fold, rồi validation error được average qua tất cả fold cho mỗi model size k . Điều này có nghĩa, chẳng hạn với best-subset regression, $\mathcal{M}_k$ — best subset size k — có thể khác nhau giữa các fold. Sau khi chọn best size k , ta tìm best model có size đó trên full dataset.

Trước đây, cross-validation có thể quá tốn computation đối với problem có p và/hoặc n lớn, nên AIC, BIC, C_p và adjusted R^2 hấp dẫn hơn để chọn trong một tập model. Với computer hiện nay, computation cho cross-validation hầu như không còn là vấn đề. Do đó cross-validation là approach rất hấp dẫn cho model selection.

Figure 6.3 hiển thị BIC, validation-set error và cross-validation error trên *Credit* theo d , cho best d -variable model. Validation error được tính bằng cách chọn ngẫu nhiên ba phần tư observation làm training set và phần còn lại làm validation set. Cross-validation error dùng $k = 10$ folds. Trong trường hợp này, cả validation lẫn cross-validation đều chọn six-variable model. Tuy nhiên, cả ba approach đều gợi ý four-, five- và six-variable model gần như tương đương về test error.

Thực tế, các estimated test-error curve ở center và right panel của Figure 6.3 khá flat. Three-variable model rõ ràng có estimated test error thấp hơn two-variable model, nhưng model từ 3 đến 11 variable có error khá giống nhau. Nếu lặp validation set approach với một split khác, hoặc lặp cross-validation bằng các fold khác, precise model có estimated test error nhỏ nhất chắc chắn có thể thay đổi.

Trong setting như vậy, ta có thể dùng *one-standard-error rule*. Trước hết, tính standard error của estimated test MSE cho mỗi model size; sau đó chọn model nhỏ nhất có estimated test error nằm trong một standard error của lowest point trên curve. Lý do là nếu một nhóm model có vẻ tốt gần như ngang nhau, ta nên chọn model đơn giản nhất — tức model có ít predictors nhất. Ở đây, áp dụng one-standard-error rule cho validation-set

one-standard-error
rule

hoặc cross-validation approach đều dẫn đến three-variable model.

6.2 Shrinkage Methods

Các subset selection method ở Section 6.1 dùng least squares để fit một linear model chỉ chứa một subset của predictors. Một alternative là fit model chứa toàn bộ p predictors bằng technique constrain hoặc regularize coefficient estimate, hay tương đương là shrink các coefficient estimate về zero. Ban đầu có thể chưa rõ tại sao constraint như vậy lại cải thiện fit, nhưng thực tế việc shrink coefficient estimate có thể làm variance giảm đáng kể. Hai technique nổi tiếng nhất để shrink regression coefficient về zero là ridge regression và lasso.

6.2.1 Ridge Regression

Nhắc lại từ Chapter 3 rằng least squares fitting procedure estimate $\beta_0, \beta_1, \dots, \beta_p$ bằng các value minimize

$$\text{RSS} = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2.$$

Ridge regression rất giống least squares, chỉ khác coefficient được estimate bằng cách minimize một quantity hơi khác. Cụ thể, ridge regression coefficient estimate $\hat{\beta}^R$ là các value minimize

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 = \text{RSS} + \lambda \sum_{j=1}^p \beta_j^2, \quad (6.5)$$

trong đó $\lambda \geq 0$ là một *tuning parameter* được xác định riêng. Equation (6.5) trade off hai criterion. Giống least squares, ridge regression tìm coefficient estimate fit data tốt bằng cách giữ RSS nhỏ. Nhưng term thứ hai, $\lambda \sum_j \beta_j^2$, gọi là *shrinkage penalty*, nhỏ khi $\beta_1, \dots, \beta_p$ gần zero và vì thế có tác dụng shrink các estimate β_j về zero. Tuning parameter λ điều khiển relative impact của hai term.


ridge regression
tuning parameter
shrinkage penalty

Khi $\lambda = 0$, penalty term không có effect và ridge regression cho đúng least squares estimate. Khi $\lambda \rightarrow \infty$, shrinkage penalty ngày càng chi phối và ridge coefficient estimate tiến về zero. Khác least squares chỉ tạo một bộ coefficient estimate, ridge regression tạo một bộ $\hat{\beta}_\lambda^R$ khác nhau cho mỗi λ . Vì thế chọn một λ tốt là critical; Section 6.2.3 sẽ dùng cross-validation cho việc này.

Trong (6.5), shrinkage penalty áp dụng cho $\beta_1, \dots, \beta_p$ nhưng không áp dụng cho intercept β_0 . Ta muốn shrink estimated association của từng variable với response, nhưng không muốn shrink intercept, vốn chỉ đo mean response khi $x_{i1} = \dots = x_{ip} = 0$. Nếu các column của data matrix X đã được center để có mean zero trước khi ridge regression, thì estimated intercept là $\hat{\beta}_0 = \bar{y} = \sum_i y_i / n$.

An Application to the Credit Data

Figure 6.4 hiển thị ridge regression coefficient estimate cho dataset **Credit**. Ở left panel, mỗi curve là coefficient estimate của một trong



HÌNH 6.4. Các standardized ridge regression coefficient trên dataset *Credit*, theo λ và $\|\hat{\beta}_\lambda^R\|_2/\|\hat{\beta}\|_2$.

mười variable theo λ . Chẳng hạn black solid line là ridge estimate cho coefficient của **income**. Ở cực trái, λ gần zero nên coefficient gần như least squares estimate. Khi λ tăng, các ridge coefficient shrink về zero; với λ cực lớn, mọi estimate gần zero, tương ứng null model không predictor. Các variable **income**, **limit**, **rating** và **student** được vẽ bằng màu riêng vì có coefficient magnitude lớn nhất. Mặc dù aggregate coefficient thường giảm theo λ , một coefficient riêng lẻ như **rating** hoặc **income** đôi khi có thể tăng trong một đoạn khi λ tăng.

Right panel của Figure 6.4 hiển thị cùng các ridge coefficient nhưng trục x là $\|\hat{\beta}_\lambda^R\|_2/\|\hat{\beta}\|_2$, trong đó $\hat{\beta}$ là vector least squares coefficient estimate. Ký hiệu $\|\beta\|_2$ là ℓ_2 norm (đọc là “ell 2”) của vector,

$$\|\beta\|_2 = \sqrt{\sum_{j=1}^p \beta_j^2},$$

và đo distance của β tới zero. Khi λ tăng, ℓ_2 norm của $\hat{\beta}_\lambda^R$ luôn giảm, nên ratio này đi từ 1 khi $\lambda = 0$ đến 0 khi $\lambda = \infty$. Vì vậy có thể xem trục x của right panel là mức độ các ridge coefficient đã bị shrink về zero.

ℓ_2 norm

Standard least squares coefficient estimate là *scale equivariant*: nhân predictor X_j với constant c chỉ làm coefficient tương ứng scale bởi $1/c$, nên $X_j\hat{\beta}_j$ không đổi. Ridge regression thì khác: coefficient estimate có thể thay đổi đáng kể khi scale một predictor. Chẳng hạn **income** có thể đo bằng dollars hoặc thousand dollars. Vì penalty trong (6.5) phụ thuộc trực tiếp vào tổng bình phương coefficient, thay đổi scale không chỉ đơn giản nhân ridge coefficient của **income** với 1,000. Giá trị $X_j\hat{\beta}_{j,\lambda}^R$ phụ thuộc cả λ lẫn scale của predictor thứ j , thậm chí có thể phụ thuộc scale của các predictor khác. Vì vậy tốt nhất nên standardize predictors trước ridge regression:

$$\tilde{x}_{ij} = \frac{x_{ij}}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}}, \quad (6.6)$$


để tất cả predictor ở cùng scale. Denominator là estimated standard deviation của predictor thứ j , nên standardized predictor có standard deviation

scale equivariant

bằng one. Nhờ vậy final fit không phụ thuộc unit đo predictor. Figure 6.4 dùng standardized ridge coefficient estimate.

Why Does Ridge Regression Improve Over Least Squares?

Advantage của ridge regression so với least squares bắt nguồn từ bias-variance trade-off. Khi λ tăng, flexibility của ridge fit giảm, variance giảm nhưng bias tăng. Figure 6.5 minh họa điều này trên simulated dataset có $p = 45$ predictors và $n = 50$ observations.



HÌNH 6.5. Squared bias (đen), variance (xanh lá), và test mean squared error (tím) của ridge regression prediction trên simulated dataset, theo λ và $\|\hat{\beta}_\lambda^R\|_2 / \|\hat{\beta}\|_2$. Horizontal dashed line là minimum possible MSE. Purple cross chỉ ridge regression model có MSE nhỏ nhất.

Green curve ở left panel của Figure 6.5 là variance của ridge prediction theo λ . Tại least squares solution ($\lambda = 0$), variance cao nhưng bias bằng zero. Khi λ tăng, shrinkage làm variance giảm mạnh đổi lại bias tăng nhẹ. Test MSE (màu tím) liên hệ chặt với variance cộng squared bias. Với λ tăng từ 0 đến khoảng 10, variance giảm nhanh trong khi bias chỉ tăng rất ít, nên MSE giảm đáng kể. Sau đó variance giảm chậm hơn còn coefficient bị shrink quá mạnh, làm bias tăng nhanh. Minimum MSE đạt gần $\lambda = 30$. Đáng chú ý, do variance cao, MSE của least squares fit gần cao bằng MSE của null model; ở intermediate λ , MSE thấp hơn nhiều.

Right panel của Figure 6.5 vẽ cùng các curve theo ratio ℓ_2 norm của ridge coefficient so với least squares coefficient. Khi đi từ trái sang phải, fit flexible hơn, bias giảm và variance tăng.

Nói chung, khi relationship giữa response và predictors gần linear, least squares estimate có bias thấp nhưng có thể variance cao: một thay đổi nhỏ trong training data có thể làm coefficient estimate thay đổi lớn. Khi p gần bằng n , như Figure 6.5, least squares estimate cực kỳ variable; nếu $p > n$, least squares thậm chí không có unique solution. Ridge regression vẫn có thể hoạt động tốt bằng cách đổi một chút tăng bias lấy giảm mạnh variance. Vì thế ridge regression hữu ích nhất khi least squares estimate có variance cao.

Ridge regression cũng có computational advantage lớn so với best subset selection, vốn phải search qua 2^p model. Ngay cả p vừa phải, search đó có thể infeasible. Với một fixed λ , ridge regression chỉ fit một model và có thể fit rất nhanh. Thực tế, có thể tính solution của (6.5) đồng thời cho toàn bộ λ với lượng computation gần như một least squares fit.

6.2.2 The Lasso

Ridge regression có một disadvantage rõ ràng. Khác best subset, forward stepwise và backward stepwise selection, ridge regression luôn giữ toàn bộ p predictors trong final model. Penalty $\lambda \sum_j \beta_j^2$ shrink tất cả coefficient về zero nhưng không đặt coefficient nào chính xác bằng zero (trừ khi $\lambda = \infty$). Điều này có thể không ảnh hưởng prediction accuracy nhưng gây khó cho model interpretation khi p lớn. Ví dụ trên **Credit**, các variable quan trọng nhất có vẻ là **income**, **limit**, **rating** và **student**; ta có thể muốn model chỉ gồm những predictor này, nhưng ridge regression vẫn luôn tạo model gồm cả mười predictors.

Lasso là alternative tương đối mới cho ridge regression và khắc phục drawback đó. Lasso coefficient $\hat{\beta}_\lambda^L$ minimize


$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| = \text{RSS} + \lambda \sum_{j=1}^p |\beta_j|. \quad (6.7)$$

So với (6.5), chỉ có β_j^2 trong ridge penalty được thay bằng $|\beta_j|$. Theo terminology thống kê, lasso dùng ℓ_1 penalty thay vì ℓ_2 penalty; ℓ_1 norm là $\|\beta\|_1 = \sum_j |\beta_j|$.

lasso

Giống ridge regression, lasso shrink coefficient estimate về zero. Nhưng ℓ_1 penalty có thể ép một số coefficient estimate bằng đúng zero khi λ đủ lớn. Vì vậy, giống best subset selection, lasso thực hiện variable selection. Model do lasso tạo ra thường dễ interpret hơn ridge regression; ta nói lasso tạo *sparse model*, tức model chỉ gồm một subset variable. Chọn λ tốt vẫn critical và sẽ được giải quyết ở Section 6.2.3 bằng cross-validation.

sparse



HÌNH 6.6. Standardized lasso coefficient trên dataset **Credit**, theo λ và $\|\hat{\beta}_\lambda^L\|_1 / \|\hat{\beta}\|_1$.

Figure 6.6 cho coefficient path khi áp dụng lasso lên **Credit**. Khi $\lambda = 0$, lasso là least squares; khi λ đủ lớn, lasso là null model với mọi coefficient bằng zero. Ở giữa hai extreme này, lasso và ridge khác nhau đáng kể. Đi từ trái sang phải trong right panel, ban đầu lasso chỉ giữ predictor **rating**; sau đó **student** và **limit** gần như cùng lúc vào model, tiếp theo là **income**; cuối cùng các variable còn lại mới vào. Vì thế tùy λ , lasso có thể tạo model với bất kỳ số variable nào. Ridge regression thì luôn gồm tất cả variable, chỉ magnitude thay đổi theo λ .

Another Formulation for Ridge Regression and the Lasso

Có thể chứng minh lasso và ridge coefficient estimate lần lượt solve

$$\underset{\beta}{\text{minimize}} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \right\} \quad \text{subject to} \quad \sum_{j=1}^p |\beta_j| \leq s, \quad (6.8)$$

và

$$\underset{\beta}{\text{minimize}} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \right\} \quad \text{subject to} \quad \sum_{j=1}^p \beta_j^2 \leq s. \quad (6.9)$$

Nói cách khác, với mỗi λ tồn tại một s sao cho (6.7) và (6.8) cho cùng lasso estimate; tương tự (6.5) và (6.9) cho cùng ridge estimate.

Khi $p = 2$, (6.8) nói rằng lasso estimate là point có RSS nhỏ nhất trong diamond $|\beta_1| + |\beta_2| \leq s$. Ridge estimate là point có RSS nhỏ nhất trong circle $\beta_1^2 + \beta_2^2 \leq s$. Có thể hiểu s như một budget: với lasso, $\sum_j |\beta_j|$ không được vượt quá s ; với ridge, $\sum_j \beta_j^2$ không được vượt quá s . Nếu s rất lớn và least squares solution nằm trong feasible region, constraint không có effect và solution chính là least squares. Nếu s nhỏ, coefficient bắt buộc phải nhỏ.

Các formulation (6.8) và (6.9) cho thấy connection gần giữa lasso, ridge regression và best subset selection. Xét problem


$$\underset{\beta}{\text{minimize}} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \right\} \quad \text{subject to} \quad \sum_{j=1}^p I(\beta_j \neq 0) \leq s. \quad (6.10)$$

Ở đây $I(\beta_j \neq 0)$ là indicator variable, bằng 1 nếu $\beta_j \neq 0$ và bằng 0 otherwise. (6.10) tìm coefficient estimate có RSS nhỏ nhất với không quá s coefficient nonzero, nên equivalent với best subset selection. Tuy nhiên khi p lớn, giải (6.10) computationally infeasible vì phải xét toàn bộ $\binom{p}{s}$ model chứa s predictors. Có thể xem ridge và lasso là computationally feasible alternative, thay constraint khó trong (6.10) bằng constraint dễ solve hơn. Lasso gần best subset selection hơn vì với s đủ nhỏ nó thực hiện feature selection, còn ridge thì không.

The Variable Selection Property of the Lasso

Tại sao lasso, khác ridge regression, có thể tạo coefficient estimate chính xác bằng zero? Figure 6.7 giúp giải thích. Least squares solution được ký hiệu $\hat{\beta}$; blue diamond và circle là lasso và ridge constraint region của (6.8) và (6.9). Nếu s đủ lớn, các region chứa $\hat{\beta}$ và cả lasso lẫn ridge cho least squares estimate. Nhưng trong Figure 6.7, least squares estimate nằm ngoài cả diamond lẫn circle.

Mỗi ellipse centered tại $\hat{\beta}$ là một contour: mọi point trên cùng ellipse có cùng RSS. Ellipse càng mở rộng khỏi least squares estimate thì RSS càng tăng. Theo (6.8) và (6.9), lasso hoặc ridge estimate là point đầu tiên nơi một ellipse chạm constraint region. Ridge có circular constraint không có sharp corner, nên intersection thường không nằm trên axis và coefficient thường đều nonzero. Lasso constraint lại có corner trên các axis, vì thế ellipse thường chạm region tại một axis; khi đó một coefficient bằng zero.




HÌNH 6.7. Contour của error và constraint function cho lasso (left) và ridge regression (right). Solid blue region là constraint $|\beta_1| + |\beta_2| \leq s$ và $\beta_1^2 + \beta_2^2 \leq s$; red ellipse là contour của RSS.

Trong higher dimension, nhiều coefficient có thể đồng thời bằng zero. Trong Figure 6.7, intersection xảy ra tại $\beta_1 = 0$, nên resulting model chỉ gồm β_2 .

Với $p = 3$, ridge constraint region là sphere còn lasso là polyhedron. Với $p > 3$, ridge thành hypersphere còn lasso thành polytope. Key idea vẫn giữ nguyên: sharp corner của lasso region dẫn đến feature selection.

Comparing the Lasso and Ridge Regression

Lasso có advantage lớn về interpretability vì tạo model đơn giản hơn, chỉ gồm subset predictors. Nhưng method nào prediction accuracy tốt hơn? Figure 6.8 hiển thị variance, squared bias và test MSE của lasso trên cùng simulated data như Figure 6.5. Khi λ tăng, lasso cũng cho variance giảm và bias tăng, giống ridge về qualitative behavior.




HÌNH 6.8. Left: Squared bias (đen), variance (xanh lá), và test MSE (tím) của lasso trên simulated dataset. Right: So sánh squared bias, variance và test MSE giữa lasso (solid) và ridge (dotted). Cả hai được plot theo training-data R^2 như một common indexing. Cross ở hai plot chỉ lasso model có MSE nhỏ nhất.

Trong right panel, dotted line là ridge fit; cả hai method được plot theo training-data R^2 , một cách hữu ích để compare model có regularization khác nhau. Trong ví dụ này, lasso và ridge có bias gần như identical, nhưng ridge có variance hơi thấp hơn nên minimum MSE cũng hơi nhỏ hơn.

Tuy nhiên, data của Figure 6.8 được generate sao cho cả 45 predictors đều liên quan đến response, tức không true coefficient nào bằng zero. Lasso implicitly assume một số coefficient thật sự bằng zero, nên không ngạc nhiên khi ridge có prediction error tốt hơn trong setting này. Figure 6.9 dùng setup tương tự nhưng response chỉ là function của 2 trong 45 predictors; khi đó lasso có xu hướng outperform ridge về bias, variance và MSE.

Hai ví dụ cho thấy không method nào universally dominate. Lasso có thể tốt hơn khi chỉ một số ít predictors có substantial coefficient, còn coefficient của predictor khác rất nhỏ hoặc zero. Ridge thường tốt hơn khi response phụ thuộc vào nhiều predictors với coefficient có magnitude tương đối giống nhau. Trong real data, ta không biết trước bao nhiêu predictor liên quan đến response; cross-validation có thể dùng để quyết định approach nào tốt hơn trên một dataset cụ thể. Cũng như ridge, khi least squares estimate có variance quá cao, lasso có thể giảm variance đổi lấy một increase nhỏ về bias và nhờ đó prediction chính xác hơn. Khác ridge, lasso thực hiện variable selection nên model dễ interpret hơn.



HÌNH 6.9. Left: Squared bias, variance và test MSE của lasso trên simulated data tương tự Figure 6.8 nhưng chỉ hai predictors liên quan đến response. Right: So sánh lasso (solid) và ridge (dotted) theo training-data R^2 . Cross chỉ lasso model có MSE nhỏ nhất.

Có các algorithm rất efficient để fit cả ridge lẫn lasso; trong cả hai trường hợp, toàn bộ coefficient path có thể được compute với lượng work xấp xỉ một single least squares fit. Lab cuối chapter sẽ khảo sát điều này kỹ hơn.

A Simple Special Case for Ridge Regression and the Lasso

Để có intuition rõ hơn về behavior của ridge và lasso, xét special case $n = p$, và X là diagonal matrix với 1 trên diagonal, 0 ở mọi off-diagonal entry. Để đơn giản thêm, giả sử regression không có intercept. Least squares problem trở thành tìm $\beta_1, \dots, \beta_p$ minimize


$$\sum_{j=1}^p (y_j - \beta_j)^2. \quad (6.11)$$

Solution là $\hat{\beta}_j = y_j$. Trong setting này, ridge regression minimize

$$\sum_{j=1}^p (y_j - \beta_j)^2 + \lambda \sum_{j=1}^p \beta_j^2, \quad (6.12)$$

còn lasso minimize

$$\sum_{j=1}^p (y_j - \beta_j)^2 + \lambda \sum_{j=1}^p |\beta_j|. \quad (6.13)$$



HÌNH 6.10. Ridge regression và lasso coefficient estimate trong simple setting $n = p$ với X là diagonal matrix có 1 trên diagonal. Left: Ridge estimate shrink proportionally về zero so với least squares estimate. Right: Lasso estimate được soft-threshold về zero.

Có thể chứng minh ridge estimate trong setting này là

$$\hat{\beta}_j^R = \frac{y_j}{1 + \lambda}, \quad (6.14)$$

còn lasso estimate là

$$\hat{\beta}_j^L = \begin{cases} y_j - \lambda/2, & y_j > \lambda/2, \\ y_j + \lambda/2, & y_j < -\lambda/2, \\ 0, & |y_j| \leq \lambda/2. \end{cases} \quad (6.15)$$

Figure 6.10 cho thấy hai loại shrinkage rất khác. Ridge shrink mọi least squares coefficient cùng một proportion. Lasso shrink mỗi coefficient về zero một constant amount $\lambda/2$; coefficient có absolute value nhỏ hơn $\lambda/2$ bị shrink hoàn toàn về zero. Kiểu shrinkage trong (6.15) gọi là *soft-thresholding*; đây là lý do lasso thực hiện feature selection.

soft-thresholding

Với data matrix X tổng quát hơn, picture phức tạp hơn Figure 6.10 nhưng main idea vẫn gần đúng: ridge shrink mọi dimension với proportion tương tự, còn lasso shrink mọi coefficient về zero với amount tương tự và các coefficient đủ nhỏ bị shrink hẳn về zero.

Bayesian Interpretation of Ridge Regression and the Lasso


Ta có thể nhìn ridge regression và lasso qua Bayesian lens. Bayesian viewpoint cho regression giả sử coefficient vector $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T$ có

prior distribution $p(\beta)$. Likelihood của data viết là $f(Y | X, \beta)$, với $X = (X_1, \dots, X_p)$. Nhân prior với likelihood cho posterior distribution, bỏ constant tỷ lệ:

$$p(\beta | X, Y) \propto f(Y | X, \beta)p(\beta | X) = f(Y | X, \beta)p(\beta),$$

trong đó proportionality theo Bayes' theorem và equality cuối dựa trên assumption rằng X fixed.

posterior
distribution



HÌNH 6.11. Left: Ridge regression là posterior mode của β dưới Gaussian prior. Right: Lasso là posterior mode của β dưới double-exponential prior.

Giả sử usual linear model $Y = \beta_0 + X_1\beta_1 + \dots + X_p\beta_p + \varepsilon$, với independent normally distributed error, và $p(\beta) = \prod_{j=1}^p g(\beta_j)$ cho density g . Ridge và lasso xuất hiện tự nhiên từ hai special case:


- Nếu g là Gaussian distribution mean zero với standard deviation là function của λ , posterior mode của β — most likely value của β given data — chính là ridge regression solution. Thực tế ridge solution cũng là posterior mean.
- Nếu g là double-exponential (Laplace) distribution mean zero với scale parameter là function của λ , posterior mode của β là lasso solution. Tuy nhiên lasso solution không phải posterior mean; posterior mean cũng không tạo sparse coefficient vector.

posterior mode

Gaussian và double-exponential prior được minh họa ở Figure 6.11. Từ Bayesian viewpoint, ridge và lasso theo trực tiếp từ usual linear model với normal error cộng một simple prior cho β . Lasso prior nhọn mạnh tại zero, còn Gaussian flatter và fatter ở zero. Vì vậy lasso kỳ vọng a priori nhiều coefficient bằng đúng zero, trong khi ridge giả sử coefficient phân bố ngẫu nhiên quanh zero.

6.2.3 Selecting the Tuning Parameter

Giống subset selection ở Section 6.1 cần một method xác định model nào tốt nhất, ridge và lasso cần method chọn tuning parameter λ trong (6.5), (6.7), hay tương đương constraint s trong (6.9), (6.8). Cross-validation cung cấp cách đơn giản: chọn một grid λ , compute cross-validation error




HÌNH 6.12. Left: Cross-validation error khi áp dụng ridge regression lên dataset *Credit* với nhiều λ . Right: Coefficient estimate theo λ . Vertical dashed line chỉ λ được cross-validation chọn.

cho từng value, chọn value có error nhỏ nhất, rồi refit model trên toàn bộ observation bằng λ đã chọn.

Figure 6.12 cho λ được chọn khi dùng leave-one-out cross-validation trên ridge fit của *Credit*. Dashed vertical line là selected λ . Value khá nhỏ, cho thấy optimal fit chỉ cần shrinkage nhẹ so với least squares. Dip của error curve cũng không rõ, nên một wide range λ cho error gần như nhau; trong case như vậy ta thậm chí có thể dùng least squares solution.

Figure 6.13 minh họa ten-fold cross-validation cho lasso trên sparse simulated data của Figure 6.9. Left panel là cross-validation error, right panel là coefficient estimate. Dashed vertical line là point error nhỏ nhất. Hai colored line ở right panel là hai predictors thật sự liên quan đến response; grey line là unrelated predictors, thường gọi lần lượt là *signal* và *noise* variable. Lasso không chỉ cho much larger coefficient cho hai signal predictors mà minimum cross-validation error còn ứng với coefficient set trong đó chỉ signal variable nonzero. Do đó cross-validation kết hợp lasso đã nhận diện đúng hai signal variable trong setting khó với $p = 45$ và chỉ $n = 50$ observations.

signal



HÌNH 6.13. Left: Ten-fold cross-validation MSE của lasso trên sparse simulated dataset trong Figure 6.9. Right: Lasso coefficient estimate tương ứng. Hai signal variable được vẽ màu, noise variable màu xám. Vertical dashed line chỉ lasso fit có cross-validation error nhỏ nhất.

Trong khi đó least squares solution ở cực phải của right panel Figure 6.13 lại assign coefficient estimate lớn cho chỉ một trong hai signal variable.

6.3 Dimension Reduction Methods

Các method đã bàn trong chapter này kiểm soát variance theo hai cách: dùng một subset của original variables, hoặc shrink coefficient của chúng về zero. Tất cả đều được định nghĩa trên original predictors $X_1, X_2, \dots, X_p$. Bây giờ ta xét một class approach transform predictors trước, rồi fit least squares model bằng transformed variables. Ta gọi các technique này là *dimension reduction methods*.


Gọi $Z_1, Z_2, \dots, Z_M$ là $M < p$ linear combination của p original predictors:

$$Z_m = \sum_{j=1}^p \phi_{jm} X_j, \quad (6.16)$$

cho một số constant $\phi_{1m}, \phi_{2m}, \dots, \phi_{pm}$, $m = 1, \dots, M$. Sau đó ta fit linear regression model

$$y_i = \theta_0 + \sum_{m=1}^M \theta_m z_{im} + \varepsilon_i, \quad i = 1, \dots, n, \quad (6.17)$$

bằng least squares. Regression coefficient trong (6.17) là $\theta_0, \theta_1, \dots, \theta_M$. Nếu các ϕ_{jm} được chọn khéo, dimension reduction approach thường có thể out-perform least squares regression trên original predictors.



HÌNH 6.14. Population size (*pop*) và ad spending (*ad*) của 100 city được hiển thị bằng purple circle. Green solid line là first principal component, blue dashed line là second principal component.

Tên gọi dimension reduction xuất phát từ việc problem estimate $p + 1$ coefficient $\beta_0, \beta_1, \dots, \beta_p$ được rút xuống còn $M + 1$ coefficient $\theta_0, \theta_1, \dots, \theta_M$, với $M < p$. Tức dimension của problem giảm từ $p + 1$ xuống $M + 1$.

Từ (6.16),

$$\sum_{m=1}^M \theta_m z_{im} = \sum_{m=1}^M \theta_m \sum_{j=1}^p \phi_{jm} x_{ij} = \sum_{j=1}^p \sum_{m=1}^M \theta_m \phi_{jm} x_{ij} = \sum_{j=1}^p \beta_j x_{ij},$$

trong đó

$$\beta_j = \sum_{m=1}^M \theta_m \phi_{jm}. \quad (6.18)$$

Vì vậy (6.17) có thể xem là special case của original linear regression model (6.1). Dimension reduction constrain estimated β_j vì giờ chúng phải có form (6.18). Constraint này có thể tạo bias, nhưng khi p lớn relative to n , chọn $M \ll p$ có thể giảm variance của fitted coefficient đáng kể. Nếu $M = p$ và mọi Z_m linearly independent, (6.18) không impose constraint nào; lúc đó không có dimension reduction và fit (6.17) tương đương least squares trên p original predictors.

Mọi dimension reduction method đều có hai step. Thứ nhất, tạo transformed predictors $Z_1, \dots, Z_M$. Thứ hai, fit model dùng M predictors này. Nhưng cách chọn Z_m , hay tương đương các ϕ_{jm} , có thể khác nhau. Chapter này xét hai approach: principal components và partial least squares.

6.3.1 Principal Components Regression

Principal components analysis (PCA) là approach phổ biến để derive một low-dimensional feature set từ một tập variable lớn. PCA được thảo luận chi tiết hơn như một tool cho unsupervised learning ở Chapter 12. Ở đây ta mô tả cách dùng PCA như dimension reduction technique cho regression.

*principal
components
analysis*

An Overview of Principal Components Analysis

PCA là technique giảm dimension của data matrix X kích thước $n \times p$. *First principal component direction* là direction mà observations vary nhiều nhất. Chẳng hạn Figure 6.14 hiển thị population size (**pop**, đơn vị chục nghìn người) và ad spending (**ad**, nghìn dollars) của 100 city.⁶ Green solid line là first principal component direction. Nhìn bằng mắt, đây là direction có greatest variability. Nếu project 100 observations lên line này (như left panel Figure 6.15), projected observations có variance lớn nhất có thể; project lên bất kỳ line nào khác sẽ cho variance nhỏ hơn. Project một point lên line đơn giản là tìm point trên line gần nó nhất.

First principal component trong Figure 6.14 có thể viết toán học là

$$Z_1 = 0.839(\text{pop} - \overline{\text{pop}}) + 0.544(\text{ad} - \overline{\text{ad}}). \quad (6.19)$$

Ở đây $\phi_{11} = 0.839$ và $\phi_{21} = 0.544$ là *principal component loadings*, định nghĩa direction nói trên. Trong (6.19), $\overline{\text{pop}}$ và $\overline{\text{ad}}$ là mean của các value tương ứng. Trong mọi linear combination của **pop** và **ad** thỏa $\phi_{11}^2 + \phi_{21}^2 = 1$, combination này có variance lớn nhất. Constraint norm bằng one là cần thiết; nếu không ta có thể tùy ý tăng ϕ_{11}, ϕ_{21} để làm variance phình ra. Hai loading trong (6.19) đều positive và có magnitude tương tự, nên Z_1 gần như average của hai variables.


Vì $n = 100$, **pop**, **ad** và Z_1 đều là vector length 100. Với observation thứ i ,

$$z_{i1} = 0.839(\text{pop}_i - \overline{\text{pop}}) + 0.544(\text{ad}_i - \overline{\text{ad}}). \quad (6.20)$$

Các value $z_{11}, \dots, z_{n1}$ được gọi là *principal component scores* và xuất hiện ở right panel Figure 6.15.

⁶Dataset này khác dataset **Advertising** được thảo luận ở Chapter 3.

PCA còn có interpretation khác: first principal component vector định nghĩa line gần data nhất có thể. Trong Figure 6.14, first principal component line minimize tổng squared perpendicular distance từ mỗi point tới line. Các distance này được vẽ bằng dashed line segment ở left panel Figure 6.15; các cross là projection của point lên first principal component line. First principal component được chọn để projected observations gần original observations nhất.



HÌNH 6.15. Một subset của advertising data. Mean $\mathbf{pop}$ và $\mathbf{ad}$ được đánh dấu bằng blue circle. Left: First principal component direction màu xanh lá; đây vừa là dimension data vary nhiều nhất, vừa là line gần toàn bộ n observations nhất. Distance từ mỗi observation tới principal component được vẽ bằng black dashed segment. Blue dot là $(\overline{\mathbf{pop}}, \overline{\mathbf{ad}})$. Right: Left panel được rotate để first principal component direction trùng với trục x .


Ở right panel của Figure 6.15, left panel đã được rotate sao cho first principal component direction trùng trục x . Có thể chứng minh first principal component score của observation thứ i , (6.20), chính là distance theo direction x từ cross thứ i tới zero. Ví dụ, point ở bottom-left của left panel có score lớn âm $z_{i1} = -26.1$, còn point top-right có score lớn dương $z_{i1} = 18.7$. Các score này có thể tính trực tiếp bằng (6.20).

Ta có thể xem value của principal component Z_1 như single-number summary của joint $\mathbf{pop}$ và $\mathbf{ad}$ budget cho mỗi location. Nếu $z_{i1} < 0$, city đó có xu hướng population size và ad spending dưới average; score dương gợi ý điều ngược lại. Một number duy nhất đại diện hai variable tốt đến đâu? Figure 6.14 cho thấy $\mathbf{pop}$ và $\mathbf{ad}$ gần linear, nên single-number summary có thể hoạt động tốt. Figure 6.16 plot z_{i1} với cả $\mathbf{pop}$ và $\mathbf{ad}$; relationship mạnh cho thấy first principal component giữ phần lớn information của hai predictors.⁷

Cho đến đây ta tập trung vào first principal component. Tổng quát có thể xây dựng tối đa p distinct principal components. Second principal component Z_2 là linear combination của variables không correlated với Z_1 và có variance lớn nhất dưới constraint đó. Second principal component direction là dashed blue line trong Figure 6.14. Condition zero correlation giữa Z_1 và Z_2 tương đương direction thứ hai phải perpendicular, hay *orthogonal*, với direction thứ nhất. Ở example này,

$$Z_2 = 0.544(\mathbf{pop} - \overline{\mathbf{pop}}) - 0.839(\mathbf{ad} - \overline{\mathbf{ad}}).$$

⁷Các principal component được tính sau khi standardize cả $\mathbf{pop}$ và $\mathbf{ad}$, một common approach. Vì vậy x-axis của Figures 6.15 và 6.16 không cùng scale.



HÌNH 6.16. Plot first principal component score z_{i1} theo *pop* và *ad*. Các relationship đều mạnh.

Advertising data chỉ có hai predictors nên first two principal components chứa toàn bộ information của *pop* và *ad*; tuy nhiên theo construction, first component giữ nhiều information nhất. Right panel Figure 6.15 cho thấy variability của z_{i1} lớn hơn nhiều z_{i2} . Figure 6.17 cũng cho thấy relationship giữa second principal component với *pop*, *ad* rất yếu, gợi ý chỉ first component đã đủ để đại diện khá chính xác hai budget này.


perpendicular
orthogonal

Với two-dimensional data ta chỉ xây được tối đa hai principal component. Nếu có thêm predictors như population age, income level hay education, ta có thể xây thêm component; từng component kế tiếp maximize variance với constraint không correlated với các component trước.

The Principal Components Regression Approach


Principal components regression (PCR) xây first M principal components $Z_1, \dots, Z_M$, rồi dùng chúng làm predictors trong linear regression model fit bằng least squares. Key idea là thường chỉ một số ít principal component đã đủ explain phần lớn variability trong data và relationship với response. Nói cách khác, ta assume những direction mà $X_1, \dots, X_p$ vary nhiều nhất cũng là những direction associated với Y . Assumption này không được guarantee, nhưng trong nhiều case là approximation đủ tốt.

principal
components
regression



HÌNH 6.17. Plot second principal component score z_{i2} theo *pop* và *ad*. Các relationship đều yếu.

and σ^2 are relationships are weak.




HÌNH 6.18. PCR được áp dụng lên hai simulated dataset. Horizontal dashed line ở mỗi panel là irreducible error. Left: Simulated data từ Figure 6.8. Right: Simulated data từ Figure 6.9.

Nếu assumption nền tảng của PCR đúng, fit least squares model trên $Z_1, \dots, Z_M$ có thể tốt hơn fit trên $X_1, \dots, X_p$, vì phần lớn information liên quan response nằm trong M components và ta chỉ estimate $M \ll p$ coefficient nên giảm overfitting. Trong advertising data, first principal component explain phần lớn variance của cả `pop` và `ad`; vì vậy PCR chỉ dùng component này để predict một response như `sales` có thể hoạt động khá tốt.

Figure 6.18 hiển thị PCR fit trên simulated dataset từ Figures 6.8 và 6.9. Cả hai có $n = 50$ observations, $p = 45$ predictors; ở dataset đầu response là function của tất cả predictors, còn dataset sau chỉ phụ thuộc hai predictors. Curve được plot theo M , số principal components dùng trong regression. Khi tăng M , bias giảm nhưng variance tăng, tạo U-shape quen thuộc cho MSE. Khi $M = p = 45$, PCR chính là least squares fit dùng toàn bộ original predictors. Figure cho thấy chọn M hợp lý có thể cải thiện đáng kể so với least squares, đặc biệt ở left panel. Tuy vậy, so với ridge và lasso trong Figures 6.5, 6.8 và 6.9, PCR không tốt bằng hai shrinkage method trong example này.


PCR tương đối kém trong Figure 6.18 vì data được generate sao cho cần nhiều principal component để model response đầy đủ. PCR sẽ làm tốt hơn khi chỉ first few principal components đã capture phần lớn variation của predictors và relationship với response. Left panel Figure 6.19 là simulated dataset thuận lợi hơn: response phụ thuộc exclusively vào first five principal components. Bias giảm nhanh về zero khi M tăng, MSE có minimum rõ tại $M = 5$. Right panel cho ridge và lasso trên cùng data; cả ba method đều cải thiện đáng kể so với least squares, nhưng PCR và ridge hơi outperform lasso.

Dù PCR cho cách đơn giản để regression với $M < p$ predictors, nó không phải feature selection method, vì mỗi principal component là linear combination của toàn bộ p original features. Ví dụ Z_1 trong (6.19) chứa cả `pop` và `ad`. Vì vậy PCR thường hoạt động tốt nhưng không tạo model chỉ dựa vào một small set original features. Theo nghĩa này, PCR gần ridge regression hơn lasso. Thực tế PCR và ridge regression rất closely related;



HÌNH 6.19. PCR, ridge regression và lasso được áp dụng lên simulated dataset nơi first five principal components của X chứa toàn bộ information về response Y . Horizontal dashed line là irreducible error $\text{Var}(\varepsilon)$. Left: PCR. Right: Lasso (solid) và ridge regression (dotted). Trục x là shrinkage factor, tức ℓ_2 norm của shrunken coefficient estimate chia cho ℓ_2 norm của least squares estimate.

thậm chí có thể xem ridge regression như continuous version của PCR.⁸



HÌNH 6.20. Left: PCR standardized coefficient estimate trên dataset *Credit* với các value M khác nhau. Right: Ten-fold cross-validation MSE của PCR theo M .

Trong PCR, số principal components M thường được chọn bằng cross-validation. Figure 6.20 hiển thị result trên dataset *Credit*; right panel là cross-validation error theo M . Lowest cross-validation error xảy ra tại $M = 10$, gần như không dimension reduction vì PCR với $M = 11$ tương đương ordinary least squares.

Khi thực hiện PCR, thông thường nên standardize từng predictor bằng (6.6) trước khi tạo principal components, để mọi variable nằm trên cùng scale. Nếu không standardize, high-variance variable có xu hướng đóng vai trò lớn hơn trong principal component, và scale đo variable sẽ ảnh hưởng final PCR model. Tuy nhiên, nếu mọi variable đều đo cùng một unit, chẳng hạn kilograms hoặc inches, có thể lựa chọn không standardize.

⁸Xem thêm Section 3.5 của *The Elements of Statistical Learning* của Hastie, Tibshirani và Friedman.