

Chúng ta tiếp tục với các bước training quen thuộc, fit model và evaluate test error. Có thể thấy test R^2 cải thiện nhẹ so với linear AR model cũng bao gồm `day_of_week`.

```
In [112]: nl_trainer = Trainer(deterministic=True,
                             max_epochs=20,
                             callbacks=[ErrorTracker()])
nl_trainer.fit(nl_module, datamodule=day_dm)
nl_trainer.test(nl_module, datamodule=day_dm)
```

```
Out[112]: [{'test_loss': 0.5625, 'test_r2': 0.4662}]
```

10.10 Exercises

Conceptual

- Xét một neural network có two hidden layers: $p = 4$ input units, 2 units ở first hidden layer, 3 units ở second hidden layer, và một output duy nhất.
 - Vẽ sơ đồ network, tương tự Figures 10.1 hoặc 10.4.
 - Viết một biểu thức cho $f(X)$, giả sử dùng ReLU activation functions. Hãy viết cụ thể nhất có thể.
 - Bây giờ hãy thay một số giá trị cho các coefficients và tính giá trị của $f(X)$.
 - Có tất cả bao nhiêu parameters?
- Xét softmax function trong (10.13) (xem thêm (4.13) ở page 145) dùng để model multinomial probabilities.
 - Trong (10.13), hãy chứng minh rằng nếu cộng cùng một constant c vào mỗi z_ℓ , thì probability không thay đổi.
 - Trong (4.13), hãy chứng minh rằng nếu cộng các constants c_j , $j = 0, 1, \dots, p$, vào các coefficients tương ứng của mỗi class, thì predictions tại bất kỳ new point x nào cũng không thay đổi.

Điều này cho thấy softmax function là over-parametrized. Tuy nhiên, regularization và SGD thường constrain các solutions nên điều này không gây ra vấn đề.
- Chứng minh rằng negative multinomial log-likelihood (10.14) tương đương với negative log của likelihood expression (4.5) khi có $M = 2$ classes.
- Xét một CNN nhận input là các grayscale images 32×32 và có một convolution layer với ba convolution filters 5×5 (không dùng boundary padding).
 - Vẽ phác thảo input và first hidden layer, tương tự Figure 10.8.
 - Model này có bao nhiêu parameters?
 - Giải thích vì sao model này có thể được xem như một ordinary feed-forward neural network với từng pixel làm input, nhưng có

các constraints trên weights trong hidden units. Các constraints đó là gì?

- (d) Nếu không có các constraints đó, ordinary feed-forward neural network trong (c) sẽ có bao nhiêu weights?
5. Trong Table 10.2 ở page 426, ordering của ba methods theo mean absolute error khác với ordering theo test-set R^2 . Điều này có thể xảy ra như thế nào?

Applied

6. Xét simple function $R(\beta) = \sin(\beta) + \beta/10$.
 - (a) Vẽ graph của function này trên range $\beta \in [-6, 6]$.
 - (b) Derivative của function này là gì?
 - (c) Với $\beta_0 = 2.3$, chạy gradient descent để tìm một local minimum của $R(\beta)$ với learning rate $\rho = 0.1$. Hãy hiển thị từng $\beta_0, \beta_1, \dots$ trên plot, cùng với đáp án cuối cùng.
 - (d) Lập lại với $\beta_0 = 1.4$.
7. Fit một neural network cho `Default` data. Dùng một hidden layer với 10 units và dropout regularization. Tham khảo Labs 10.9.1–10.9.2 để được hướng dẫn. So sánh classification performance của model với linear logistic regression.
8. Từ bộ sưu tập ảnh cá nhân của bạn, chọn 10 images về động vật (chẳng hạn dogs, cats, birds, farm animals, v.v.). Nếu subject không chiếm một phần hợp lý của image thì crop image. Sau đó dùng một pretrained image-classification CNN như trong Lab 10.9.4 để predict class của từng image, và báo cáo probabilities của năm predicted classes có probability cao nhất cho mỗi image.
9. Fit một lag-5 autoregressive model cho `NYSE` data, như mô tả trong phần lý thuyết và Lab 10.9.6. Refit model với một 12-level factor biểu diễn month. Factor này có cải thiện performance của model không?
10. Trong Section 10.9.6, chúng ta đã fit một linear AR model cho `NYSE` data bằng function `LinearRegression()`. Tuy nhiên, chúng ta cũng đề cập rằng có thể “flatten” các short sequences được tạo cho RNN model để fit một linear AR model. Hãy dùng cách thứ hai này để fit một linear AR model cho `NYSE` data. So sánh test R^2 của linear AR model này với linear AR model đã fit trong lab. Ưu điểm và nhược điểm của mỗi approach là gì?
11. Lập lại exercise trước, nhưng lần này fit một nonlinear AR model bằng cách “flatten” các short sequences được tạo cho RNN model.
12. Xét RNN fit cho `NYSE` data trong Section 10.9.6. Modify code để cho phép include variable `day_of_week`, rồi fit RNN. Tính test R^2 .
13. Lập lại analysis của Lab 10.9.5 trên IMDb data bằng một neural network có structure tương tự. Chúng ta đã dùng 16 hidden units ở mỗi trong two hidden layers. Hãy explore effect của việc tăng con số này

lên 32 và 64 units per layer, cả khi có và không có 30% dropout regularization.

11

Survival Analysis and Censored Data

*survival analysis;
censored data*

Trong chapter này, chúng ta sẽ xem xét hai chủ đề quan trọng là *survival analysis* và *censored data*. Chúng xuất hiện khi outcome variable có một dạng đặc biệt: thời gian cho đến khi một event xảy ra.

Ví dụ, giả sử chúng ta tiến hành một medical study kéo dài 5 năm, trong đó các patients được điều trị cancer. Ta muốn fit một model để predict survival time của patient, sử dụng các features như baseline health measurements hoặc loại treatment. Thoạt nhìn, đây có vẻ là một regression problem giống như những bài toán đã xét ở Chapter 3. Tuy nhiên, có một complication quan trọng: hy vọng rằng một số, hoặc nhiều, patients vẫn sống cho đến khi study kết thúc. Survival time của một patient như vậy được gọi là *censored*: ta biết nó ít nhất là 5 năm, nhưng không biết true value. Ta không muốn loại bỏ subset những patients còn sống này, vì việc họ sống được ít nhất 5 năm vẫn là thông tin có giá trị. Tuy nhiên, chưa rõ làm thế nào để sử dụng thông tin đó bằng các techniques đã trình bày cho đến thời điểm này trong sách.

Mặc dù cụm từ “survival analysis” thường gợi đến một medical study, các applications của survival analysis vượt xa phạm vi medicine. Chẳng hạn, một company có thể muốn model *churn*, tức quá trình customers hủy subscription đối với một service. Company có thể thu thập data về customers trong một khoảng thời gian để model time to cancellation của mỗi customer như một function của demographics hoặc các predictors khác. Tuy nhiên, có lẽ không phải mọi customer đều hủy subscription trước khi khoảng thời gian quan sát kết thúc; với những customers như vậy, time to cancellation bị censored.

Thực ra, survival analysis còn có liên quan ngay cả trong các application areas không gắn trực tiếp với time. Ví dụ, giả sử ta muốn model weight của một người như một function của một số covariates, dựa trên một dataset gồm measurements của rất nhiều người. Nếu chiếc scale dùng để cân không thể report các weights vượt quá một ngưỡng nhất định, thì mọi weight vượt ngưỡng đó đều bị censored. Các survival-analysis methods được trình bày trong chapter này có thể được dùng để analyze dataset như vậy.

Survival analysis là một topic đã được nghiên cứu rất kỹ trong statistics, do tầm quan trọng then chốt của nó trong nhiều applications cả trong và ngoài medicine. Tuy vậy, chủ đề này nhận được tương đối ít sự chú ý trong machine learning community.

11.1 Survival and Censoring Times

Với mỗi individual, giả sử tồn tại một true survival time T , đồng thời tồn tại một true censoring time C . Survival time còn được gọi là failure time hoặc event time. Survival time biểu diễn thời điểm event of interest xảy ra, chẳng hạn thời điểm patient chết hoặc customer hủy subscription. Ngược lại, censoring time là thời điểm censoring xảy ra, ví dụ thời điểm patient rời study hoặc thời điểm study kết thúc.

Ta quan sát hoặc survival time T , hoặc censoring time C . Cụ thể, ta quan sát random variable

$$Y = \min(T, C). \quad (11.1)$$

Nói cách khác, nếu event xảy ra trước censoring (tức $T < C$) thì ta quan sát true survival time T ; còn nếu censoring xảy ra trước event ($T > C$) thì ta quan sát censoring time. Ta cũng quan sát một status indicator,

$$\delta = \begin{cases} 1, & T \leq C, \\ 0, & T > C. \end{cases}$$

Do đó, $\delta = 1$ nếu ta quan sát true survival time, và $\delta = 0$ nếu giá trị quan sát được là censoring time.

Bây giờ, giả sử ta quan sát n pairs (Y, δ) , được ký hiệu là $(y_1, \delta_1), \dots, (y_n, \delta_n)$. Figure 11.1 minh họa một medical study giả định với $n = 4$ patients được follow-up trong 365 days. Với patients 1 và 3, ta quan sát time to event (chẳng hạn death hoặc disease relapse), nên $T = t_i$. Patient 2 vẫn sống khi study kết thúc, còn patient 4 rời study, hay “lost to follow-up”; với hai patients này ta quan sát $C = c_i$. Vì vậy, $y_1 = t_1$, $y_3 = t_3$, $y_2 = c_2$, $y_4 = c_4$, $\delta_1 = \delta_3 = 1$, và $\delta_2 = \delta_4 = 0$.

11.2 A Closer Look at Censoring


Để analyze survival data, ta cần đưa ra một số assumptions về nguyên nhân censoring xảy ra. Chẳng hạn, giả sử một số patients rời một cancer study sớm vì họ đang rất sick. Một analysis không tính đến lý do patients rời study có khả năng sẽ overestimate true average survival time. Tương tự, giả sử các males đang rất sick có khả năng rời study cao hơn các females đang rất sick. Khi đó, comparison giữa male và female survival times có thể sai lệch và gợi ý rằng males sống lâu hơn females.

Nói chung, ta cần giả sử censoring mechanism là *independent*: conditional on the features, event time T independent of censoring time C . Hai examples ở trên đều vi phạm assumption về independent censoring. Thông thường, chỉ từ data thì không thể xác định censoring mechanism có independent hay không. Thay vào đó, cần xem xét cẩn thận data-collection process để đánh giá xem independent censoring có phải là một assumption hợp lý hay không. Trong phần còn lại của chapter, ta sẽ giả sử censoring mechanism là independent.¹

¹Assumption về independent censoring có thể được nối lỏng phần nào bằng notion of non-informative censoring; tuy nhiên, định nghĩa của non-informative censoring quá technical so với phạm vi của cuốn sách này.

survival time;
censoring time;
failure time; event
time

independent
censoring



HÌNH 11.1. Minh họa censored survival data. Với patients 1 và 3, event được quan sát. Patient 2 vẫn sống khi study kết thúc. Patient 4 rời khỏi study.

Trong chapter này, chúng ta tập trung vào *right censoring*, xảy ra khi $T \geq Y$, tức true event time T ít nhất bằng observed time Y . Tên “right censoring” xuất phát từ việc time thường được biểu diễn từ trái sang phải, như trong Figure 11.1. Tuy nhiên, còn có các dạng censoring khác. Với *left censoring*, true event time T nhỏ hơn hoặc bằng observed time Y . Ví dụ, trong một study về pregnancy duration, giả sử ta khảo sát patients 250 days sau conception, khi một số người đã sinh con. Với những patients đó, ta chỉ biết pregnancy duration nhỏ hơn 250 days. Tổng quát hơn, *interval censoring* là setting trong đó ta không biết exact event time, nhưng biết nó nằm trong một interval nào đó; chẳng hạn khi patients chỉ được kiểm tra mỗi tuần để xác định event đã xảy ra hay chưa. Left censoring và interval censoring có thể được xử lý bằng các variants của những ideas trình bày trong chapter này, nhưng từ đây trở đi ta tập trung cụ thể vào right censoring.

right censoring; left
censoring; interval
censoring

11.3 The Kaplan–Meier Survival Curve

Survival curve, hay *survival function*, được định nghĩa bởi

$$S(t) = \Pr(T > t). \quad (11.2)$$

Đây là một decreasing function định lượng probability of surviving past time t . Ví dụ, giả sử một company quan tâm đến việc model customer churn. Gọi T là thời điểm một customer hủy subscription. Khi đó $S(t)$ là probability rằng customer sẽ hủy sau time t . Giá trị $S(t)$ càng lớn thì customer càng ít có khả năng hủy trước time t .

survival curve;
survival function

Trong section này, ta xem xét bài toán estimate survival curve. Phần trình bày được motivate bởi **BrainCancer** dataset, chứa survival times của patients có primary brain tumors và được treatment bằng stereotactic radiation methods.² Các predictors gồm **gtv** (gross tumor volume, tính bằng cubic centimeters); **sex** (male hoặc female); **diagnosis** (meningioma, LG glioma, HG glioma, hoặc other); **loc** (vị trí tumor: infratentorial hoặc supratentorial); **ki** (Karnofsky index); và **stereo** (stereotactic method: stereotactic radiosurgery hoặc fractionated stereotactic radiotherapy, lần

²Dataset này được mô tả trong Selingerová et al. (2016), “Survival of patients with primary brain tumors: Comparison of two statistical approaches”, PLoS One, 11(2):e0148733.

lượt viết tắt là SRS và SRT). Chỉ 53 trong số 88 patients vẫn sống ở cuối study.

Bây giờ xét bài toán estimate $S(20) = \Pr(T > 20)$, tức probability rằng một patient sống ít nhất $t = 20$ months. Ta có thể bị cám dỗ đơn giản lấy proportion các patients chắc chắn sống quá 20 months, tức proportion có $Y > 20$. Con số này là $48/88$, xấp xỉ 55%. Tuy nhiên, cách làm này chưa đúng vì Y và T là hai quantities khác nhau. Cụ thể, trong 40 patients không có $Y > 20$, có 17 patients thực ra bị censored; cách tính vừa rồi ngầm giả sử $T < 20$ với tất cả 17 patients đó, trong khi ta không hề biết điều này có đúng hay không.

Một alternative để estimate $S(20)$ là lấy proportion patients có $Y > 20$ trong số 71 patients chưa bị censored trước time $t = 20$. Khi đó ta được $48/71$, xấp xỉ 68%. Tuy nhiên, cách này cũng chưa đúng vì nó hoàn toàn bỏ qua những patients bị censored trước $t = 20$, dù time at which they are censored có thể cung cấp thông tin. Chẳng hạn, một patient bị censored tại $t = 19.9$ nhiều khả năng vẫn sẽ sống qua $t = 20$ nếu không bị censored.

Ta đã thấy việc estimate $S(t)$ trở nên phức tạp do censoring. Để giải quyết vấn đề, đặt $d_1 < d_2 < \dots < d_K$ là K unique death times trong số các non-censored patients, và đặt q_k là số patients chết tại time d_k . Với $k = 1, \dots, K$, đặt r_k là số patients còn sống và vẫn ở trong study ngay trước d_k ; đây là các patients *at risk*. Tập các patients at risk tại một time được gọi là *risk set*. Theo law of total probability,³

$$\begin{aligned} \Pr(T > d_k) &= \Pr(T > d_k \mid T > d_{k-1}) \Pr(T > d_{k-1}) \\ &\quad + \Pr(T > d_k \mid T \leq d_{k-1}) \Pr(T \leq d_{k-1}). \end{aligned}$$

Vì $d_{k-1} < d_k$, ta có $\Pr(T > d_k \mid T \leq d_{k-1}) = 0$. Do đó,

$$S(d_k) = \Pr(T > d_k) = \Pr(T > d_k \mid T > d_{k-1}) \Pr(T > d_{k-1}),$$

hay

$$S(d_k) = \Pr(T > d_k \mid T > d_{k-1}) S(d_{k-1}).$$

Suy ra

$$S(d_k) = \Pr(T > d_k \mid T > d_{k-1}) \times \dots \times \Pr(T > d_2 \mid T > d_1) \Pr(T > d_1).$$

Giờ ta chỉ cần thay các estimates vào từng term ở vế phải. Một estimator tự nhiên là

$$\widehat{\Pr}(T > d_j \mid T > d_{j-1}) = \frac{r_j - q_j}{r_j},$$

tức fraction của risk set tại time d_j sống qua d_j . Điều này dẫn đến Kaplan–Meier estimator của survival curve,

$$\widehat{S}(d_k) = \prod_{j=1}^k \left(\frac{r_j - q_j}{r_j} \right). \quad (11.3)$$


Với times t nằm giữa d_k và d_{k+1} , ta đặt $\widehat{S}(t) = \widehat{S}(d_k)$. Vì vậy, Kaplan–Meier survival curve có dạng step-like.

*Kaplan–Meier
estimator; risk set*


³Law of total probability phát biểu rằng với hai events A và B , $\Pr(A) = \Pr(A \mid B) \Pr(B) + \Pr(A \mid B^c) \Pr(B^c)$, trong đó B^c là complement của event B .

Kaplan–Meier survival curve của **BrainCancer** data được hiển thị trong Figure 11.2. Mỗi point trên solid step-like curve cho biết estimated probability of surviving past the time trên horizontal axis. Estimated probability of survival past 20 months là 71%, cao hơn đáng kể so với hai naive estimates 55% và 68% nêu ở trên.

Sequential construction của Kaplan–Meier estimator—bắt đầu tại time zero và lần lượt theo dõi các observed events khi chúng xảy ra—là ý tưởng nền tảng của nhiều techniques quan trọng trong survival analysis. Trong số đó có log-rank test ở Section 11.4 và Cox’s proportional hazards model ở Section 11.5.2.



HÌNH 11.2. Với *BrainCancer* data, Kaplan–Meier survival curve được hiển thị bằng solid curve, cùng các standard-error bands bằng dashed curves.



HÌNH 11.3. Với *BrainCancer* data, Kaplan–Meier survival curves cho males và females được hiển thị.

11.4 The Log-Rank Test

Ta tiếp tục analysis của **BrainCancer** data được giới thiệu ở Section 11.3. Mục tiêu là compare survival của males và females. Figure 11.3 cho thấy Kaplan–Meier survival curves của hai groups. Females dường như có outcome tốt hơn một chút cho đến khoảng 50 months, nhưng sau đó cả hai

curves cùng level off quanh 50%. Làm thế nào để thực hiện một formal test về equality của hai survival curves?

Thoạt nhìn, two-sample t -test có vẻ là lựa chọn hiển nhiên: ta có thể test xem mean survival time của females có bằng mean survival time của males hay không. Nhưng censoring lại gây ra complication. Để vượt qua vấn đề này, ta dùng *log-rank test*,⁴ một test xem xét cách các events trong mỗi group diễn tiến tuần tự theo time.

log-rank test

	Group 1	Group 2	Total
Died	q_{1k}	q_{2k}	q_k
Survived	$r_{1k} - q_{1k}$	$r_{2k} - q_{2k}$	$r_k - q_k$
Total	r_{1k}	r_{2k}	r_k

BẢNG 11.1. Trong risk set tại time d_k , bảng cho biết số patients died và survived trong mỗi of two groups.

Recall từ Section 11.3 rằng $d_1 < d_2 < \dots < d_K$ là unique death times của non-censored patients, r_k là số patients at risk tại d_k , và q_k là số patients chết tại d_k . Ta định nghĩa thêm r_{1k} và r_{2k} là số patients thuộc groups 1 và 2, tương ứng, đang at risk tại d_k . Tương tự, q_{1k} và q_{2k} là số patients của hai groups chết tại d_k . Lưu ý rằng $r_{1k} + r_{2k} = r_k$ và $q_{1k} + q_{2k} = q_k$. Tại mỗi death time d_k , ta lập một 2×2 table như Table 11.1. Nếu các death times là unique, thì một trong q_{1k} và q_{2k} bằng 1, còn giá trị kia bằng 0.

Ý tưởng chính của log-rank test statistic như sau. Để test $H_0 : E(X) = \mu$ cho một random variable X , một approach là xây dựng test statistic dạng

$$W = \frac{X - \mu}{\sqrt{\text{Var}(X)}}. \quad (11.4)$$

Để xây dựng log-rank test statistic, ta dùng đúng dạng (11.4), với $X = \sum_{k=1}^K q_{1k}$, trong đó q_{1k} nằm ở ô trên-trái của Table 11.1.

Cụ thể hơn, nếu không có difference in survival giữa hai groups, và conditional on row and column totals trong Table 11.1, expected value của q_{1k} là

$$\mu_k = \frac{r_{1k}}{r_k} q_k. \quad (11.5)$$

Do đó expected value của $X = \sum_{k=1}^K q_{1k}$ là $\mu = \sum_{k=1}^K (r_{1k}/r_k) q_k$. Hơn nữa, có thể chứng minh⁵ rằng

$$\text{Var}(q_{1k}) = \frac{q_k(r_{1k}/r_k)(1 - r_{1k}/r_k)(r_k - q_k)}{r_k - 1}. \quad (11.6)$$

Mặc dù $q_{11}, \dots, q_{1K}$ có thể correlated, ta vẫn estimate

$$\text{Var}\left(\sum_{k=1}^K q_{1k}\right) \approx \sum_{k=1}^K \frac{q_k(r_{1k}/r_k)(1 - r_{1k}/r_k)(r_k - q_k)}{r_k - 1}. \quad (11.7)$$

⁴Log-rank test còn được gọi là Mantel-Haenszel test hoặc Cochran-Mantel-Haenszel test.

⁵Chi tiết xem Exercise 7 ở cuối chapter.

Vì vậy, để compute log-rank test statistic, ta chỉ cần áp dụng (11.4) với $X = \sum_{k=1}^K q_{1k}$ và dùng (11.5), (11.7):

$$W = \frac{\sum_{k=1}^K (q_{1k} - \mu_k)}{\sqrt{\sum_{k=1}^K \text{Var}(q_{1k})}}. \quad (11.8)$$

Khi sample size lớn, log-rank test statistic W approximately có standard normal distribution; từ đó có thể compute p-value cho null hypothesis rằng hai survival curves không khác nhau.⁶

Comparison survival times giữa females và males trên **BrainCancer** data cho log-rank test statistic $W = 1.2$, tương ứng với two-sided p-value 0.2 theo theoretical null distribution và p-value 0.25 theo permutation null distribution với 1,000 permutations. Vì vậy, ta không thể reject null hypothesis rằng hai survival curves không khác nhau. Log-rank test có quan hệ chặt chẽ với Cox's proportional hazards model, sẽ được trình bày ở Section 11.5.2.

11.5 Regression Models With a Survival Response

Bây giờ ta xét bài toán fit một regression model cho survival data. Như trong Section 11.1, observations có dạng (Y, δ) , với $Y = \min(T, C)$ là survival time quan sát được (có thể censored), còn δ là indicator bằng 1 nếu $T \leq C$. Ngoài ra, $X \in \mathbb{R}^p$ là vector gồm p features. Mục tiêu là predict true survival time T .

Vì observed quantity Y dương và có thể có long right tail, ta có thể nghĩ đến việc fit linear regression của $\log(Y)$ theo X . Nhưng censoring lại gây ra vấn đề, vì điều ta thực sự muốn predict là T chứ không phải Y . Để xử lý difficulty này, ta tiếp tục sử dụng một sequential construction tương tự Kaplan–Meier survival curve ở Section 11.3 và log-rank test ở Section 11.4.

11.5.1 The Hazard Function

Hazard function hoặc hazard rate—còn được gọi là force of mortality—được định nghĩa chính thức là

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t < T \leq t + \Delta t \mid T > t)}{\Delta t}. \quad (11.9)$$

Nó là death rate trong instant ngay sau time t , conditional on survival past that time.⁷

Tại sao ta quan tâm đến hazard function? Thứ nhất, nó có quan hệ chặt chẽ với survival curve (11.2), như ta sẽ thấy ngay sau đây. Thứ hai, một approach quan trọng để model survival data như một function

*hazard function;
hazard rate*

⁶Alternatively, p-value có thể được estimate bằng permutations, sử dụng các ideas sẽ trình bày ở Section 13.5. Permutation distribution được tạo bằng cách randomly swapping labels của observations trong hai groups.

⁷Do Δt nằm ở denominator của (11.9), hazard function là một rate of death chứ không phải probability of death. Tuy nhiên, giá trị $h(t)$ lớn hơn trực tiếp tương ứng với probability of death lớn hơn, tương tự như giá trị lớn hơn của probability density function tương ứng với outcomes có khả năng cao hơn. Thực ra, $h(t)$ là probability density function của T conditional on $T > t$.

của covariates dựa rất nhiều vào hazard function; approach này là Cox's proportional hazards model ở Section 11.5.2.

Recall rằng với hai events A và B , $\Pr(A | B) = \Pr(A \cap B) / \Pr(B)$, và từ (11.2), $S(t) = \Pr(T > t)$. Do đó,

$$h(t) = \frac{f(t)}{S(t)}, \quad (11.10)$$

trong đó

$$f(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t < T \leq t + \Delta t)}{\Delta t} \quad (11.11)$$

là probability density function gắn với T , tức instantaneous rate of death tại time t . Equality thứ hai trong derivation của (11.10) dùng fact rằng nếu $t < T \leq t + \Delta t$ thì nhất thiết $T > t$. Equation (11.10) cho thấy mối quan hệ giữa hazard function $h(t)$, survival function $S(t)$ và probability density function $f(t)$. Trên thực tế, đây là ba ways tương đương để mô tả distribution của T .⁸

Likelihood contribution của observation thứ i là

$$L_i = f(y_i)^{\delta_i} S(y_i)^{1-\delta_i}. \quad (11.12)$$

Intuition của (11.12) như sau: nếu $Y = y_i$ và observation thứ i không censored, likelihood là probability of dying trong một interval rất nhỏ quanh time y_i . Nếu observation thứ i censored, likelihood là probability of surviving ít nhất đến time y_i . Giả sử n observations independent, likelihood của toàn data là

$$L = \prod_{i=1}^n f(y_i)^{\delta_i} S(y_i)^{1-\delta_i} = \prod_{i=1}^n h(y_i)^{\delta_i} S(y_i), \quad (11.13)$$

trong đó equality thứ hai follows from (11.10).

Ta có thể bắt đầu model survival times bằng cách assume exponential survival, tức probability density function của T có dạng $f(t) = \lambda \exp(-\lambda t)$. Khi đó việc estimate parameter λ bằng cách maximize likelihood (11.13) khá straightforward.⁹ Ta cũng có thể assume survival times đến từ một family distributions flexible hơn, chẳng hạn Gamma hoặc Weibull; hoặc model survival times non-parametrically như Kaplan–Meier estimator ở Section 11.3.

Tuy nhiên, điều ta thực sự muốn là model survival time như một function của covariates. Để làm vậy, làm việc trực tiếp với hazard function thuận tiện hơn probability density function.¹⁰ Một approach là assume một functional form cho $h(t | x_i)$, chẳng hạn $h(t | x_i) = \exp(\beta_0 + \sum_{j=1}^p \beta_j x_{ij})$, trong đó exponential function đảm bảo hazard không âm. Exponential hazard function là một trường hợp đặc biệt vì nó không thay đổi theo time.¹¹ Nếu biết $h(t | x_i)$, ta có thể calculate $S(t | x_i)$ rồi plug các equations vào

⁸Xem Exercise 8.

⁹Xem Exercise 9.

¹⁰Do hazard function $h(t)$ và density function $f(t)$ có quan hệ chặt chẽ, việc giả định form của hazard function cũng gần với việc giả định form của density function.

¹¹Notation $h(t | x_i)$ biểu thị hazard function của observation thứ i conditional on covariate values x_i .

(11.13) để maximize likelihood và estimate $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T$. Tuy nhiên, approach này khá restrictive vì phải áp đặt một assumption rất mạnh về form của hazard function. Section tiếp theo trình bày một approach flexible hơn nhiều.

11.5.2 Proportional Hazards


The Proportional Hazards Assumption

Proportional hazards assumption phát biểu rằng

$$h(t | x_i) = h_0(t) \exp\left(\sum_{j=1}^p x_{ij}\beta_j\right), \quad (11.14)$$

trong đó $h_0(t) \geq 0$ là một unspecified function, được gọi là *baseline hazard*. Đây là hazard function của một individual có features $x_{i1} = \dots = x_{ip} = 0$. Tên “proportional hazards” xuất phát từ việc hazard function của một individual có feature vector x_i bằng unknown function $h_0(t)$ nhân với factor $\exp(\sum_j x_{ij}\beta_j)$. Quantity $\exp(\sum_j x_{ij}\beta_j)$ được gọi là *relative risk* của feature vector $x_i = (x_{i1}, \dots, x_{ip})^T$ so với feature vector $(0, \dots, 0)^T$.

proportional
hazards; baseline
hazard; relative
risk



HÌNH 11.4. Top: trong một simple example với $p = 1$ và binary covariate $x_i \in \{0, 1\}$, log hazard và survival function dưới model (11.14) được hiển thị (green cho $x_i = 0$ và black cho $x_i = 1$). Do proportional hazards assumption, hai log-hazard functions khác nhau bởi một constant và hai survival functions không cross. Bottom: vẫn là một binary covariate, nhưng proportional hazards assumption không hold; cả log-hazard functions lẫn survival functions đều cross.

Việc $h_0(t)$ là “unspecified” nghĩa là về cơ bản ta không đặt assumptions lên functional form của nó. Instantaneous probability of death tại time t , conditional on having survived ít nhất đến t , có thể nhận bất kỳ form nào. Điều này làm hazard function rất flexible và cho phép model nhiều dạng relationship giữa covariates và survival time. Assumption chính chỉ là mỗi one-unit increase trong x_{ij} làm $h(t | x_i)$ tăng theo factor $\exp(\beta_j)$.

Figure 11.4 minh họa proportional hazards assumption trong một setting đơn giản với one binary covariate $x_i \in \{0, 1\}$. Ở top row, assumption

(11.14) hold. Vì vậy, hazard functions của hai groups là constant multiples của nhau, và trên log scale khoảng cách giữa chúng là constant. Survival curves không bao giờ cross và ban đầu thường tách xa nhau hơn theo time. Ngược lại, ở bottom row, (11.14) không hold: log-hazard functions cross, và survival curves cũng cross.

Cox's Proportional Hazards Model

Vì form của $h_0(t)$ trong proportional hazards assumption (11.14) là unknown, ta không thể đơn giản plug $h(t | x_i)$ vào likelihood (11.13) rồi estimate $\beta = (\beta_1, \dots, \beta_p)^T$ bằng maximum likelihood. Điểm đặc biệt của *Cox's proportional hazards model* là vẫn có thể estimate β mà không cần specify form của $h_0(t)$.

*Cox's proportional
hazards model;
partial likelihood*

Để làm điều này, ta dùng lại logic “sequential in time” đã dùng để derive Kaplan–Meier survival curve và log-rank test. Để đơn giản, giả sử không có ties giữa các failure times. Giả sử $\delta_i = 1$, tức observation thứ i uncensored và y_i là failure time của nó. Khi đó hazard của observation i tại y_i là $h_0(y_i) \exp(\sum_j x_{ij}\beta_j)$, còn total hazard tại y_i của toàn bộ observations đang at risk¹² là

$$\sum_{i': y_{i'} \geq y_i} h_0(y_i) \exp\left(\sum_{j=1}^p x_{i'j}\beta_j\right).$$

Do đó, probability rằng observation thứ i chính là observation failure tại time y_i là

$$\frac{\exp(\sum_{j=1}^p x_{ij}\beta_j)}{\sum_{i': y_{i'} \geq y_i} \exp(\sum_{j=1}^p x_{i'j}\beta_j)}, \quad (11.15)$$

bởi vì $h_0(y_i)$ cancels khỏi numerator và denominator.

Partial likelihood đơn giản là product của các probabilities này trên toàn bộ uncensored observations,

$$PL(\beta) = \prod_{i: \delta_i=1} \frac{\exp(\sum_{j=1}^p x_{ij}\beta_j)}{\sum_{i': y_{i'} \geq y_i} \exp(\sum_{j=1}^p x_{i'j}\beta_j)}. \quad (11.16)$$

Điểm then chốt là partial likelihood này valid bất kể true value của $h_0(t)$, khiến model rất flexible và robust.¹³ Để estimate β , ta maximize (11.16) theo β . Tương tự logistic regression ở Chapter 4, không có closed-form solution nên cần iterative algorithms. Ngoài estimates của β , ta cũng có thể obtain p-values cho các null hypotheses cụ thể, chẳng hạn $H_0: \beta_j = 0$, và confidence intervals của các coefficients.

Connection With The Log-Rank Test

Giả sử chỉ có một predictor ($p = 1$) và predictor này binary, $x_i \in \{0, 1\}$. Để xác định có difference giữa survival times của group $\{i: x_i = 0\}$ và group $\{i: x_i = 1\}$ hay không, ta có hai approaches: (1) fit Cox proportional

¹²Recall rằng observations “at risk” tại y_i là những observations vẫn còn có khả năng failure, tức chưa failure hoặc censored trước time y_i .

¹³Trong các settings mà full likelihood cho mọi parameters khó compute, partial likelihood được dùng để tạo likelihood chỉ cho các parameters được quan tâm chính. Ở đây đó là $\beta_1, \dots, \beta_p$. Có thể chứng minh rằng maximizing (11.16) cho các estimates tốt của các parameters này.

hazards model rồi test $H_0 : \beta = 0$; hoặc (2) thực hiện log-rank test để compare hai groups như ở Section 11.4. Approach nào nên được ưu tiên?

Thực ra hai approaches có quan hệ rất chặt chẽ. Khi dùng Cox model, có nhiều ways để test H_0 . Một trong số đó là score test. Với một binary covariate duy nhất, score test cho $H_0 : \beta = 0$ trong Cox proportional hazards model chính xác bằng log-rank test. Nói cách khác, trong setting này hai approaches cho cùng kết quả.

Additional Details

Phần trình bày về Cox's proportional hazards model ở trên đã lược qua một số subtleties:

- Không có intercept trong (11.14) hoặc các equations tiếp theo, vì intercept có thể được absorb vào baseline hazard $h_0(t)$.
- Ta giả sử không có tied failure times. Khi có ties, exact form của partial likelihood (11.16) phức tạp hơn và cần một số computational approximations.
- (11.16) được gọi là partial likelihood vì không hoàn toàn là likelihood; tức nó không tương ứng chính xác với probability của data dưới assumption (11.14). Tuy nhiên, nó là một approximation rất tốt.
- Ta mới tập trung vào estimation của coefficients $\beta = (\beta_1, \dots, \beta_p)^T$. Đôi khi ta cũng muốn estimate baseline hazard $h_0(t)$, chẳng hạn để estimate survival curve $S(t | x)$ cho một individual có feature vector x . Chi tiết vượt quá phạm vi sách. Python package **lifelines**, được dùng ở Section 11.8, có implementation để estimate $h_0(t)$.

11.5.3 Example: Brain Cancer Data

Table 11.2 cho thấy kết quả fit proportional hazards model cho **BrainCancer** data được giới thiệu ở Section 11.3. Column Coefficient hiển thị $\hat{\beta}_j$. Chẳng hạn, estimated hazard của một male patient bằng $e^{0.18} = 1.2$ lần estimated hazard của một female patient. Nói cách khác, giữ tất cả các features khác cố định, males có instantaneous chance of dying cao gấp 1.2 lần females tại bất kỳ point in time nào. Tuy nhiên, p-value 0.61 cho thấy difference này không significant.

Một example khác: mỗi one-unit increase trong Karnofsky index tương ứng với multiplier $\exp(-0.05) = 0.95$ đối với instantaneous chance of dying. Nói cách khác, Karnofsky index càng cao thì chance of dying tại một time bất kỳ càng thấp. Effect này highly significant, với p-value 0.0027.

11.5.4 Example: Publication Data


Tiếp theo, xét **Publication** dataset về time to publication của các journal papers báo cáo results của clinical trials được National Heart, Lung, and Blood Institute tài trợ.¹⁴ Với 244 trials, time tính bằng months cho

¹⁴Dataset này được mô tả trong Gordon et al. (2013), "Publication of trials funded by the National Heart, Lung, and Blood Institute", New England Journal of Medicine, 369(20):1926–

	Coefficient	Std. error	z-statistic	p-value
sex[Male]	0.18	0.36	0.51	0.61
diagnosis[LG Glioma]	0.92	0.64	1.43	0.15
diagnosis[HG Glioma]	2.15	0.45	4.78	0.00
diagnosis[Other]	0.89	0.66	1.35	0.18
loc[Supratentorial]	0.44	0.70	0.63	0.53
ki	-0.05	0.02	-3.00	< 0.01
gtv	0.03	0.02	1.54	0.12
stereo[SRT]	0.18	0.60	0.30	0.77

BẢNG 11.2. Kết quả Cox's proportional hazards model fit cho *BrainCancer* data, lần đầu được mô tả ở Section 11.3. Variable *diagnosis* là qualitative với four levels: *meningioma*, *LG glioma*, *HG glioma*, và *other*. Variables *sex*, *loc*, và *stereo* là binary.

đến publication được ghi lại. Trong 244 trials, chỉ 156 được published trong study period; các studies còn lại bị censored. Covariates gồm trial có tập trung vào clinical endpoint hay không (*clinend*), có involve multiple centers hay không (*multi*), funding mechanism trong National Institutes of Health (*mech*), trial sample size (*sampsize*), budget (*budget*), impact (*impact*, liên quan đến number of citations), và trial có cho positive/significant result hay không (*posres*). Covariate cuối đặc biệt đáng quan tâm vì một số studies đã gợi ý positive trials có publication rate cao hơn.



HÌNH 11.5. Survival curves cho time until publication của *Publication* data được mô tả ở Section 11.5.4, stratified theo việc study có cho positive result hay không.

Figure 11.5 cho thấy Kaplan–Meier curves của time until publication, stratified theo việc study có positive result hay không. Có một chút evidence rằng time until publication ngắn hơn với studies có positive result. Tuy nhiên, log-rank test cho p-value không ấn tượng là 0.36.

Bây giờ ta thực hiện một analysis cẩn thận hơn bằng cách dùng tất cả available predictors. Results của Cox's proportional hazards model được trình bày trong Table 11.3. Chance of publication của một study có positive result là $e^{0.55} = 1.74$ lần chance of publication của một study có negative result tại bất kỳ point in time nào, giữ tất cả covariates khác cố định. P-value rất nhỏ của *posres* trong Table 11.3 cho thấy result này highly

significant. Điều này khá striking nếu so với finding trước đó rằng log-rank test giữa positive và negative results cho p-value 0.36. Sự khác biệt xuất phát từ fact rằng log-rank test không xét các covariates khác, còn Table 11.3 dựa trên Cox model dùng toàn bộ available covariates. Nói cách khác, sau khi adjust cho các covariates khác, việc study có positive result hay không trở thành predictor rất mạnh của time to publication.

Để hiểu thêm, Figure 11.6 hiển thị estimated survival curves của positive và negative results sau khi adjust cho các predictors khác. Để tạo các curves này, ta estimate underlying baseline hazard $h_0(t)$ và chọn representative values cho các predictors còn lại: mean cho mỗi quantitative predictor, và category phổ biến nhất (R01) cho qualitative predictor **mech**. Sau adjustment, sự khác biệt giữa positive và negative results trở nên rõ ràng. Table 11.3 còn cho một số insights khác; chẳng hạn, studies có clinical endpoint có xu hướng được published sớm hơn studies không có clinical endpoint, trong khi funding mechanism dường như không significantly associated với time until publication.

	Coefficient	Std. error	z-statistic	p-value
posres[Yes]	0.55	0.18	3.02	0.00
multi[Yes]	0.15	0.31	0.47	0.64
clinend[Yes]	0.51	0.27	1.89	0.06
mech[K01]	1.05	1.06	1.00	0.32
mech[K23]	-0.48	1.05	-0.45	0.65
mech[P01]	-0.31	0.78	-0.40	0.69
mech[P50]	0.60	1.06	0.57	0.57
mech[R01]	0.10	0.32	0.30	0.76
mech[R18]	1.05	1.05	0.99	0.32
mech[R21]	-0.05	1.06	-0.04	0.97
mech[R24.K24]	0.81	1.05	0.77	0.44
mech[R42]	-14.78	3414.38	-0.00	1.00
mech[R44]	-0.57	0.77	-0.73	0.46
mech[RC2]	-14.92	2243.60	-0.01	0.99
mech[U01]	-0.22	0.32	-0.70	0.48
mech[U54]	0.47	1.07	0.44	0.66
sampsize	0.00	0.00	0.19	0.85
budget	0.00	0.00	1.67	0.09
impact	0.06	0.01	8.23	0.00

BẢNG 11.3. Kết quả Cox’s proportional hazards model fit cho *Publication* data bằng tất cả available features. Features **posres**, **multi**, và **clinend** là binary. Feature **mech** là qualitative với 14 levels và được coded với baseline level là *Contract*.

11.6 Shrinkage for the Cox Model


Trong section này, ta minh họa rằng shrinkage methods của Section 6.2 có thể áp dụng cho survival data. Xuất phát từ formulation “loss+penalty” ở Section 6.2, ta xét việc minimize một penalized version của negative log partial likelihood trong (11.16),

$$-\log \left[\prod_{i: \delta_i=1} \frac{\exp(\sum_{j=1}^p x_{ij}\beta_j)}{\sum_{i': y_{i'} \geq y_i} \exp(\sum_{j=1}^p x_{i'j}\beta_j)} \right] + \lambda P(\beta), \quad (11.17)$$

đối với $\beta = (\beta_1, \dots, \beta_p)^T$. Ta có thể chọn $P(\beta) = \sum_{j=1}^p \beta_j^2$, tương ứng với ridge penalty, hoặc $P(\beta) = \sum_{j=1}^p |\beta_j|$, tương ứng với lasso penalty.

Trong (11.17), λ là một non-negative tuning parameter; thông thường ta minimize objective với nhiều values của λ . Khi $\lambda = 0$, minimizing

(11.17) tương đương maximizing ordinary Cox partial likelihood (11.16). Khi $\lambda > 0$, minimizing (11.17) cho một shrunken version của coefficient estimates. Với large λ , ridge penalty cho các coefficients nhỏ nhưng không exactly bằng zero; ngược lại, với sufficiently large λ , lasso penalty làm một số coefficients exactly zero.



HÌNH 11.6. Với *Publication* data, hiển thị survival curves của time until publication, stratified theo việc study có positive result hay không, sau khi adjust cho mọi covariates khác.

Bây giờ apply lasso-penalized Cox model cho *Publication* data. Trước hết, ta randomly split 244 trials thành training set và test set có size bằng nhau. Cross-validation results trên training set được hiển thị trong Figure 11.7. “Partial likelihood deviance” trên y-axis bằng hai lần cross-validated negative log partial likelihood và đóng vai trò như cross-validation error.¹⁵ Curve của partial likelihood deviance có dạng chữ U: giống như ở các chapters trước, cross-validation error nhỏ nhất tại một mức model complexity trung gian. Cụ thể, điều này xảy ra khi chỉ hai predictors *budget* và *impact* có non-zero estimated coefficients.

Làm thế nào để áp dụng model này cho test set? Có một conceptual point quan trọng: về cơ bản không có cách đơn giản để compare predicted survival times với true survival times trên test set. Vấn đề thứ nhất là một số observations bị censored nên true survival times của chúng không observed. Vấn đề thứ hai là Cox model không predict một single survival time từ covariate vector x ; thay vào đó nó estimate cả một survival curve $S(t | x)$ như một function của t .


Vì vậy, để assess model fit, ta dùng một approach khác bằng cách stratify observations theo coefficient estimates. Với mỗi test observation, tính “risk” score

$$\text{budget}_i \hat{\beta}_{\text{budget}} + \text{impact}_i \hat{\beta}_{\text{impact}},$$

trong đó $\hat{\beta}_{\text{budget}}$ và $\hat{\beta}_{\text{impact}}$ được estimate từ training set. Sau đó dùng các risk scores để categorize observations theo risk. High-risk group gồm observations có risk score lớn nhất; theo (11.14), đó là những observations có instantaneous probability of being published lớn nhất tại bất kỳ moment in time nào. Nói cách khác, high-risk group gồm những trials có khả năng

¹⁵Cross-validation cho Cox model phức tạp hơn linear hoặc logistic regression vì objective function không phải là sum trên các observations.

được published sớm hơn. Trên *Publication* data, ta stratify observations thành tertiles low, medium và high risk. Figure 11.8 cho thấy survival curves của ba strata tách biệt rõ ràng và được ordered đúng theo mức risk of publication.



HÌNH 11.7. Với *Publication* data ở Section 11.5.4, Figure hiển thị cross-validation results của lasso-penalized Cox model. Y-axis là partial likelihood deviance, đóng vai trò cross-validation error. X-axis là ℓ_1 norm của coefficients của lasso-penalized Cox model với tuning parameter λ , chia cho ℓ_1 norm của coefficients của unpenalized Cox model. Dashed line chỉ minimum cross-validation error.

11.7 Additional Topics

11.7.1 Area Under the Curve for Survival Analysis


Trong Chapter 4, ta đã giới thiệu area under the ROC curve, thường gọi là AUC, để quantify performance của một two-class classifier. Gọi score của observation thứ i là estimate của classifier cho $\Pr(Y = 1 \mid X = x_i)$. Nếu xét mọi pairs gồm một observation thuộc Class 1 và một observation thuộc Class 2, thì AUC là fraction các pairs trong đó score của observation thuộc Class 1 lớn hơn score của observation thuộc Class 2.

Điều này gợi ý một cách generalize notion of AUC sang survival analysis. Ta tính estimated risk score $\hat{\eta}_i = \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip}$, $i = 1, \dots, n$, từ Cox model coefficients. Nếu $\hat{\eta}_{i'} > \hat{\eta}_i$, model predict observation i' có hazard lớn hơn observation i , và do đó survival time t_i sẽ lớn hơn $t_{i'}$. Ta có thể muốn generalize AUC bằng proportion observations có $t_i > t_{i'}$ và $\hat{\eta}_{i'} > \hat{\eta}_i$. Tuy nhiên, ta không observe $t_1, \dots, t_n$; chỉ observe possibly-censored times $y_1, \dots, y_n$ và censoring indicators $\delta_1, \dots, \delta_n$.

Vì vậy, Harrell's concordance index, hay C-index, tính proportion các observation pairs mà $\hat{\eta}_{i'} > \hat{\eta}_i$ và $y_i > y_{i'}$:

$$C = \frac{\sum_{i, i': y_i > y_{i'}} I(\hat{\eta}_{i'} > \hat{\eta}_i) \delta_{i'}}{\sum_{i, i': y_i > y_{i'}} \delta_{i'}}.$$

Indicator $I(\hat{\eta}_{i'} > \hat{\eta}_i)$ bằng one nếu inequality hold và zero nếu không. Numerator và denominator đều được nhân với status indicator $\delta_{i'}$, vì nếu observation i' uncensored ($\delta_{i'} = 1$), thì $y_i > y_{i'}$ suy ra $t_i > t_{i'}$. Ngược lại, nếu $\delta_{i'} = 0$, inequality $y_i > y_{i'}$ không đảm bảo $t_i > t_{i'}$.



HÌNH 11.8. Với *Publication* data, ta chia test set thành các tertiles của “risk” bằng coefficients estimated trên training set. Các resulting survival curves tách biệt rõ ràng.

Fit Cox proportional hazards model trên training set của *Publication* data và compute C-index trên test set cho $C = 0.733$. Nói một cách gần đúng, nếu chọn ngẫu nhiên hai papers từ test set, model predict với accuracy 73.3% paper nào sẽ được published trước.

11.7.2 Choice of Time Scale

Trong các examples đến đây, cách define time khá rõ. Trong *Publication* example, time zero của mỗi paper được define là calendar time tại end of study, còn failure time là số months trôi qua từ end of study cho đến khi paper được published. Tuy nhiên, trong các settings khác, definitions của time zero và failure time có thể tinh tế hơn.

Ví dụ, khi xét association giữa risk factors và disease occurrence trong một epidemiological study, có thể dùng patient age để define time, tức time zero là date of birth. Với choice này, association giữa age và survival không thể được đo riêng, nhưng cũng không cần adjust cho age trong analysis. Khi xét covariates associated với disease-free survival, tức amount of time giữa treatment và disease recurrence, ta có thể dùng treatment date làm time zero.

11.7.3 Time-Dependent Covariates

Một feature mạnh của proportional hazards model là khả năng xử lý *time-dependent covariates*, tức predictors có value thay đổi theo time. Ví dụ, giả sử đo blood pressure của một patient mỗi tuần trong một medical study. Khi đó ta có thể xem blood pressure của observation thứ i không phải là một fixed x_i , mà là $x_i(t)$ tại time t .

*time-dependent
covariates*

Vì partial likelihood trong (11.16) được xây dựng sequentially in time, việc xử lý time-dependent covariates khá straightforward. Cụ thể, chỉ cần thay x_{ij} và $x_{i'j}$ trong (11.16) bằng current values $x_{ij}(y_i)$ và $x_{i'j}(y_i)$. Ngược lại, time-dependent covariates gây difficulty lớn hơn nhiều trong traditional parametric approach như (11.13).

Một example về time-dependent covariates xuất hiện trong analysis của

Stanford Heart Transplant Program. Patients cần heart transplant được đưa vào waiting list. Một số patients nhận transplant, nhưng một số khác chết khi vẫn còn trên waiting list. Primary objective là xác định transplant có associated với longer patient survival hay không.

Một naive approach sẽ dùng fixed covariate để represent transplant status: $x_i = 1$ nếu patient thứ i từng nhận transplant, và $x_i = 0$ nếu không. Nhưng cách này bỏ qua fact rằng patients phải sống đủ lâu mới có thể nhận transplant; do đó, trung bình, healthier patients có khả năng nhận transplant cao hơn. Vấn đề được giải quyết bằng time-dependent covariate: $x_i(t) = 1$ nếu patient đã nhận transplant trước hoặc tại time t , và $x_i(t) = 0$ nếu chưa.

11.7.4 Checking the Proportional Hazards Assumption

Ta đã thấy Cox's proportional hazards model dựa trên proportional hazards assumption (11.14). Dù results của Cox model thường khá robust trước violations của assumption này, vẫn nên kiểm tra xem nó có hợp lý hay không. Với qualitative feature, ta có thể plot log hazard function cho từng level của feature. Nếu (11.14) hold, các log-hazard functions chỉ nên khác nhau bởi một constant, như ở top-left panel của Figure 11.4. Với quantitative feature, có thể dùng approach tương tự sau khi stratify feature thành các groups.

11.7.5 Survival Trees

Trong Chapter 8, ta đã thảo luận các flexible và adaptive learning procedures như trees, random forests và boosting, áp dụng cho cả regression và classification. Hầu hết các approaches này có thể generalize sang survival-analysis setting. Ví dụ, *survival trees* là modification của classification và regression trees, dùng split criterion nhằm maximize difference giữa survival curves của resulting daughter nodes. Survival trees sau đó có thể được combine để tạo random survival forests.

survival trees

11.8 Lab: Survival Analysis

Trong lab này, chúng ta thực hiện survival analyses trên ba datasets riêng biệt. Ở Section 11.8.1, ta analyze **BrainCancer** data lần đầu được mô tả ở Section 11.3. Ở Section 11.8.2, ta xét **Publication** data từ Section 11.5.4. Cuối cùng, Section 11.8.3 explore một simulated call-center dataset.

Ta bắt đầu bằng cách import một số libraries quen thuộc ở top level. Điều này giúp code dễ đọc hơn, vì chỉ cần scan vài lines đầu của notebook là có thể thấy những libraries nào được dùng.

In [1]:

```
from matplotlib.pyplot import subplots
import numpy as np
import pandas as pd
from ISLP.models import ModelSpec as MS
from ISLP import load_data
```

Ta cũng tập hợp các imports mới cần cho lab này.

```
In [2]: from lifelines import \
        (KaplanMeierFitter,
         CoxPHFitter)
        from lifelines.statistics import \
        (logrank_test,
         multivariate_logrank_test)
        from ISLP.survival import sim_time
```

11.8.1 Brain Cancer Data

Ta bắt đầu với **BrainCancer** dataset có trong ISLP package.

```
In [3]: BrainCancer = load_data('BrainCancer')
        BrainCancer.columns
```

```
Out[3]: Index(['sex', 'diagnosis', 'loc', 'ki', 'gtv', 'stereo',
              'status', 'time'],
              dtype='object')
```

Các rows index 88 patients, còn 8 columns chứa predictors và outcome variables. Trước tiên, ta briefly examine data.

```
In [4]: BrainCancer['sex'].value_counts()
```

```
Out[4]: Female    45
        Male      43
        Name: sex, dtype: int64
```

```
In [5]: BrainCancer['diagnosis'].value_counts()
```

```
Out[5]: Meningioma    42
        HG glioma     22
        Other         14
        LG glioma      9
        Name: diagnosis, dtype: int64
```

```
In [6]: BrainCancer['status'].value_counts()
```

```
Out[6]: 0     53
        1     35
        Name: status, dtype: int64
```

Trước khi bắt đầu analysis, cần biết variable **status** được coded như thế nào. Hầu hết survival software dùng convention rằng status bằng 1 chỉ một uncensored observation, thường là death, còn status bằng 0 chỉ một censored observation. Tuy nhiên, một số scientists có thể dùng coding ngược lại. Với **BrainCancer** data, 35 patients chết trước khi study kết thúc, vì vậy dataset này dùng conventional coding.

Để bắt đầu analysis, ta re-create Kaplan–Meier survival curve trong Figure 11.2. Package chính dùng cho survival analysis là **lifelines**. Variable **time** tương ứng với y_i , tức time to the i th event (censoring hoặc death). Argument đầu của **km.fit()** là event time, còn argument thứ hai là cen-

soring/status variable, trong đó 1 chỉ một observed failure time. Method `plot()` tạo survival curve với pointwise confidence intervals. Theo default, đây là 90% confidence intervals, nhưng có thể thay đổi bằng cách đặt argument `alpha` bằng one minus desired confidence level.

In [7]:

```
fig, ax = subplots(figsize=(8,8))
km = KaplanMeierFitter()
km_brain = km.fit(BrainCancer['time'], BrainCancer['status'])
km_brain.plot(label='Kaplan Meier estimate', ax=ax)
```

Tiếp theo ta tạo Kaplan–Meier survival curves stratified by sex để reproduce Figure 11.3. Ta dùng method `groupby()` của dataframe. Method này trả về một generator có thể iterate trong for loop. Ở đây, mỗi item là một 2-tuple đại diện cho một group: entry thứ nhất là value của grouping column `sex`, còn entry thứ hai là dataframe gồm các rows có value `sex` tương ứng. Ta sẽ cần data này cho log-rank test ở dưới, vì vậy lưu các groups trong dictionary `by_sex`. Cuối cùng, ta dùng string interpolation để tự động label các curves khác nhau; Python có nhiều cách hỗ trợ việc format strings như vậy.

In [8]:

```
fig, ax = subplots(figsize=(8,8))
by_sex = {}
for sex, df in BrainCancer.groupby('sex'):
    by_sex[sex] = df
    km_sex = km.fit(df['time'], df['status'])
    km_sex.plot(label='Sex=%s' % sex, ax=ax)
```

Như đã thảo luận ở Section 11.4, ta có thể thực hiện log-rank test để compare survival của males và females. Ta dùng function `logrank_test()` từ module `lifelines.statistics`. Hai arguments đầu là event times của hai groups, còn hai arguments tiếp theo là các censoring indicators tương ứng.

In [9]:

```
logrank_test(by_sex['Male']['time'],
             by_sex['Female']['time'],
             by_sex['Male']['status'],
             by_sex['Female']['status'])
```

Out[9]:

	t_0	-1
null_distribution		chi squared
degrees_of_freedom		1
test_name		logrank_test

test_statistic	p	-log2(p)
1.44	0.23	2.12

Resulting p-value là 0.23, cho thấy không có evidence về difference in survival giữa hai sexes.

Tiếp theo, ta dùng estimator `CoxPHFitter()` từ `lifelines` để fit Cox proportional hazards models. Trước hết xét model chỉ dùng `sex` làm predictor.

In [10]:

```
coxph = CoxPHFitter # shorthand
sex_df = BrainCancer[['time', 'status', 'sex']]
model_df = MS(['time', 'status', 'sex'],
              intercept=False).fit_transform(sex_df)
```

```
cox_fit = coxph().fit(model_df,
                      'time',
                      'status')
cox_fit.summary[['coef', 'se(coef)', 'p']]
```

```
Out[10]:
```

	coef	se(coef)	p
covariate			
sex[Male]	0.407667	0.342004	0.233263

Argument đầu của `fit()` phải là một dataframe chứa ít nhất event time (argument thứ hai, `time`, trong example này), cùng với optional censoring variable (argument `status`). Lưu ý Cox model không có intercept, vì vậy ta dùng `intercept=False` trong `ModelSpec`. Method `summary()` trả về nhiều columns; ở đây ta chỉ hiển thị một subset. Ta cũng có thể obtain likelihood-ratio test comparing model này với model không có features như sau.

```
In [11]: cox_fit.log_likelihood_ratio_test()
```

```
Out[11]:
```

	chi squared
degrees_freedom	1
test_name	log-likelihood ratio test

test_statistic	p	-log2(p)
1.44	0.23	2.12

Bất kể dùng test nào, ta đều thấy không có clear evidence về difference in survival giữa males và females. Như đã học trong chapter này, score test từ Cox model với một binary covariate chính xác bằng log-rank test statistic.

Bây giờ fit một model dùng thêm các predictors khác. Trước tiên, lưu ý có một missing value trong `diagnosis`, vì vậy ta drop observation đó trước khi tiếp tục.

```
In [12]: cleaned = BrainCancer.dropna()
all_MS = MS(cleaned.columns, intercept=False)
all_df = all_MS.fit_transform(cleaned)
fit_all = coxph().fit(all_df,
                     'time',
                     'status')
fit_all.summary[['coef', 'se(coef)', 'p']]
```

```
Out[12]:
```

	coef	se(coef)	p
covariate			
sex[Male]	0.183748	0.360358	0.610119
diagnosis[LG glioma]	-1.239541	0.579557	0.032454
diagnosis[Meningioma]	-2.154566	0.450524	0.000002
diagnosis[Other]	-1.268870	0.617672	0.039949
loc[Supratentorial]	0.441195	0.703669	0.530664
ki	-0.054955	0.018314	0.002693
gtv	0.034293	0.022333	0.124660
stereo[SRT]	0.177778	0.601578	0.767597

Variable `diagnosis` được coded sao cho baseline là HG glioma. Results cho thấy risk associated với HG glioma cao hơn hơn tám lần risk associated với meningioma, vì $e^{2.15} = 8.62$. Nói cách khác, sau khi adjust cho các predictors khác, patients có HG glioma có survival tệ hơn nhiều so với

patients có meningioma. Ngoài ra, values lớn hơn của Karnofsky index `ki` associated với lower risk, tức longer survival.

Cuối cùng, ta plot estimated survival curves cho từng diagnosis category, đồng thời adjust cho các predictors khác. Để tạo các plots này, ta đặt quantitative variables bằng mean của chúng và categorical variables bằng mode. Ta dùng method `apply()` theo columns (`axis=0`) với một function `representative` để kiểm tra column có categorical hay không.

```
In [13]: levels = cleaned['diagnosis'].unique()
def representative(series):
    if hasattr(series.dtype, 'categories'):
        return pd.Series.mode(series)
    else:
        return series.mean()
modal_data = cleaned.apply(representative, axis=0)
```

Sau đó tạo bốn copies của representative row và gán column `diagnosis` bằng bốn diagnosis levels khác nhau.

```
In [14]: modal_df = pd.DataFrame(
    [modal_data.iloc[0] for _ in range(len(levels))]
modal_df['diagnosis'] = levels
modal_df
```

```
Out[14]:
```

	sex	diagnosis	loc	ki	gtv	stereo	...
Female	Female	Meningioma	Supratentorial	80.920	8.687	SRT	...
Female	Female	HG glioma	Supratentorial	80.920	8.687	SRT	...
Female	Female	LG glioma	Supratentorial	80.920	8.687	SRT	...
Female	Female	Other	Supratentorial	80.920	8.687	SRT	...

Ta construct model matrix dựa trên model specification `all_MS` đã dùng để fit model, rồi đặt row names theo các diagnosis levels.

```
In [15]: modal_X = all_MS.transform(modal_df)
modal_X.index = levels
modal_X
```

Ta có thể dùng method `predict_survival_function()` để obtain estimated survival function.

```
In [16]: predicted_survival = fit_all.predict_survival_function(modal_X)
predicted_survival
```

```
Out[16]:
```

	Meningioma	HG glioma	LG glioma	Other
0.070	0.998	0.982	0.995	0.995
1.180	0.998	0.982	0.995	0.995
1.410	0.996	0.963	0.989	0.990
1.540	0.996	0.963	0.989	0.990
...	...	...	...	...
67.380	0.689	0.040	0.394	0.405
73.740	0.689	0.040	0.394	0.405
78.750	0.689	0.040	0.394	0.405
82.560	0.689	0.040	0.394	0.405

85 rows × 4 columns

Kết quả trả về một dataframe; plot methods của dataframe tạo các survival curves khác nhau. Để tránh làm plot quá rối, ta không hiển thị confidence intervals.

```
In [17]: fig, ax = subplots(figsize=(8, 8))
         predicted_survival.plot(ax=ax);
```

11.8.2 Publication Data

Publication data được trình bày ở Section 11.5.4 có trong ISLP package. Trước tiên ta reproduce Figure 11.5 bằng cách plot Kaplan–Meier curves stratified theo variable `posres`, variable này ghi study có positive result hay không.

```
In [18]: fig, ax = subplots(figsize=(8,8))
         Publication = load_data('Publication')
         by_result = {}
         for result, df in Publication.groupby('posres'):
             by_result[result] = df
             km_result = km.fit(df['time'], df['status'])
             km_result.plot(label='Result=%d' % result, ax=ax)
```

Như đã thảo luận trước đó, p-values từ việc fit Cox's proportional hazards model chỉ với `posres` khá lớn, nên không có evidence về difference in time-to-publication giữa studies có positive và negative results.

```
In [19]: posres_df = MS(['posres',
                        'time',
                        'status'],
                    intercept=False).fit_transform(Publication)
         posres_fit = coxph().fit(posres_df,
                                'time',
                                'status')
         posres_fit.summary[['coef', 'se(coef)', 'p']]
```

```
Out[19]:
```

	coef	se(coef)	p
covariate			
posres	0.148076	0.161625	0.359578

Tuy nhiên, results thay đổi đáng kể khi include các predictors khác trong model. Ở đây ta exclude funding mechanism variable.

```
In [20]: model = MS(Publication.columns.drop('mech'),
                    intercept=False)
         coxph().fit(model.fit_transform(Publication),
                    'time',
                    'status').summary[['coef', 'se(coef)', 'p']]
```

```
Out[20]:
```

	coef	se(coef)	p
covariate			
posres	0.570774	0.175960	1.179606e-03
multi	-0.040863	0.251194	8.707727e-01
clinend	0.546180	0.262001	3.710099e-02
sampsize	0.000005	0.000015	7.506978e-01
budget	0.004386	0.002464	7.511276e-02
impact	0.058318	0.006676	2.426779e-18

Ta thấy một số variables statistically significant, gồm việc trial có clinical endpoint hay không, impact của study, và study có positive hay negative result.

11.8.3 Call Center Data

Trong section này, ta simulate survival data bằng mối quan hệ giữa cumulative hazard và survival function được explore trong Exercise 8. Simulated data đại diện cho observed wait times, tính bằng seconds, của 2,000 customers gọi đến một call center. Trong context này, censoring xảy ra nếu customer gác máy trước khi call được answered.

Có ba covariates: **Operators** (số call-center operators có sẵn tại thời điểm call, từ 5 đến 15), **Center** (A, B hoặc C), và **Time of day** (Morning, Afternoon hoặc Evening). Ta generate data sao cho mọi possibilities đều equally likely; chẳng hạn morning, afternoon và evening calls equally likely, và mỗi số operators từ 5 đến 15 cũng equally likely.

In [21]:

```
rng = np.random.default_rng(10)
N = 2000
Operators = rng.choice(np.arange(5, 16),
                        N,
                        replace=True)
```

In [22]:

```
Center = rng.choice(['A', 'B', 'C'],
                    N,
                    replace=True)
Time = rng.choice(['Morn.', 'After.', 'Even.'],
                  N,
                  replace=True)
D = pd.DataFrame({'Operators': Operators,
                  'Center': pd.Categorical(Center),
                  'Time': pd.Categorical(Time)})
```

Sau đó ta build model matrix, bỏ intercept.

In [23]:

```
model = MS(['Operators',
            'Center',
            'Time'],
            intercept=False)
X = model.fit_transform(D)
X[:5]
```

Out[23]:

	Operators	Center[B]	Center[C]	Time[Even.]	Time[Morn.]
0	13	0.0	1.0	0.0	0.0
1	15	0.0	0.0	1.0	0.0
2	7	1.0	0.0	0.0	1.0
3	7	0.0	1.0	0.0	1.0
4	13	0.0	1.0	1.0	0.0

Nên xem qua model matrix X để chắc rằng ta hiểu các variables được coded như thế nào. Theo default, levels của categorical variables được sorted và, như thường lệ, first column của one-hot encoding bị dropped.

Tiếp theo, ta specify coefficients và hazard function.

In [24]:

```
true_beta = np.array([0.04, -0.3, 0, 0.2, -0.2])
true_linpred = X.dot(true_beta)
hazard = lambda t: 1e-5 * t
```

Coefficient associated với **Operators** được đặt bằng 0.04; nói cách khác, mỗi additional operator làm “risk” rằng call được answered tăng theo factor $e^{0.04} = 1.041$, conditional on **Center** và **Time**. Điều này hợp lý: càng nhiều

operators thì wait time càng ngắn. Coefficient của `Center == B` là -0.3 , còn `Center == A` được coi là baseline. Vì vậy risk rằng call được answered tại Center B bằng 0.74 lần risk tại Center A; nói cách khác, wait times tại Center B dài hơn một chút.

Recall từ Section 2.3.7 việc dùng `lambda` để tạo các short functions on the fly. Ta dùng function `sim_time()` từ package `ISLP.survival`. Function này dùng relationship giữa survival function và cumulative hazard $S(t) = \exp(-H(t))$, cùng specific form của cumulative hazard trong Cox model, để simulate data từ values của linear predictor `true_linpred` và cumulative hazard. Ta cần cung cấp cumulative hazard function như sau.

```
In [25]: cum_hazard = lambda t: 1e-5 * t**2 / 2
```

Bây giờ ta có thể generate data dưới Cox proportional hazards model. Ta truncate maximum time tại 1000 seconds để simulated wait times ở mức hợp lý. Function `sim_time()` nhận linear predictor, cumulative hazard function và random number generator.

```
In [26]: W = np.array([sim_time(1, cum_hazard, rng)
                      for l in true_linpred])
D['Wait time'] = np.clip(W, 0, 1000)
```

Tiếp theo simulate censoring variable, với assumption rằng 90% calls được answered (`Failed==1`) trước khi customer gác máy (`Failed==0`).

```
In [27]: D['Failed'] = rng.choice([1, 0],
                                N,
                                p=[0.9, 0.1])
D[:5]
```

```
Out[27]:
```

	Operators	Center	Time	Wait time	Failed
0	13	C	After.	525.064979	1
1	15	A	Even.	254.677835	1
2	7	B	Morn.	487.739224	1
3	7	C	Morn.	308.580292	1
4	13	C	Even.	154.174608	1

```
In [28]: D['Failed'].mean()
```

```
Out[28]: 0.8985
```

Bây giờ ta plot Kaplan–Meier survival curves. Trước hết stratify theo `Center`.

```
In [29]: fig, ax = subplots(figsize=(8,8))
by_center = {}
for center, df in D.groupby('Center'):
    by_center[center] = df
    km_center = km.fit(df['Wait time'], df['Failed'])
    km_center.plot(label='Center=%s' % center, ax=ax)
ax.set_title("Probability of Still Being on Hold")
```

Tiếp theo stratify theo `Time`.

```
In [30]: fig, ax = subplots(figsize=(8,8))
by_time = {}
for time, df in D.groupby('Time'):
    by_time[time] = df
    km_time = km.fit(df['Wait time'], df['Failed'])
    km_time.plot(label='Time=%s' % time, ax=ax)
ax.set_title("Probability of Still Being on Hold")
```

Có vẻ calls tại Call Center B mất nhiều time hơn mới được answered so với Centers A và C. Tương tự, wait times dường như dài nhất vào morning và ngắn nhất vào evening. Ta dùng log-rank test để xác định các differences này có statistically significant hay không, thông qua function `multivariate_logrank_test()`.

```
In [31]: multivariate_logrank_test(D['Wait time'],
                                   D['Center'],
                                   D['Failed'])
```

```
Out[31]:
```

	t_0	-1
null_distribution		chi squared
degrees_of_freedom		2
test_name		multivariate_logrank_test
test_statistic	p	-log2(p)
	20.30	<0.005
		14.65

Tiếp theo, xét effect của Time.

```
In [32]: multivariate_logrank_test(D['Wait time'],
                                   D['Time'],
                                   D['Failed'])
```

```
Out[32]:
```

	t_0	-1
null_distribution		chi squared
degrees_of_freedom		2
test_name		multivariate_logrank_test
test_statistic	p	-log2(p)
	49.90	<0.005
		35.99

Giống trường hợp categorical variable có 2 levels, những results này gần với likelihood-ratio test từ Cox proportional hazards model. Trước tiên xem results cho **Center**.

```
In [33]: X = MS(['Wait time',
                 'Failed',
                 'Center'],
                intercept=False).fit_transform(D)
F = coxph().fit(X, 'Wait time', 'Failed')
F.log_likelihood_ratio_test()
```

```
Out[33]:
```

		chi squared
degrees_freedom		2
test_name		log-likelihood ratio test
test_statistic	p	-log2(p)
	20.58	<0.005
		14.85

Tiếp theo xem results cho Time.

In [34]:

```
X = MS(['Wait time',
        'Failed',
        'Time'],
        intercept=False).fit_transform(D)
F = coxph().fit(X, 'Wait time', 'Failed')
F.log_likelihood_ratio_test()
```

Out[34]:

```

null_distribution          chi squared
degrees_freedom              2
test_name          log-likelihood ratio test

test_statistic      p      -log2(p)
         48.12  <0.005         34.71
```

Ta thấy differences giữa các centers highly significant, và differences giữa các times of day cũng vậy.

Cuối cùng, ta fit Cox's proportional hazards model cho toàn bộ data.

In [35]:

```
X = MS(D.columns,
        intercept=False).fit_transform(D)
fit_queuing = coxph().fit(
    X,
    'Wait time',
    'Failed')
fit_queuing.summary[['coef', 'se(coef)', 'p']]
```

Out[35]:

```

      coef  se(coef)          p
covariate
Operators    0.043934  0.007520  5.143677e-09
Center[B]   -0.236059  0.058113  4.864734e-05
Center[C]    0.012231  0.057518  8.316083e-01
Time[Even.]  0.268845  0.057797  3.294914e-06
Time[Morn.] -0.148215  0.057334  9.734378e-03
```

P-values của Center B và evening time đều rất nhỏ. Đồng thời, hazard—tức instantaneous risk rằng một call sẽ được answered—tăng theo number of operators. Vì data do chính ta generate, ta biết true coefficients của Operators, Center = B, Center = C, Time = Even. và Time = Morn. lần lượt là 0.04, −0.3, 0, 0.2, −0.2. Coefficient estimates từ fitted Cox model khá accurate.