

11.9 Exercises

Conceptual

1. Với từng ví dụ sau, hãy cho biết censoring mechanism có independent hay không. Giải thích câu trả lời.
 - (a) Trong một study về disease relapse, do một research scientist bất cẩn, tất cả patients có số điện thoại bắt đầu bằng chữ số “2” đều bị lost to follow-up.
 - (b) Trong một study về longevity, một formatting error khiến mọi patient age vượt quá 99 years bị mất (tức ta biết các patients đó lớn hơn 99 tuổi nhưng không biết exact age).
 - (c) Hospital A tiến hành một study về longevity. Tuy nhiên, các very sick patients có xu hướng được chuyển sang Hospital B và do đó bị lost to follow-up.
 - (d) Trong một study về unemployment duration, những người tìm được việc sớm ít có động lực giữ liên lạc với study investigators hơn, và vì vậy có probability bị lost to follow-up cao hơn.
 - (e) Trong một study về pregnancy duration, những women sinh pre-term có xu hướng sinh ở ngoài bệnh viện thông thường của họ và vì vậy có probability bị censored cao hơn so với women sinh full-term.
 - (f) Một researcher muốn model number of years of education của residents trong một small town. Residents theo học college ngoài thị trấn có probability bị lost to follow-up cao hơn, đồng thời cũng có probability học graduate school cao hơn, so với những người học college trong thị trấn.
 - (g) Researchers tiến hành một study về disease-free survival (tức time until disease relapse sau treatment). Patients không relapse trong vòng 5 years được xem là cured, và vì vậy survival time của họ bị censored tại 5 years.
 - (h) Ta muốn model failure time của một electrical component. Component này có thể được sản xuất tại Iowa hoặc Pittsburgh, không có difference về quality. Iowa factory mở 5 years trước nên components sản xuất tại Iowa bị censored tại 5 years. Pittsburgh factory mở 2 years trước nên components ở đó bị censored tại 2 years.
 - (i) Ta muốn model failure time của một electrical component được sản xuất tại two different factories, trong đó một factory mở sớm hơn factory kia. Có lý do để tin rằng components sản xuất tại factory mở sớm hơn có quality cao hơn.
2. Ta tiến hành một study với $n = 4$ participants vừa mua cell phones, nhằm model time until phone replacement. Participant thứ nhất thay phone sau 1.2 years. Participant thứ hai vẫn chưa thay phone khi study period 2 years kết thúc. Participant thứ ba đổi phone number và bị lost to follow-up (nhưng vẫn chưa thay phone) sau 1.5 years. Participant

thứ tư thay phone sau 0.2 years. Với mỗi participant ($i = 1, \dots, 4$), trả lời các câu hỏi sau bằng notation đã giới thiệu ở Section 11.1:

- (a) Cell phone replacement time của participant có bị censored không?
 - (b) Giá trị c_i có known không, và nếu có thì bằng bao nhiêu?
 - (c) Giá trị t_i có known không, và nếu có thì bằng bao nhiêu?
 - (d) Giá trị y_i có known không, và nếu có thì bằng bao nhiêu?
 - (e) Giá trị δ_i có known không, và nếu có thì bằng bao nhiêu?
3. Với example trong Exercise 2, hãy report các giá trị

$$K, \quad d_1, \dots, d_K, \quad r_1, \dots, r_K, \quad q_1, \dots, q_K,$$

trong đó notation này được định nghĩa ở Section 11.3.

4. Problem này sử dụng Kaplan–Meier survival curve hiển thị trong Figure 11.9. Raw data dùng để plot survival curve này được cho trong Table 11.4. Column covariate của table không cần thiết cho problem này.
- (a) Estimated probability of survival past 50 days là bao nhiêu?

Observation (Y)	Censoring Indicator (δ)	Covariate (X)
26.5	1	0.1
37.2	1	11
57.3	1	-0.3
90.8	0	2.8
20.2	0	1.8
89.8	0	0.4

BẢNG 11.4. Data được dùng trong Exercise 4.

- (b) Viết một analytical expression cho estimated survival function. Chẳng hạn, answer có thể có dạng

$$\widehat{S}(t) = \begin{cases} 0.8, & t < 31, \\ 0.5, & 31 \leq t < 77, \\ 0.22, & 77 \leq t. \end{cases}$$


(Equation trên chỉ để minh họa; đó không phải correct answer.)

5. Phác thảo survival function cho bởi equation

$$\widehat{S}(t) = \begin{cases} 0.8, & t < 31, \\ 0.5, & 31 \leq t < 77, \\ 0.22, & 77 \leq t. \end{cases}$$

Answer nên trông tương tự Figure 11.9.

6. Problem này sử dụng data hiển thị trong Figure 11.1. Khi làm problem này, có thể ký hiệu observation times là $y_1, \dots, y_4$. Thứ tự của các observation times có thể đọc từ Figure 11.1; không cần exact values.



HÌNH 11.9. Một Kaplan–Meier survival curve được dùng trong Exercise 4.

- (a) Report các giá trị $\delta_1, \dots, \delta_4, K, d_1, \dots, d_K, r_1, \dots, r_K$, và $q_1, \dots, q_K$. Relevant notation được định nghĩa ở Sections 11.1 và 11.3.
 - (b) Phác thảo Kaplan–Meier survival curve tương ứng với dataset này. (Không cần dùng software; có thể sketch bằng tay dựa trên kết quả ở (a).)
 - (c) Dựa trên survival curve estimated ở (b), probability event xảy ra trong vòng 200 days là bao nhiêu? Probability event không xảy ra trong vòng 310 days là bao nhiêu?
 - (d) Viết một expression cho estimated survival curve từ (b).
7. Trong problem này, ta sẽ derive (11.5) và (11.6), cần thiết để construct log-rank test statistic (11.8). Recall notation trong Table 11.1.
- (a) Giả sử không có difference giữa survival functions của hai groups. Khi đó có thể xem q_{1k} là number of failures khi draw r_{1k} observations, without replacement, từ một risk set gồm r_k observations chứa tổng cộng q_k failures. Hãy lập luận rằng q_{1k} follows a hypergeometric distribution. Viết parameters của distribution này theo r_{1k}, r_k , và q_k .
 - (b) Dựa trên answer trước và properties của hypergeometric distribution, mean và variance của q_{1k} là gì? So sánh answer với (11.5) và (11.6).
8. Recall rằng survival function $S(t)$, hazard function $h(t)$, và density function $f(t)$ được định nghĩa lần lượt trong (11.2), (11.9), và (11.11). Đồng thời define $F(t) = 1 - S(t)$. Chứng minh các relationships sau:

$$f(t) = \frac{dF(t)}{dt}, \quad S(t) = \exp\left(-\int_0^t h(u) du\right).$$

9. Trong exercise này, ta explore consequences của assumption rằng survival times follow an exponential distribution.
- (a) Giả sử survival time follows an $\text{Exp}(\lambda)$ distribution, sao cho density function là $f(t) = \lambda \exp(-\lambda t)$. Dùng các relationships trong Exercise 8 để chứng minh $S(t) = \exp(-\lambda t)$.
 - (b) Bây giờ giả sử mỗi trong n independent survival times follows an $\text{Exp}(\lambda)$ distribution. Viết expression cho likelihood function (11.13).

- (c) Chứng minh maximum likelihood estimator của λ là

$$\hat{\lambda} = \frac{\sum_{i=1}^n \delta_i}{\sum_{i=1}^n y_i}.$$

- (d) Dùng answer ở (c) để derive một estimator của mean survival time.

Hint: Với (d), recall rằng mean của một $\text{Exp}(\lambda)$ random variable là $1/\lambda$.

Applied

10. Exercise này tập trung vào brain tumor data có trong ISLP library.
 - (a) Plot Kaplan–Meier survival curve với ± 1 standard error bands, dùng estimator `KaplanMeierFitter()` trong package `lifelines`.
 - (b) Draw một bootstrap sample có size $n = 88$ từ các pairs (y_i, δ_i) và compute Kaplan–Meier survival curve tương ứng. Repeat process này $B = 200$ times. Dùng results để estimate standard error của Kaplan–Meier survival curve tại mỗi timepoint. So sánh với standard errors ở (a).
 - (c) Fit Cox proportional hazards model dùng tất cả predictors để predict survival. Tóm tắt main findings.
 - (d) Stratify data theo value của `ki`. (Vì chỉ có one observation có `ki==40`, có thể group observation đó với observations có `ki==60`.) Plot Kaplan–Meier survival curves cho mỗi trong five strata, adjusted for other predictors.
11. Exercise này sử dụng data trong Table 11.4.
 - (a) Tạo two groups of observations. Trong Group 1, $X < 2$, còn trong Group 2, $X \geq 2$. Plot Kaplan–Meier survival curves tương ứng với hai groups. Hãy label curves rõ ràng để biết curve nào thuộc group nào. Bằng mắt, có vẻ tồn tại difference giữa survival curves của hai groups hay không?
 - (b) Fit Cox’s proportional hazards model, dùng group indicator làm covariate. Estimated coefficient là bao nhiêu? Viết một câu giải thích coefficient này theo hazard hoặc instantaneous probability of the event. Có evidence rằng true coefficient value khác zero hay không?
 - (c) Recall từ Section 11.5.2 rằng với single binary covariate, log-rank test statistic phải identical với score statistic của Cox model. Thực hiện log-rank test để xác định có difference giữa survival curves của hai groups hay không. p-value của log-rank test statistic so với p-value của score statistic cho Cox model ở (b) như thế nào?

12

Unsupervised Learning

Phần lớn cuốn sách này tập trung vào các supervised learning methods như regression và classification. Trong supervised learning setting, ta thường có một tập gồm p features $X_1, X_2, \dots, X_p$ được đo trên n observations, cùng một response Y cũng được đo trên chính n observations đó. Mục tiêu khi ấy là predict Y bằng $X_1, X_2, \dots, X_p$.

Chapter này thay vào đó tập trung vào *unsupervised learning*, một tập các statistical tools dành cho setting trong đó ta chỉ có features $X_1, X_2, \dots, X_p$ được đo trên n observations. Ta không quan tâm đến prediction vì không có associated response variable Y . Thay vào đó, mục tiêu là khám phá những điều thú vị trong measurements của $X_1, X_2, \dots, X_p$. Có cách informative nào để visualize data không? Có thể discover subgroups giữa các variables hoặc giữa các observations hay không? Unsupervised learning chỉ một tập đa dạng các techniques nhằm trả lời những câu hỏi như vậy. Trong chapter này, ta tập trung vào hai loại unsupervised learning cụ thể: *principal components analysis*, một tool dùng cho data visualization hoặc data pre-processing trước khi áp dụng supervised techniques, và *clustering*, một broad class of methods để discover các unknown subgroups trong data.

12.1 The Challenge of Unsupervised Learning

Supervised learning là một area đã được hiểu khá rõ. Nếu đã đọc các chapters trước, đến đây bạn hẳn đã nắm được khá vững supervised learning. Chẳng hạn, nếu được yêu cầu predict một binary outcome từ data set, bạn có một bộ tools phát triển rất tốt để sử dụng, như logistic regression, linear discriminant analysis, classification trees, support vector machines, và nhiều methods khác; đồng thời bạn cũng hiểu khá rõ cách assess quality của results bằng cross-validation, validation trên independent test set, v.v.

Ngược lại, unsupervised learning thường khó hơn đáng kể. Bài toán có xu hướng subjective hơn và không có một goal đơn giản cho analysis như prediction của response. Unsupervised learning thường được thực hiện như một phần của *exploratory data analysis*. Hơn nữa, results từ unsupervised learning methods có thể khó assess vì không có một universally accepted mechanism để thực hiện cross-validation hoặc validate results trên independent data set. Lý do rất đơn giản. Nếu fit một predictive model bằng supervised learning technique, ta có thể check work bằng cách xem model predict response Y tốt đến đâu trên observations không dùng để fit model.

Nhưng trong unsupervised learning, không có cách tương tự để check vì ta không biết true answer — problem là unsupervised.

*exploratory data
analysis*

Các unsupervised learning techniques ngày càng quan trọng trong nhiều fields. Một cancer researcher có thể assay gene-expression levels ở 100 patients bị breast cancer rồi tìm subgroups giữa các breast-cancer samples hoặc giữa các genes để hiểu disease tốt hơn. Một online shopping site có thể identify groups of shoppers có browsing và purchase histories tương tự, cũng như các items đặc biệt hấp dẫn đối với shoppers trong từng group. Khi đó, một individual shopper có thể được ưu tiên hiển thị những items mà người đó đặc biệt có khả năng quan tâm, dựa trên purchase histories của similar shoppers. Một search engine có thể chọn search results để hiển thị cho một individual dựa trên click histories của những người khác có search patterns tương tự. Các statistical learning tasks này, cùng nhiều tasks khác, đều có thể thực hiện bằng unsupervised learning techniques.

12.2 Principal Components Analysis

Principal components đã được thảo luận ở Section 6.3.1 trong context của principal components regression. Khi đối mặt với một large set of correlated variables, principal components cho phép summarize set này bằng một số nhỏ hơn các representative variables nhưng collectively explain phần lớn variability trong original set. Principal component directions được trình bày ở Section 6.3.1 như những directions trong feature space dọc theo đó original data có variability lớn. Các directions này cũng define những lines và subspaces gần data cloud nhất có thể. Để thực hiện principal components regression, ta chỉ cần dùng principal components làm predictors trong regression model thay cho original larger set of variables.

Principal components analysis (PCA) là process dùng để compute principal components và sau đó sử dụng các components này để understand data. PCA là một unsupervised approach vì chỉ involves một set of features $X_1, X_2, \dots, X_p$ mà không có associated response Y . Ngoài việc tạo derived variables dùng trong supervised learning problems, PCA còn là một tool cho data visualization, cả visualization của observations lẫn visualization của variables. PCA cũng có thể dùng cho data imputation, tức fill missing values trong một data matrix.

*principal
components
analysis*

Ta sẽ xem PCA chi tiết hơn, tập trung vào việc dùng PCA như một tool cho unsupervised data exploration phù hợp với chủ đề của chapter này.

12.2.1 What Are Principal Components?

Giả sử ta muốn visualize n observations với measurements trên p features $X_1, X_2, \dots, X_p$ như một phần của exploratory data analysis. Một cách là examine các two-dimensional scatterplots, mỗi plot chứa measurements của n observations trên hai features. Tuy nhiên, có tới $\binom{p}{2} = p(p-1)/2$ scatterplots như vậy; chẳng hạn với $p = 10$ đã có 45 plots. Nếu p lớn, rõ ràng không thể xem hết; hơn nữa, nhiều khả năng chẳng plot nào đặc biệt informative vì mỗi plot chỉ chứa một phần nhỏ total information trong data set. Ta cần một method tốt hơn để visualize n observations khi p lớn. Cụ thể, ta muốn tìm một low-dimensional representation của data giữ lại nhiều information nhất có thể. Ví dụ, nếu thu được một two-dimensional

representation giữ lại phần lớn information, ta có thể plot observations trong low-dimensional space đó.

PCA cung cấp đúng tool như vậy. Nó tìm một low-dimensional representation của data set chứa càng nhiều variation càng tốt. Ý tưởng là mỗi observation sống trong p -dimensional space, nhưng không phải mọi dimension đều equally interesting. PCA tìm một số nhỏ dimensions “interesting” nhất, trong đó mức interesting được đo bằng amount mà observations vary dọc theo mỗi dimension. Mỗi dimension mà PCA tìm ra là một linear combination của p features. Sau đây ta mô tả cách các dimensions, hay principal components, được tìm.

First principal component của features $X_1, X_2, \dots, X_p$ là normalized linear combination

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{p1}X_p \quad (12.1)$$

có variance lớn nhất. “Normalized” nghĩa là $\sum_{j=1}^p \phi_{j1}^2 = 1$. Các elements $\phi_{11}, \dots, \phi_{p1}$ được gọi là *loadings* của first principal component; cùng nhau chúng tạo thành principal component loading vector $\phi_1 = (\phi_{11}, \phi_{21}, \dots, \phi_{p1})^T$. Ta constrain loadings sao cho sum of squares bằng one, bởi nếu không, chỉ cần làm absolute values của các elements lớn tùy ý là có thể tạo variance lớn tùy ý.

loading

Với một $n \times p$ data set X , làm thế nào compute first principal component? Vì chỉ quan tâm đến variance, giả sử mỗi variable trong X đã được centered để có mean zero, tức column means của X bằng zero. Ta tìm linear combination của sample feature values có dạng

$$z_{i1} = \phi_{11}x_{i1} + \phi_{21}x_{i2} + \dots + \phi_{p1}x_{ip} \quad (12.2)$$

có sample variance lớn nhất, subject to constraint $\sum_{j=1}^p \phi_{j1}^2 = 1$. Nói cách khác, first principal component loading vector solve optimization problem

$$\text{maximize}_{\phi_{11}, \dots, \phi_{p1}} \left\{ \frac{1}{n} \sum_{i=1}^n \left(\sum_{j=1}^p \phi_{j1}x_{ij} \right)^2 \right\} \quad \text{subject to} \quad \sum_{j=1}^p \phi_{j1}^2 = 1. \quad (12.3)$$

Từ (12.2), objective trong (12.3) có thể viết là $n^{-1} \sum_{i=1}^n z_{i1}^2$. Vì $n^{-1} \sum_i x_{ij} = 0$, average của $z_{11}, \dots, z_{n1}$ cũng bằng zero. Do đó objective đang maximize chính là sample variance của n values z_{i1} . Ta gọi $z_{11}, \dots, z_{n1}$ là *scores* của first principal component. Problem (12.3) có thể được solve bằng *eigen decomposition*, một standard technique trong linear algebra, nhưng details nằm ngoài scope của sách.¹

score; eigen
decomposition

Có một geometric interpretation đẹp cho first principal component. Loading vector ϕ_1 với elements $\phi_{11}, \phi_{21}, \dots, \phi_{p1}$ define một direction trong feature space mà dọc theo đó data vary nhiều nhất. Nếu project n data points $x_1, \dots, x_n$ lên direction này, projected values chính là principal component scores $z_{11}, \dots, z_{n1}$. Chẳng hạn Figure 6.14 ở page 254 hiển thị first principal component loading vector trên advertising data set. Vì data đó chỉ có two features, observations và loading vector đều có thể display dễ dàng. Từ (6.19), $\phi_{11} = 0.839$ và $\phi_{21} = 0.544$.

¹Một alternative cho eigen decomposition là một related technique gọi là singular value decomposition. Technique này sẽ được explore trong lab ở cuối chapter.

Sau khi first principal component Z_1 được xác định, ta có thể tìm second principal component Z_2 . Second principal component là linear combination của $X_1, \dots, X_p$ có maximal variance trong tất cả linear combinations uncorrelated với Z_1 . Second principal component scores $z_{12}, z_{22}, \dots, z_{n2}$ có dạng

$$z_{i2} = \phi_{12}x_{i1} + \phi_{22}x_{i2} + \dots + \phi_{p2}x_{ip}, \quad (12.4)$$

trong đó ϕ_2 là second principal component loading vector. Constraining Z_2 uncorrelated với Z_1 tương đương constraining direction ϕ_2 orthogonal với direction ϕ_1 . Trong Figure 6.14, observations nằm trong two-dimensional space nên sau khi tìm ϕ_1 chỉ còn một possibility cho ϕ_2 , hiển thị bằng blue dashed line. Từ Section 6.3.1, $\phi_{12} = 0.544$ và $\phi_{22} = -0.839$. Với larger data set có $p > 2$, có multiple distinct principal components được define tương tự. Để tìm ϕ_2 , ta solve problem giống (12.3) với ϕ_2 thay ϕ_1 , đồng thời thêm constraint $\phi_2 \perp \phi_1$.²

Sau khi compute principal components, ta có thể plot chúng against each other để tạo low-dimensional views của data. Chẳng hạn có thể plot score vector Z_1 against Z_2 , Z_1 against Z_3 , Z_2 against Z_3 , v.v. Geometrically, điều này tương đương project original data xuống subspace spanned by ϕ_1, ϕ_2, ϕ_3 rồi plot projected points.

Ta minh họa PCA trên **USArrests** data set. Với mỗi trong 50 states của United States, data set chứa number of arrests per 100,000 residents cho ba crimes: **Assault**, **Murder**, và **Rape**. Ta cũng record **UrbanPop**, percent population của mỗi state sống trong urban areas. Principal component score vectors có length $n = 50$, còn loading vectors có length $p = 4$. PCA được thực hiện sau khi standardize mỗi variable để có mean zero và standard deviation one.

	PC1	PC2
Murder	0.5358995	-0.4181809
Assault	0.5831836	-0.1879856
UrbanPop	0.2781909	0.8728062
Rape	0.5434321	0.1673186


BẢNG 12.1. Principal component loading vectors ϕ_1 và ϕ_2 cho **USArrests** data. Chúng cũng được display trong Figure 12.1.

Figure 12.1 plot first two principal components của data này. Figure biểu diễn cả principal component scores và loading vectors trong một *biplot*. Loadings cũng được cho trong Table 12.1.

biplot

Trong Figure 12.1, first loading vector đặt approximately equal weight lên **Assault**, **Murder**, và **Rape**, nhưng much less weight lên **UrbanPop**. Vì vậy component này roughly tương ứng với một measure của overall rates of serious crimes. Second loading vector đặt phần lớn weight lên **UrbanPop** và ít hơn nhiều lên ba features còn lại, nên roughly tương ứng với level of urbanization của state. Nhìn chung, crime-related variables (**Murder**, **Assault**, và **Rape**) nằm gần nhau, còn **UrbanPop** nằm xa ba variables kia. Điều này cho thấy crime-related variables correlated với nhau — states có

²Về mặt technical, principal component directions $\phi_1, \phi_2, \phi_3, \dots$ là ordered sequence of eigenvectors của matrix $X^T X$, còn variances của components là eigenvalues. Có nhiều nhất $\min(n-1, p)$ principal components.



HÌNH 12.1. Hai principal components đầu tiên của *USArrests* data. Blue state names biểu diễn scores của first two principal components. Orange arrows biểu diễn first two principal component loading vectors, với axes ở top và right. Chẳng hạn loading của *Rape* trên first component là 0.54 và loading trên second component là 0.17; từ *Rape* được centered tại point (0.54, 0.17). Figure này được gọi là một biplot vì hiển thị cả principal component scores lẫn principal component loadings.


high murder rates có xu hướng cũng có high assault và rape rates — còn *UrbanPop* less correlated với ba variables kia.

Ta cũng có thể examine differences giữa states qua two principal component score vectors trong Figure 12.1. Discussion về loadings gợi ý rằng states có large positive scores trên first component, như California, Nevada và Florida, có high crime rates, trong khi states như North Dakota với negative score có low crime rates. California cũng có high score trên second component, cho thấy high level of urbanization, trong khi Mississippi thì ngược lại. States gần zero trên cả two components, như Indiana, có levels gần average cho cả crime lẫn urbanization.

12.2.2 Another Interpretation of Principal Components

First two principal component loading vectors trong một simulated three-dimensional data set được hiển thị ở left-hand panel Figure 12.2; hai loading vectors này span một plane dọc theo đó observations có highest variance.

Ở section trước, ta mô tả principal component loading vectors như directions trong feature space mà data vary nhiều nhất, và principal component scores như projections dọc theo các directions này. Tuy nhiên còn một interpretation khác cũng hữu ích: principal components cung cấp các low-dimensional linear surfaces gần observations nhất. Ta mở rộng interpretation này ở đây.³



HÌNH 12.2. Ninety observations simulated trong three dimensions. Observations được display bằng color để dễ visualization. Left: first two principal component directions span plane fit data tốt nhất; plane được positioned để minimize sum of squared distances tới từng point. Right: first two principal component score vectors cho coordinates của projection của 90 observations lên plane.

First principal component loading vector có một property đặc biệt: đó là line trong p -dimensional space gần n observations nhất, dùng average squared Euclidean distance làm measure of closeness. Interpretation này có thể thấy trong left-hand panel của Figure 6.15; dashed lines chỉ distances giữa từng observation và line define bởi first principal component loading vector. Appeal của interpretation này rất rõ: ta tìm một single dimension của data nằm càng gần tất cả data points càng tốt, vì một line như vậy có khả năng summarize data tốt.

Ý tưởng principal components là những dimensions gần n observations nhất không chỉ áp dụng cho first component. Chẳng hạn first two principal components span plane gần n observations nhất theo average squared Euclidean distance, như left-hand panel Figure 12.2. First three principal components span three-dimensional hyperplane gần observations nhất, và cứ tiếp tục như vậy.

Dùng interpretation này, cùng nhau first M principal component score vectors và first M loading vectors tạo best M -dimensional approximation, theo Euclidean distance, cho observation x_{ij} :

$$x_{ij} \approx \sum_{m=1}^M z_{im} \phi_{jm}. \quad (12.5)$$

Ta có thể phát biểu hơn bằng một optimization problem. Giả

³Trong section này, ta tiếp tục assume rằng mỗi column của data matrix X đã centered để có mean zero, tức column mean đã được subtract khỏi mỗi column.

sử data matrix X đã column-centered. Trong tất cả approximations dạng $x_{ij} \approx \sum_{m=1}^M a_{im} b_{jm}$, ta tìm approximation có smallest residual sum of squares:

$$\underset{A \in \mathbb{R}^{n \times M}, B \in \mathbb{R}^{p \times M}}{\text{minimize}} \left\{ \sum_{j=1}^p \sum_{i=1}^n \left(x_{ij} - \sum_{m=1}^M a_{im} b_{jm} \right)^2 \right\}. \quad (12.6)$$

Ở đây A là $n \times M$ matrix với element (i, m) là a_{im} , còn B là $p \times M$ matrix với element (j, m) là b_{jm} .

Có thể chứng minh rằng với bất kỳ M , columns của matrices $\widehat{A}$ và $\widehat{B}$ solve (12.6) thực ra chính là first M principal component score và loading vectors. Nói cách khác, nếu $\widehat{A}, \widehat{B}$ solve (12.6) thì $\hat{a}_{im} = z_{im}$ và $\hat{b}_{jm} = \phi_{jm}$.⁴ Vì vậy smallest possible value của objective trong (12.6) là

$$\sum_{j=1}^p \sum_{i=1}^n \left(x_{ij} - \sum_{m=1}^M z_{im} \phi_{jm} \right)^2. \quad (12.7)$$

Tóm lại, M principal component score vectors cùng M loading vectors có thể cho một good approximation to data khi M đủ lớn. Khi $M = \min(n-1, p)$, representation là exact: $x_{ij} = \sum_{m=1}^M z_{im} \phi_{jm}$.

12.2.3 The Proportion of Variance Explained

Trong Figure 12.2, ta thực hiện PCA trên một three-dimensional data set và project data lên first two principal component loading vectors để thu two-dimensional view của data, tức principal component score vectors. Ta thấy representation 2D này capture tốt major pattern trong 3D data: orange, green và cyan observations gần nhau trong 3D space vẫn nằm gần nhau trong 2D representation. Tương tự, với **USArrests**, ta đã summarize 50 observations và 4 variables chỉ bằng first two score vectors và first two loading vectors.

Ta có thể đặt một câu hỏi tự nhiên: bao nhiêu information trong data set bị lost khi project observations lên first few principal components? Tức bao nhiêu variance của data không contained trong first few components? Tổng quát hơn, ta quan tâm đến *proportion of variance explained* (PVE) bởi mỗi principal component.

*proportion of
variance explained*

Total variance trong một data set, assuming variables đã centered về mean zero, được define là

$$\sum_{j=1}^p \text{Var}(X_j) = \sum_{j=1}^p \frac{1}{n} \sum_{i=1}^n x_{ij}^2, \quad (12.8)$$

còn variance explained bởi m th principal component là

$$\frac{1}{n} \sum_{i=1}^n z_{im}^2 = \frac{1}{n} \sum_{i=1}^n \left(\sum_{j=1}^p \phi_{jm} x_{ij} \right)^2. \quad (12.9)$$

⁴Về mặt technical, solution của (12.6) không unique. Chính xác hơn, bất kỳ solution nào của (12.6) cũng có thể dễ dàng transform để yield principal components.

Do đó PVE của m th principal component bằng

$$\frac{\sum_{i=1}^n z_{im}^2}{\sum_{j=1}^p \sum_{i=1}^n x_{ij}^2} = \frac{\sum_{i=1}^n \left(\sum_{j=1}^p \phi_{jm} x_{ij} \right)^2}{\sum_{j=1}^p \sum_{i=1}^n x_{ij}^2}. \quad (12.10)$$

PVE của mỗi principal component là positive. Để compute cumulative PVE của first M components, ta đơn giản sum (12.10) qua first M PVEs. Tổng cộng có $\min(n-1, p)$ principal components và PVEs của chúng sum to one.

Ở Section 12.2.2, ta chỉ ra rằng first M loading và score vectors có thể được interpret là best M -dimensional approximation to data theo residual sum of squares. Variance của data có thể decompose thành variance của first M principal components cộng mean squared error của M -dimensional approximation:

$$\sum_{j=1}^p \frac{1}{n} \sum_{i=1}^n x_{ij}^2 = \sum_{m=1}^M \frac{1}{n} \sum_{i=1}^n z_{im}^2 + \frac{1}{n} \sum_{j=1}^p \sum_{i=1}^n \left(x_{ij} - \sum_{m=1}^M z_{im} \phi_{jm} \right)^2. \quad (12.11)$$

$\underbrace{\hspace{1.5cm}}_{\text{Var. of data}} \{ \mathbf{Z} \}$

$\underbrace{\hspace{1.5cm}}_{\text{Var. of first } M \text{ PCs}} \{ \mathbf{Z} \}$

$\underbrace{\hspace{2.5cm}}_{\text{MSE of } M\text{-dimensional approximation}} \{ \mathbf{Z} \}$

Ba terms trong decomposition này được thảo luận lần lượt ở (12.8), (12.9), và (12.7). Vì first term fixed, maximizing variance của first M principal components tương đương minimizing MSE của M -dimensional approximation, và ngược lại. Điều này giải thích vì sao principal components có thể equivalently được xem là minimize approximation error hoặc maximize variance.

Ngoài ra, từ (12.11), cumulative PVE của first M components bằng

$$1 - \frac{\sum_{j=1}^p \sum_{i=1}^n \left(x_{ij} - \sum_{m=1}^M z_{im} \phi_{jm} \right)^2}{\sum_{j=1}^p \sum_{i=1}^n x_{ij}^2} = 1 - \frac{RSS}{TSS}.$$

Ở đây TSS là total sum of squared elements của X , còn RSS là residual sum of squares của M -dimensional approximation. Recall definition của R^2 ở (3.17), điều này nghĩa là PVE có thể được interpret như R^2 của approximation cho X bằng first M principal components.


Trong **USArrests** data, first principal component explain 62.0% variance, và next principal component explain 24.7%. Together, first two principal components explain gần 87% variance, còn last two chỉ explain 13%. Điều này nghĩa là Figure 12.1 cung cấp một summary khá accurate của data chỉ bằng two dimensions. PVE của từng component và cumulative PVE được display trong Figure 12.3. Left-hand panel được gọi là *scree plot*, sẽ được thảo luận thêm sau trong chapter.

scree plot

12.2.4 More on PCA

Scaling the Variables

Ta đã nói rằng trước khi PCA được thực hiện, variables nên được centered để có mean zero. Hơn nữa, results của PCA còn phụ thuộc vào việc



HÌNH 12.3. Left: scree plot biểu diễn proportion of variance explained bởi từng trong four principal components của *USArrests* data. Right: cumulative proportion of variance explained bởi four principal components.

variables có được individually scaled hay không, tức mỗi variable được multiply bởi một different constant. Điều này khác với một số supervised và unsupervised learning techniques khác, như linear regression, nơi scaling variables không ảnh hưởng substantively đến model; multiply một variable bởi c chỉ làm corresponding coefficient estimate multiply bởi $1/c$.

Figure 12.1 được tạo sau khi scale mỗi variable để có standard deviation one, và được reproduce ở left-hand plot Figure 12.4. Tại sao scaling quan trọng? Trong data này, variables measured in different units: **Murder**, **Rape**, và **Assault** là number of occurrences per 100,000 people, còn **UrbanPop** là percentage dân số sống ở urban area. Four variables có variances lần lượt 18.97, 87.73, 6945.16, và 209.5. Vì vậy nếu thực hiện PCA trên unscaled variables, first loading vector sẽ có loading rất lớn cho **Assault**, do variable này có variance cao nhất.


Right-hand plot Figure 12.4 hiển thị first two principal components của *USArrests* mà không scale variables về standard deviation one. Đúng như dự đoán, first loading vector đặt gần như toàn bộ weight lên **Assault**, còn second loading vector đặt gần như toàn bộ weight lên **UrbanPop**. So với left-hand plot, scaling rõ ràng có substantial effect lên results.

Tuy nhiên, result này chỉ là consequence của scales mà variables được measured. Chẳng hạn nếu **Assault** measured theo occurrences per 100 people thay vì per 100,000 people, tức divide mọi element của variable cho 1000, variance của variable sẽ rất nhỏ và first loading vector sẽ có value rất nhỏ cho variable đó. Vì không desirable để principal components phụ thuộc vào arbitrary choice of scaling, ta thường scale mỗi variable để có standard deviation one trước PCA.

Trong một số settings, variables có thể measured bằng cùng units. Khi đó ta có thể không muốn scale về standard deviation one. Ví dụ nếu variables là expression levels của p genes, vì expression measured trong cùng “units” cho mỗi gene, ta có thể chọn không scale từng gene về standard deviation one.

Uniqueness of the Principal Components

Về theory, principal components không nhất thiết unique, nhưng trong



HÌNH 12.4. Hai principal component biplots cho *USArrests* data. Left: giống Figure 12.1, với variables scaled để có unit standard deviations. Right: principal components dùng unscaled data. *Assault* có loading lớn nhất rất nhiều trên first principal component vì nó có variance lớn nhất trong four variables. Nhìn chung, scaling variables để có standard deviation one được recommended.

gần như mọi practical setting chúng unique up to sign flips. Hai software packages khác nhau sẽ yield cùng loading vectors, dù signs có thể khác. Signs có thể khác vì mỗi loading vector specify một direction trong p -dimensional space; flip sign không đổi direction. Tương tự, score vectors unique up to a sign flip vì variance của Z bằng variance của $-Z$. Khi dùng (12.5) để approximate x_{ij} , ta multiply z_{im} với ϕ_{jm} ; nếu flip sign của cả loading lẫn score vectors thì final product không đổi.

Deciding How Many Principal Components to Use

Một $n \times p$ data matrix X nói chung có $\min(n-1, p)$ distinct principal components. Tuy nhiên, ta thường chỉ quan tâm first few components để visualize hoặc interpret data, và muốn dùng smallest number đủ để có good understanding. Bao nhiêu principal components là cần thiết? Không có một answer duy nhất hoặc đơn giản.

Thông thường ta decide number of components cần cho visualization bằng cách examine scree plot như left-hand panel Figure 12.3. Ta chọn smallest number of components cần để explain một sizable amount of variation, thường bằng cách eyeball scree plot và tìm point tại đó PVE của subsequent components drop off. Drop này thường được gọi là một *elbow*. Với Figure 12.3, có thể conclude rằng first two components explain khá nhiều variance và có elbow sau second component. Third component explain less than 10%, còn fourth explain less than half của third nên gần như worthless.

Tuy vậy, visual analysis này inherently ad hoc. Không có một well-accepted objective way để decide bao nhiêu components là enough; câu hỏi này inherently ill-defined và phụ thuộc application cùng data set. Trong practice, ta thường xem first few components để tìm interesting patterns. Nếu không có interesting patterns trong first few components thì subsequent components nhiều khả năng cũng không interesting. Ngược lại, nếu first

few components interesting, ta tiếp tục xem các components kế tiếp cho tới khi không còn patterns mới. Đây là subjective approach, phản ánh việc PCA thường được dùng như tool cho exploratory data analysis.

Mặt khác, nếu compute principal components để dùng trong supervised analysis, như principal components regression ở Section 6.3.1, có một cách simple và objective hơn để determine number of components: xem number of score vectors dùng trong regression như một tuning parameter được selected bằng cross-validation hoặc related approach. Simplicity này là một biểu hiện của việc supervised analyses thường được define rõ và evaluated objectively hơn unsupervised analyses.

12.2.5 Other Uses for Principal Components

Ở Section 6.3.1 ta thấy có thể perform regression bằng principal component score vectors làm features. Thực ra nhiều statistical techniques, như regression, classification, và clustering, có thể dễ dàng adapt để dùng $n \times M$ matrix có columns là first M principal component score vectors, thay vì full $n \times p$ data matrix. Điều này có thể cho less noisy results vì signal, khác với noise, thường concentrated trong first few principal components.

12.3 Missing Values and Matrix Completion

Datasets thường có missing values, gây nhiều bất tiện. Chẳng hạn muốn analyze **USArrests** và discover rằng 20 trong 200 values đã randomly corrupted và marked as missing. Statistical learning methods đã học trong sách nhìn chung không handle missing values. Nên làm gì?

Ta có thể remove rows chứa missing observations và perform analysis trên complete rows, nhưng cách này wasteful và có thể unrealistic tùy fraction missing. Hoặc nếu x_{ij} missing, ta có thể replace bằng mean của j th column tính trên non-missing entries. Đây là common và convenient strategy, nhưng thường có thể làm tốt hơn bằng cách exploit correlation giữa variables.

Trong section này, ta cho thấy principal components có thể dùng để *impute* missing values thông qua process gọi là *matrix completion*. Completed matrix sau đó có thể dùng trong statistical learning method như linear regression hoặc LDA.

Approach này phù hợp nếu missingness là random. Ví dụ nó appropriate nếu weight của một patient missing vì battery của electronic scale hết đúng lúc exam. Ngược lại, nếu weight missing vì patient quá nặng để bước lên scale, missingness là informative và không phải *missing at random*; approach ở đây không phù hợp.

Đôi khi data missing by necessity. Ví dụ, nếu tạo matrix ratings từ 1 đến 5 mà n customers cho toàn bộ Netflix catalog gồm p movies, phần lớn matrix sẽ missing vì không customer nào đã xem và rate hơn một tiny fraction của catalog. Nếu impute tốt missing values, ta có thể có ý tưởng mỗi customer sẽ nghĩ gì về movies chưa xem. Vì vậy matrix completion có thể power *recommender systems*.

Principal Components with Missing Values

Section 12.2.2 cho thấy first M principal component score và loading

*impute;
imputation; matrix
completion*

missing at random

*recommender
systems*

vectors provide “best” approximation to data matrix X theo (12.6). Giả sử một số observations x_{ij} missing. Ta có thể vừa impute missing values vừa solve principal component problem bằng modified optimization problem

$$\underset{A \in \mathbb{R}^{n \times M}, B \in \mathbb{R}^{p \times M}}{\text{minimize}} \left\{ \sum_{(i,j) \in \mathcal{O}} \left(x_{ij} - \sum_{m=1}^M a_{im} b_{jm} \right)^2 \right\}, \quad (12.12)$$

trong đó $\mathcal{O}$ là set của all observed pairs of indices (i, j) , một subset của $n \times p$ possible pairs.

Sau khi solve problem này:

- ta có thể estimate một missing observation x_{ij} bằng $\hat{x}_{ij} = \sum_{m=1}^M \hat{a}_{im} \hat{b}_{jm}$, trong đó $\hat{a}_{im}$ và $\hat{b}_{jm}$ là elements tương ứng của matrices $\hat{A}$ và $\hat{B}$ solve (12.12);
- ta có thể approximately recover M principal component scores và loadings như trong complete data.

Solve (12.12) exactly là difficult, khác complete-data case vì eigen decomposition không còn apply. Nhưng simple iterative approach trong Algorithm 12.1, được demonstrate ở Section 12.5.2, thường cung cấp good solution.⁵⁶

Ta minh họa Algorithm 12.1 trên **USArrests**. Có $p = 4$ variables và $n = 50$ observations. Trước tiên standardize data để mỗi variable có mean zero và standard deviation one. Sau đó randomly select 20 trong 50 states và với mỗi state randomly set one of four variables to missing. Vì vậy 10% elements của data matrix missing. Ta apply Algorithm 12.1 với $M = 1$ principal component. Figure 12.5 cho thấy recovery của missing elements khá accurate.

Algorithm 12.1 Iterative Algorithm for Matrix Completion

1. Tạo complete data matrix $\tilde{X}$ kích thước $n \times p$ với element (i, j) bằng

$$\tilde{x}_{ij} = \begin{cases} x_{ij}, & (i, j) \in \mathcal{O}, \\ \bar{x}_j, & (i, j) \notin \mathcal{O}, \end{cases}$$

trong đó $\bar{x}_j$ là average của observed values cho j th variable trong incomplete data matrix X .

2. Repeat (a)–(c) cho đến khi objective (12.14) không còn decrease:

(a) Solve

$$\underset{A \in \mathbb{R}^{n \times M}, B \in \mathbb{R}^{p \times M}}{\text{minimize}} \left\{ \sum_{j=1}^p \sum_{i=1}^n \left(\tilde{x}_{ij} - \sum_{m=1}^M a_{im} b_{jm} \right)^2 \right\} \quad (12.13)$$

bằng cách compute principal components của $\tilde{X}$.

⁵Algorithm này được gọi là “Hard-Impute” trong Mazumder, Hastie, and Tibshirani (2010), “Spectral regularization algorithms for learning large incomplete matrices”, *Journal of Machine Learning Research*, 2287–2322.

⁶Mỗi iteration của Step 2 làm decrease objective (12.14). Tuy nhiên algorithm không guaranteed đạt global optimum của (12.12).


- (b) Với mỗi $(i, j) \notin \mathcal{O}$, set $\tilde{x}_{ij} \leftarrow \sum_{m=1}^M \hat{a}_{im} \hat{b}_{jm}$.
- (c) Compute objective

$$\sum_{(i,j) \in \mathcal{O}} \left(x_{ij} - \sum_{m=1}^M \hat{a}_{im} \hat{b}_{jm} \right)^2. \quad (12.14)$$

3. Return estimated missing entries $\tilde{x}_{ij}$, $(i, j) \notin \mathcal{O}$.

Trên 100 random runs của experiment, average correlation giữa true và imputed values của missing elements là 0.63, standard deviation 0.11. Performance này tốt đến đâu? Có thể compare với unattainable benchmark dùng complete data: đơn giản compute $\hat{x}_{ij} = z_{i1} \phi_{j1}$ từ first score và loading vectors của complete data.⁷ Complete-data approach cho average correlation 0.79, standard deviation 0.08. Vậy imputation method kém hơn benchmark dùng all data (0.63 ± 0.11 so với 0.79 ± 0.08), nhưng vẫn khá tốt. Và benchmark all-data dĩ nhiên không usable trong real-world setting có missing data.

Figure 12.6 cũng cho thấy Algorithm 12.1 hoạt động khá tốt trên dataset này.



HÌNH 12.5. Missing value imputation trên *USArrests*. Twenty values, tức 10% total matrix elements, được artificially set to missing rồi imputed bằng Algorithm 12.1 với $M = 1$. Figure hiển thị true value x_{ij} và imputed value $\hat{x}_{ij}$ cho all twenty missing values. Color chỉ variable và label chỉ state. Correlation giữa true và imputed values khoảng 0.63.


Ta kết thúc phần này bằng vài observations:

⁷Đây là một unattainable gold standard: khi có missing data, tất nhiên ta không thể compute principal components của complete data.

- **USArrests** chỉ có four variables, khá ít cho methods như Algorithm 12.1 hoạt động tốt. Vì vậy trong demonstration này ta randomly set nhiều nhất one variable per state to missing và chỉ dùng $M = 1$ principal component.
- Nói chung, để apply Algorithm 12.1 ta phải select M , number of principal components dùng cho imputation. Một approach là randomly leave out thêm một vài known elements và select M dựa trên mức độ recover các known values đó. Điều này closely related với validation-set approach ở Chapter 5.

Recommender Systems

Digital streaming services như Netflix và Amazon dùng data về content customer đã xem trước đây, cùng data từ other customers, để suggest content khác. Ví dụ cụ thể, nhiều năm trước Netflix cho customers rate mỗi movie đã xem từ 1–5. Điều này tạo một very large $n \times p$ matrix, element (i, j) là rating customer i cho movie j .



HÌNH 12.6. Như mô tả trong text, trong mỗi trong 100 trials ta leave out 20 elements của **USArrests**. Mỗi trial apply Algorithm 12.1 với $M = 1$ để impute missing elements và compute principal components. Left: với mỗi trong 50 states, imputed first principal component scores, averaged over 100 trials và displayed cùng standard deviation bar, được plot against first principal component scores computed using all data. Right: imputed principal component loadings, averaged over 100 trials và displayed cùng standard deviation bar, được plot against true principal component loadings.

Một early example cụ thể của matrix Netflix có $n = 480,189$ customers và $p = 17,770$ movies. Tuy nhiên, average mỗi customer chỉ xem khoảng 200 movies nên 99% matrix elements missing. Table 12.2 minh họa setup.

Để suggest một movie mà particular customer có thể thích, Netflix cần impute missing values của matrix. Key idea là set movies customer i đã xem sẽ overlap với những movies mà other customers đã xem, và một số other customers có movie preferences tương tự customer i . Vì vậy có thể dùng ratings của similar customers cho những movies customer i chưa xem để predict customer i có thích các movies đó hay không.

Cụ thể hơn, bằng Algorithm 12.1, ta predict rating của customer i cho

movie j bằng $\hat{x}_{ij} = \sum_{m=1}^M \hat{a}_{im} \hat{b}_{jm}$. Ta cũng có thể interpret M components theo “cliques” và “genres”:

- $\hat{a}_{im}$ biểu diễn strength mà user i thuộc m th clique, nơi clique là group customers thích movies thuộc m th genre;
- $\hat{b}_{jm}$ biểu diễn strength mà movie j thuộc m th genre.

Examples of genres gồm Romance, Western, và Action. Principal-component models tương tự Algorithm 12.1 nằm ở core của nhiều recommender systems.

	Jerry Maguire	Oceans	Road to Perdition	A Fortunate Man	Catch Me If You Can	Driving Miss Daisy	The Two Popes	The Laundromat	Code 8	The Social Network	...
Customer 1	•	•	•	•	4	•	•	•	•	•	...
Customer 2	•	•	3	•	•	•	3	•	•	3	...
Customer 3	•	2	•	4	•	•	•	•	2	•	...
Customer 4	3	•	•	•	•	•	•	•	•	•	...
Customer 5	5	1	•	•	4	•	•	•	•	•	...
Customer 6	•	•	•	•	•	2	4	•	•	•	...
Customer 7	•	•	5	•	•	•	•	3	•	•	...
Customer 8	•	•	•	•	•	•	•	•	•	•	...
Customer 9	3	•	•	•	5	•	•	1	•	•	...
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

BẢNG 12.2. Excerpt của Netflix movie rating data. Movies được rated từ 1 (worst) đến 5 (best). Symbol • biểu diễn missing value: movie không được corresponding customer rate.

Mặc dù data matrices involved thường massive, các algorithms đã được phát triển để exploit high level of missingness nhằm thực hiện efficient computations.

12.4 Clustering Methods

Clustering là một broad set of techniques để tìm subgroups, hay clusters, trong data set. Khi cluster observations, ta tìm cách partition chúng thành distinct groups sao cho observations within each group khá similar, còn observations ở different groups khá different. Để cụ thể hóa, phải define “similar” hoặc “different”, và đây thường là domain-specific consideration dựa trên knowledge của data đang study.

Ví dụ, giả sử có n observations với p features. Observations có thể là tissue samples của breast-cancer patients, còn features là measurements trên mỗi sample: clinical measurements như tumor stage hoặc grade, hoặc gene-expression measurements. Ta có thể tin rằng n tissue samples có heterogeneity, chẳng hạn tồn tại vài unknown subtypes of breast cancer. Clustering có thể dùng để find các subgroups này. Đây là unsupervised problem vì ta cố discover structure — distinct clusters — chỉ dựa trên data set. Ngược lại, supervised problems cố predict outcome vector như survival time hoặc response to drug treatment.

Clustering và PCA đều seek to simplify data bằng một số nhỏ summaries nhưng mechanisms khác nhau:

clustering

- PCA tìm low-dimensional representation của observations explain một good fraction of variance;
- clustering tìm homogeneous subgroups giữa observations.

Một application khác của clustering là marketing. Ta có thể có nhiều measurements như median household income, occupation, distance from nearest urban area, v.v. cho rất nhiều people. Goal là perform market segmentation bằng cách identify subgroups có khả năng receptive hơn với một form of advertising hoặc likely hơn để purchase particular product. Market segmentation về bản chất là clustering people trong data set.

Vì clustering popular trong nhiều fields, tồn tại rất nhiều clustering methods. Ở đây ta tập trung vào hai approaches nổi tiếng nhất: *K-means clustering* và *hierarchical clustering*. Với K-means, ta partition observations vào một pre-specified number of clusters. Với hierarchical clustering, ta không cần biết trước number of clusters; thay vào đó thu một tree-like representation gọi là *dendrogram*, cho phép view cùng lúc clusterings ứng với mọi possible number of clusters từ 1 đến n . Mỗi approach có advantages và disadvantages.

Nói chung, ta có thể cluster observations dựa trên features để identify subgroups among observations, hoặc cluster features dựa trên observations để discover subgroups among features. Trong phần sau, để đơn giản ta thảo luận clustering observations based on features; converse có thể thực hiện bằng cách transpose data matrix.

*K-means
clustering;
hierarchical
clustering;
dendrogram*

12.4.1 K-Means Clustering

K-means clustering là simple và elegant approach để partition data set thành K distinct, non-overlapping clusters. Trước hết phải specify desired number of clusters K ; sau đó K-means algorithm assign mỗi observation vào exactly one of K clusters. Figure 12.7 minh họa results trên simulated example gồm 150 observations trong two dimensions với three different values of K .


K-means procedure xuất phát từ một simple và intuitive mathematical problem. Gọi $C_1, \dots, C_K$ là sets chứa indices của observations trong mỗi cluster. Các sets này thỏa hai properties:

1. $C_1 \cup C_2 \cup \dots \cup C_K = \{1, \dots, n\}$: mỗi observation thuộc ít nhất one cluster.
2. $C_k \cap C_{k'} = \emptyset$ cho mọi $k \neq k'$: clusters non-overlapping, không observation nào thuộc more than one cluster.

Nếu observation i nằm trong k th cluster thì $i \in C_k$. Ý tưởng của K-means là một good clustering có within-cluster variation càng nhỏ càng tốt. Với cluster C_k , within-cluster variation là measure $W(C_k)$ về mức observations trong cluster differ from each other. Vì vậy ta muốn solve

$$\underset{C_1, \dots, C_K}{\text{minimize}} \left\{ \sum_{k=1}^K W(C_k) \right\}. \quad (12.15)$$

Nói bằng lời, ta partition observations thành K clusters sao cho total within-cluster variation, summed over all K clusters, nhỏ nhất.



HÌNH 12.7. Một simulated data set với 150 observations trong two-dimensional space. Panels cho results của K-means clustering với different values of K . Color của observation chỉ cluster được assigned bởi K-means algorithm. Không có ordering của clusters nên coloring là arbitrary; labels này không được dùng trong clustering mà là outputs của procedure.

Để operationalize (12.15), cần define within-cluster variation. Choice phổ biến nhất dùng squared Euclidean distance:

$$W(C_k) = \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2, \quad (12.16)$$

trong đó $|C_k|$ là number of observations trong k th cluster. Tức within-cluster variation là sum của all pairwise squared Euclidean distances giữa observations trong cluster, divided by number of observations trong cluster.

Combining (12.15) và (12.16) cho optimization problem define K-means clustering:

$$\text{minimize}_{C_1, \dots, C_K} \left\{ \sum_{k=1}^K \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 \right\}. \quad (12.17)$$

Ta muốn một algorithm solve (12.17), tức partition observations thành K clusters minimize objective. Exact solution rất difficult vì có gần K^n ways để partition n observations vào K clusters, một enormous number trừ khi K, n rất nhỏ. May thay, một simple algorithm có thể provide local optimum, tức một pretty good solution. Approach được nêu trong Algorithm 12.2.

Algorithm 12.2 K-Means Clustering

1. Randomly assign một number từ 1 đến K cho mỗi observation. Đây là initial cluster assignments.
2. Iterate cho đến khi cluster assignments stop changing:
 - (a) Với mỗi trong K clusters, compute cluster centroid. k th cluster centroid là vector của p feature means cho observations trong

k th cluster.

- (b) Assign mỗi observation vào cluster có centroid closest, trong đó closest được define bằng Euclidean distance.

Algorithm 12.2 guaranteed decrease value của objective (12.17) tại each step. Identity sau giúp thấy vì sao:

$$\frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 = 2 \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \bar{x}_{kj})^2, \quad (12.18)$$

trong đó $\bar{x}_{kj} = |C_k|^{-1} \sum_{i \in C_k} x_{ij}$ là mean của feature j trong cluster C_k . Trong Step 2(a), cluster means minimize sum-of-squared deviations; trong Step 2(b), reallocating observations chỉ có thể improve (12.18). Vì vậy khi algorithm chạy, clustering liên tục improve tới khi result không đổi; objective (12.17) không bao giờ increase. Khi result stable, local optimum đã đạt. Tên K-means đến từ việc Step 2(a) compute cluster centroids bằng mean của observations assigned to each cluster.

Vì K-means finds local thay vì global optimum, results depend on initial random cluster assignment trong Step 1. Do đó quan trọng là run algorithm multiple times từ different random initial configurations rồi chọn best solution, tức solution có smallest objective (12.17).

Figure 12.9 cho local optima thu được khi run K-means six times với six different initial cluster assignments trên toy data Figure 12.7. Trong case này, best clustering có objective value 235.8.

Để perform K-means, ta phải decide how many clusters expect trong data. Problem selecting K far from simple. Issue này, cùng other practical considerations, được addressed ở Section 12.4.3.

12.4.2 Hierarchical Clustering

Một potential disadvantage của K-means là phải pre-specify number of clusters K . Hierarchical clustering là alternative không cần commit trước vào particular K , và còn cho attractive tree-based representation của observations gọi là dendrogram.


Trong section này ta mô tả *bottom-up* hay *agglomerative clustering*, loại hierarchical clustering phổ biến nhất. Dendrogram, thường drawn như upside-down tree, được build starting from leaves rồi combining clusters lên trunk. Trước tiên ta học cách interpret dendrogram, sau đó xem cách dendrogram được build.

Interpreting a Dendrogram

Ta bắt đầu với simulated data set Figure 12.10 gồm 45 observations trong two-dimensional space. Data được generated từ three-class model và true class labels hiển thị bằng distinct colors. Giả sử labels không observed và ta muốn hierarchical cluster data. Hierarchical clustering với complete linkage cho result ở left-hand panel Figure 12.11. Ta interpret dendrogram này như thế nào?

Mỗi leaf của dendrogram represent one observation. Khi move up tree, some leaves fuse thành branches; chúng tương ứng với observations similar nhau. Higher up, branches fuse với leaves hoặc other branches. Fusions

*bottom-up;
agglomerative
clustering*



HÌNH 12.8. Progress của K -means algorithm trên example Figure 12.7 với $K = 3$. Top left: observations. Top center: Step 1 randomly assigns observations to clusters. Top right: Step 2(a) computes cluster centroids, shown as large colored disks; initially centroids gần overlap vì assignments random. Bottom left: Step 2(b) assigns each observation to nearest centroid. Bottom center: Step 2(a) được thực hiện lại và cho new centroids. Bottom right: results sau ten iterations.


occur càng early, tức càng low in tree, thì groups of observations càng similar. Fusions occur later gần top có thể correspond to quite different observations. Precisely, với any two observations, tìm point nơi branches chứa hai observations first fuse; height của fusion trên vertical axis indicates how different chúng are. Vì vậy observations fuse near bottom khá similar, còn observations fuse near top có xu hướng quite different.

Điểm rất quan trọng thường bị hiểu sai là horizontal proximity trong dendrogram không trực tiếp indicate similarity. Figure 12.12 minh họa simple dendrogram từ nine observations.

Observations 5 và 7 khá similar vì fuse ở lowest point; observations 1 và 6 cũng similar. Tuy nhiên sẽ sai nếu conclude observations 9 và 2 similar chỉ vì nằm gần nhau horizontally trên dendrogram. Theo information trong dendrogram, observation 9 không similar với observation 2 hơn so với observations 8,5,7. Điều này thấy rõ từ raw data ở right-hand panel Figure 12.12. Mathematically, với n leaves có 2^{n-1} possible reorderings of dendrogram vì tại mỗi trong $n - 1$ fusion points, positions của two fused branches




HÌNH 12.9. K-means clustering được thực hiện six times trên data Figure 12.7 với $K = 3$, mỗi lần dùng different random assignment ở Step 1. Trên mỗi plot là objective value (12.17). Thu được three different local optima; một optimum có smaller objective và better separation. Các plots labeled red đạt cùng best solution với objective 235.8.




HÌNH 12.10. Forty-five observations generated trong two-dimensional space. Thực tế có three distinct classes, shown in separate colors. Tuy nhiên ta treat class labels là unknown và seek to cluster observations để discover classes từ data.

có thể swap mà không đổi meaning. Vì vậy similarity phải được infer từ vertical height nơi branches first fuse, không phải horizontal proximity.



HÌNH 12.11. Left: dendrogram từ hierarchical clustering data Figure 12.10 với complete linkage và Euclidean distance. Center: cùng dendrogram cut ở height 9, shown by dashed line, cho two clusters. Right: cut ở height 5 cho three clusters. Colors không được dùng trong clustering mà chỉ dùng cho display.

Để identify clusters từ dendrogram, ta make một horizontal cut như center và right panels Figure 12.11. Distinct sets of observations beneath cut được interpret là clusters. Cut ở height 9 cho two clusters; cut ở height 5 cho three clusters. Các cuts thấp hơn có thể cho bất kỳ number of clusters từ 1 đến n . Height of cut vì thế đóng same role như K trong K-means: control number of clusters obtained.



HÌNH 12.12. Minh họa cách interpret đúng một dendrogram với nine observations trong two-dimensional space. Left: dendrogram dùng Euclidean distance và complete linkage. Observations 5 và 7 khá similar, cũng như 1 và 6. Observation 9 không similar với observation 2 hơn so với 8,5,7, dù 9 và 2 gần nhau horizontally, vì all 2,8,5,7 fuse với 9 ở cùng height khoảng 1.8. Right: raw data confirm điều này.

Figure 12.11 highlights một attractive aspect của hierarchical clustering: single dendrogram có thể dùng để obtain any number of clusters. Trong practice, người ta thường look at dendrogram và select by eye sensible number of clusters dựa trên fusion heights và desired number. Với Figure 12.11 có thể chọn two hoặc three clusters, nhưng thường choice cut height không clear.

Term *hierarchical* nghĩa là clusters obtained bằng cut ở một height neces-

sarily nested trong clusters obtained bằng cut ở any greater height. Nhưng trên arbitrary data set, assumption hierarchical structure có thể unrealistic. Ví dụ observations là men và women evenly split giữa Americans, Japanese, và French. Best division into two groups có thể split by gender, còn best division into three groups split by nationality. True clusters không nested, nên situation này không thể represented tốt bằng hierarchical clustering. Vì vậy hierarchical clustering đôi khi yield worse results hơn K-means với cùng number of clusters.

Algorithm 12.3 Hierarchical Clustering

1. Bắt đầu với n observations và một measure, chẳng hạn Euclidean distance, của all $\binom{n}{2} = n(n-1)/2$ pairwise dissimilarities. Treat mỗi observation như own cluster.
2. Với $i = n, n-1, \dots, 2$:
 - (a) Examine all pairwise inter-cluster dissimilarities giữa i clusters và identify pair least dissimilar, tức most similar. Fuse hai clusters. Dissimilarity giữa chúng determines height trong dendrogram của fusion.
 - (b) Compute new pairwise inter-cluster dissimilarities giữa $i-1$ remaining clusters.

The Hierarchical Clustering Algorithm

Dendrogram được obtain bằng một extremely simple algorithm. Bắt đầu bằng một dissimilarity measure giữa mỗi pair observations, thường Euclidean distance. Ở bottom của dendrogram, mỗi observation là own cluster. Fuse two most similar clusters để còn $n-1$, tiếp tục fuse two most similar để còn $n-2$, và lặp cho đến khi all observations thuộc one single cluster. Figure 12.13 depict first few steps cho data Figure 12.12. Algorithm 12.3 summarize process.

Một issue vẫn chưa addressed: trong bottom-right panel Figure 12.13, làm sao decide cluster $\{5, 7\}$ nên fuse với cluster $\{8\}$? Ta biết dissimilarity between pair observations, nhưng làm sao define dissimilarity between two clusters khi một hoặc cả hai chứa multiple observations? Concept này được extend bằng *linkage*, define dissimilarity giữa two groups of observations. Four common linkage types — complete, average, single, centroid — được mô tả trong Table 12.3. Average, complete, single phổ biến nhất trong statistics; average và complete thường preferred hơn single vì tend to yield more balanced dendrograms. Centroid linkage thường dùng trong genomics nhưng có drawback: *inversion* có thể xảy ra, khi two clusters fuse ở height lower than either individual cluster, gây difficulty cho visualization và interpretation.

linkage; inversion

Dissimilarities computed ở Step 2(b) của hierarchical clustering algorithm depend on linkage type và choice of dissimilarity measure. Vì vậy resulting dendrogram thường depend khá strongly on linkage type, như Figure 12.14.

Choice of Dissimilarity Measure

Các examples đến đây dùng Euclidean distance làm dissimilarity mea-

Linkage	Description
Complete	Maximal intercluster dissimilarity. Compute all pairwise dissimilarities giữa observations trong cluster A và cluster B, rồi record largest value.
Single	Minimal intercluster dissimilarity. Compute all pairwise dissimilarities giữa observations trong A và B, rồi record smallest value. Single linkage có thể tạo extended, trailing clusters trong đó single observations được fuse one-at-a-time.
Average	Mean intercluster dissimilarity. Compute all pairwise dissimilarities giữa observations trong A và B rồi record average.
Centroid	Dissimilarity giữa centroid của cluster A, một mean vector length p , và centroid của cluster B. Centroid linkage có thể tạo undesirable inversions.


BẢNG 12.3. Summary của four most commonly-used linkage types trong hierarchical clustering.

sure. Nhưng sometimes other measures preferable. Chẳng hạn correlation-based distance xem two observations similar nếu feature profiles của chúng highly correlated, dù observed values có thể far apart theo Euclidean distance. Đây là một unusual use of correlation, vốn thường computed between variables; ở đây correlation computed giữa observation profiles của each pair observations. Figure 12.15 minh họa difference. Correlation-based distance focus on shapes of observation profiles hơn magnitudes.

Choice of dissimilarity measure rất important vì ảnh hưởng mạnh đến resulting dendrogram. Cần chú ý type of data đang cluster và scientific question; chúng nên determine dissimilarity measure dùng trong hierarchical clustering.

Ví dụ một online retailer muốn cluster shoppers theo past shopping histories để identify subgroups of similar shoppers và show items/advertisements likely to interest từng subgroup. Data matrix có rows là shoppers, columns là items, elements là number of times shopper purchased item. Nếu dùng Euclidean distance, shoppers mua rất few items overall, tức infrequent users, sẽ cluster together. Điều này có thể undesirable. Nếu dùng correlation-based distance, shoppers có similar preferences, chẳng hạn mua A và B nhưng không C hoặc D, sẽ cluster together dù some shoppers có higher purchase volume. Với application này, correlation-based distance có thể là better choice.

Ngoài careful selection của dissimilarity measure, còn phải consider có nên scale variables về standard deviation one trước khi compute inter-observation dissimilarities. Tiếp tục online-shopping example: một số items purchased thường xuyên hơn, như shopper có thể mua ten pairs of socks per year nhưng computer rất hiếm. High-frequency purchases như socks vì thế có much larger effect lên inter-shopper dissimilarities và resulting clustering hơn rare purchases như computers. Điều này có thể undesirable. Scaling variables về standard deviation one làm each variable effectively có equal importance. Ta cũng có thể muốn scale khi variables measured trên different scales; nếu không, choice of units như centimeters versus



HÌNH 12.13. First few steps của hierarchical clustering algorithm dùng data Figure 12.12, complete linkage và Euclidean distance. Top left: ban đầu có nine distinct clusters $\{1\}, \dots, \{9\}$. Top right: closest clusters $\{5\}$ và $\{7\}$ fuse. Bottom left: $\{6\}$ và $\{1\}$ fuse. Bottom right: theo complete linkage, cluster $\{8\}$ fuse với cluster $\{5, 7\}$.

kilometers sẽ ảnh hưởng mạnh dissimilarity. Việc scale có tốt hay không phụ thuộc application. Issue này cũng apply cho K-means.


12.4.3 Practical Issues in Clustering

Clustering có thể là very useful tool cho unsupervised data analysis, nhưng có nhiều issues cần cân nhắc.


Small Decisions with Big Consequences

Để perform clustering, phải đưa ra một số decisions.

- Có nên standardize observations hoặc features trước theo một cách nào đó không? Ví dụ scale variables để có standard deviation one.
- Với hierarchical clustering:
 - nên dùng dissimilarity measure nào?
 - nên dùng linkage type nào?
 - nên cut dendrogram ở đâu để obtain clusters?



HÌNH 12.14. Average, complete, và single linkage applied cho một example data set. Average và complete linkage tend to yield more balanced clusters.



HÌNH 12.15. Three observations với measurements trên 20 variables. Observations 1 và 3 có similar values cho each variable nên small Euclidean distance, nhưng very weakly correlated nên large correlation-based distance. Observations 1 và 2 có quite different values nên large Euclidean distance, nhưng highly correlated nên small correlation-based distance.


- Với K-means clustering, nên tìm bao nhiêu clusters trong data?

Mỗi decision có thể có strong impact lên results. Trong practice, ta thử several choices và tìm solution useful hoặc interpretable nhất. Với các methods này, không có single right answer — bất kỳ solution nào expose interesting aspects của data đều đáng consider.

Validating the Clusters Obtained

Bất cứ khi nào cluster một data set ta đều sẽ find clusters. Nhưng điều thực sự muốn biết là clusters tìm được represent true subgroups trong data

hay chỉ là result của clustering noise. Chẳng hạn nếu có independent set of observations, chúng có display same set of clusters không? Đây là hard question. Có một số techniques assign p-value cho cluster để assess liệu evidence cho cluster có vượt mức expect by chance hay không, nhưng chưa có consensus về one best approach. More details có trong ESL.⁸



HÌNH 12.16. Một eclectic online retailer bán socks và computers. Left: numbers of socks và computers purchased bởi eight shoppers. Nếu dissimilarities computed bằng Euclidean distance trên raw variables, sock purchases dominate và computer purchases có little effect, điều có thể undesirable. Center: same data sau khi scale each variable by its standard deviation, nên two products có comparable effects. Right: same data nhưng y-axis là dollars spent; vì computers much more expensive, computer purchase history giữ dominate dissimilarities.

Other Considerations in Clustering

Cả K-means lẫn hierarchical clustering assign each observation to a cluster, nhưng đôi khi điều này không appropriate. Giả sử most observations truly belong to một số nhỏ unknown subgroups, còn một small subset rất different from each other và from all other observations. Vì K-means và hierarchical clustering force every observation into a cluster, clusters có thể bị heavily distorted bởi outliers không thuộc any cluster. Mixture models là attractive approach để accommodate outliers; có thể xem chúng như soft version of K-means và được mô tả trong ESL.

Ngoài ra, clustering methods nói chung không very robust trước perturbations to data. Chẳng hạn cluster n observations rồi cluster lại sau khi randomly remove một subset. Ta có thể hy vọng two sets of clusters khá similar, nhưng thường không phải vậy.

A Tempered Approach to Interpreting the Results of Clustering

Ta đã mô tả một số issues của clustering. Tuy nhiên, clustering vẫn là useful và valid statistical tool nếu used properly. Small decisions như cách standardize data hay linkage type có thể tạo large effect. Vì vậy, nên perform clustering với different choices of parameters và xem full set of results để nhận ra patterns nào consistently emerge. Vì clustering có thể

⁸ESL: *The Elements of Statistical Learning* by Hastie, Tibshirani and Friedman.

non-robust, cũng nên cluster subsets of data để đánh giá robustness của clusters obtained. Quan trọng nhất, phải careful khi report results: không nên xem chúng như absolute truth về data set. Thay vào đó, chúng nên là starting point cho development of a scientific hypothesis và further study, preferably trên independent data set.