

13.3 The Family-Wise Error Rate

Trong các section tiếp theo, ta sẽ discuss việc testing multiple hypotheses đồng thời control probability của việc mắc ít nhất một Type I error.

13.3.1 What is the Family-Wise Error Rate?

Nhắc lại rằng Type I error rate là probability of rejecting H_0 khi H_0 true. Family-wise error rate (FWER) generalizes notion này sang setting có m null hypotheses, $H_{01}, \dots, H_{0m}$, và được defined là probability of making at least one Type I error. Dùng notation trong Table 13.2, V là number of Type I errors (còn gọi là false positives hay false discoveries), S là number of true positives, U là number of true negatives, và W là number of Type II errors (false negatives). Khi đó

$$\text{FWER} = \Pr(V \geq 1). \quad (13.3)$$

Một strategy là reject bất kỳ null hypothesis nào có p-value dưới α — tức control Type I error của từng test ở level α . Strategy này dẫn đến

$$\text{FWER}(\alpha) = 1 - \Pr(V = 0) \quad (13.3)$$

$$= 1 - \Pr(\text{không falsely reject bất kỳ null hypothesis nào}) \quad (13.4)$$

$$= 1 - \Pr\left(\bigcap_{j=1}^m \{\text{không falsely reject } H_{0j}\}\right). \quad (13.4)$$


Nhắc lại rằng nếu two events A và B independent thì $\Pr(A \cap B) = \Pr(A)\Pr(B)$. Vì vậy, nếu thêm hai assumptions khá mạnh rằng m tests independent và tất cả m null hypotheses đều true, thì

$$\text{FWER}(\alpha) = 1 - \prod_{j=1}^m (1 - \alpha) = 1 - (1 - \alpha)^m. \quad (13.5)$$

Do đó, nếu chỉ test một null hypothesis thì $\text{FWER}(\alpha) = \alpha$, nên Type I error rate và FWER bằng nhau. Nhưng nếu perform $m = 100$ independent tests, thì với $\alpha = 0.05$ ta có $1 - (1 - 0.05)^{100} = 0.994$: gần như guaranteed sẽ mắc ít nhất một Type I error.

Figure 13.2 displays (13.5) cho nhiều values của m và α . Setting $\alpha = 0.05$ tạo high FWER ngay cả với moderate m . Với $\alpha = 0.01$, ta test được không quá five null hypotheses trước khi FWER vượt 0.05. Chỉ với very small values như $\alpha = 0.001$ mới giữ được small FWER cho moderately-sized m .

Quay lại example ở Section 13.1.1, ta test $H_0 : \mu_t = \mu_c$ bằng two-sample t-statistic. Figure 13.1 cho thấy để Type I error không exceed 0.02, ta reject khi $|T| \geq 2.33$. Nếu thay vì one test, ta test 10 null hypotheses, Section 13.3.2 sẽ cho thấy có thể guarantee FWER không exceed 0.02 bằng cách chỉ reject p-values dưới 0.002. Điều này tương ứng cutpoint much more stringent là 3.09: reject H_{0j} chỉ nếu $|T_j| \geq 3.09$. Nói cách khác, control FWER ở level α đặt một bar cao hơn nhiều về evidence cần để reject từng null hypothesis so với chỉ control Type I error của từng test ở level α .



HÌNH 13.2. Family-wise error rate như một function của number of hypotheses tested (displayed trên log scale), cho ba values của α : 0.05, 0.01, và 0.001. Dashed line chỉ 0.05. Chẳng hạn, để control FWER ở 0.05 khi testing $m = 50$ null hypotheses, ta phải control Type I error của từng null hypothesis ở level $\alpha = 0.001$.

Manager	Mean, $\bar{x}$	Standard Deviation, s	t-statistic	p-value
One	3.0	7.4	2.86	0.006
Two	-0.1	6.9	-0.10	0.918
Three	2.8	7.5	2.62	0.012
Four	0.5	6.7	0.53	0.601
Five	0.3	6.8	0.31	0.756

BẢNG 13.3. Hai columns đầu là sample mean và sample standard deviation của percentage excess return trong $n = 50$ months cho five managers đầu tiên của **Fund** dataset. Hai columns cuối cho t-statistic $\sqrt{n} \bar{X}/S$ và p-value associated với test $H_{0j} : \mu_j = 0$.

13.3.2 Approaches to Control the Family-Wise Error Rate

Ta briefly survey một số approaches để control FWER, minh họa bằng **Fund** dataset, nơi monthly percentage excess returns được recorded cho 2,000 fund managers qua $n = 50$ months.¹³ Table 13.3 cung cấp summary statistics cho five managers đầu tiên.

Trước hết là Bonferroni method và Holm's step-down procedure, hai general-purpose approaches có thể apply whenever m p-values đã computed, bất kể form của null hypotheses, choice of test statistics, hay dependence giữa p-values. Sau đó ta briefly discuss Tukey's method và Scheffé's method để minh họa rằng trong certain situations, specialized approaches có thể preferable.

The Bonferroni Method

Giả sử ta muốn test $H_{01}, \dots, H_{0m}$. Gọi A_j là event rằng ta make a Type

¹³Excess return là phần return mà fund manager đạt thêm beyond overall market return. Nếu market tăng 5% trong một period và manager đạt 7%, excess return là $7\% - 5\% = 2\%$.

I error cho j th null hypothesis. Khi đó

$$\text{FWER} = \Pr(\text{falsely reject at least one null hypothesis}) \quad (13.5)$$

$$= \Pr\left(\bigcup_{j=1}^m A_j\right) \quad (13.6)$$

$$\leq \sum_{j=1}^m \Pr(A_j). \quad (13.6)$$

Inequality này theo union bound và không require independence. Bonferroni method, hay Bonferroni correction, đặt threshold cho each test là α/m , nên $\Pr(A_j) \leq \alpha/m$ và vì thế $\text{FWER}(\alpha/m) \leq m(\alpha/m) = \alpha$.

Chẳng hạn, để control FWER ở 0.1 với $m = 100$, Bonferroni yêu cầu Type I error của từng null hypothesis ở 0.001, tức reject p-values dưới 0.001.

Trong Table 13.3, nếu control Type I error ở $\alpha = 0.05$ cho từng manager riêng rẽ, ta reject $H_{01} : \mu_1 = 0$ và $H_{03} : \mu_3 = 0$. Nhưng procedure này không account for multiple testing nên FWER exceeds 0.05. Với Bonferroni để control FWER ở 0.05, threshold là $0.05/5 = 0.01$; khi đó chỉ Manager One bị reject. Bonferroni gives peace of mind về false rejections, nhưng price là reject ít hypotheses và thường incur nhiều Type II errors.

Bonferroni là multiplicity correction nổi tiếng và commonly used nhất, nhờ dễ hiểu, dễ implement, và controls Type I error regardless of dependence. Tuy nhiên nó thường không phải most powerful hay best approach. Bonferroni có thể khá conservative: true FWER thường thấp hơn nominal FWER do inequality trong (13.6). Một less conservative procedure có thể control FWER trong khi reject nhiều hypotheses hơn và do đó make fewer Type II errors.

Holm's Step-Down Procedure

Holm's method, còn gọi Holm's step-down procedure hay Holm-Bonferroni method, là alternative cho Bonferroni. Nó controls FWER nhưng less conservative, nên thường reject more null hypotheses, tạo fewer Type II errors và greater power. Procedure nằm trong Algorithm 13.1. Threshold dùng để reject từng hypothesis phụ thuộc vào all m p-values, khác với Bonferroni. Holm không assume independence và uniformly more powerful than Bonferroni.

Holm's method

Algorithm 13.1 Holm's Step-Down Procedure to Control the FWER


1. Specify α , level cần control FWER.
2. Compute p-values $p_1, \dots, p_m$ cho $H_{01}, \dots, H_{0m}$.
3. Order chúng: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$.
4. Define

$$L = \min \left\{ j : p_{(j)} > \frac{\alpha}{m+1-j} \right\}. \quad (13.7)$$

5. Reject mọi H_{0j} sao cho $p_j < p_{(L)}$.

Áp dụng Holm cho five managers trong Table 13.3 với FWER 0.05: ordered p-values là 0.006, 0.012, 0.601, 0.756, 0.918. Ta có $0.006 < 0.01$ và $0.012 < 0.0125$, nhưng $0.601 > 0.0167$, nên $L = 3$. Holm reject null hypotheses cho Managers One và Three, trong khi Bonferroni chỉ reject Manager One.

Figure 13.3 illustrates Bonferroni và Holm trên three simulated datasets với $m = 10$ tests, trong đó $m_0 = 2$ null hypotheses true. Ten p-values được ordered và plotted trên log scale; red points là false nulls, black points là true nulls. Để control FWER ở 0.05, Bonferroni reject dưới black horizontal line, Holm reject dưới blue line. Blue line luôn nằm above black line. Trong left panel cả hai reject 7/8 false nulls; center panel Holm reject cả 8 còn Bonferroni miss one; right panel Bonferroni chỉ reject three còn Holm reject all eight. Neither makes Type I errors trong examples này.



HÌNH 13.3. Mỗi panel hiển thị sorted p-values của $m = 10$ null hypotheses trong một simulation. Hai true null hypotheses ($m_0 = 2$) màu black, còn lại red. Khi control FWER ở 0.05, Bonferroni reject dưới black line, Holm reject dưới blue line. Region giữa hai lines là hypotheses được Holm reject nhưng Bonferroni không reject. Center panel: Holm reject thêm one null hypothesis; right panel: thêm five.

Two Special Cases: Tukey's Method and Scheffé's Method


Bonferroni và Holm có thể dùng trong gần như mọi setting vì không assume nature của null hypotheses, test statistic, hay dependence. Tuy vậy, trong very specific settings, tailored approaches có thể achieve higher power. Tukey's method và Scheffé's method là two examples.

Table 13.3 cho thấy Managers One và Two có largest difference trong sample mean returns. Nếu ta test $H_0 : \mu_1 = \mu_2$ bằng two-sample t-test, p-value là 0.0349, có vẻ là modest evidence. Nhưng p-value này misleading vì comparison chỉ được chosen after examining all five managers; effectively ta đã perform $m = 5(5 - 1)/2 = 10$ pairwise tests và select smallest p-value. Bonferroni ở FWER 0.05 would require p-value below 0.005, nên không reject được equality của Managers One và Two.

Trong setting này Bonferroni hơi too stringent vì 10 pairwise tests related với nhau; p-values không independent. Tukey's method exploits structure này: khi perform $m = G(G - 1)/2$ pairwise comparisons của G means, nó cho threshold $\alpha_T > \alpha/m$ trong khi vẫn control FWER ở α .

Tukey's method

Figure 13.4 dùng $G = 6$ với $\mu_1 = \dots = \mu_5 \neq \mu_6$, nên trong 15 pairwise hypotheses có ten true và five false. Horizontal lines cho thấy Tukey luôn



HÌNH 13.4. Ba simulations của $m = 15$ hypotheses tương ứng pairwise tests về equality của $G = 6$ means. $m_0 = 10$ true nulls màu black, còn lại red. Bonferroni reject dưới black line, Tukey dưới blue line; green line là control Type I error không adjust multiple testing. Tukey có slightly higher power.

reject at least as many as Bonferroni; left panel Tukey correctly rejects two more false nulls.

Bây giờ nhìn Table 13.3 và notice Managers One và Three có higher mean returns hơn Managers Two, Four, Five. Điều đó có thể motivate test

$$H_0 : \frac{1}{2}(\mu_1 + \mu_3) = \frac{1}{3}(\mu_2 + \mu_4 + \mu_5). \quad (13.8)$$

Một variant của two-sample t-test cho p-value 0.004. Tuy nhiên hypothesis này cũng được chosen after peeking at data, nên có implicit multiple testing.

Scheffé's method được designed cho exactly setting này. Với Fund example, để control Type I error at $\alpha = 0.05$, threshold cần là $\alpha_S = 0.002$, nên p-value 0.004 không đủ để reject (13.8). Advantage quan trọng là same threshold có thể dùng để compare bất kỳ split nào của managers thành two groups, chẳng hạn $\frac{1}{3}(\mu_1 + \mu_2 + \mu_3) = \frac{1}{2}(\mu_4 + \mu_5)$ hay $\frac{1}{4}(\mu_1 + \mu_2 + \mu_3 + \mu_4) = \mu_5$, mà không cần additional multiplicity adjustment.¹⁴

Scheffé's method

Tóm lại, Holm và Bonferroni là very general multiple testing corrections. Trong special cases, more powerful corrections có thể control FWER với higher power và fewer Type II errors; Tukey và Scheffé minh họa two such cases.


13.3.3 Trade-Off Between the FWER and Power

Có trade-off giữa FWER threshold và power. Power là number of false null hypotheses rejected chia cho total false null hypotheses, tức $S/(m - m_0)$. Figure 13.5 mô phỏng m hypotheses, 90% true và 10% false. Với $m = 10$, FWER 0.05 cho power khoảng 60%. Khi m tăng, power decreases; với $m = 500$, power dưới 0.2 tại FWER 0.05.

Vì vậy control FWER reasonable khi m small như 5 hay 10. Nhưng với $m = 100$ hay 1,000, FWER control làm gần như impossible để reject false nulls; power extremely low. Reason là $\text{FWER} = \Pr(V \geq 1)$ guarantees rất

¹⁴Thực tế, calculating “correct” value của m trong setting này khá technical và outside scope của book.

low probability của even one false positive. Khi m large, guarantee đó có thể force analyst reject very few hypotheses hoặc none at all.



HÌNH 13.5. Trong simulation có 90% của m null hypotheses true, power được displayed như function của FWER cho $m = 10, 100, 500$. Khi m tăng, power decreases. Vertical dashed line chỉ FWER 0.05.

Điều này scientifically uninteresting và thường dẫn tới very low power. Trong practice, khi m large, ta có thể willing to tolerate một few false positives để make more discoveries. Đây là motivation cho false discovery rate.

13.4 The False Discovery Rate

13.4.1 Intuition for the False Discovery Rate

Khi m large, cố prevent any false positives như FWER control là too stringent. Thay vào đó, ta có thể muốn ratio false positives V trên total positives $R = V + S$ sufficiently low, để most rejected null hypotheses không phải false positives. Ratio V/R gọi là false discovery proportion (FDP).

false discovery
proportion

Có vẻ tempting để yêu cầu analyst control FDP, chẳng hạn guarantee không quá 20% rejected hypotheses là false positives. Nhưng trên một particular dataset, analyst không biết chắc hypotheses nào true hay false, nên impossible to guarantee FDP. Tương tự, analyst có thể control FWER in probability nhưng không guarantee $V = 0$ trên từng dataset trừ khi reject none.

Vì vậy ta control false discovery rate (FDR),¹⁵ defined là

$$\text{FDR} = E(\text{FDP}) = E(V/R). \quad (13.9)$$

Khi control FDR ở $q = 20\%$, ta reject as many null hypotheses as possible while guaranteeing rằng no more than 20% của rejected nulls là false positives, on average.

false discovery rate

Expectation trong (13.9) lấy over population generating the data. Nếu repeat experiment many times và mỗi lần control FDR ở 0.2, then on

¹⁵Nếu $R = 0$, ratio V/R được replace bằng 0 để tránh 0/0. Formally, $\text{FDR} = E(V/R \mid R > 0) \Pr(R > 0)$.

average 20% rejected nulls sẽ là false positives. Trên any given dataset, fraction có thể above hoặc below 20%.

FDR cũng align với exploratory data collection hiện đại. Ví dụ genomic researcher có thể test association cho 20,000 genes mà không có specific pre-specified hypothesis. Nếu simply investigate all p-values below 0.05, even khi no genes associated ta expect $0.05 \times 20,000 = 1,000$ small p-values by chance. Control FDR ở 20% guarantees rằng, on average, không quá 20% genes selected for follow-up là false positives.

Không giống p-values, FDR không có universally accepted threshold. Choice thường context- hoặc dataset-dependent: 10% có thể phù hợp nếu follow-up expensive, trong khi 30% có thể suitable nếu follow-up inexpensive.

13.4.2 The Benjamini–Hochberg Procedure

Ta cần decide hypotheses nào reject while guaranteeing $\text{FDR} \leq q$. Algorithm 13.2 provides một simple connection giữa m p-values và desired FDR level.

Algorithm 13.2 Benjamini–Hochberg Procedure to Control the FDR

1. Specify q , level cần control FDR.
2. Compute p-values $p_1, \dots, p_m$ cho $H_{01}, \dots, H_{0m}$.
3. Order: $p_{(1)} \leq \dots \leq p_{(m)}$.
4. Define

$$L = \max\{j : p_{(j)} < qj/m\}. \quad (13.10)$$

5. Reject mọi H_{0j} sao cho $p_j \leq p_{(L)}$.

Với five managers trong Table 13.3, $m = 5$. Ta có $p_{(1)} = 0.006 < 0.05(1/5)$, $p_{(2)} = 0.012 < 0.05(2/5)$, còn three p-values còn lại fail inequalities tương ứng. Do đó để control FDR ở 5%, ta reject null hypotheses rằng Managers One và Three perform no better than chance.


*Benjamini–
Hochberg procedure*

Miễn là m p-values independent hoặc only mildly dependent, Benjamini–Hochberg guarantees¹⁶ $\text{FDR} \leq q$. Remarkably, guarantee này không depend on number of true null hypotheses hay distribution của p-values corresponding to false nulls.

Có fundamental difference giữa Bonferroni và Benjamini–Hochberg. Bonferroni threshold α/m không depend on data beyond m . BH dùng data-dependent threshold $p_{(L)}$, với L là function của all p-values. Do đó ta không biết rejection threshold trước khi seeing data. Holm procedure cũng share property này.

Figure 13.6 applies both methods cho all 2,000 Fund managers. Bonferroni ở FWER 0.3 chỉ reject one hypothesis, dù 13 managers có p-values below 0.001. BH ở FDR 0.3 reject 279 managers; expected no more than around $279 \times 0.3 = 83.7$ là chance successes. FDR control vì thế milder và

¹⁶Proof nằm well beyond scope của book.



HÌNH 13.6. Cùng $m = 2,000$ ordered p -values của *Fund* data. Green lines là Bonferroni thresholds cho FWER levels 0.05, 0.1, 0.3; orange lines là Benjamini–Hochberg thresholds cho FDR levels tương ứng. Ở $q = 0.1$, 146 null hypotheses bị reject; ở $q = 0.3$, 279 bị reject.

more powerful than FWER control, đổi lại substantially more false positives.

Benjamini–Hochberg có từ mid-1990s. Dù nhiều alternative FDR procedures được proposed cho particular scenarios, BH vẫn là highly useful và widely applicable.

13.5 A Re-Sampling Approach to p-Values and False Discovery Rates

Cho đến đây ta assumed test statistic T có known hoặc assumed distribution under H_0 , như normal, t , χ^2 , hoặc F distribution. Đây gọi là theoretical null distribution, thường được dùng để obtain p-value. Với most familiar hypotheses, theoretical null exists nếu willing to make stringent assumptions.

Nếu H_0 hoặc T unusual, theoretical null distribution có thể unavailable. Hoặc distribution exists nhưng assumptions của nó bị violated, chẳng hạn sample size too small. Section này presents một general computer-based framework để approximate null distribution và obtain p-values. Ta focus on specific example testing equality of two means bằng two-sample t-test. Material này more challenging và có thể skipped nếu reader content với theoretical null distributions.

*theoretical null
distribution*

13.5.1 A Re-Sampling Approach to the p-Value

Xét $H_0 : E(X) = E(Y)$ versus $H_a : E(X) \neq E(Y)$ với n_X independent observations của X và n_Y của Y . Two-sample t-statistic là

$$T = \frac{\hat{\mu}_X - \hat{\mu}_Y}{s\sqrt{1/n_X + 1/n_Y}}, \quad (13.11)$$

where $\hat{\mu}_X = n_X^{-1} \sum_{i=1}^{n_X} x_i$ và $\hat{\mu}_Y = n_Y^{-1} \sum_{i=1}^{n_Y} y_i$, còn pooled standard-deviation estimator là

$$s = \sqrt{\frac{(n_X - 1)s_X^2 + (n_Y - 1)s_Y^2}{n_X + n_Y - 2}}.$$

Large $|T|$ provides evidence against H_0 .

Nếu n_X, n_Y large, T approximately follows $N(0, 1)$. Nếu samples small và ta không make strong distributional assumptions, theoretical null của T unknown.¹⁷ Ta có thể approximate nó bằng re-sampling, specifically a permutation approach.

re-sampling;
permutation

Thought experiment: nếu H_0 holds và distributions của X, Y actually identical, swapping observations between groups leaves distribution of T invariant. Vì vậy randomly permute all $n_X + n_Y$ observations B times; mỗi lần compute (13.11), yielding $T^{*1}, \dots, T^{*B}$. Đây approximates null distribution. Re-sampling p-value là fraction permuted datasets có statistic at least as extreme as observed:

$$\text{p-value} = \frac{\sum_{b=1}^B \mathbf{1}(|T^{*b}| \geq |T|)}{B}. \quad (13.12)$$

Algorithm 13.3 Re-Sampling p-Value for a Two-Sample t-Test

1. Compute T in (13.11) on original $x_1, \dots, x_{n_X}$ and $y_1, \dots, y_{n_Y}$.
2. For $b = 1, \dots, B$ (e.g. $B = 10,000$):
 - (a) Randomly permute all observations; first n_X become $x_1^*, \dots, x_{n_X}^*$ and remaining n_Y become $y_1^*, \dots, y_{n_Y}^*$.
 - (b) Compute (13.11) trên permuted data, call result T^{*b} .
3. p-value bằng expression trong (13.12).


Apply procedure cho **Khan** dataset, expression measurements của 2,308 genes trong four sub-types của small round blood cell tumors. Ta restrict vào rhabdomyosarcoma ($n_X = 29$) và Burkitt's lymphoma ($n_Y = 25$). Với 11th gene, two-sample t-test gives $T = -2.09$. Theoretical t_{52} null gives p-value 0.041; Algorithm 13.3 với $B = 10,000$ gives 0.042. Figure 13.7 cho thấy almost no difference giữa two null distributions.

Figure 13.8 shows analogous results cho 877th gene, nơi theoretical và re-sampling null distributions differ substantially, leading to different p-values. Differences tend to be more pronounced với smaller samples hoặc more skewed data. Ở gene 877, một observation rất far from others creates strong skewness.


13.5.2 A Re-Sampling Approach to the False Discovery Rate

Giả sử ta muốn control FDR cho m hypotheses nhưng không muốn rely on theoretical null. Ta có thể compute m re-sampling p-values rồi apply BH;

¹⁷Nếu assume X và Y normally distributed, T follows a t-distribution với $n_X + n_Y - 2$ degrees of freedom under H_0 . Trong practice distribution thường unknown, nên re-sampling có thể preferable. Nếu re-sampling và theoretical approach disagree, re-sampling results are more trustworthy.



HÌNH 13.7. 11th gene trong *Khan* dataset có $T = -2.09$. Theoretical và re-sampling null distributions gần như identical. Theoretical p-value là 0.041 và re-sampling p-value là 0.042.



HÌNH 13.8. 877th gene trong *Khan* dataset có $T = -0.57$. Theoretical và re-sampling null distributions khá different. Theoretical p-value là 0.571 và re-sampling p-value là 0.673.

tuy nhiên có một more direct way không cần compute p-values.

Using notation Table 13.2, $\text{FDR} = E(V/R)$. Re-sampling approach bắt đầu với approximation

$$\text{FDR} = E\left(\frac{V}{R}\right) \approx \frac{E(V)}{R}. \quad (13.13)$$

Nếu reject hypotheses với $|T_j| \geq c$, denominator straightforward: $R = \sum_{j=1}^m \mathbf{1}(|T_j| \geq c)$.

Numerator $E(V)$ khó hơn vì ta không biết nulls nào truly true. Solution là simulate data under all null hypotheses. For each hypothesis, randomly permute its $n_X + n_Y$ observations and compute t-statistic; under permuted data all nulls hold. Number of permuted statistics exceeding c estimates V . Repeat B times và average để improve estimate.

Algorithm 13.4 formalizes procedure, yielding a plug-in estimate của FDR: plug observed R vào denominator và estimated $E(V)$ vào numerator.¹⁸

¹⁸Để implement Algorithm 13.4 efficiently, same set of permutations in Step 2(b)i should

Apply Algorithm 13.4 và BH using theoretical p-values cho all $m = 2,308$ Khan genes. Figure 13.9 shows, for a given number of rejections, estimated FDRs almost identical.

Nếu define re-sampling p-value bằng pooled information across all m tests,

$$p_j = \frac{\sum_{j'=1}^m \sum_{b=1}^B \mathbf{1}(|T_{j'}^{*b}| \geq |T_j|)}{Bm}, \quad (13.14)$$

then applying BH to these p-values is exactly equivalent to Algorithm 13.4. Equation (13.14) is an alternative to (13.12) that pools information across tests when approximating null distribution.

Algorithm 13.4 Plug-In FDR for a Two-Sample T-Test

1. Select threshold $c > 0$.
2. For $j = 1, \dots, m$:
 - (a) Compute $T^{(j)}$, the two-sample t-statistic for H_{0j} on original data.
 - (b) For $b = 1, \dots, B$: randomly permute $n_X + n_Y$ observations and compute $T^{(j),*b}$ on the permuted data.
3. Compute $R = \sum_{j=1}^m \mathbf{1}(|T^{(j)}| \geq c)$.
4. Compute $\widehat{V} = B^{-1} \sum_{b=1}^B \sum_{j=1}^m \mathbf{1}(|T^{(j),*b}| \geq c)$.
5. Estimated FDR associated with c is $\widehat{V}/R$.

13.5.3 When Are Re-Sampling Approaches Useful?

Sections 13.5.1 và 13.5.2 cho thấy re-sampling có thể differ strongly from theoretical p-values khi theoretical null inaccurate, nhưng agree closely khi approximation good. Re-sampling particularly useful trong two settings:


1. No theoretical null distribution is available, vì H_0 hoặc test statistic unusual.
2. A theoretical null exists nhưng assumptions required for validity fail. Chẳng hạn t-statistic (13.11) follows $t_{n_X+n_Y-2}$ only under normality, và only approximates $N(0, 1)$ khi sample sizes large. Với non-normal small samples, theoretical p-values may not properly control Type I error.

Generally, nếu có cách re-sample hoặc permute observations để generate data following null distribution, variants of Algorithms 13.3 và 13.4 cho phép compute p-values hoặc estimate FDR. Đây là powerful tool khi no out-of-box hypothesis test exists hoặc key assumptions của standard tests bị violated.

13.6 Lab: Multiple Testing

Ta bắt đầu bằng các usual imports đã thấy trong earlier labs.

be used cho all m null hypotheses.



HÌNH 13.9. Với $m = 2,308$ Khan genes, y -axis là estimated FDR khi reject hypotheses tương ứng với k smallest p -values, $k = 1, \dots, 2308$. Orange dashed curve dùng Benjamini-Hochberg; blue solid curve dùng re-sampling Algorithm 13.4 với $B = 10,000$. Hai estimates gần như identical; rejecting 500 smallest p -values corresponds to FDR khoảng 17.7%.

```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
from ISLP import load_data
```

Ta cũng collect các new imports cần cho lab này.

```
In [2]: from scipy.stats import \
        (ttest_1samp,
         ttest_rel,
         ttest_ind,
         t as t_dbn)
from statsmodels.stats.multicomp import \
        pairwise_tukeyhsd
from statsmodels.stats.multitest import \
        multipletests as mult_test
```

13.6.1 Review of Hypothesis Tests

Ta bắt đầu bằng one-sample t-tests. Trước hết create 100 variables, mỗi variable có 10 observations. First 50 variables có mean 0.5 và variance 1, còn remaining variables có mean 0 và variance 1.

```
In [3]: rng = np.random.default_rng(12)
X = rng.standard_normal((10, 100))
true_mean = np.array([0.5]*50 + [0]*50)
X += true_mean[None,:]
```

Đầu tiên dùng `ttest_1samp()` từ `scipy.stats` để test $H_0 : \mu_1 = 0$.

`ttest_1samp()`

```
In [4]: result = ttest_1samp(X[:,0], 0)
result.pvalue
```

Out[4]: 0.931

P-value 0.931 không small enough để reject ở $\alpha = 0.05$. Ở đây $\mu_1 = 0.5$,

nên H_0 false; fail to reject là một Type II error.

Bây giờ test $H_{0j} : \mu_j = 0$ cho $j = 1, \dots, 100$. Ta compute 100 p-values, rồi record decision dựa trên threshold 0.05.

```
In [5]: p_values = np.empty(100)
for i in range(100):
    p_values[i] = ttest_1samp(X[:,i], 0).pvalue
decision = pd.cut(p_values,
                  [0, 0.05, 1],
                  labels=['Reject H0',
                        'Do not reject H0'])
truth = pd.Categorical(true_mean == 0,
                      categories=[True, False],
                      ordered=True)
```

Vì đây là simulated data, ta có thể tạo 2×2 table tương tự Table 13.2.

```
In [6]: pd.crosstab(decision,
                    truth,
                    rownames=['Decision'],
                    colnames=['H0'])
```

```
Out[6]: H0                True  False
Decision
Reject H0                5     15
Do not reject H0        45     35
```

Ở level 0.05, ta reject 15/50 false null hypotheses và incorrectly reject 5 true null hypotheses. Theo notation Section 13.3, $V = 5, S = 15, U = 45, W = 35$. Vì $\alpha = 0.05$, ta expect reject khoảng 5% true nulls; observed 5/50 phù hợp với expectation này.

Trong simulation trên, signal-to-noise ratio cho false nulls chỉ $0.5/1 = 0.5$, nên Type II errors nhiều. Nếu tăng mean shift lên 1, signal mạnh hơn và chỉ còn 10 Type II errors.

```
In [7]: true_mean = np.array([1]*50 + [0]*50)
X = rng.standard_normal((10, 100))
X += true_mean[None,:]
for i in range(100):
    p_values[i] = ttest_1samp(X[:,i], 0).pvalue
decision = pd.cut(p_values,
                  [0, 0.05, 1],
                  labels=['Reject H0',
                        'Do not reject H0'])
truth = pd.Categorical(true_mean == 0,
                      categories=[True, False],
                      ordered=True)

pd.crosstab(decision,
            truth,
            rownames=['Decision'],
            colnames=['H0'])
```

```
Out[7]: H0                True  False
Decision
Reject H0                2     40
Do not reject H0        48     10
```

13.6.2 Family-Wise Error Rate

Từ (13.5), nếu all m null hypotheses true và tests independent thì FWER = $1 - (1 - \alpha)^m$. Ta compute expression này cho $m = 1, \dots, 500$ và $\alpha = 0.05, 0.01, 0.001$ để reproduce Figure 13.2.

```
In [8]: m = np.linspace(1, 501)
fig, ax = plt.subplots()
[ax.plot(m,
         1 - (1 - alpha)**m,
         label=r'$\alpha = %s$' % str(alpha))
 for alpha in [0.05, 0.01, 0.001]]
ax.set_xscale('log')
ax.set_xlabel('Number of Hypotheses')
ax.set_ylabel('Family-Wise Error Rate')
ax.legend()
ax.axhline(0.05, c='k', ls='--');
```

Ngay cả với $m = 50$, FWER exceeds 0.05 trừ khi α rất small như 0.001; nhưng threshold quá low tạo many Type II errors và low power.

Ta conduct one-sample t-test cho first five managers của Fund, testing $H_{0j} : \mu_j = 0$.

```
In [9]: Fund = load_data('Fund')
fund_mini = Fund.iloc[:, :5]
fund_mini_pvals = np.empty(5)
for i in range(5):
    fund_mini_pvals[i] = ttest_1samp(fund_mini.iloc[:, i], 0).pvalue
fund_mini_pvals
```

```
Out[9]: array([0.006, 0.918, 0.012, 0.601, 0.756])
```

P-values low cho Managers One và Three, high cho three managers còn lại. Nhưng không thể simply reject H_{01} và H_{03} vì phải account for multiple testing. Ta dùng `multiplerejects()` từ `statsmodels` (abbreviated `mult_test()`). Với methods như Holm và Bonferroni, function returns adjusted p-values; nếu adjusted p-value $\leq \alpha$, hypothesis có thể reject while maintaining FWER $\leq \alpha$.

*multiplerejects();
adjusted p-values*

```
In [10]: reject, bonf = mult_test(fund_mini_pvals, method="bonferroni")[:2]
reject
```

```
Out[10]: array([ True, False, False, False, False])
```

Bonferroni adjusted p-values chính là raw p-values multiplied by 5 rồi truncated ở 1.

```
In [11]: bonf, np.minimum(fund_mini_pvals * 5, 1)
```

```
Out[11]: (array([0.03, 1.   , 0.06, 1.   , 1.   ]),
          array([0.03, 1.   , 0.06, 1.   , 1.   ]))
```

Do đó Bonferroni chỉ reject Manager One ở FWER 0.05. Holm thì reject Managers One và Three.

```
In [12]: mult_test(fund_mini_pvals, method="holm", alpha=0.05)[:2]
```

```
Out[12]: (array([ True, False,  True, False, False]),
          array([0.03, 1.   , 0.05, 1.   , 1.   ]))
```

Manager One seems particularly strong, còn Manager Two poor.

```
In [13]: fund_mini.mean()
```

```
Out[13]: Manager1    3.0
          Manager2   -0.1
          Manager3    2.8
          Manager4    0.5
          Manager5    0.3
          dtype: float64
```

Có evidence of meaningful difference giữa Managers One và Two không? Paired t-test bằng `ttest_rel()` cho:

paired t-test;
ttest_rel()

```
In [14]: ttest_rel(fund_mini['Manager1'],
                  fund_mini['Manager2']).pvalue
```

```
Out[14]: 0.038
```

P-value 0.038 suggests statistically significant difference. Nhưng test này chỉ được chosen sau khi examining data và noticing highest/lowest means. Effectively ta implicitly considered $\binom{5}{2} = 10$ pairwise tests. Vì vậy ta dùng Tukey's method qua `pairwise_tukeyhsd()` để adjust multiple testing. Function treats response là monthly excess returns và predictor là manager identity, tương đương ANOVA regression với qualitative predictor.


pairwise_
tukeyhsd();
ANOVA

```
In [15]: returns = np.hstack([fund_mini.iloc[:,i] for i in range(5)])
          managers = np.hstack([[i+1]*50 for i in range(5)])
          tukey = pairwise_tukeyhsd(returns, managers)
          print(tukey.summary())
```

Multiple Comparison of Means - Tukey HSD, FWER=0.05

```
=====
group1 group2 meandiff p-adj  lower upper reject
-----
1      2      -3.1 0.1862 -6.9865 0.7865 False
1      3      -0.2 0.9999 -4.0865 3.6865 False
1      4      -2.5 0.3948 -6.3865 1.3865 False
1      5      -2.7 0.3152 -6.5865 1.1865 False
2      3       2.9 0.2453 -0.9865 6.7865 False
2      4       0.6 0.9932 -3.2865 4.4865 False
2      5       0.4 0.9986 -3.4865 4.2865 False
3      4      -2.3 0.4820 -6.1865 1.5865 False
3      5      -2.5 0.3948 -6.3865 1.3865 False
4      5      -0.2 0.9999 -4.0865 3.6865 False
=====
```

Tukey-adjusted p-value cho difference giữa Managers One và Two tăng từ 0.038 lên 0.186, nên evidence không còn clear. `plot_simultaneous()` plots confidence intervals; non-overlap would indicate significance at nom-



HÌNH 13.10. 95% confidence intervals cho each manager trong *Fund* data, dùng Tukey's method để adjust multiple testing. All intervals overlap, nên no differences among managers are statistically significant khi control FWER ở 0.05.

inal 0.05. Ở đây none are significant.¹⁹

```
In [16]: fig, ax = plt.subplots(figsize=(8,8))
         tukey.plot_simultaneous(ax=ax);
```

13.6.3 False Discovery Rate

Bây giờ perform hypothesis tests cho all 2,000 Fund managers, each one testing $H_{0j} : \mu_j = 0$.

```
In [17]: fund_pvalues = np.empty(2000)
         for i, manager in enumerate(Fund.columns):
             fund_pvalues[i] = ttest_1samp(Fund[manager], 0).pvalue
```

Có quá many managers để realistically control FWER, nên ta control FDR. `mult_test()` thực hiện Benjamini–Hochberg.

```
In [18]: fund_qvalues = mult_test(fund_pvalues, method="fdr_bh")[1]
         fund_qvalues[:10]
```

```
Out[18]: array([0.09, 0.99, 0.12, 0.92, 0.96, 0.08, 0.08, 0.08, 0.08,
              0.08])
```

Q-values có thể interpreted như smallest FDR threshold tại đó particular null hypothesis would be rejected. Q-value 0.1 nghĩa là reject được ở FDR 10% hoặc greater, nhưng không dưới 10%.

q-values

```
In [19]: (fund_qvalues <= 0.1).sum()
```

```
Out[19]: 146
```

¹⁹Traditionally plot này shows intervals cho each paired difference. Với many groups, displaying one interval per group convenient và equivalent; differencing all pairs recovers traditional plot.

Có 146 managers có q-value below 0.1, nên ta conclude 146 managers beat market at FDR 10%. Khoảng 15 trong số này expected là false discoveries. Ngược lại, Bonferroni control FWER 0.1 sẽ reject none.

```
In [20]: (fund_pvalues <= 0.1 / 2000).sum()
```

```
Out[20]: 0
```

Ta implement BH manually để reproduce middle panel of Figure 13.6: order p-values, find all $p_{(j)} < qj/m$, rồi select p-values không exceed largest qualifying value.

```
In [21]: sorted_ = np.sort(fund_pvalues)
m = fund_pvalues.shape[0]
q = 0.1
sorted_set_ = np.where(sorted_ < q * np.linspace(1, m, m) / m)[0]
if sorted_set_.shape[0] > 0:
    selected_ = fund_pvalues < sorted_[sorted_set_].max()
    sorted_set_ = np.arange(sorted_set_.max())
else:
    selected_ = []
    sorted_set_ = []
```

Bây giờ reproduce middle panel of Figure 13.6.

```
In [22]: fig, ax = plt.subplots()
ax.scatter(np.arange(0, sorted_.shape[0]) + 1,
           sorted_, s=10)
ax.set_yscale('log')
ax.set_xscale('log')
ax.set_ylabel('P-Value')
ax.set_xlabel('Index')
ax.scatter(sorted_set_+1, sorted_[sorted_set_], c='r', s=20)
ax.axline((0, 0), (1,q/m), c='k', ls='--', linewidth=3);
```

13.6.4 A Re-Sampling Approach

Ta implement re-sampling hypothesis testing trên Khan dataset. Merge training và testing data tạo observations cho 83 patients và 2,308 genes.

```
In [23]: Khan = load_data('Khan')
D = pd.concat([Khan['xtrain'], Khan['xtest']])
D['Y'] = pd.concat([Khan['ytrain'], Khan['ytest']])
D['Y'].value_counts()
```

```
Out[23]: 2    29
         4    25
         3    18
         1    11
Name: Y, dtype: int64
```

Có four cancer classes. Với each gene, ta compare mean expression ở class 2 (rhabdomyosarcoma) và class 4 (Burkitt's lymphoma). Standard two-sample t-test trên 11th gene gives statistic -2.09 và p-value 0.041.

ttest_ind()

```
In [24]: D2 = D[lambda df:df['Y'] == 2]
         D4 = D[lambda df:df['Y'] == 4]
```

```
gene_11 = 'G0011'
observedT, pvalue = ttest_ind(D2[gene_11],
                              D4[gene_11],
                              equal_var=True)

observedT, pvalue
```

Out[24]: (-2.094, 0.041)

Theoretical p-value assumes t_{52} null. Thay vào đó, randomly split 54 patients into groups 29 và 25, compute statistic, repeat 10,000 times, rồi estimate p-value bằng fraction re-sampled statistics more extreme than observed.

```
In [25]: B = 10000
Tnull = np.empty(B)
D_ = np.hstack([D2[gene_11], D4[gene_11]])
n_ = D2[gene_11].shape[0]
D_null = D_.copy()
for b in range(B):
    rng.shuffle(D_null)
    ttest_ = ttest_ind(D_null[:n_],
                      D_null[n_:],
                      equal_var=True)
    Tnull[b] = ttest_.statistic
(np.abs(Tnull) > np.abs(observedT)).mean()
```

Out[25]: 0.0398

Re-sampling p-value 0.0398 gần như identical với theoretical 0.0412. Ta plot histogram để reproduce Figure 13.7.

```
In [26]: fig, ax = plt.subplots(figsize=(8,8))
ax.hist(Tnull,
        bins=100,
        density=True,
        facecolor='y',
        label='Null')
xval = np.linspace(-4.2, 4.2, 1001)
ax.plot(xval,
        t_dbn.pdf(xval, D_.shape[0]-2),
        c='r')
ax.axvline(observedT,
           c='b',
           label='Observed')
ax.legend()
ax.set_xlabel("Null Distribution of Test Statistic");
```

Cuối cùng implement plug-in re-sampling FDR từ Algorithm 13.4. Vì all 2,308 genes có thể slow, ta randomly choose 100 genes; for each gene compute observed statistic và 10,000 re-sampled statistics.

```
In [27]: m, B = 100, 10000
idx = rng.choice(Khan['xtest'].columns, m, replace=False)
T_vals = np.empty(m)
Tnull_vals = np.empty((m, B))

for j in range(m):
    col = idx[j]
    T_vals[j] = ttest_ind(D2[col],
                          D4[col],
                          equal_var=True).statistic
```

```

D_ = np.hstack([D2[col], D4[col]])
D_null = D_.copy()
for b in range(B):
    rng.shuffle(D_null)
    ttest_ = ttest_ind(D_null[:n_],
                      D_null[n_:],
                      equal_var=True)
    Tnull_vals[j,b] = ttest_.statistic

```

Compute number rejected R , estimated false positives $\widehat{V}$, và estimated FDR cho range of cutoffs c chosen từ absolute observed statistics.

```

In [28]: cutoffs = np.sort(np.abs(T_vals))
FDRs, Rs, Vs = np.empty((3, m))
for j in range(m):
    R = np.sum(np.abs(T_vals) >= cutoffs[j])
    V = np.sum(np.abs(Tnull_vals) >= cutoffs[j]) / B
    Rs[j] = R
    Vs[j] = V
    FDRs[j] = V / R

```

Ở FDR 0.1, 15/100 hypotheses được reject, expected one or two false discoveries. Ở FDR 0.2, 28 genes được reject, expected around six false discoveries.

```

In [29]: sorted(idx[np.abs(T_vals) >= cutoffs[FDRs < 0.1].min()])

```

Threshold 0.2 selects more genes at the cost of higher expected proportion of false discoveries.

```

In [30]: sorted(idx[np.abs(T_vals) >= cutoffs[FDRs < 0.2].min()])

```

Dòng tiếp theo generates Figure 13.11, analogous to Figure 13.9 nhưng based on only 100 genes.

```


In [31]: fig, ax = plt.subplots()
ax.plot(Rs, FDRs, 'b', linewidth=3)
ax.set_xlabel("Number of Rejections")
ax.set_ylabel("False Discovery Rate");

```

13.7 Exercises

Conceptual

- Giả sử test m null hypotheses, tất cả đều true. Ta control Type I error cho each null hypothesis ở level α . Với mỗi part, justify answer.
 - Tổng cộng expected bao nhiêu Type I errors?
 - Nếu m tests independent, family-wise error rate của m tests là gì? *Hint:* nếu events A, B independent thì $\Pr(A \cap B) = \Pr(A) \Pr(B)$.
 - Với $m = 2$, p-values positively correlated. FWER qualitatively compare thế nào với answer (b) khi $m = 2$? *Hint:* first suppose two p-values perfectly correlated.
 - Với $m = 2$ nhưng p-values negatively correlated, FWER compare thế nào với (b)? *Hint:* suppose whenever one p-value $< \alpha$, the



HÌNH 13.11. Estimated false discovery rate versus number of rejected null hypotheses, cho 100 genes randomly selected từ *Khan* dataset.

other $> \alpha$, so never reject both.

2. Giả sử test m hypotheses, control Type I error của each ở level α . Assume all p-values independent và all null hypotheses true.
 - (a) Let $A_j = 1$ nếu j th null rejected, 0 otherwise. Distribution của A_j là gì?
 - (b) Distribution của $\sum_{j=1}^m A_j$ là gì?
 - (c) Standard deviation của number of Type I errors là gì?
3. Giả sử test m null hypotheses và control Type I error của j th test ở α_j . Argue rằng FWER không lớn hơn $\sum_{j=1}^m \alpha_j$.

Null Hypothesis	p-value
H_{01}	0.0011
H_{02}	0.031
H_{03}	0.017
H_{04}	0.32
H_{05}	0.11
H_{06}	0.90
H_{07}	0.07
H_{08}	0.006
H_{09}	0.004
H_{10}	0.0009

BẢNG 13.4. P-values cho Exercise 4.

4. Giả sử test $m = 10$ hypotheses và obtain p-values trong Table 13.4.
 - (a) Control Type I error cho each null ở $\alpha = 0.05$: reject hypotheses nào?
 - (b) Control FWER ở $\alpha = 0.05$: reject hypotheses nào? Justify.
 - (c) Control FDR ở $q = 0.05$: reject hypotheses nào? Justify.

- (d) Control FDR ở $q = 0.2$: reject hypotheses nào? Justify.
 - (e) Trong hypotheses rejected ở FDR $q = 0.2$, approximately bao nhiêu là false positives? Justify.
5. Make up p-values dẫn đến specified rejection counts bằng Bonferroni và Holm.
- (a) Give five p-values sao cho both Bonferroni và Holm reject exactly one null hypothesis khi control FWER ở 0.1.
 - (b) Give five p-values sao cho Bonferroni rejects one null hypothesis và Holm rejects more than one at 0.1.
6. Với each of three panels trong Figure 13.3, answer:
- (a) Bao nhiêu false positives, false negatives, true positives, true negatives, Type I errors, Type II errors khi Bonferroni control FWER ở $\alpha = 0.05$?
 - (b) Same quantities cho Holm ở $\alpha = 0.05$?
 - (c) FDP associated với Bonferroni ở $\alpha = 0.05$?
 - (d) FDP associated với Holm ở $\alpha = 0.05$?
 - (e) Answers (a) và (c) change thế nào nếu Bonferroni controls FWER ở $\alpha = 0.001$?

Applied

7. Dùng **Carseats** dataset trong ISLP.
- (a) Với each quantitative variable besides **Sales**, fit linear model predicting **Sales** using that variable. Report p-value associated với slope β_1 trong $Y = \beta_0 + \beta_1 X + \varepsilon$.
 - (b) Control Type I error ở $\alpha = 0.05$ cho p-values ở (a): reject null hypotheses nào?
 - (c) Control FWER ở 0.05: reject hypotheses nào?
 - (d) Control FDR ở 0.2: reject hypotheses nào?
8. Trong bài này, simulate data từ $m = 100$ fund managers.

```
rng = np.random.default_rng(1)
n, m = 20, 100
X = rng.normal(size=(n, m))
```

Data represent percentage returns của each manager over $n = 20$ months. Test null rằng each manager's population mean return equals zero. Simulation được generated sao cho all m null hypotheses true.

- (a) Conduct one-sample t-test cho each manager và plot histogram của p-values.
- (b) Nếu control Type I error cho each null ở $\alpha = 0.05$, reject bao nhiêu null hypotheses?
- (c) Nếu control FWER ở 0.05, reject bao nhiêu?
- (d) Nếu control FDR ở 0.05, reject bao nhiêu?

- (e) Bây giờ “cherry-pick” 10 fund managers perform best trong data. Nếu control FWER cho only these 10 ở 0.05, reject bao nhiêu? Nếu control FDR cho only these 10 ở 0.05, reject bao nhiêu?
- (f) Explain vì sao analysis ở (e) misleading. *Hint:* standard FWER/FDR methods assume all tested null hypotheses are adjusted for multiplicity và no cherry-picking of smallest p-values. What goes wrong if we cherry-pick?